

DAT 1기 캡스톤 프로젝트 보고서

다이아몬드 가격에 영향을 주는 요인 : 시각화와 회귀분석을 중심으로

DAT 1기

2팀 베2직

조윤진, 고은서, 정민서, 김태희



DAT 1기 캡스톤 프로젝트 보고서

다이아몬드 가격에 영향을 주는 요인

: 시각화와 회귀분석을 중심으로

Factors Influencing Diamond Prices

: Focus on Visualization and Regression Analysis

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2023년 06월 08일

DAT 1기

2팀 베2직

조윤진, 고은서, 정민서, 김태희

DAT 1기 캡스톤 프로젝트 보고서



다이아몬드 가격에 영향을 주는 요인

: 시각화와 회귀분석을 중심으로

국문 요약

세계에는 다양한 천연광물들이 존재하지만 그 중 가장 광채가 뛰어나며 가장 아름다운 보석으로 꼽히는 다이아몬드는 우리가 흔히 접할 수 없는 광물 중 하나이다. 그 상징성 또한 뛰어나 대부분의 사람들이 알고 있는 보석이다. 이러한 다이아몬드들은 다양한 요인들로 인해 천차만별인 경우가 많다. 다이아몬드의 가격을 결정하는 중요한 여러 요인들의 부족한 데이터로 인해 그에 따른 사람들의 관심도도 적은 것이 사실이다. 그래서 본 연구에서는 다이아몬드의 가격을 결정 짓는 여러 요인들 중 어떤 특징이 가격에 가장 큰 영향을 미치고 있는지 확인하였다. 분석 결과 다이아몬드의 가격 형성에 가장 많은 영향을 미치는 변수는 carat인 것으로 확인되었다. 결과적으로 본 연구를 통해 다양한 특징을 가진 다이아몬드의 가격에 대한 분석을 하여 다이아몬드에 대한 전반적인 이해도를 높이는 데 큰 역할을 할 수 있을 것이라 판단한다.

Abstract

There are a variety of natural minerals in the world, but diamonds, which are considered the most brilliant and beautiful jewels, are the scarcest. It is also a gem that most people know because of its excellent symbolism. Diamonds often vary in price due to various factors. However, lack of research and data on the subject matter has contributed to customer's disinterest on these factors that determine diamond's price. Therefore, in this study, we will analyze collected data to determine which factor has the greatest impact on price. This report will improve the market's overall understanding of the diamond pricing process and serve as a tool to predict price.

DAT 1기

2팀 배2직

조윤진, 고은서, 정민서, 김태희



목 차

제1장 서론	1
제1절 연구 배경	1
제2절 수집 데이터 소개	1
제2장 데이터 시각화	4
제1절 데이터 시각화 및 분석	4
제3장 회귀분석	8
제1절 모델 소개	8
제2절 분석 과정	8
제4장 결론	12
제1절 한계점 및 향후 과제	12
참고문헌	15
국내문헌	15
국외문헌	15



표 목차

[표 1].....	3
[표 2].....	4
[표 3].....	5
[표 4].....	5
[표 5].....	5
[표 6].....	6
[표 7].....	6
[표 8].....	7
[표 9].....	7
[표 10].....	8
[표 11].....	10
[표 12].....	11
[표 13].....	11
[표 14].....	12
[표 15].....	12
[표 16].....	13
[표 17].....	13

그림 목차

[그림 1].....	2
[그림 2].....	3

[2]



제 1 장 서론

제 1 절 연구 배경

대중적으로 널리 알려져 있고 그 상징성 또한 뛰어나지만 동시에 값비싼 가격 때문에 자주 접하지 못하는 광물 중 하나인 다이아몬드는 21 세기를 살아가는 현대인들에게 부를 상징하는 대표적인 보석 중 하나이다. ‘정복할 수 없다’는 뜻의 그리스어인 아다마스(adamas)에서 유래되어 굉장한 희소성을 이유로 0.2g 의 굉장히 작은 무게에 비해 막대한 가치가 정해진다. 하지만 우리가 다이아몬드의 가치를 평가할 때는 흔히 사용하는 다이아몬드의 크기 단위인 캐럿만을 이용하지 않는다. 다이아몬드내의 불순물의 포함정도를 나타내는 투명도부터 다이아몬드의 가공 정도를 나타내는 컷(cut)까지 그 가치를 판단하는 여러 다양한 요소들이 존재한다. 이렇듯 다양한 요소들을 종합적으로 평가하는 과정을 거치기 때문에 각각요인들이 가격을 결정하는 데에 크고 작은 영향을 끼친다.

다이아몬드를 판매하거나 구매하기 전까지는 이런 자세한 사항을 미리 알지 못하는 경우가 빈번하다. 또한 해당 요소들을 알고 있다고 해도 어떤 요인들이 얼마나 큰 영향을 미치는지는 많은 거래를 거치지 않고서는 알기 어려운 것이 사실이기 때문에 구매를 하거나 개인간 거래를 할 때 막연히 감정서를 통한 거래가 이루어지기 일수이다. 하지만 본인이 잘 알지 못하는 것을 거래할 때는 그에 따른 큰 위험성이 따르기 마련이다. 실제로도 소비자의 입장에서 다이아몬드를 구매하려고 할 때 한국에만 해도 우신, 버진, 현대 등 여러 감정서들이 존재한다. 이런 각각의 감정서가 가진 기준이 명확하지 않아 판매와 매입가격이 상이한 경우가 종종 발생한다. 이러한 판매자와 구매자 간의 의견차이를 좁히고 객관적인 수치들을 분석하여 광물의 가치에 대한 최소한의 근거를 제공하는 것 또한 이 논문의 목적 중 하나이다. 더 나아가 데이터를 활용하여 다이아몬드의 가격을 예측하는 방식을 통해 높은 다이아몬드에 대한 이해도를 한층 끌어올릴 수 있는 기회를 제공할 것이다.

제 2 절 수집 데이터 소개

이번 프로젝트를 위한 데이터 파일은 Kaggle 에서 발췌했다. 총 10 개의 열과 53,943 개의 행으로 이루어져 있다. 열은 carat(다이아몬드의 크기 단위), cut(가공등급), color(색상), clarity(투명도), depth(높이), table(다이아몬드의 가장 윗부분), price(가격), x(length in mm), y(width in mm), z(depth in mm) 로 차례대로 이루어져 있다. 해당 데이터에서 종속변수는 price 로 놓고 다중회귀를 이용한 다양한 독립변수들(cut, color, clarity 등)의 조합을 통해 종속변수에 가장 큰 영향을 미치는 요인을 파악할 것이다.

1) 칼럼에 대한 설명

가장 먼저 캐럿(Carat)은 다이아몬드의 크기 단위이다. 1ct 는 0.20g 으로 크기가 아닌 중량을 의미한다. 다음으로 cut(가공 등급)은 Fair, Good, Very good, Premium, Ideal 의 형식으로 되어있다. I Fair 등급은 매우 적게 빛이 나며 추천을 하지 않는 등급이다. Good 등급은 Fair 등급 이상의 등급을 이야기한다. Very Good 은 중간 등급의 다이아몬드이며 빛이 적은 편이기는 하지만 품질은 꽤 좋은 편의 다이아몬드를 이야기한다. Premium 등급은 두번째로 좋은 등급으로 추천을 하는 등급이다. 마지막으로 Ideal 등급의 다이아몬드는 많은 사람들에게 추천을 해주는 다이아몬드이며 밝기 역시 매우 좋은 편으로 이야기된다.

color(색상)는 다이아몬드의 경우 Colorless(무색)에 가까울수록 좋은 다이아몬드로 이야기가 된다. 낮은 색상 등급의 다이아몬드는 밝게 빛나는 화이트 대신 옅은 노란색을 띌 수 있다. 노란색을 띄는 다이아몬드 일 수 록 낮은 색상 등급을 이야기한다. 등급은 D, E, F, G, H, I, J, K-M, N-R, S-Z 등급으로 이루어져 있다. D, E, F 의 경우 색이 없는 다이아몬드이다. 가장 좋은 품질의 다이아몬드로 이야기된다. G, H 의 경우 색이 거의 없이 존재하는 다이아몬드이다. I, J 의 경우 색이 거의 없고 약간의 염료가 보이는 수준의 다이아몬드이다. K-M 의 경우 희미한 노란색이 보이는 다이아몬드이다. N-R 의 경우 매우 밝은 노란색을 띄고 있다. S-Z 의 경우 노란색 빛이 나는 다이아몬드 색을 지니고 있다.



<그림 1. 다이아몬드의 color 등급>

Clarity(투명도)의 경우 I3, I2, I1, S3, S2, S1, VS2, VS1, VVS2, VVS1, 1F, FL 의 순서로 되어있다. I, S, VS, VVS, F 의 등급대로 되어있으며 옆에 붙는 숫자가 클수록 불순물이 많이 들어간 다이아몬드이다. I 등급의 경우 INCLUDED 의 I 이며 불순물이 가장 많이 들어가 있는 등급이다. S 등급의 경우 SMALL INCLUSIONS 의 약자이며 두번째로 불순물이 많이 들어가 있는 등급이다. VS 의 경우 VERY SMALL INCLUSIONS 의 등급이며 중간 등급의 다이아몬드이다, VVS 는 VERY VERY SMALL INCLUSIONS 의 등급이며 2 번째로 좋은 다이아몬드 등급이다. 마지막 F 등급은 FLAESS 등급의 약자이며 가장 좋은 등급의 약자이다.

다이아몬드는 Depth(높이) 와 Table(다이아몬드의 가장 윗부분)을 통해서 모양에 따라 세분화된 등급을 나눌 수 있다.



<그림 2. Depth 와 Table>

해당 부분은 식을 통해 %를 계산하여 Poor, Fair, Good, Very good, Excellent 세분등급으로 나누어진다. Table %는 Table + 다이아몬드의 전체 지름을 통해서 구할 수 있다. Depth %는 Table + 다이아몬드의 전체 지름을 통해서 구할 수 있다. Depth의 경우 Poor 은 Over 70%, Fair 은 64%-70%, Good 의 경우 56%-64%, Very good 은 58.0%-62.0%, Excellent 의 경우 59.0%-61.0%이다. Table 의 경우 Poor 은 over 66% or under 53%이다. Fair 의 경우 64%-66%, Good 의 경우 62%-64%의 경우, Very good 61%-62%의 경우, Excellent 의 경우 53%-60%를 이야기한다.

2) 데이터 전처리

전처리 과정에서는 파이썬을 사용하여 분석하였다. NumPy 를 이용하여 파이썬에서 숫자 연산 및 배열 조작을 하였으며 pandas 를 사용하여 csv 형태의 파일을 분석할 수 있었다. 해당 데이터 타입에 대해서는 각각 float64, object, int64 를 반영하여 이루어져 있다.

#	Column	Non-Null Count	Dtype
0	carat	53943 non-null	float64
1	cut	53943 non-null	object
2	color	53943 non-null	object
3	clarity	53943 non-null	object
4	depth	53943 non-null	float64
5	table	53943 non-null	float64
6	price	53943 non-null	int64
7	x	53943 non-null	float64
8	Y	53943 non-null	float64
9	z	53943 non-null	float64

dtypes: float64(6), int64(1), object(3)

<표 1. Diamonds.csv 의 데이터타입>

	carat	depth	table	price	x	y	z
count	53943.000000	53943.000000	53943.000000	53943.000000	53943.000000	53943.000000	53943.000000
mean	0.797935	61.749322	57.457251	3932.734294	5.731158	5.734526	3.538730
std	0.473999	1.432626	2.234549	3989.338447	1.121730	1.142103	0.705679
min	0.200000	43.000000	43.000000	326.000000	0.000000	0.000000	0.000000
25%	0.400000	61.000000	56.000000	950.000000	4.710000	4.720000	2.910000
50%	0.700000	61.800000	57.000000	2401.000000	5.700000	5.710000	3.530000
75%	1.040000	62.500000	59.000000	5324.000000	6.540000	6.540000	4.040000
max	5.010000	79.000000	95.000000	18823.000000	10.740000	58.900000	31.800000

<표 2. Diamonds 관련 통계>


수치형 데이터에 관련된 통계 정보를 계산하였다. 평균, 표준편차, 최소값, 25%, 50%, 75%의 데이터 프레임을 만들어서 해당 정보에 대해서 파악할 수 있었다.

제 2 장 데이터 시각화

제 1 절 데이터 시각화 및 분석

각 열에 대한 통계적 정보는 해당 열의 분포와 중심경향성(평균), 퍼짐 정도(표준편차), 이상치 등을 파악하는데 도움을 주었다. 각 다이아몬드의 각 문항에 대한 분석을 통해 데이터의 대략적인 특성에 대해서 파악할 수 있었다. 평균과 50%(중앙값)을 통해서는 데이터의 중심 경향성을 파악할 수 있었다. 해당 값들을 통해서는 데이터의 분포에 대한 대표적인 위치를 파악할 수 있었다. 표준편차와 최소 나머지 값들을 통해서는 변동성을 분석할 수 있었다. 표준편차를 통해 해당 부분들의 데이터의 퍼짐 정도가 얼마나 들어가는지 확인하였으며 각 %별로 분석하는 방향을 통해 데이터의 분포도를 확인할 수 있었다. 대략적인 다이아몬드의 분산정도를 파악하고, 다른 변수와의 비교와 분석 추이를 활용할 때 사용하기 위해서 분석하였다.


1) chr 형 변수들의 분포도




<표 3. cut, color, clarity 에 대한 count 개수>

seaborn 라이브러리의 countplot 기능을 이용하여 문자형 변수들의 각 카테고리 값 별로 데이터가 얼마나 있는지 시각화 하였다. 그 결과, cut 에서는 Ideal 등급, color 에서는 G 등급, clarity 에서는 SI1 등급이 가장 많은 것으로 나타났다. 각 차트에 나타난 카테고리별 등급의 고하는 왼쪽에서 오른쪽으로 갈수록 더 높아지도록 표현하였다.

2) 종속변수 price 에 따른 문자형 독립변수 clarity, color, cut 의 분포도



<표 4. cut 등급별 가격 분포>




<표 5. color 등급별 가격 분포>

R ggplot2 의 boxplot 을 이용하여 각 변수의 등급별로 가격 분포를 알아보았다. 이를 위해 각 등급을 팩터화시켜 순서에 맞게 levels 를 지정하였다. 또한 해당 boxplot 은 이상치를 분석하기 어려운 형태이기 때문에 이상치에 영향을 적게 받는 중앙값을 위주로 분석하였다.

cut 등급의 경우, 중앙값을 고려했을 때 Premium, Fair, Good 순으로 가격이 높았다. Premium 이 가격의 변동성이 가장 크게 나타났으며 특히나 ideal 의 경우 상위 가격대와 하위 가격대의 편차가 상대적으로 크다는 것을 알 수 있다.


또한 (표 3*) color 등급의 경우 중앙값을 고려해 보았을 때 J- I- H 등급 순으로 가격이 높다. 마찬가지로 J-I- G 등급 순으로 큰 변동성을 확인할 수 있다.



<표 6. clarity 등급별 가격 분포>

Ch 형 독립 변수인 clarity 즉, 투명도 등급의 중앙값을 고려해 보았을 때, clarity 중 SI2, I1, SI1 순으로 가격이 높다. 또한 VS2 과 VS1 의 가격변동성이 타 등급에 비해 상당히 큰 것으로 보이기 때문에 가격 편차가 크다고 할 수 있다.


2) num 형 데이터 분포도



<표 7. 연속형 변수들의 컬럼 별 분포도>

위 그림은 연속형 변수들의 컬럼 별 분포도를 seaborn 의 boxplot 기능을 활용하여 산점도로 시각화한 것이다. 결과를 살펴보면, 전반적으로 carat, depth, table, 그리고 price 은 좁은 분포 범위를 보이고 있으나 이상점들이 넓게 많이 나타나고 있다. 특히 carat 의 경우 2 와 3 사이에 이상점들이 많이 분포해 있는 것을 확인할 수 있다. depth 와 table 은 최대 최소값과의 거리가 매우 먼 극단점을 보이고 있다. price 는 상대적으로 많은 편차를 가지고 있으며 많은 이상점들이 균일하게 분포되어 있음을 확인할 수 있다. x, y, z 의 경우 비교적 적은 이상점들을 가지고 있지만 마찬가지로 좁은 범위의 분포를 보인다.

3) 각 독립변수와 종속변수 간의 상관관계 지표



<표 8, 9. 각 컬럼 별 price 와의 상관관계를 나타내는 산점도, Heatmap>

위 그림은 seaborn 의 scatterplot 과 heatmap 기능을 활용하여 각 컬럼 별 price 와의 상관관계를 시각화한 것이다. Heatmap 을 살펴보면 상대적으로 carat 이 가장 price 와의 상관관계가 유의미한 것으로 나타나고 있다. Heatmap 의 색이 진할수록 상관관계수가 높고, 반대로 색이 연할수록 상관관계수가 낮은 것이다. 반대로 price 와 가장 약한 상관관계수를 보이는 컬럼은 depth 와 table 로 각각 -0.011 과 0.13 으로 약한 음의 상관관계수를 보이며, carat 은 0.92 의 양의 상관관계수를 보이며 가장 높은 상관관계를 보인다. 그러나 산점도를 살펴보면 carat 의 값이 커질수록 price 의 값이 퍼지는 경향성이 보인다는 문제점이 존재한다. 또한 depth 와 table 은 price 와의 상관관계가 원통형 형태로 나타나고 있는 것을 확인할 수 있다. 이는 가장 보편적인 커팅 방식인 라운드 브릴리언트 컷 때문에 나타나는 현상으로 유추된다. 라운드 브릴리언트 컷은 가장 이상적이고 보편적인 커팅 방식으로 완벽한 라운드 형태로 다이아몬드의 광채를 가장 잘

보여주는 커팅 방식이다. 다만 커팅 과정에서 원석의 손실이 가장 크기 때문에 비싼 가격의 원인이 된다.

제 3 장 분석 결과

제 1 절 모델 소개

각 컬럼과 price 간의 상관관계를 살펴보기 위해 회귀분석을 진행하였다. 이때 활용한 회귀분석 모델은 단순 선형 회귀로, 선형 회귀(Linear Regression)는 널리 사용되는 대표적인 회귀 알고리즘이며 단순 선형 회귀와 다중 선형 회귀로 나뉜다. 그 중에서 본 회귀분석에 사용한 선형 회귀는 종속 변수 y 와 하나 이상의 독립 변수 x 와의 선형 상관관계를 모델링하는 기법이다.

$$y = Wx + b$$

단순 선형 회귀는 $y=Wx+b$ 의 식으로 표현할 수 있는데, 머신 러닝에서는 독립 변수 x 에 곱해지는 W 값을 가중치(weight), 상수항에 해당하는 b 를 편향(bias)이라고 부른다. 따라서 단순 선형 회귀 모델을 훈련하는 것은 적절한 W 와 b 값을 찾는 것이다. 그래프의 형태는 직선으로 나타난다.

본 연구는 통계 프로그램 R 을 이용하여 선형 회귀 분석을 진행하였다.

제 2 절 분석 과정

1) 다중공선성(Collinearity Statistics)

	GVIF	Df	GVIF ^{1/(2*Df)}
carat	22.439246	1	4.737008
cut	1.945570	4	1.086753
color	1.178333	6	1.013769
clarity	1.347475	7	1.021531
depth	1.782449	1	1.335084
table	1.787674	1	1.337039
x	57.517927	1	7.584057
y	20.592150	1	4.537857
z	23.585595	1	4.857500

<표 10. VIF 계산 결과>

독립변수끼리 과하게 겹쳐서 발생하는 문제인 다중공선성은 상관관계가 매우 높은 독립변수들이 동시에 모델에 포함될 때 발생한다. 다중공선성을 찾아내는 방법 중 하나는 VIF (분산 팽창 지수)를 이용하는 것이다. $1/\text{tolerance}$ 수식을 이용해 VIF 를 계산하는데 VIF 가 크다는 것은 곧 다중공선성일 가능성이 크다는 의미이다. VIF 를 계산할 때 필요한 tolerance 는 $1 - R^2$ 값을 의미한다. 따라서 R^2 가 1 일 되어 tolerance 가 0 이 되는 경우에 독립변수 간에 심각한 상관관계가 있다는 것을 의미하고 곧 다중공선성이 심각하다는 것을 반증하는 수치이다. 변수마다 다른 분산팽창지수를 확인 후 다중공선성이 큰 변수가 유의한지 아닌지 우선적으로 확인이 필요하다. 이후 가장 일반적인 방법으로는 해당 변수를 제거하는 방식을 통해 문제를 해결한다.

처음 모든 데이터에 등장한 모든 독립변수들을 입력하고 VIF 를 계산했을 때는 carat, x, y, 그리고 z 변수에서 2 이상의 VIF 지수를 나타내었다. 다중공선성을 해결하기 위해 이번 논문에서는 가장 일반적인 방법인 이상 변수를 제거하는 방법을 선택하였다. 다양한 변수의 조합에 대해 고민해본 후 변수 x, y, z 를 제거했을 때 나머지 변수들의 분산팽창지수가 각각 1 점대를 나타내어 다중공선성 문제를 해결할 수 있었다. 따라서 변수 x, y, z 를 제거하고 논문을 진행하기로 결정했다.

다만 carat 이라는 독립변수는 제거하지 않았는데, 그 이유는 단순히 분산팽창지수가 크다는 이유로 제거하는 것보다는 해당 독립변수가 연구에 유의미할지 아닌지 판단하는 것이 중요하기 때문이다. 다중공선성이 있음에도 불구하고 해당 독립변수가 유의미한 경우가 존재한다. 이런 경우에 표준오차가 비정상적으로 팽창이 되어있음에도 유의미하다는 뜻으로 이 사실 자체만으로도 의미가 있다. 따라서 carat 이라는 독립변수가 이 경우에 해당하는 경우라고 판단하였고 제거하지 않았다.

2) 정규화

본 연구의 정확성을 위해 종속변수 price 를 로그 변환 정규화를 진행하였다. 로그 변환은 데이터의 비대칭성을 줄이고 비선형 관계를 선형 관계로 변환하는 데 도움이 될 수 있다. 데이터의 산점도들을 살펴보면 비대칭성이 쉽게 관측될 수 있다. 이러한 비선형적이며 비대칭적인 데이터를 정상화시키기 위해 로그변환 정규화를 진행한 것이라고 할 수 있다.

여기서 정규화는 데이터나 모델을 적절하게 변환하여 가정을 만족시키거나 모델의 성능을 향상시키기 위해 사용된다. 더하여 왜곡된 데이터는 한 쪽으로 치우쳐진 분포를 가지고 있기 때문에 이 경우 로그 변환을 통해 데이터를 정규분포에 가깝게 만들어야 한다. 예를 들면 로그 변환(log transformation), 제곱근 변환(square root transformation), Box-Cox 변환(Box-Cox transformation) 등이 있다.

2) 모델 계수 (Model coefficients)

	Estimate	Std.Error	t value	p value
as.factor(clarity)IF	1.026e+ 00	1.094e-01	67.157	< 2e-16
as.factor(clarity)SI1	7.249e-01	1.528e-02	55.501	< 2e-16
as.factor(clarity)SI2	5.412e-01	1.306e-02	41.253	< 2e-16
as.factor(clarity)VS1	8.825e-01	1.312e-02	66.144	< 2e-16
as.factor(clarity)VS2	8.191e-01	1.334e-02	62.356	< 2e-16
as.factor(clarity)VVS1	9.418e-01	1.413e-02	66.665	< 2e-16
as.factor(clarity)VVS2	9.315e-01	1.374e-02	67.801	< 2e-16
as.factor(color)E	-5.597e-02	5.362e-02	-10.438	< 2e-16
as.factor(color)F	-1.203e-02	5.419e-03	-9.603	< 2e-16
as.factor(color)G	-1.278e-01	5.307e-03	-24.081	< 2e-16
as.factor(color)H	-2.609e-01	5.645e-03	-46.219	< 2e-16
as.factor(color)I	-4.179e-01	6.340e-03	-65.919	< 2e-16
as.factor(color)J	-5.801e-01	7.826e-03	-74.121	< 2e-16
as.factor(cut)Good	5.255e-02	1.0006e-02	5.224	1.76e-07
as.factor(cut)Ideal	1.047e-01	1.000e-02	10.466	< 2e-16
as.factor(cut)Premium	5.886e-02	9.654e-03	6.097	1.09e-09
as.factor(cut)Very Good	6.597e-02	9.648e-03	6.838	8.14e-12
carat	2.195e+ 00	3.539e-03	620.219	< 2e-16
depth	7.425e-05	1.195e-03	0.062	0.95
table	6.892e-03	8.722e-04	7.902	2.80e-15

<표 11. 회귀계수 분석>

“Model coefficients”는 회귀분석 모델에서 독립 변수들의 영향력과 관련된 핵심적인 정보를 제공하는 개념이다. 여기서 변수가 cut, color, clarity, carat, depth, table 일때 가장 t-value, p-value 가 유의미한 변수는 carat 이다.

또한 분석결과 독립변수 depth 의 p-value 는 0.95 이므로 유의미한 값이라고 볼 수 없다. 따라서 depth 값을 제외하고 회귀계수를 확인하면 다음과 같이 나온다. 이에 대한 다중공선성은 전부 1.0 대의 값으로 독립변수들간의 상관관계가 약한 것으로 볼 수 있겠다.

	Estimate	Std.Error	t value	p value
as.factor(clarity)IF	1.0263663	0.0152627	67.246	< 2e-16
as.factor(clarity)SI1	0.7248854	0.0130558	55.552	< 2e-16
as.factor(clarity)SI2	0.5412209	0.0131117	41.278	< 2e-16
as.factor(clarity)VS1	0.8825031	0.0133303	66.203	< 2e-16
as.factor(clarity)VS2	0.8190500	0.0131271	62.394	< 2e-16
as.factor(clarity)VVS1	0.9417184	0.0141135	66.724	< 2e-16
as.factor(clarity)VVS2	0.9315045	0.0137270	67.859	< 2e-16
as.factor(color)E	-0.0559658	0.0053618	-10.438	< 2e-16
as.factor(color)F	-0.0520348	0.0054185	-9.603	< 2e-16
as.factor(color)G	-0.1277938	0.0053061	-24.084	< 2e-16
as.factor(color)H	-0.2608800	0.0056424	-46.235	< 2e-16
as.factor(color)I	-0.4178986	0.0063370	-65.945	< 2e-16
as.factor(color)J	-0.5800421	0.0078230	-74.145	< 2e-16
as.factor(cut)Good	0.0586501	0.0098489	5.323	1.03e-07
as.factor(cut)Ideal	0.1044687	0.0092788	11.259	< 2e-16
as.factor(cut)Premium	0.0586501	0.0090570	6.476	9.52e-11
as.factor(cut)Very Good	0.0657874	0.0091913	7.158	8.31e-13
carat	2.1946898	0.0035374	620.432	< 2e-16
table	0.0068702	0.0007963	8.627	< 2e-16

<표 12. 수정된 회귀계수 분석>

	GVIF	Df	GVIF ^{1/(2*Df)}
as.factor(clarity)	1.297041	7	1.018751
as.factor(color)	1.166203	6	1.012895
as.factor(cut)	1.572275	4	1.058196
carat	1.322218	1	1.149877
table	1.489201	1	1.220328

<표 13. 수정된 VIF 계산 결과>

따라서 종속 변수 price 에 가장 큰 영향을 주는 계수는 현저하게 낮은 표준오차와 가장 큰 t-value 620.432, 0.05 이하의 p-value 를 가진 독립변수 “carat”이다. 여기서 높은 t-value 는 독립변수와 종속변수 간의 상관도가 높다는 것을 의미한다. 또한 해당 회귀계수에 대한 유의성을 의미하는 p-value 는 0.05 이하의 값이어야 유의미하다고 볼 수 있다. 따라서 독립변수와 종속변수 간의 높은 상관도, 유의미하게 작은 회귀계수에 대한 유의성, 상대적으로 작은 표준오차로 인해 높은 확실성을 보여주는 carat 이 price 에 가장 강한 영향력을 미친다는 것을 알 수 있다.

4) 모델 평가

Residual standard error	Multiple R-squared	Adjusted R-squared	F-statistic	p-value
1156 (on 53923 degrees of freedom)	0.916	0.916	3.095e+ 04 (on 19 and 53923 Df)	< 2.2e-16

<표 14. R^2 와 수정된 R 의 결과 값>

모델의 성능을 평가하기 위한 지표로는 R, R^2 , Adjusted R^2 , RSE 가 있다. R^2 은 모델의 성능을 나타내는 지표인 결정계수로, 독립변수의 개수가 증가하면 독립변수의 유의성과 관계없이 증가한다는 한계점이 있다. 따라서 독립변수의 개수를 고려하는 Adjusted R^2 값을 통해 이러한 한계점을 보완하였다. RSE 는 실제값과 예측값의 차이를 제공해 평균화한 값에 루트를 취한 값이다. RSE 값이 너무 크면 실제값과 예측값이 크게 다른 것을 의미하며, Adjusted R^2 은 1 에 가까울수록 좋은 모델이라는 것을 의미한다.


위 표는 로그 변환을 통한 정규화를 거친 모델의 성능을 평가한 표이다. 따라서 결과값을 해석하면 Adjusted R^2 은 1 에 가까운 0.916 으로 모델의 성능이 좋음을 의미하고 있지만 RSE 값은 1156 으로 실제 값과 예측 값의 오차가 크다는 것을 의미한다.

제 4 장 결론

이렇게 다이아몬드의 가격 형성에 미치는 요인을 알아보았다. 유의성 검정을 거친 결과 종속변수는 로그화된 가격(logged price), 독립변수는 carat, cut, clarity, color, table 으로 결정되었다. 회귀계수를 살펴보니 carat 이 가장 가격에 영향을 미치는 주요한 변수인 것으로 밝혀졌다. 또한 이처럼 변수를 설정하고 선형회귀분석을 진행한 결과, R^2 과 Adjusted R^2 가 0.8886, RSE 이 0.3387 으로 나온 것을 확인할 수 있었다.

제 1 절 한계점 및 향후 과제


1) 한계점(1): 잔차도




<표 15. 로그변환 전후의 잔차도>

위 그림은 로그변환 후의 QQ plot 과 잔차도 after transformation, 로그변환 전의 잔차도 Before transformation 이다. 먼저 로그변환 전후의 잔차도를 확인할 수 있는데 정규화를 시켜도 여전히 비정상적 잔차를 보이고 있음을 확인할 수 있다. 가장 이상적인 잔차도는 어떤 특정한 패턴이나 추세가 없어야 한다. 만약 잔차에 패턴이 존재한다면, 이는 모델이 데이터의 일부 패턴을 잡아내지 못하거나 오차 구조에 문제가 있다는 것을 의미할 것이다. 따라서 log_price 에 대한 잔차도는 linear 한 모델이 아닌 non-linear 한 모델이 더 적합 하다는 것을 의미한다.


2) 한계점(2): QQ plot



<표 16. Diamonds 데이터의 QQ plot>



<표 17. 정규분포표와 QQ plot>



여기서 QQ plot (Quantile-Quantile plot)은 데이터의 분포와 정규분포의 분포 형태를 비교하기 위해 사용되는 그래프이며 분석 대상 데이터가 정규분포와 유사한 분포를

가지고 있을 수록 직선의 형태를 보이게 된다. 도표 상의 점들이 직선에 얼마나 많이 어긋나는지에 대해 정규성을 판단할 수 있는 것이다.

모집단과 price 간의 QQ plot 은 직선위로 치솟는 ‘Heavy Tailed’ 모양으로, 이는 극단에 위치한 데이터가 더 많고 중심값에 위치한 데이터는 더 적다는 것을 의미한다. 표를 보면 x 축 값이 극한에 분포돼 있는 모습을 통해 알 수 있다. 따라서 ‘Heavy Tailed’ 모양의 분포도는 가장 이상적인 형태의 가우시안 분포와는 차이를 보인다고 할 수 있다. 따라서 해당 결과의 QQ plot 은 데이터의 비대칭성과 이상치가 있을 가능성을 시사할 수 있다.

3) 향후과제

종종 실제 데이터에서는 종종 독립 변수와 종속 변수 간에 비선형적인 관계가 존재하는 경우가 나타나는데 이번 논문에서 살펴본 다이아몬드와 관련된 데이터도 이 경우에 해당한다. 표 15 의 ‘after transformation’잔차도를 보면 알 수 있듯이 우하향 선형 형태를 보이고 있다. 이는 등분산성이 만족되지 않는 것을 의미할 수 있다. 이러한 패턴은 일반적으로 회귀 모델이 적절하지 않거나 추가적인 모델링 기법이 필요함을 나타낸다.

이 때 활용할 수 있는 것이 바로 역수형 모델이다. 역수형 모델은 종속 변수가 작을 때 큰 영향을 미치고, 값이 커질수록 영향력이 감소하는 형태를 가진다. 역수형 모델은 독립 변수의 역수를 사용하여 비선형 관계를 모델링하는데, 예를 들어 독립 변수 X 와 종속 변수 Y 가 있을 때, 독립 변수 X 의 역수를 적용한 역수형 모델은 다음과 같이 표현될 수 있다.

$$Y = \beta_0 + \beta_1 * (1/X)$$

위에서 나타난 β_0 와 β_1 은 회귀분석에서 추정되는 회귀 계수이며, 이 모델은 독립 변수 X 의 값이 커질수록 종속 변수 Y 에 대한 영향이 감소한다는 특징을 가지고 있다. 따라서 본 논문의 향후과제는 역수형 모델을 적용하여 회귀분석을 진행하는 것이 되겠다.

또한 독립변수의 정규성을 안정화시키는 방법으로는 ‘Box-Cox transformation’방법이 있을 수 있다. 이는 선형회귀분석을 하는데 있어서 반응변수가 정규분포라는 가정을 기본적으로 하며 비선형 변환을 통해 정규성을 확보할 수 있다는 주장이다.

지금까지 통계 프로그램 R 을 사용하여 다이아몬드의 가격에 영향을 주는 변수들을 회귀분석해 보았다. 다중공선성과 회귀계수, 모델 평가에 있어서 독립변수 carat 이 가장 영향이 큰 변수로 도출되었으나 잔차도와 QQ plot 의 경우에는 정상적인 분포 형태가 아니라는 한계점을 발견하게 되었다. 그러므로 향후 과제로서 역수형 모델과 ‘Box-Cox transformation’을 설정하여 연구를 지속해 나갈 계획이다.

참고문헌

[국내문헌]

- 1) “R 회귀분석 모델 성능판단 - RMSE, MAE, R squared”, 티스토리 블로그, 2023년 6월 3일 접속, <https://yogyui.tistory.com/entry/R-%ED%9A%8C%EA%B7%80%EB%B6%84%EC%84%9D-%EB%AA%A8%EB%8D%B8-%EC%84%B1%EB%8A%A5%ED%8C%90%EB%8B%A8-RMSE-MAE-R-square>
- 2) “선형 회귀, Linear Regression”, 티스토리 블로그, 2023년 6월 4일 접속, <https://umbum.dev/865>
- 3) “[R] 회귀분석(Regression Analysis) [회귀식 추정, 회귀모형 검정, 적합도 파악]”, 티스토리 블로그, 2023 6월 4일 접속, <https://umbum.dev/865>
- 4) “[회귀분석]다중회귀분석(3)-다중공선성(다중공선성 검정 및 해결)”, 티스토리 블로그, 2023년 6월 2일 접속, <https://ysyblog.tistory.com/171>
- 5) “QQ Plot 해석하기”, velog, 2023년 6월 1일 접속, https://velog.io/@yuns_u/QQ-plot-%ED%95%B4%EC%84%9D%ED%95%98%EA%B8%B0
- 6) “파이썬 시각화 큐큐플롯”, 네이버 블로그, 2023년 6월 1일 접속, <https://blog.naver.com/breezehome50/222339337268>
- 7) “R STUDIO 데이터 시각화 15”, 네이버 블로그, 2023년 6월 1일 접속, https://blog.naver.com/sharp_kiss/222663556889
- 8) “QQ Plot 직관적으로 이해하기”, 티스토리 블로그, 2023년 6월 1일 접속, <https://diseny.tistory.com/entry/QQ-Plot-%EA%B7%B8%EB%A6%AC%EA%B8%B0-%EB%B0%8F-%ED%99%9C%EC%9A>
- 9) “QQ Plot”, www.actruce.com, 2023년 6월 4일 접속, <https://www.actruce.com/qq-plot/>

[국외문헌]

- 1) “A Q-Q Plot Dissection Kit”, Sean Kross blog, 2023년 6월 2일 접속, <https://seankross.com/2016/02/29/A-Q-Q-Plot-Dissection-Kit.html>
- 2) “Diamond price prediction:Linear Regression”, Kaggle, 2023년 5월 29일 접속, <https://www.kaggle.com/code/nabanic/diamond-price-prediction-linear->



[regression#Step-5:-Bivariate-Analysis.](#)

3) “What is Diamonds Cut?”, Tiffany & Co, 2023년 6월 2일 접속,
<https://www.tiffany.kr/engagement/the-tiffany-guide-to-diamonds/color/>

%A9%EB%B2%95

4) “Are two asymptotic values enough to fail the test of normality?”, stackexchange,
2023년 6월 4일 접속, <https://stats.stackexchange.com/questions/183663/are-two-asymptotic-values-enough-to-fail-the-test-of-normality>

