

다양한 머신 러닝 기법을 활용한 배달 소요 시간 예측 프로젝트

DAT 3조 3각김밥

김선민(GBT 20학번)
김예진(GBT 20학번)
김가영(국제금융학과 20학번)

목차


- 1 연구배경
- 2 데이터 전처리
- 3 데이터 선별
- 4 모델 학습 및 비교
- 5 연구 결론

1

연구 배경

연구 배경 |

[배달앱 총 사용량 변화]



배달 앱에서는

최소주문금액 / 결제방법 / 배달시간

등의 주요 정보를 우선 제공

4차 산업혁명과 코로나 19의 영향으로 인한
비대면 라이프 스타일이 가속화되어

배달 플랫폼 기반 배달 수요 급성장

[배달앱 제공 정보]

	배달주문	포장/방문주문
최소주문금액	27,000원	
결제방법	바로결제,	배달 예상 시간은 실제 배달시간과 차이가 있을 수 있습니다
배달시간	49~64분 소요 예상 ⑦	

연구 배경 |

[배달앱 예상소요시간과 실제 배달 소요시간과의 차이]

배달주문

포장/방문주문

최소주문금액 27,000원

결제방법 바로결제,

배달시간 49~64분 소요 예상 ②

배달 예상 시간은
실제 배달시간과 차이가 있을 수 있습니다



26분 만에 배달이 완료되었어요

주문하신 메뉴는 어떠셨어요?
다른 분들을 위해 리뷰를 남겨보세요

But,

배달 어플리케이션에서 안내되는 배달시간은

“ 판매자가 직접 설정하는 조리시간 + 업체와의 거리반영” 하여 나타나는 예상소요시간으로,

배달 예상소요시간에 대한 객관성 저하 및 예측력 부족 문제

연구 목적 |

배달 소요 시간에 영향을 줄 것이라 예상되는

배달 기사 / 배달 수단 / 음식 유형 / 교통 혼잡도 / 동시 배달 수 등

변수들을 활용한 배달 소요시간 예측 프로젝트

판매자

도착 예정 시간을 고려한
조리 및 배달 절차 최적화

구매자

정확한 배달 시간 인지로
배달 이용의 편의성 증대

[Food Delivery Dataset]



2

데이터 전처리

The Kaggle logo, featuring the word "kaggle" in a lowercase, blue, sans-serif font.

Food Delivery Dataset

Use this dataset to determine estimated time for food delivery.

: 음식 배달 서비스를 이용할 때 수집되는 데이터

조사 및 분석 데이터 소개 | 변수 소개

X(독립변수)	변수설명	유형
ID	배달 시킨 사람 ID	object
Delivery_person_ID	배달 기사 ID	object
Delivery_person_Age	배달 기사 나이	object
Delivery_person_Ratings	배달 기사의 평점	object
Restaurant_latitude	식당 위도	float64
Restaurant_longitude	식당 경도	float64
Delivery_location_latitude	배달 장소 위도	float64
Delivery_location_longitude	배달 장소 경도	float64
Order_Date	배달 시킨 날짜	object
Time_Orderd	배달 시킨 시간	object
Time_Order_picked	배달 음식을 챙긴 시간	object
Weatherconditions	날씨 상태	object
Road_traffic_density	교통 혼잡도	object
Vehicle_condition	배달 수단 상태	int64
Type_of_order	배달 시킨 음식의 종류	object
Type_of_vehicle	배달 수단	object
multiple_deliveries	동시 배달 수	object
Festival	축제	object
City	도시 여부	object
Y(종속변수)	변수설명	타입
Time_taken(min)	배달 소요 시간(분)	object

20개의 변수

독립변수 19개

종속변수 1개

총 관측치 45593개

데이터 전처리 | 수치형 데이터화

X(독립변수)	변수설명	유형
ID	배달 시킨 사람 ID	object
Delivery_person_ID	배달 기사 ID	object
Delivery_person_Age	배달 기사 나이	object
Delivery_person_Ratings	배달 기사의 평점	object
Restaurant_latitude	식당 위도	float64
Restaurant_longitude	식당 경도	float64
Delivery_location_latitude	배달 장소 위도	float64
Delivery_location_longitude	배달 장소 경도	float64
Order_Date	배달 시킨 날짜	object
Time_Orderd	배달 시킨 시간	object
Time_Order_picked	배달 음식을 챙긴 시간	object
Weatherconditions	날씨 상태	object
Road_traffic_density	교통 혼잡도	object
Vehicle_condition	배달 수단 상태	int64
Type_of_order	배달 시킨 음식의 종류	object
Type_of_vehicle	배달 수단	object
multiple_deliveries	동시 배달 수	object
Festival	축제	object
City	도시 여부	object



숫자형 변경

float64

데이터 전처리 | 결측치 처리

X(독립변수)	변수설명	유형
ID	배달 시킨 사람 ID	object
Delivery_person_ID	배달 기사 ID	object
Delivery_person_Age	배달 기사 나이	float64
Delivery_person_Ratings	배달 기사의 평점	float64
Restaurant_latitude	식당 위도	float64
Restaurant_longitude	식당 경도	float64
Delivery_location_latitude	배달 장소 위도	float64
Delivery_location_longitude	배달 장소 경도	float64
Order_Date	배달 시킨 날짜	object
Time_Orderd	배달 시킨 시간	object
Time_Order_picked	배달 음식을 챙긴 시간	object
Weatherconditions	날씨 상태	object
Road_traffic_density	교통 혼잡도	object
Vehicle_condition	배달 수단 상태	int64
Type_of_order	배달 시킨 음식의 종류	object
Type_of_vehicle	배달 수단	object
multiple_deliveries	동시 배달 수	object
Festival	축제	object
City	도시 여부	object



평균치 대체



결측치 행 제거

데이터 전처리 | 새로운 변수 생성

X(독립변수)	변수설명	유형
ID	배달 시킨 사람 ID	object
Delivery_person_ID	배달 기사 ID	object
Delivery_person_Age	배달 기사 나이	float64
Delivery_person_Ratings	배달 기사의 평점	float64
Restaurant_latitude	식당 위도	float64
Restaurant_longitude	식당 경도	float64
Delivery_location_latitude	배달 장소 위도	float64
Delivery_location_longitude	배달 장소 경도	float64
Order_Date	배달 시킨 날짜	float64
Time_Orderd	배달 시킨 시간	object
Time_Order_picked	배달 음식을 챙긴 시간	object
Weatherconditions	날씨 상태	object
Road_traffic_density	교통 혼잡도	object
Vehicle_condition	배달 수단 상태	int64
Type_of_order	배달 시킨 음식의 종류	object
Type_of_vehicle	배달 수단	object
multiple_deliveries	동시 배달 수	object
Festival	축제	object
City	도시 여부	object

➡ [Year-Month-Day]

Order_Month

Order_Day

Order_week

데이터 전처리 | 새로운 변수 생성

X(독립변수)	변수설명	유형
ID	배달 시킨 사람 ID	object
Delivery_person_ID	배달 기사 ID	object
Delivery_person_Age	배달 기사 나이	float64
Delivery_person_Ratings	배달 기사의 평점	float64
Restaurant_latitude	식당 위도	float64
Restaurant_longitude	식당 경도	float64
Delivery_location_latitude	배달 장소 위도	float64
Delivery_location_longitude	배달 장소 경도	float64
Order_Date	배달 시킨 날짜	object
Time_Orderd	배달 시킨 시간	object
Time_Order_picked	배달 음식을 챙긴 시간	object
Weatherconditions	날씨 상태	object
Road_traffic_density	교통 혼잡도	object
Vehicle_condition	배달 수단 상태	int64
Type_of_order	배달 시킨 음식의 종류	object
Type_of_vehicle	배달 수단	object
multiple_deliveries	동시 배달 수	object
Festival	축제	object
City	도시 여부	object



음식주문시간과
음식픽업시간의 차
diff_picked_min

데이터 전처리 | 범주형 변수의 더미변수화

X(독립변수)	변수설명	유형
ID	배달 시킨 사람 ID	object
Delivery_person_ID	배달 기사 ID	object
Delivery_person_Age	배달 기사 나이	float64
Delivery_person_Ratings	배달 기사의 평점	float64
Restaurant_latitude	식당 위도	float64
Restaurant_longitude	식당 경도	float64
Delivery_location_latitude	배달 장소 위도	float64
Delivery_location_longitude	배달 장소 경도	float64
Order_Date	배달 시킨 날짜	object
Time_Orderd	배달 시킨 시간	object
Time_Order_picked	배달 음식을 챙긴 시간	object
Weatherconditions	날씨 상태	object
Road_traffic_density	교통 혼잡도	object
Vehicle_condition	배달 수단 상태	int64
Type_of_order	배달 시킨 음식의 종류	object
Type_of_vehicle	배달 수단	object
multiple_deliveries	동시 배달 수	object
Festival	축제	object
City	도시 여부	object

범주형 데이터
➡ `get_dummies()`
더미변수화

데이터 전처리 | 변수 삭제

X(독립변수)	변수설명	유형
ID	배달 시킨 사람 ID	object
Delivery_person_ID	배달 기사 ID	object
Delivery_person_Age	배달 기사 나이	float64
Delivery_person_Ratings	배달 기사의 평점	float64
Restaurant_latitude	식당 위도	float64
Restaurant_longitude	식당 경도	float64
Delivery_location_latitude	배달 장소 위도	float64
Delivery_location_longitude	배달 장소 경도	float64
Order_Date	배달 시킨 날짜	object
Time_Orderd	배달 시킨 시간	object
Time_Order_picked	배달 음식을 챙긴 시간	object
Weatherconditions	날씨 상태	object
Road_traffic_density	교통 혼잡도	object
Vehicle_condition	배달 수단 상태	int64
Type_of_order	배달 시킨 음식의 종류	object
Type_of_vehicle	배달 수단	object
multiple_deliveries	동시 배달 수	object
Festival	축제	object
City	도시 여부	object

➡ 불필요한 변수 제거


최종 데이터셋 완성

총 30개의 변수
총 관측치 41616개

3

데이터 선별

연구 모형 | 선형 회귀 모형




정규화 이전 평균제곱오차

adjusted- R2 (OLS)	RMSE (Linear Regression)
0.941	6.07654

정규화
Standard Scaler



표준화
Min&max



정규화 이후 평균제곱오차

adjusted- R2 (OLS)	RMSE (Linear Regression)
0.822	0.15174

연구 모형 | 선형 회귀 모형 - 다중공선성 확인

[독립변수들 간의 다중공선성]

VIF Factor	features
25.262097	Delivery_person_Ratings
9.633762	Type_of_vehicle_motorcycle
7.500685	Time_taken
4.719550	Type_of_vehicle_scooter
4.382135	Delivery_person_Age
⋮	
1.123936	Festival_Yes
1.033907	City_Semi-Urban

가장 높은 VIF 수치를 보인 변수는
Delivery_person_Ratings


VIF = 10 기준치를 넘는 수치로,
변수 제거



재확인 시, 모두 VIF 10 이하의 수치

연구 모형 | 변수 선출-단계 선택법(stepwise selection)

[Stepwise Selection]



분석치를 개선시키는 변수를
추가 또는 제거하여 변수를 선정


STEP 12



총 12개의 독립변수 추출

연구 모형 | 변수 선출 - 랜덤 포레스트의 변수 중요도

[랜덤포레스트 feature_importances]



Features Importance 통해
예측에 큰 영향을 주는 변수 확인



상위 20개의 독립변수 추출

Stepwise selection
&
Variable Importance(Random Forest)

추출된 두 변수집단의 교집합 11개의 변수를 최종 독립변수로 선정

Vehicle_condition	multiple_deliveries	Delivery_person_Age	Festival_Yes
Road_traffic_density_Jam	Road_traffic_density_Low	City_Urban	
Weatherconditions_conditions_Sunny		Weatherconditions_conditions_Sandstormy	
Weatherconditions_conditions_Stormy		Weatherconditions_conditions_Windy	

4

모델 학습 및 비교

모델 성능 비교 | 모든 모델 성능

[선형회귀모형]

	train	Test
정확도	0.493	0.49
RMSE	0.1517	

배달기사의 나이가 많을수록
동시에 배달하는 음식 개수가 많을수록
축제 여부 YES 일수록

배달 소요시간 증가 (양의 상관)

날씨가 맑을수록
도시일수록
교통밀도가 낮을수록

배달 소요시간 감소 (음의 상관)

모델 성능 비교 | 모든 모델 성능

[Ridge]

	0.001	0.005	0.01	0.05	0.1	1	10
정확도	0.49	0.49	0.49	0.49	0.49	0.49	0.49
RMSE	0.1517	0.1517	0.1517	0.1517	0.1517	0.1517	0.1517

[Lasso]

	0.001	0.005	0.01	0.05	0.1	1	10
정확도	0.487	0.429	0.335	0.0	0.0	0.0	0.0
RMSE	0.1521	0.1605	0.1733	0.2125	0.2125	0.2125	0.2125

[ElasticNet]

	0.001	0.005	0.01	0.05	0.1	1	10
정확도	0.489	0.468	0.421	0.094	0.0	0.0	0.0
RMSE	0.1518	0.1550	0.1616	0.2022	0.2125	0.2125	0.2125

알파값에 따른 모델성능 큰 차이 없음

알파값이 0.05 이상으로 넘어가면
정확도 감소 / RMSE 증가

알파값이 0.1 이상으로 넘어가면
정확도 감소 / RMSE 증가

모델 성능 비교 | 모든 모델 성능

[RandomForest]







	하이퍼파라미터	모델 성능 (정확도)		RMSE
GridSearchCV	'max_depth': 10 'min_samples_leaf': 8 'min_samples_split': 20 'n_estimators': 1000	훈련데이터	0.62979	0.129040
		검증데이터	0.61966	0.131075
RandomSearchCV	'max_depth': 11 'min_samples_leaf': 14 'min_samples_split': 15 'n_estimators': 9083	훈련데이터	0.630976	0.128834
		검증데이터	0.618280	0.131314

최적 하이퍼파라미터 조정을 위한
SearchCV 알고리즘 사용

GridSearchCV
하이퍼파라미터 선택
'max_depth': 10
'min_samples_leaf': 8
'min_samples_split': 20
'n_estimators': 1000

모델 성능 비교 | 모든 모델 성능

[visualization]



5

연구 결론

연구 내용 종합

- 1 Stepwise와 Feature importance를 고려하여 변수 선출함
- 2 선형 회귀 방식과 비교했을 때 랜덤 포레스트의 정확도를 60%로 높였음
- 3 GridSearchCV 하이퍼파라미터를 적용한 랜덤 포레스트가 가장 높은 정확도

한계점

다양한 변수 선출 방식을 사용하지 못 함

1

변수 중요도 수치가 낮아도 실제로는 중요한 영향을 끼칠 가능성 있음

배달 주문이 몰리는 시간대를 새로운 변수로 고려하지 못 함

2

배달 소요시간에 큰 영향을 미칠 수 있는 변수를 새로운 변수로써 고려하지 못함

향후 연구 방향성 제안

1 보루타 알고리즘을 활용한 새로운 변수 선출 방식

보루타 알고리즘이란, 랜덤포레스트를 기반으로 변수를 선택하는 래퍼 방법(Wrapper Method)으로 기본적인 아이디어는 기존 변수를 복원추출해서 만든 변수(shadow) 보다 모형 생성에 영향을 주지 못했다고 하면 이는 가치가 크지 않은 변수로 인식하여 제거하는 방식

2 피크 타임 변수와 같이 배달 소요 시간에 많은 영향을 끼치는 변수 새롭게 생성

- 배달음식을 주로 먹는 시간대로 '저녁 6~9시'가 55.8%로 1위, 2위는 '저녁 9~12시'(28.8%)
- 배달음식을 먹는 요일은 '토요일(68.4%)', '금요일(56.6%)', '일요일(42.3%)'순으로 집중

'대학내일20대연구소'에서 진행한 <19~34세 식생활 및 식문화 연구 보고서>

Q&A
