

패널회귀모형을 이용한 정곡 생산량 추정

데박 2기 송은지 2기 김민지 3기 이나원 3기 원시현

목차

01

연구배경 및 주제

02

데이터 소개

03

공간가중패널 모형

04

패널회귀모형

05

결론

06

한계 및 제언

연구 배경 및 주제

01 농산물 생산량 파악의 필요성

02 한국인의 주식 쌀

03 불안정한 기후현상

“패널회귀모형을 이용한 지역별 쌀 생산량 예측”

분석 개요

변수선택

RFECV & RFE 이용

모델 적합

모델 적합 & 결과 해석

01 ——— 02 ——— 03 ——— 04

데이터 수집

정곡 생산량 자료와
기상 자료를 수집

공간적 자기상관

공간가중치 행렬 생성
공간적 자기상관 검정

데이터 소개

월 평균기온(°C)

월 평균최고기온 (°C)

월 평균최저기온 (°C)

월 평균상대습도 (%)

월 누적 강수량 (mm)

월 평균풍속 (m/s)

월 누적 일조시간 (hr)

월 평균지면온도 (°C)

데이터 수집 : 종관기상 관측(ASOS)을 기준으로 수집

종관기상관측장비가 없는 지역의 경우

방재기상관측(AWS) 자료로 대체

기상관측장비가 없는 지역인 경우

가장 인접해 있는 지역의 기상자료로 대체

데이터 소개

변수		세부자료
y	단수 : 생산량(1000t/10a)	2013-2022, 지역별 10a 당 쌀 생산량
	월 평균기온(° C)	
x	월 평균최고기온 (° C)	2013-2022, 지역별 월별 기상데이터
	월 평균최저기온 (° C)	
	월 평균상대습도 (%)	
	월 누적 강수량 (mm)	
	월 평균풍속 (m/s)	
	월 누적 일조시간 (hr)	
	월 평균지면온도 (° C)	

쌀의 주 수확시기인
10월을 기준으로
연간 단위당 생산량 변화

≡

해당연도의 쌀 생산량에 영향을
미치는 기상자료를
전년도 10월부터
해당년도 9월까지로 설정

쌀 생산량

시군	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022
철원군	463	594	572	576	522	573	551	445	578	508
파주시	483	514	546	487	480	474	467	461	525	504
서산시	539	566	547	547	527	557	537	519	589	546
청주시	538	559	565	568	526	572	553	522	540	522
포항시	469	473	513	514	513	495	471	434	520	459
양평군	457	476	480	482	468	477	468	459	482	473
이천시	491	523	528	539	511	517	516	471	541	536
인제군	447	475	498	505	499	525	505	381	525	462
정선군	460	520	537	565	493	505	504	456	486	466
정읍시	528	556	589	578	561	546	531	506	521	524
해남군	469	473	513	514	513	495	471	434	520	459
고흥군	515	506	517	513	516	492	459	439	514	483
김포시	466	492	510	511	508	516	469	455	522	500
포천시	407	521	535	498	452	491	484	465	522	504

2013년부터 2022년까지 KOSIS(국가통계포털)에서 제공
32개 시군의 10a 당 쌀(정곡, 92.9%) 생산량

변수선택

RFE(Reclusive Feature Elimination)

특성 알고리즘으로 모든 특성들로부터 특성을 한 가지 씩 제거

원하는 개수의 특성이 남을 때까지 반복

RFECV(Reclusvie Feature Elimination with Cross Validation)

RFE 과정을 k차 교차검증의 각 겹에 대해 수행

각 겹마다의 모델 성능을 평가하여 최적의 특성 수를 선택

변수 중요도가 낮은 특성부터 하나씩 제거

최적의 특성 수가 될 때까지 각 단계를 반복

최종 선택 변수

4월 평균 기온 9월 강수량 4월 평균최고기온

11월 평균지면온도 7월 합계일조시간

패널회귀모형

시계열 자료 (time series data)

+



패널 자료 (Panel data)

횡단면 자료 (cross sectional data)

패널 선형회귀의 기본 모형식

$$y_{it} = \alpha + \beta x_{it} + e_{it}, \quad \left(\text{단 } e_{it} = \mu_i + \varepsilon_{it}, \quad \varepsilon_{it} \sim N(0, \sigma_\varepsilon^2) \right), i = 1, 2, \dots, N, t = 1, 2, \dots, T$$

패널회귀모형

하우스만 검정

Hausman Test

확률효과 모형(Random Effects Model)

: 설명변수와 오차항 μ_i 간의 상관성이 없음 *fail to reject H_0*

고정효과 모형(Fixed Effects Model)

: 설명변수와 오차항 μ_i 간의 상관성이 존재 *reject H_0*

$$H_0 : cov(x_{it}, \mu_i) = 0$$

패널회귀모형

장점

- 패널자료에는 개체(i) 정보와 시간(t) 정보가 동시에 존재
- 개체의 정적(static)인 관계만을 추정할 수 있는 횡단면자료와 달리, 개체의 동적(dynamic)인 관계를 추정가능
- 시계열자료에 비해 더 많은 정보/표본수와 변수의 변이(variability)를 제공

단점

- 데이터를 수집하고 유지하는 데(비용문제) 어려움이 있음

공간가중패널회귀모형

패널회귀모형

+

공간적 자기상관



공간가중패널회귀모형

(SAR)

SAR 모형 기본 모형식

$$y_t = \sum_{r=1}^k S_r(W)x_r + (I_N - \rho W_N)^{-1}\mu + (I_N - \rho W_N)^{-1}\varepsilon_t,$$
$$S_r(W) = (I_N - \rho W_N)^{-1}I_N\beta_r, (I_N - \rho W_N)^{-1} = I_N + \rho W + \rho^2 W^2 + \rho^3 W^3 + \dots$$

공간가중치 행렬 : 공간적 종속성을 행렬으로 나타낸 것



거리 기준 행렬 생성 방법

임계치 설정법

: 지역 간 거리가 특정 임계치를 기준으로 가까울 경우는 서로 자기 상관성이 존재한다고 판단하는 방법

1. 김포와 고양 간의 거리를 최소 임계치로 설정하는 방법
2. 진도와 양양 간의 거리를 최대 임계치로 설정하는 방법

최근 거리 설정 방법

: 특정 지역을 기준으로 가장 가까운 m번째까지 지역은 서로 자기 상관성이 존재한다고 판단하는 방법

용인을 기준으로 $m=3$ 인 경우 용인과 가장 가까운 이천, 평택, 화성의 지역만 용인과 공간적인 자기 상관성을 가짐

공간가중패널회귀모형 적합 결과

임계치 설정 방법

변수	최소임계치		최대임계치	
	Estimate	p 값	Estimate	p 값
4 월 평균기온	0.209835	0.91983	-0.168364	0.929853
4 월 평균최고기온	1.785340	0.25530	1.022769	0.494067
9 월 합계 강수량	-0.039854	0.01414 *	-0.033616	0.004189 **
7 월 합계 일조시간	0.058256	0.04689 *	0.043438	0.034218 *
11 월 평균 지면 온도	1.042548	0.33258	0.659758	0.363231
ϕ	2.1179723	0.0004207 ***	2.28830	0.002038 **
ρ	0.0089692	0.8953797	-0.73237	0.600920
Hausman	0.8212		0.8376	
AIC	4586.429		4650.913	
BIC	4597.639		4662.123	
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1				

최근 거리 설정 방법

변수	m=3		m=4		m=5	
	Estimate	p 값	Estimate	p 값	Estimate	p 값
4 월 평균기온	2.767886	0.1960270	8.201536	0.019241 *	7.337044	0.024662 *
4 월 평균최고기온	1.351513	0.3953103	-4.694440	0.089712 .	-4.359830	0.091851 .
9 월 합계 강수량	-0.073258	2.28e-05 ***	-0.049833	0.001335 **	-0.042710	0.002583 **
7 월 합계 일조시간	0.104940	0.000742 ***	0.059515	0.021701 *	0.046915	0.043908 *
11 월 평균 지면 온도	1.746259	0.1244869	1.436475	0.108803	1.171200	0.144033
ϕ	1.783409	0.001935 **	.	.	.	.
ρ	-0.018759	0.952084	-0.41089	0.01815 *	-0.57324	0.00099 ***
Hausman	0.0732		0.01035		0.007243	
AIC	4257.812		2836.702		2796.765	
BIC	4269.021		2851.648		2815.448	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

결과

최종 유의한 변수

- 최소임계치, 최대임계치, $m=3$ 방법
당해년도 9월 강수량, 당해년도 7월 합계 일조시간
- $m=4$, $m=5$ 방법 :
당해년도 4월 평균 기온, 당해년도 9월 강수량,
당해년도 7월 합계일조시간

가장 좋은 모형

각 모형의 AIC, BIC 값을 비교



$m = 5$ 모델

결과

각 모델의 결정계수

Table 4.3. R-square

method	m=3	m=4	m=5	최소임계치	최대임계치
R-square	0.006507609	0.003295526	0.0003733637	0.006649406	0.00706432

모두 매우 작은 값을 가짐
: 공간적 자기상관 검정 필요


Moran's I Test 결과

Table 4.4. Moran's I

method	m=3	m=4	m=5	최소임계치	최대임계치
Moran's I	0.419	0.385	0.356	-0.018	-0.039

모두 공간적 자기상관이
없다고 할 수 있음

결과



공간가중패널회귀모형이 적절하지 않음을 확인

패널 회귀모형 적합 결과

하우스만 검정

데이터를 고정효과, 확률효과 모형에 적합해 하우스만 검정 진행

```
##  
## Hausman Test  
##  
## data: 생산량 ~ 기온 + 최고기온 + 강수량 + 일조시간 + ...  
## chisq = 1.3061, df = 5, p-value = 0.9343  
## alternative hypothesis: one model is inconsistent
```

p-value가 0.9343이므로 확률 효과 모형을 채택

확률 효과 모형 모델링

```
              Estimate Std. Error z-value Pr(>|z|)
(Intercept) 406.153229  16.909340 24.0195 < 2.2e-16 ***
기온         4.320584   2.134344  2.0243  0.04294 *
최고기온     1.278717   1.537340  0.8318  0.40554
강수량      -0.094003   0.018559 -5.0652 4.079e-07 ***
일조시간     0.139835   0.033429  4.1830 2.877e-05 ***
지면온도     2.450550   1.213495  2.0194  0.04344 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    270710
Residual Sum of Squares: 184960
R-Squared:               0.31674
Adj. R-Squared: 0.3055
Chisq: 140.926 on 5 DF, p-value: < 2.22e-16
```

검정 결과 p-value 값이 큰 평균최고기온(4월) 변수 제외 후 데이터 적합

선형 회귀모형 적합 결과

선형 회귀모형 모델링

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	397.30499	19.85030	20.015	< 2e-16 ***
X4월.평균기온...	-1.73466	1.84740	-0.939	0.348
X4월.평균최고기온...	3.46738	0.77543	4.472	1.10e-05 ***
X9월.강수량.mm.	-0.12869	0.02705	-4.758	3.02e-06 ***
X7월.합계.일조시간.hr.	0.22269	0.04817	4.623	5.59e-06 ***
X11월.평균.지면온도..C.	6.63202	1.37319	4.830	2.17e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

검정 결과 p-value 값이 큰 평균기온(4월) 변수 제외 후 데이터 적합

선형 회귀모형 모델링 결과

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	390.47675	18.46672	21.145	< 2e-16	***
X4월.평균최고기온...	3.15389	0.69974	4.507	9.37e-06	***
X9월.강수량.mm.	-0.12675	0.02696	-4.701	3.92e-06	***
X7월.합계.일조시간.hr.	0.20401	0.04386	4.652	4.92e-06	***
X11월.평균.지면온도..C.	5.92320	1.14685	5.165	4.35e-07	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

평균최고기온(4월) 1°C 증가 → 생산량 3.15kg **증가**

강수량(9월) 1mm 증가 → 생산량 0.13kg **감소**

선형 회귀모형 모델링 결과

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	390.47675	18.46672	21.145	< 2e-16 ***
X4월.평균최고기온...	3.15389	0.69974	4.507	9.37e-06 ***
X9월.강수량.mm.	-0.12675	0.02696	-4.701	3.92e-06 ***
X7월.합계.일조시간.hr.	0.20401	0.04386	4.652	4.92e-06 ***
X11월.평균.지면온도..C.	5.92320	1.14685	5.165	4.35e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

일조시간(7월) 1시간 증가 → 생산량 0.204kg **증가**

평균 지면온도(11월) 1°C 증가 → 생산량 5.92kg **증가**

패널 모형 vs 선형 모형

	확률효과모형	일반선형회귀모형
AIC	2796.765	3139.569
BIC	2815.448	3158.252
결정계수	0.31627	0.2479

패널 회귀 모형이 일반 선형회귀 모형보다 잘 적합됨을 확인

연구 결과

패널 회귀모형 모델링 결과

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	412.825038	14.811968	27.8710	< 2.2e-16 ***
기온	5.789698	1.228876	4.7114	2.460e-06 ***
강수량	-0.094417	0.018485	-5.1079	3.258e-07 ***
일조시간	0.136766	0.033163	4.1241	3.723e-05 ***
지면온도	2.367318	1.208900	1.9582	0.0502 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

평균기온(4월) 1°C 증가 → 생산량 5.79kg **증가**

강수량(9월) 1mm 증가 → 생산량 0.094kg **감소**







패널 회귀모형 모델링 결과

	Estimate	Std. Error	z-value	Pr(> z)	
(Intercept)	412.825038	14.811968	27.8710	< 2.2e-16	***
기온	5.789698	1.228876	4.7114	2.460e-06	***
강수량	-0.094417	0.018485	-5.1079	3.258e-07	***
일조시간	0.136766	0.033163	4.1241	3.723e-05	***
지면온도	2.367318	1.208900	1.9582	0.0502	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

일조시간(7월) 1시간 증가 → 생산량 0.137kg **증가**

평균 지면온도(11월) 1°C 증가 → 생산량 2.37kg **증가**



예측값에 대한 증가, 감소 추세가 실제 값과 비슷하게 나타나고 있음을 확인

한계점 및 제언

한계점 및 제언

기상 관측소가 없는 일부 지역은 인접 지역의 기상 관측 자료를 사용함
+ 제안한 모형이 우수한 성능을 보여주지 못함



모든 생산지를 대상으로 더욱 세분화된 기상 관측 자료, 병충해 발생 정보, 유전자 알고리즘 등 다양한 자료를 활용하여 향상된 예측도를 기대

Q&A