

캐치! 머신핑

상수관로 누수타입 예측 모델 개발: 앙상블과 LIME의 적용

김효훈 문서영 박민규 이나원

목차

01 서론

02 데이터 소개

03 분석 결과

04 결론

서론

연구 배경

[2024 국감] 전국 상하수도 노후화 심각... 연간 7천억 손실

배소현 기자 | 승인 2024.10.08 14:49 | 댓글 0

국회 환노위 소속 국민의힘 김형동 의원, 환경부 자료 분석




<https://www.shinailbo.co.kr/news/articleView.html?idxno=1941731>

상주시, AI 분석시스템 활용해 누수 최소화해 나서, 소중한 물자원 효율적 관리

최고관리자 | 0건 | 30회

24-05-01 10:01

- 모서지역 누수감지시스템 설치사업 추진 -




<https://www.shinailbo.co.kr/news/articleView.html?idxno=1941731>

01

연구 배경

신속 정확한 누수탐지의 필요성



01

누수 지점 및 누수 원인을 파악하여

2차 문제를 방지

- 수압 저하
- 지반침하 및 싱크홀

02

오탐지 시 낭비되는 인력 및 자원 절약

선행 연구

최석윤, 김광주. (2023). 진동센서를 이용한 AI 기반 상수관로 누수 판별 기술 비교
: 상수관로 누수탐지에 딥러닝 모델을 적용하여 그 성능을 비교

사용 모델 : MLP, GRU, LSTM, **Bi-LSTM(89.8%)**
의의 및 한계 : 여러 딥러닝 모델을 비교했지만 자세한 분석 및
하이퍼파라미터 튜닝 과정이 드러나지 않았고
성능도 타 연구에 비해서 높지 않았음

김병학, 전제성, 이수안. (2022) 상수관로 진동 센서 데이터를 이용한 누수 감지
머신러닝 모델.
: 머신러닝 모델 2개와 딥러닝 모델 2개를 함께 비교

사용 모델: DNN, TabNet, **XGBoost(96.03%)**, SVM
의의 및 한계: 머신러닝 모델과 딥러닝 모델을 함께 비교함

이수현, 고상근, 이수한. (2024) 진동 센서 기반 상수관 누수 감지 및 분류 모델.
: 다섯가지 머신러닝 모델 비교 분석

사용 모델: Decision Tree, **LightGBM(F1-Score96.71%)**,
NeuralNetwork, Random Forest, ExtraTrees
의의 및 한계: Precision, Recall, F1-score를 종합적으로 고려

최준규, 임성빈. (2023). 누수 잡음 크기 스펙트럼을 이용한 SVM 기반의 상수관로
누수 감지 및 분류.
: SVM을 통한 분류 모델 구축

사용 모델: SVM(85.29%)
의의 및 한계: 데이터 불균형을 고려하여 Accuracy와 F1-score,
MCC(Matthews Correlation Coefficient) 3개의 평가지표를 모두 활용

연구 목적

선행 연구의 한계 개선

1 단일 모델을 개별적으로 사용



기존 연구에서 높은 성능을 보인
모델을 이용한 앙상블 모델 개발
(XGBoost, LightGBM, Bi-LSTM)

2 결과 해석에 대한 논의 미흡



LIME 적용
: 모델에 대한 설명을 제공 및
모델 개선에 활용

데이터 개요

02

수집 데이터 소개

AI Hub에서 제공하는 '상수관 누수 진동 데이터'

Training set: 62,564개 Validation set: 7,820개 Column: 539개

수집 방법

STEP1

상수관망 현대화사업 및 광주광역시와
고흥군의 누수 감지 센서로부터 수집

STEP2

현장 전문가의 탐사 결과를 바탕으로
진동 원인과 누수 여부를 최종 결정

칼럼 명	칼럼 설명	타입	예시
site	누수 감지 센서가 설치된 사이트 번호	string	s-4687025030
sid	누수 감지 센서 번호	string	s-0359369085120315
leaktype	누수 감지 여부를 표시	string	out
ldate	누수 이벤트를 감지한 일자	string	20200708
lrate	일일 새벽 시간 2시간 동안 총 10번의 누수 감지 여부를 체크, 일정 기준치 이상 반응한 결과를 확률로 표시	int	90
llevel	일일 새벽 시간 2시간 동안 총 10번의 누수 감지 여부를 체크. 일정 기준치 이상 반응한 크기의 평균값을 표시	int	256
0-5120HZ	해당 주파수 HZ에 감지된 누수 진동 크기	int	4680
MAX0-19	누수 감지 n회에 감지된 누수 진동 크기	int	260

Leak Type

옥외누수 (OUT)

옥내누수 (IN)

기계 및 전기음 (NOISE)

환경음 (OTHER)

정상음 (NORMAL)

데이터 전처리

01 변수 삭제

02 오버샘플링

03 결측치 처리

결측치 존재 X

04 스케일링 및 범주형 변수 처리

최종 Input 변수가 모든 주파수 Hz에 대한 값
Feature Scaling 및 One-Hot Encoding X

05 이상치 처리

Isolation Forest를 적용하여 이상 인스턴스를 제거
& Baseline 모델링 , 성능 하락 : 이상치 제거 X

02

변수 삭제

01 최종적으로 모델에 사용한 변수

Input

10Hz - 5120Hz까지
10Hz 간격의 수치 값

총 512개의 변수

Target

leaktype (누수 여부 및 유형)
out in nosie other normal

02 어떤 현장에서도 적용 가능한 모델을 목표

[site] [sid] [ldate]처럼 센서의 환경을 특징하는 변수 제거

02

변수 삭제

03 훈련 과정에서 결과에 대한 정보를 학습하여 성능이 과도하게 높아지는 것을 방지

누수 결과에 대한 정보를 가지고 있는 [lrate] [llevel] [Max0]-[Max19]를 제거

04 0Hz - 모든 인스턴스에서 값이 0으로 동일하므로 제거

오버샘플링

누수 유형별로 데이터 수가 불균형 ----- 오버샘플링

SMOTE

소수 클래스 데이터의 특징 공간에서 k-최근접 이웃 정보를 활용하여 새로운 데이터를 생성

기존 데이터를 단순히 복제하는 방식 X


데이터 간의 관계를 고려하여 새로운 샘플 생성 - 학습 데이터의 다양성 향상 및 모델의 일반화 성능을 개선

오버샘플링

SMOTE

- 각 클래스의 데이터 수를 정상 클래스에 맞추
- 누수 유형별 데이터 수 : 19704개로 균형
- 총 훈련 데이터의 수 : 98520개
(19704 X 5)

모든 클래스의 데이터가 동일한 비중으로
모델 학습에 관여



분석 결과

분석에 사용된 모델




XGBoost

트리 기반, 높은 계산 효율성과 과적합 방지



LightGBM

Leaf-wise 성장 방식으로 성능 강화



Bi-LSTM

양방향 RNN으로 시계열 데이터의 문맥 이해



앙상블

여러 개의 모델을 결합하여 단일 모델보다 더 나은 예측 성능을 달성하는 기법으로 Bagging, Boosting, Stacking이 존재

XGBoost 파라미터 튜닝 : Optuna 라이브러리 사용

최적화된 주요 파라미터

학습률	0.1
트리의 최대 깊이	6
특성 샘플링 비율	0.8
최소 손실 감소 값	0.1
트리 개수	200

XGBoost 모델 성능

Accuracy	Precision	Recall	F1 Score
0.923	0.915	0.908	0.911

XGBoost 모델은 높은 정확도(92.3%)와 우수한 F1 점수(91.1%)를 통해 안정적인 예측 성능을 보여줌

정밀도(91.5%)와 재현율(90.8%)이 균형을 이루어, 모델이 특정 누수 유형을 효과적으로 감지

이러한 성능은 데이터 기반 누수탐지 시스템 구축에 있어 적절한 신뢰도 제공

LightGBM 파라미터 튜닝: Optuna 라이브러리 사용

최적화된 주요 파라미터


학습률	0.1512
리프 노드 수	171
최대 깊이	14
특징 비율	0.8847
최소 자식 샘플 수	9

* 나머지 하이퍼파라미터는 기본값을 사용하거나 실험적으로 최적의 값을 설정

LightGBM 모델 성능 및 혼동 행렬

Accuracy	Precision	Recall	F1 Score
0.9472	0.95	0.93	0.9671

- 모델의 정확도는 94.72%로 나타나, 전체 데이터 중 상당히 높은 비율을 정확하게 분류한 것으로 평가
- 정밀도는 모든 클래스에서 평균 0.95의 높은 정밀도를 기록
- 재현율은 평균 0.93으로 측정
- 정밀도와 재현율 간의 균형을 나타내는 F1 점수는 평균 0.95로 높은 수준의 성능



Bi-LSTM 모델 성능 : Optuna 라이브러리 사용

Accuracy	Precision	Recall	F1 Score
0.9412	0.93	0.93	0.93

최적화된 파라미터

첫 번째 LSTM 유닛 : 192
두 번째 LSTM 유닛: 64
첫 번째 드롭아웃 비율: 0.4
두 번째 드롭아웃 비율: 0.4
학습률(learning_rate): 4.59e-05

학습 설정

배치 크기 : 16
에포크 수 : 20
조기 종료 (EarlyStopping) 사용

앙상블 적용 과정

사용한 모델

BI-LSTM

문맥 기반 분석

XGBoost

트리 기반 머신러닝


LightGBM

고속 GBDT 알고리즘

Soft Voting 기법

각 모델의 확률값 - 평균 - 최종 예측

개별 모델의 약점을 보완하고 예측 정확도 향상



앙상블 성능 평가

훈련 데이터

Accuracy	Precision	Recall	F1 Score
0.9956	0.9956	0.9956	0.9956


검증 데이터

Accuracy	Precision	Recall	F1 Score
0.9514	0.9519	0.9514	0.9515

LIME

LIME 개요

Local Interpretable Model-Agnostic Explanation



Local - 개별 예측
Model-Agnostic - 어떤 모델이든
Surrogate - 대리 모델, 블랙박스 모델과 독립적

개별 예측에 대한 설명 제공
(변수의 영향)

블랙박스 모델의 분석 과정에 대한
이해를 도움

LIME 작동 원리

01 변형 데이터 생성

- 국소적 (local) 영역 탐색 목적
- 원래 샘플 주변의 다양한 변형 데이터 생성

02 모델 예측값 계산 및 가중치 부여

- 변형 데이터에 대해 모델 예측값 계산
- 국소적 중요도 반영하여 가중치 데이터셋 구성

LIME 작동 원리

03 단순 선형 모델 학습

- 가중치 데이터셋 기반으로 선형 모델 학습 - 본 모델과 근사하도록
- 특징별 중요도 수치화

04 예측 결과 해석

- 모델 예측의 근거 시각화
- 개별 샘플 예측 설명

LIME - 앙상블 모델에 적용

각각의 클래스에서 하나씩 인스턴스를 임의로 선택한 뒤 LIME을 통해 설명

LIME 설명기 객체의 파라미터 설정

discretize_continuous – True : 수치형 변수의 경우 이산적으로 학습하도록

EX 10HZ 변수의 수치들을 50보다 큰지 아닌지 두 경우로 이산화

“10HZ 변수의 값이 2% 영향을 준다.” - **X**

“10HZ 변수의 값이 50보다 큰 것이 결과에 2% 영향을 준다.” - **O**

LIME - 앙상블 모델에 적용

LIME 설명기 객체의 파라미터 설정

sample_around_instance - True : 변형 데이터 샘플을 생성 시 인스턴스 근처에서만 생성

지역적으로 더 충실한 설명을 생성

선형 모델


설명변수

기본 값인 릿지 회귀 모델 (alpha 값은 1.0) 10개

03


옥내누수 IN에 대한 LIME 설명

Prediction probabilities



NOT in

in



Feature Value

340HZ	467.00
370HZ	78.00
60HZ	2.00
350HZ	601.00
320HZ	90.00
360HZ	170.00
330HZ	146.00
1860HZ	2.00
400HZ	24.00
620HZ	2.00

옥내 누수로 분류된 인스턴스 중 하나
“340HZ” 값이 467로 72보다 큼 - 3% 영향
“370HZ” 값이 78로 73보다 큼 - 2% 영향
전체적으로 350Hz 전후의 값이 큰 점이 주요하게 작용

03

옥외누수 OUT에 대한 LIME 설명

Predicted probabilities: [[0.43673357 0.00980042 0.00743757 0.02745205 0.51857643]]

Prediction probabilities

in	0.44
noise	0.01
normal	0.01
other	0.03
out	0.52

NOT out

out

120HZ ≤ 5.00
0.05
400HZ > 66.00
0.03
420HZ > 53.00
0.02
23.00 < 380HZ ≤ ...
0.02
240HZ ≤ 14.00
0.02
230HZ ≤ 12.00
0.01
6.00 < 560HZ ≤ ...
0.01
21.00 < 290HZ ≤ ...
0.01
440HZ > 36.00
0.01
2610HZ > 6.00
0.01

Feature Value

120HZ	5.00
400HZ	72.00
420HZ	234.00
380HZ	49.00
240HZ	5.00
230HZ	7.00
560HZ	13.00
290HZ	29.00
440HZ	228.00
2610HZ	7.00

옥외 누수로 분류된 인스턴스 중 하나


“120HZ” 값이 5로 5보다 같거나 작음 - 5% 영향

“400HZ” 값이 72로 66보다 큼 - 3% 영향

전체적으로 200대의 Hz 값이 작고, 400대의 Hz에서 값이 큰 점이 주요하게 작용

03

정상음 Normal에 대한 LIME 설명



정상으로 분류된 인스턴스 중 하나

“370HZ” 값이 5로 9보다 작음 - 3% 영향

“380HZ” 값이 6로 8보다 작음 - 2% 영향

전체적으로 모든 Hz의 값이 다른 클래스에 비해 작은 점이 주요하게 작용

정상음의 경우 누수나 잡음의 영향이 없기 때문으로 유추

03

환경음 other에 대한 LIME 설명



환경음으로 분류된 인스턴스 중 하나

“120HZ” 값이 24로 18보다 큼 - 2% 영향


“4310HZ” 값이 15로 6보다 큼 - 1% 영향

전체적으로 모든 Hz의 값이 다른 클래스에 비해 큰 점이 주요하게 작용

환경음의 경우 외부 잡음의 영향이 큼

03

기계,전기음 noise에 대한 LIME 설명



기계,전기음로 분류된 인스턴스 중 하나
“280HZ” 값이 365로 97보다 큼 - 3% 영향
“290HZ” 값이 255로 80보다 큼 - 2% 영향
전체적으로 200 후반 Hz의 값이 큰 점이 주요하게 작용

결론

연구 결과 종합 및 한계점

결과

01

앙상블 모델 적용을 통해
개별 모델의 한계를 극복 & 예측 정확도 UP

02

LIME을 통해 누수탐지에 영향을 미치는 주요 특징들을 시각적으로 확인

한계점

01

제한된 데이터 사용으로 실제 현장의 상황을 정확히 반영 X

02

LIME은 모델의 국소적 해석만 제공해 전체적인 모델 동작에 대한 완벽 이해 불가

감사합니다