

DAT 4기 캡스톤 프로젝트

코드스위칭 발화를 위한 기계 번역 모델 개선 연구

Enhanced Machine Translation Models
for Code-Switched Speech Data

파인마이닝
김세린 김예경
이지원 조재표

Table of Contents

- 코드스위칭
- 연구 배경 및 목적
- 제안 프레임워크
- 음성인식 모델
- 번역 모델
- 시스템 구현
- 결론

Code-Switching ?

“어제 영화 봤는데, it was really good, 근데 마지막 장면은 좀 별로였어.
그래도 You should still watch it, 재미는 있어.”

한 발화나 담화 내에서 둘 이상의 언어 또는 방언이 의사소통 상에서 섞여 사용되는 언어 행위

- 글로벌 사회에서 다양한 언어를 혼합한 코드스위칭 발화가 점점 더 보편화
- 일상 대화뿐만 아니라 비즈니스 환경, 교육 현장, 미디어 등 다양한 분야에서 발생

연구 배경 및 목적



다중언어 커뮤니케이션을 위한
필수적인 기반 기술

현존하는 음성 인식 및 번역 시스템의 한계

- 주로 단일 언어 환경에 최적화되어 언어 전환 인식이 어려움
- 서로 다른 문법 구조 & 발음 체계로 인해 정확도가 저하됨


연구 배경 및 목적

“

한국어와 영어가 혼합된 코드스위칭 발화를
효과적으로 인식하고 자연스럽게 번역하는
음성인식 및 번역 시스템 구현

”

제안 프레임워크



입력

모델에 코드스위칭된
발화가 입력

음성인식

Whisper 모델을 통해
입력 음성으로부터
텍스트 전사

번역

Marian MT 모델을 통해
전사된 텍스트가
문법적으로 올바른
영어로 번역


출력

번역된 영어 텍스트 출력

음성인식 모델

Whisper 모델

대규모 사전 학습 데이터셋을 활용하여 멀티랭귀지 환경에서도 음성 데이터를 효과적으로 처리할 수 있도록 설계됨



encoder-decoder Transformer 기반 모델

- 입력 처리: 16kHz로 다시 샘플링된 음성을 80채널 log Mel spectrogram으로 변환(25ms 윈도우, 10ms stride 2)한 후, -1~1로 정규화
- 인코더 구조: 두 개의 convolution layer(GELU 활성화, stride 2)로 입력 데이터를 압축하고, sinusoidal position embedding 추가해 Transformer 블록으로 처리
- 디코더 구조: 학습된 position embedding과 Transformer 블록으로 음성을 텍스트로 변환

음성인식 모델

초기 시도

1. 임베딩 유사도 기반 언어 전환 탐지

다국어 언어 모델을 사용해 한국어와 영어 텍스트를 워드 임베딩으로 변환하고, 코사인 유사도를 계산하여 언어 전환 구간을 탐지

--> 한국어와 영어 임베딩이 서로 독립된 공간에서 학습되었기 때문에 유사도 계산이 부정확하여 언어 전환 탐지 성능이 제한적이었음

2. 형태소 분석을 통한 접근

한국어와 영어의 형태소 분석기를 사용하여 음성 데이터를 분석하고, 언어 전환 구간을 탐지

--> 형태소 단위로 분리된 데이터를 올바르게 재조합하지 못해 태깅된 시퀀스를 병합하는 데 실패함

음성인식 모델

한-영 혼합 음성 데이터셋을 활용한 파인튜닝

한국어-영어 코드스위칭 음성에 특화된 인식 성능을
확보하고자 Whisper 모델 파인튜닝을 진행


데이터셋

AI Hub 제공 한국어-영어 혼합 음성 데이터
(250시간)

음성인식 모델

LoRA (Low-Rank Adaptation)

Whisper의 방대한 파라미터 수로 인해 고사양의 GPU 메모리가 요구되었으며, 학습 시간이 길어. 이러한 한계를 해결하기 위해 LoRA 기법을 적용하여 자원 효율성을 높임.



Reparameterization 과정

- 가중치 업데이트 표현

사전 학습된 가중치 W_0 에 대한 업데이트 ΔW 를 저차원 행렬의 곱 BA 로 근사 $W = W_0 + \Delta W = W_0 + B \times A$

- 학습 단계

학습 중에는 W_0 를 Freeze하고, 저차원 행렬 B 와 A 만 업데이트, 결과적으로 $\Delta W = B \times A$ 를 통해 효율적으로 가중치 변화 학습

- 추론 단계

학습 완료 후 $W = W_0 + B \times A$ 를 계산하여 사용


번역 모델

Marian MT 모델 (opus-mt-ko-en)

Opus-MT-ko-en은 Helsinki-NLP에서 개발한 오픈소스 뉴럴 기계 번역 (NMT) 모델로, Marian MT 프레임워크를 기반으로 구축되어, 효율적이고 고 품질의 번역 성능을 제공

주요 특징

- 사전 학습된 번역 모델: 대규모 번역 데이터셋인 OPUS 코퍼스로 학습
- 언어 지정: 입력에 언어 토큰 추가(e.g. <en>, <ko>)로 번역 방향 제어
- Transformer 기반 아키텍처: 고성능 Attention 메커니즘으로 문맥과 단어의 관계를 효과적으로 학습



Marian MT는 트랜스포머 구조와 동일

번역 모델

한국어 구 분리를 통한 선택적 번역

- Marian MT는 단일 언어쌍 기반 모델로, 코드스위칭 데이터를 처리하는 데 한계가 존재
- 정규표현식을 사용하여 한국어 구를 분리 번역 후 원래 텍스트의 위치를 유지한 채 삽입

1) Input : 오늘 아침에는 정말 바빴어. I had to finish some 보고서 for my class

2) 정규표현식을 통한 분리 : [오늘 아침에는 정말 바빴어., I had to finish some, **보고서**, for my class]

3) 번역 : [**I was really busy this morning.**, I had to finish some, **Report**, for my class]

4) Output : I was really busy this morning. I had to finish some Report for my class

시스템 구현

시연 영상

결론

결과 종합 및 시사점

- Whipser 모델과 MarianMT 모델을 활용한 통합 시스템 설계 및 구현
- 단일 언어의 음성 인식 및 번역 시스템과 차별화
- 텍스트 기반의 기존 코드스위칭 연구에서 음성 데이터 처리 가능성 확장
- 글로벌 사회의 다양한 다중언어 환경에서 발생하는 복잡한 문제 해결 가능성

결론

한계점

- 코드스위칭 발화 특성 상 기존 성능 평가 적용이 불가능
- 코드스위칭 발화 데이터 부족으로 다양한 언어 전환 패턴 반영이 어려움

향후 연구 계획

- 다양한 언어 조합 및 복잡한 전환 패턴을 포함한 대규모 데이터셋 구축
- 빈번한 언어 전환에도 정확도 높은 음성 인식 기술 개발
- 발화 맥락 및 문화적 특성을 반영한 자연스러운 번역 기술 개발
- 다국적 회의, 글로벌 고객 서비스, 국제 행사 등에 실제로 활용 가능한 시스템 구축

Q & A