

DAT 4 기 캡스톤 프로젝트 보고서

상수관로 누수탐입 예측 모델 개발

: 앙상블과 LIME 의 적용

DAT 4 기

머신러닝 A 캐치!머신평

김효훈

문서영

박민규

이나원



Data Analysis & Technology



DAT 4 기 캡스톤 프로젝트 보고서

상수관로 누수타입 예측 모델 개발

: 앙상블과 LIME 의 적용

Development of a Leakage Type Prediction Model for Water Pipelines:
Application of Ensemble Methods and LIME

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2024 년 12 월 3 일

DAT 4 기

머신러닝 A 캐치!머신평

김효훈, 문서영, 박민규, 이나원



Data Analysis & Technology



DAT 4 기 캡스톤 프로젝트 보고서

상수관로 누수탐지 예측 모델 개발

: 앙상블과 LIME 의 적용

국문 요약

본 연구는 상수관로 누수탐지를 위해 머신러닝 및 딥러닝 모델의 통합적 접근법을 제시한다. 인공지능 기반 이상 탐지 기술을 활용하여 물 손실 관리의 효율성을 높이하고자 하였다. AI hub 데이터셋을 바탕으로 XGBoost, LightGBM, Bi-LSTM 등 다양한 모델을 분석하고, 앙상블 기법을 적용하여 누수탐지 성능을 개선하였다. 연구의 주요 성과로는 첫째, 개별 모델 분석을 통해 LightGBM의 우수한 성능을 확인하였고, 둘째, 앙상블 모델을 통해 예측 정확도를 향상시켰다. 셋째, LIME 기법을 활용하여 모델의 의사결정 과정에 대한 해석 가능성을 제공하였다. 연구는 제한된 데이터셋, 모델링 과정의 제약, LIME 방법론의 한계 등을 인정하며, 향후 연구 방향으로 더욱 포괄적인 데이터셋 확보, 고급 머신러닝 기법 탐색, 정교한 XAI 방법론 적용, 실제 현장 검증 등을 제안한다.

Abstract

This study proposes an integrated approach to water pipeline leak detection using machine learning and deep learning models. Leveraging artificial intelligence-based anomaly detection techniques, the research aims to enhance water loss management efficiency. Utilizing the AI hub dataset, we analyzed various models including XGBoost, LightGBM, and Bi-LSTM, and applied ensemble methods to improve leak detection performance. Key research achievements include individual model analysis revealing LightGBM's superior performance, improving predictive accuracy through ensemble modeling, and providing model interpretability using the LIME technique. The models demonstrated significant potential in identifying water pipeline leaks with high precision and efficiency. While acknowledging limitations such as restricted dataset, modeling constraints, and LIME methodology boundaries, the study suggests future research directions including acquiring more comprehensive datasets, exploring advanced machine learning techniques, applying sophisticated explainable AI methodologies, and conducting real-world field validations. The research contributes to the field by presenting a novel approach to water pipeline leak detection, offering both high-performance predictive models and insights into their decision-making processes.

DAT 4 기

머신러닝 A 캐치!머신평

김효훈, 문서영, 박민규, 이나원



Data Analysis & Technology



목 차

제 1 장 서론	3
제 1 절 연구 배경	3
제 2 절 선행연구 분석	3
제 3 절 연구 목적 및 논문 구성	4
제 2 장 데이터 소개	5
제 1 절 데이터 개요	5
제 2 절 데이터 전처리	6
제 3 장 분석 결과	8
제 1 절 분석 모델	8
제 2 절 앙상블 기법	13
제 3 절 LIME	15
제 4 장 결론	18
제 1 절 연구 결과 종합 및 시사점 도출	18
제 2 절 한계점 및 향후 연구 방향성 제언	19
참고문헌	20



표 목차

[표 1]	6
[표 2]	9
[표 3]	9
[표 4]	10
[표 5]	11
[표 6]	13
[표 7]	13
[표 8]	15
[표 9]	15

그림 목차

[그림 1]	7
[그림 2]	8
[그림 3]	11
[그림 4]	12
[그림 5]	16
[그림 6]	16
[그림 7]	17
[그림 8]	17
[그림 9]	17
[그림 10]	18



제 1 장 서론

제 1 절 연구 배경

인공지능을 통한 이상 탐지(Anomaly Detection)는 효율적으로 문제를 해결할 수 있는 방안으로 자원의 경제적인 활용을 위해 활발히 연구되고 있다. 상수관로 누수탐지 또한 센서를 통해 수집된 데이터를 분석하여 누수를 탐지하고, 유형을 분류한다는 점에서 이상 탐지의 일종으로 볼 수 있다. 정확하고 신속한 누수탐지는 빠르게 누수 지점 및 누수 원인을 파악하여 2 차 문제를 방지하는데 필수적이다. 상수관로에 누수가 발생하면 수압이 저하되고, 경우에 따라 지반 침하 및 싱크홀 발생으로 이어지기 때문에 빠르게 누수를 탐지하지 못하면 큰 피해로 이어질 수도 있다. 누수를 미리 예측하는 것 또한 어렵기 때문에 누수 발생을 빠르게 감지하는 것이 그만큼 더 중요하다. 그리고 누수 및 누수 유형 오탐지 시에는 인력 및 자원이 낭비될 수 있다. 현재 주로 사용되는 청음식 누수탐지는 센서를 통해 들어오는 소리의 주파수를 통해 누수를 찾아내는 방식으로, 누수가 탐지되어도 직접 현장을 방문하여 누수 여부를 확인해야 한다. 청음식 누수탐지의 경우 소리만을 가지고 판단하기 때문에 감지 센서가 설치된 위치에 따라 외부 잡음이나 소음의 영향을 많이 받게 된다. 따라서 누수를 오탐지하는 상황도 자주 발생하게 되는데, 이로 인해 불필요한 인력 및 자원이 투입된다. 하지만 정확한 누수탐지가 가능하다면 자원이 낭비되는 것을 막을 수 있다.

제 2 절 선행 연구 분석

기후 변화 및 계절성으로 인해 대한민국에서 물 손실 관리(water loss management)는 상수도 경영에서 중요한 문제이다. 상수관로 누수탐지는 이러한 물 손실 관리에 기여하는 부분으로 다각적으로 연구되고 있다. 본 연구에서 사용한 데이터와 동일한, AI hub 에서 제공되는 상수관로 누수감지 데이터를 활용한 여러 연구들이 있었고 연구자들은 다양한 접근법을 제시했다. 최석윤은 상수관로 누수탐지에 딥러닝 모델을 적용하여 그 성능을 비교했다.(최석윤 2023). 딥러닝 모델인 MLP, GRU, LSTM, Bi-LSTM 네 가지를 사용하였고, Bi-LSTM 이 89.8%로 가장 높은 정확도를 나타냈다. 여러 딥러닝 모델을 비교했지만 자세한 분석 및 하이퍼파라미터 튜닝 과정이 드러나지 않았고, 성능도 타 연구에 비해서 높지 않았다. 이수현은 다섯가지 머신러닝 모델을 비교 분석하였다(이수현 2024). Decision Tree, LightGBM, Neural Network, Random Forest, Extra Trees 모델을 사용하였고, LightGBM 의 성능이 F1-score 96.71%로 압도적으로 좋았다. Precision, Recall, F1-score 를 종합적으로 고려하였다는 점에서 의의가 있다. 김병학은 머신러닝 모델



2 개와 딥러닝 모델 2 개를 함께 비교하였다.(김병학 2022) DNN(Deep Neural Network)과 TabNet, 그리고 XGBoost 와 SVM(Support Vector Machine) 모델을 사용하여 분석을 진행하였고, XGBoost 가 Accuracy 96.03%로 가장 좋은 성능을 보였다. 머신러닝 모델과 딥러닝 모델을 함께 비교했다는 점에서 의의를 가진다. 최준규는 SVM 을 통해 분류 모델을 구축하였고 85.29%의 Accuracy 를 기록했다.(최준규 2023) 데이터 불균형을 고려하여 Accuracy 와 F1-score, MCC(Matthews Correlation Coefficient) 3 개의 평가지표를 모두 활용하였다. 앞선 네 연구 모두 단일 모델을 개별적으로 사용하였고, 모델 성능 비교 및 향상에 초점을 맞추어 결과 해석에 대한 논의는 다소 미흡하였다.

제 3 절 연구 목적 및 논문 구성

본 연구는 선행 연구의 한계점을 고려하여, 여러 머신러닝 및 딥러닝 모델을 함께 고려하는 앙상블 모델을 제안한다. 또한 XAI(eXplainable AI) 방법론 중 하나인 LIME 을 통해 모델에 대한 해석을 제공하여, 실무자들에게 설명을 제공하고 추후 모델 개선에 활용하게끔 한다. 기존의 연구들은 모두 단일 머신러닝 모델, 혹은 딥러닝 모델을 구성하고 이를 비교하였다. 다수의 모델을 함께 활용하여 과적합을 방지하고 성능을 높이려는 시도는 이루어지지 않았다. 그리고 클래스 간의 불균형 문제를 고려해 F1-score 와 MCC 를 평가 지표를 사용하기는 하였지만, 오버샘플링이나 언더샘플링을 적용하여 직접 클래스의 균형을 맞추어 모델을 구성하지는 않았다. 또한 성능 평가에 초점을 두고 변수의 영향력 등 결과를 해석하려는 논의가 부족하였다. 따라서 본 연구에서는 앙상블 기법을 적용해 여러 모델을 상호 보완하여 성능을 향상시켰고, LIME 방법론을 적용해 모델의 분류 과정에 대한 해석을 제공한다. 그리고 오버샘플링을 통해 클래스간 불균형을 해결하였다.

본 연구의 구성은 다음과 같다. 2 장에서는 분석에 사용된 데이터를 소개한다. 데이터의 출처와 실제 수집 과정을 소개하며, 변수 선택, 결측치 처리, 이상치 처리, 오버샘플링과 같은 전처리 과정을 설명한다. 3 장에서는 분석 결과를 제시한다. 누수탐지에 활용된 머신러닝 모델인 XGBoost 과 LightGBM, 딥러닝 모델인 Bi-LSTM 을 설명하고, 각 성능을 비교한다. 이어서 개별 모델을 복합적으로 고려하는 앙상블(Ensemble)의 개념을 소개하고, 앙상블 적용 후 성능의 변화를 관찰한다. 마지막으로 설명가능한 AI(XAI) 방법론 중 하나인 LIME 의 개념을 설명하고, LIME 을 통해 상수관로 누수탐지 과정에 대한 설명을 제공한다. 4 장에서는 연구결과를 종합하고 시사점을 도출한다. 추가적으로 본 연구의 한계점에 대해 논의하고, 추후 연구 방향성을 제시한다. 이러한 구성으로 본 연구는 상수관로 누수탐지의



정확도를 높이고, 탐지 결과에 대한 해석을 덧붙여 설명 가능한 모델을 개발할 것이다. 이를 통해 누수탐지 과정에 대한 실무자 및 개발자들의 이해를 높이고자 한다.

제 2 장 데이터 개요

제 1 절 수집 데이터 소개

이번 프로젝트에서 활용한 데이터는 AI Hub 에서 제공하는 ‘상수관 누수 진동 데이터’로, 상수관로의 누수 여부를 감지하고 이를 분석하기 위한 학습 데이터셋이다. 이 데이터는 총 5 개의 클래스(옥외누수, 옥내누수, 기계·전기음, 환경음, 정상음)로 구성되어 있으며, CSV 파일 형식으로 제공된다. 본 데이터셋은 상수관망 현대화사업 및 광주광역시(누수 감지 센서 7,600 대) 와 고흥군(누수 감지 센서 3,400 대)의 누수 감지 센서로부터 수집되었다. 총 11,000 대의 누수 감지 센서를 통해 누수 진동 데이터를 수집하였다. 누수 감지 센서를 통해 수집된 진동 데이터를 바탕으로 현장 누수 탐사 결과를 반영하여 정제 및 라벨링 작업을 수행한 결과물이다. 각 데이터에는 다음의 라벨링 정보가 포함된다.

- 누수 감지 센서 번호, 설치 위치, 설치 주소, 누수 감지 일자, 누수 적출일자 누수 확률, 누수 강도, 누수 진동 주파수(0 ~ 5000Hz)

데이터 수집 과정에서 누수 확률이 90% 이상으로 5 일 이상 반복된 진동 데이터를 우선적으로 취득하였으며, 현장 전문가의 탐사 결과를 바탕으로 진동 원인과 누수 여부를 최종적으로 구분하였다. 학습 데이터는 총 62,564 개의 Training 데이터셋과 7,820 개의 Validation 데이터셋으로 구성되어 있으며, 539 개의 칼럼을 포함하고 있다. Training 데이터셋은 모델이 누수 여부를 예측하기 위한 패턴을 학습하는 데 활용되며, Validation 데이터셋은 학습된 모델의 성능을 검증하고 과적합을 방지하는 데 사용된다.

칼럼명	칼럼 설명	타입	예시
site	누수 감지 센서가 설치된 사이트 해당번호 (식별번호 1)	string	S-46870 25030
sid	누수 감지 센서 번호 (식별번호 2)	string	S-0359369 085120315
ldate	누수 이벤트를 감지한 일자 (식별번호 3)	string	20200708
lrate	일일 새벽 시간대 2 시간동안 총 10 번의	int	90

	누수 감지 여부를 체크하고 일정 기준치이상 반응한 결과를 확률로 표시 (누수감지센서 자동 생성)		
llevel	일일 새벽 시간대 2 시간동안 총 10 번의 누수 감지 여부를 체크하고 일정 기준치이상 반응한 크기의 평균값을 표시 (누수감지센서 자동 생성)	int	256
leaktype	누수 감지 여부를 표시 (옥외누수(out), 옥내누수(in), 기계.전기음(noise), 환경음(other), 정상음(normal))	string	out
0 Hz	주파수 0 Hz 에 감지된 누수 진동 크기	int	0
10 Hz	주파수 10 Hz 에 감지된 누수 진동 크기	int	18
20 Hz	주파수 20 Hz 에 감지된 누수 진동 크기	int	19
30 Hz	주파수 30 Hz 에 감지된 누수 진동 크기	int	16
...	주파수 Hz 별로 감지된 누수 진동 크기	int	...
5,100 Hz	주파수 5,100 Hz 에 감지된 누수 진동 크기	int	18
5,110 Hz	주파수 5,110 Hz 에 감지된 누수 진동 크기	int	22
5,120 Hz	주파수 5,120 Hz 에 감지된 누수 진동 크기	int	20
MAX	누수 감지 1 회에 감지된 최대 주파수 Hz	int	4680
MAX1	누수 감지 1 회에 감지된 최대 누수 크기	int	290
...	누수 감지 횟수에 감지된 최대 주파수 Hz 및 최대 누수 크기	int	...
MAX18	누수 감지 10 회에 감지된 최대 주파수 Hz	int	4710
MAX19	누수 감지 10 회에 감지된 최대 누수 크기	int	260

[표 1] 전처리 이전의 원본 데이터셋

제 2 절 데이터 전처리

데이터 전처리는 최종적으로 변수 삭제, 오버샘플링을 하였다. 결측치는 존재하지 않았고, 최종적으로 모델에 투입된 변수들이 모두 주파수 Hz 에 대한 값이었기 때문에 스케일링(Feature Scaling) 및 원핫 인코딩(One-Hot Encoding) 등은 사용하지 않았다. 이상치의 경우 개별 이상 값(Value)을 평균이나 중앙값으로 대체하기에는 주변 Hz 에서의 값과 연관성이 고려되지 않기 때문에 이상 인스턴스(Instance) 제거를 시도하였다.


iForest(Isolation Forest)를 적용하여 이상 인스턴스를 제외시킨 뒤 베이스라인(Baseline) 모델링을 진행하였으나 성능이 더 떨어짐을 확인하였다. 따라서 이상치는 처리하지 않고 그대로 진행하였다.

2.2.1 변수 삭제

최종적으로 모델에 사용한 변수는 “10HZ”에서 “5120HZ”까지의 값으로, 10Hz 간격으로 수집된 총 512 개의 변수를 사용했다. 어떤 실제 현장에서도 적용가능한 모델을 목표로 하였기 때문에, "site", "sid", "ldate"처럼 센서의 환경을 특정하는 변수는 제거해주었다. 또한 누수 결과에 대한 정보를 가지고 있는 "lrate", "llevel", “MAX0”~“MAX19”를 제거하였다. 모델의 훈련 과정에 결과에 대한 정보가 포함되어 성능이 과도하게 높아지는 것을 방지하기 위함이다. 또한 “0HZ”의 경우 모든 인스턴스에서 값이 0 으로 동일했기 때문에 제거해주었다.

2.2.2 오버샘플링(SMOTE)

누수 유형별로 데이터 수가 불균형하기 때문에 오버샘플링을 활용하여 문제를 해결하였다. 훈련 데이터셋에서 누수 타입에 따른 분포는 다음과 같다.



[그림 1] 누수유형에 따른 데이터 수

이와 같이 누수 유형에 따라 데이터의 수가 불균형하기 때문에 데이터 수를 임의적으로 균등하게 만들어 주어야 하는데, 언더샘플링의 경우 학습 데이터의 수가 줄어들기 때문에 성능이 하락하기 쉽다. 따라서 오버샘플링을 통해 데이터 수를 늘려서 문제를 해결하였다. 오버샘플링 기법 중 SMOTE(Synthetic Minority Oversampling Technique) 기법을 사용하여 각 클래스의 데이터 수를 가장 데이터 수가 많은 클래스의 값으로 맞춰주었다.


SMOTE는 기존 데이터를 단순히 복제하는 방식과는 달리, 소수 클래스 데이터의 특징 공간에서 k-최근접 이웃 정보를 활용하여 새로운 데이터를 생성한다. 이 방법은 데이터 간의 관계를 고려하여 새로운 샘플을 만들어내기 때문에, 학습 데이터의 다양성을 향상시키고 모델의 일반화 성능을 개선하는 데 도움이 된다. SMOTE 기법을 적용한 결과, 각 누수 유형별 데이터 수가 모두 19704 개로 균형을 이루었고 최종적으로 훈련 데이터의 수는 98520 개가 되었다. 이를 통해 모든 클래스의 데이터가 동일한 비중으로 모델 학습에 참여할 수 있는 환경이 조성되었다.

제 3 장 분석 결과

제 1 절 예측에 사용한 알고리즘

3.1.1 XGBoost

XGBoost는 머신러닝 알고리즘 중 하나로 Gradient Boosting 알고리즘을 기반으로 성능과 효율성을 극대화하기 위해 개발되었다. XGBoost의 알고리즘은 트리 기반 모델을 활용해 데이터를 반복적으로 학습하며 예측 성능을 점진적으로 향상시키는 방식을 사용한다. XGBoost는 높은 계산 효율성을 가지고 있으며, 분산 및 병렬 처리가 가능하여 대용량의 데이터에서도 빠른 학습이 가능하다는 장점이 있다. 또한 과적합 방지를 위한 L1 및 L2 정규화를 지원하고, 학습 과정에서 조기 종료(early stopping)를 통해 불필요한 학습을 줄인다. 단점으로는 비교적 복잡한 모델 구조로 인해 하이퍼파라미터튜닝에 시간이 소요된다는 점이 있다. XGBoost는 다양한 손실 함수와 학습률을 선택할 수 있으며, 기본적으로 Gradient Descent 알고리즘을 활용해 모델을 최적화한다.



[그림 2] XGBoost 모델 작동 원리

XGBoost 모델 성능의 최적화를 위해 하이퍼파라미터 튜닝 과정을 진행하였다. 튜닝 과정에서는 Optuna 라이브러리를 활용하여 주요 하이퍼파라미터를 탐색하였다. 조정된 파라미터는 학습률(learning_rate), 트리의 최대 깊이(max_depth), 특성 샘플링 비율(colsample_bytree), 최소 손실 감소값(gamma), 트리 개수(n_estimators)가 있다. 각 파라미터의 탐색 범위는 학습률 0.01~0.3, 트리의 최대 깊이 3~10, 특성 샘플링 비율 0.5~1.0, 최소 손실 감소값 0~0.5, 트리 개수 100~500 으로 지정하여 하이퍼파라미터 튜닝을 진행하였다. 튜닝을 통해 최적화된 파라미터는 다음과 같다.

학습률(learning_rate)	0.1
트리의 최대 깊이(max_depth)	6
특성 샘플링 비율(colsample_bytree)	0.8
최소 손실 감소값(gamma)	0.1
트리 개수(n_estimators)	200

[표 2] 최적화된 하이퍼파라미터

튜닝 후에는 학습된 모델을 평가하기 위해 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 점수(F1-score)를 사용하여 성능을 측정하였다. 해당 평가지표들을 통해 모델의 전반적인 성능을 종합적으로 판단할 수 있다. 최적화된 파라미터를 바탕으로 학습한 결과 모델의 성능은 다음과 같다.

Accuracy	Precision	Recall	F1 score
0.923	0.915	0.908	0.911

[표 3] 최적의 파라미터를 사용하여 학습한 모델의 성능

3.1.2 LightGBM

LightGBM(Light Gradient Boosting Machine)은 그래디언트 부스팅 결정 트리(Gradient Boosting Decision Tree) 기반의 기계학습 알고리즘으로, 기존 GBDT 모델들의 계산 효율성과 메모리 사용 문제를 개선한 알고리즘이다. 이 알고리즘은 대규모 데이터셋에서도 빠르고 높은 성능을 보장하며, 전통적인 결정 트리 기반 알고리즘들이 겪었던 속도와 메모리 문제를 해결하여 대용량 데이터 처리에 탁월한 성능을 보인다.

LightGBM의 주요 특징 중 하나는 Leaf-wise 트리 성장 방식이다. 기존 트리 알고리즘들이 수평적(Level-wise)으로 트리를 성장시키는 것과 달리, LightGBM은

수직적(Leaf-wise) 방식으로 트리를 성장시킨다. 가장 큰 손실 값(Loss)을 가진 리프 노드를 지속적으로 분할하는 방식으로 모델의 성능을 더욱 빠르게 향상시키며, 과적합(Overfitting)을 방지하는 데 효과적이다. 또한 히스토그램 기반 알고리즘을 통해 연속형 데이터를 이산형 구간으로 분할한 뒤, 히스토그램 단위로 분할 지점을 탐색한다. 이를 통해 계산 복잡도가 크게 감소하며, 메모리 사용량이 줄어들고 훈련 속도가 획기적으로 향상된다.

고차원 희소 데이터 처리에서도 LightGBM 은 강력한 성능을 발휘한다. 특징 번들링(Feature Bundling) 기법을 사용하여 상호 배타적이거나 상관관계가 낮은 특징들을 하나의 번들로 묶어 데이터의 차원을 줄이면서도 정보 손실을 최소화한다. 특히, 배타적 특징 번들링(Exclusive Feature Bundling) 기법은 동시에 0 이 아닌 값을 가지지 않는 특징들을 병합하여 메모리 사용량을 줄이고 데이터의 정보 손실을 방지한다. LightGBM 은 이러한 설계를 통해 대규모 데이터셋에서 높은 학습 효율성과 예측 정확도를 제공하며, 누수 탐지와 같은 복잡한 분류 문제에서 우수한 성능을 보인다.

본 연구에서는 Optuna 를 사용하여 LightGBM 모델의 하이퍼파라미터를 최적화하였다. 최적화 과정에서 모델 성능에 중요한 영향을 미친 주요 파라미터는 다음과 같다:

학습률(learning_rate)	0.1512
리프 노드 수(num_leaves)	171
최대 깊이(max_depth)	14
특징 비율(feature_fraction)	0.8847
최소 자식 샘플 수(min_child_samples)	9

[표 4] 최적화된 하이퍼파라미터

나머지 하이퍼파라미터는 기본값을 사용하거나 실험적으로 최적의 값을 설정하였으며, 최적의 조합은 모델의 로그 손실(log loss)을 최소화하였다.


본 연구에서는 LightGBM 모델의 성능을 평가하기 위해 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 점수와 같은 대표적인 분류 성능 지표를 활용하였다. 모델의 정확도는 94.72%로 나타나, 전체 데이터 중 상당히 높은 비율을 정확하게 분류한 것으로 평가되었다. 정밀도는 모델이 특정 클래스를 예측할 때, 해당 예측이 실제로 올바른 경우의 비율을 나타내며, 모든 클래스에서 평균 0.95 의 높은 정밀도를 기록하였다. 또한,

재현율은 실제 특정 클래스에 속하는 샘플 중에서 모델이 이를 올바르게 분류한 비율로, 평균 0.93 으로 측정되었다. 마지막으로, 정밀도와 재현율 간의 균형을 나타내는 F1 점수는 평균 0.95 로 높은 수준의 성능을 보였다.

Accuracy	Recall	Recall	F1 score
0.9472	0.93	0.95	0.9671

[표 5] 최적의 파라미터를 사용하여 학습한 모델의 성능

혼동 행렬을 통해 분석한 결과, Class 1('noise')와 Class 0('in') 사이에서 혼동이 다소 발생하였으며, 이는 두 클래스의 데이터 분포가 유사하거나 경계가 불분명할 가능성을 시사한다. 또한, Class 3('other')의 일부 샘플이 Class 4('normal')로 잘못 분류되었으며, 이러한 오분류는 클래스 간 경계가 모호하거나 학습 데이터에 포함된 잠재적인 노이즈에 의해 발생했을 가능성이 높다. 이러한 분석을 통해 모델의 강점과 한계를 파악할 수 있었으며, 추가적인 데이터 보완 또는 모델 개선을 통해 성능을 더욱 향상시킬 수 있는 여지가 있음을 확인하였다.




[그림 3] 혼동 행렬

3.1.3 BI-LSTM

BI-LSTM(Bidirectional Long Short-Term Memory)은 시계열 데이터나 순차적인 데이터를 처리하는 데 효과적인 순환 신경망(RNN) 모델이다. 기존 LSTM 이 데이터를 한 방향(과거에서 미래)으로만 처리하는 반면, Bi-LSTM 은 데이터를 양방향(과거-미래, 미래-과거)으로 처리하여 더 많은 정보를 활용할 수 있다. 이를 통해 데이터의 미래 정보까지 고려할 수 있어, 문맥을 더 정확히 이해하고 예측 성능을 향상시킨다.

BI-LSTM 은 LSTM 의 장기 의존성 학습 능력을 활용하면서, 입력 게이트, 망각 게이트, 출력 게이트를 통해 중요한 정보를 장기적으로 기억하고, 불필요한 정보는 잊어버린다. 양방향 처리 덕분에 과거뿐만 아니라 미래의 정보도 예측에 반영되어, 자연어 처리(NLP), 주식 예측, 음성 인식 등 다양한 분야에서 활용된다. 하지만 BI-LSTM 은 연산 비용이 높고, 과적합 위험이 있을 수 있다. 이를 해결하기 위해 드롭아웃이나 조기 종료와 같은 정규화 기법을 사용해야 한다.



[그림 4] BI-LSTM 모델 작동 원리

본 연구에서는 Bi-LSTM 모델 성능의 최적화를 위해 하이퍼파라미터 튜닝 과정을 진행하였다. 튜닝 과정에서는 Optuna 라이브러리를 활용하여 주요 하이퍼파라미터를 탐색하였다. 조정된 파라미터는 LSTM 유닛의 수(lstm_units_1, lstm_units_2), 드롭아웃 비율(dropout_rate_1, dropout_rate_2), 학습률(learning_rate)이다. 각 파라미터의 탐색 범위는 LSTM 유닛 수 128~192 (단위:64), 두 번째 LSTM 유닛 수 64~128 (단위:32), 드롭아웃 비율 0.3~0.4 (단위:0.1), 학습률 $1e-5 \sim 1e-3$ 으로 설정하여 하이퍼파라미터 튜닝을 진행하였다. 튜닝을 통해 최적화된 파라미터는 다음과 같다.

LSTM 유닛 수 (lstm_units_1)	192
--------------------------	-----

두 번째 LSTM 유닛 수 (lstm_units_2)	64
첫 번째 드롭아웃 비율 (dropout_rate_1)	0.4
두 번째 드롭아웃 비율 (dropout_rate_2)	0.4
학습률 (learning_rate)	4.59e-05

[표 6] 최적화된 하이퍼파라미터

BI-LSTM 모델은 두 개의 Bidirectional LSTM 층으로 구성되며, 각 LSTM 층 뒤에는 드롭아웃 레이어가 적용된다. 드롭아웃 레이어는 과적합을 방지하는 데 도움을 주며, 학습률은 매우 작은 값으로 설정되어 모델이 안정적으로 학습할 수 있도록 조정되었다. 최종 출력층은 다중 클래스 분류를 위한 소프트맥스 활성화 함수를 사용하며, 이는 각 클래스에 대한 확률을 출력한다.

학습 과정에서 조기 종료(EarlyStopping) 콜백을 사용하여 검증 손실이 개선되지 않으면 학습을 중단하고, 최적의 모델을 선택하도록 설정하였다. 에포크 수는 20 으로 설정되었으며, 배치 크기는 16 으로 설정하여 모델의 학습 속도와 성능을 최적화하였다. 튜닝 후 학습된 모델을 평가하기 위해 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 점수(F1-score)를 사용하여 성능을 측정하였다. 이러한 평가지표들을 통해 모델의 전반적인 성능을 종합적으로 판단할 수 있다. 최적화된 파라미터를 바탕으로 학습한 결과, 모델의 성능은 다음과 같다.

Accuracy	Precision	Recall	F1 score
0.9412	0.93	0.93	0.93

[표 7] 최적의 파라미터를 사용하여 학습한 모델의 성능

제 2 절 앙상블 기법

3.2.1 앙상블 기법 개요

앙상블 기법은 단일 모델보다 더 나은 예측 성능 달성을 위해 여러 개의 모델을 결합하여 사용하는 머신러닝 기법이다. 서로 다른 모델들의 장점을 활용하거나 동일한 모델을 여러 번 학습시키는 방식으로 구성된다. 대표적인 앙상블 기법으로는 배깅(Bagging), 부스팅(Boosting), 그리고 스택킹(Stacking)이 있다.

앙상블 기법은 단일 모델의 약점을 보완하며, 모델의 다수결 또는 가중치를 통해 다양한 데이터 분포나 문제 상황에서 안정적인 성능을 낼 수 있다는 장점이 있다. 단점으로는

다수의 모델을 학습하기 때문에 계산 비용이 증가한다는 점과 모델 간 조합 및 가중치를 설정하는 과정에서 추가적인 복잡성이 발생한다는 점이 있다.

3.2.2 앙상블 과정

BI-LSTM, XGBoost, LightGBM 세 가지 모델을 사용하여 다중 분류 문제를 해결하고, Soft Voting 앙상블 기법을 통해 최적의 성능을 도출하는 과정을 진행하였다. 각 모델의 특성과 예측 결과를 결합함으로써 개별 모델의 약점을 보완하고 더 신뢰성 있는 최종 결과를 얻는 것이 핵심이다.

먼저, 각 모델의 예측 결과를 도출하기 위해 데이터를 사전 처리한 뒤, 개별 모델을 학습시켰다. BI-LSTM 모델은 시계열 데이터의 특성을 학습하도록 설계된 순환 신경망(RNN)으로, 데이터의 문맥 정보를 양방향으로 처리할 수 있는 구조를 활용하였다. BI-LSTM 모델의 입력 데이터는 패딩(padding) 처리된 시퀀스 형태로, 이를 통해 샘플별로 다중 분류 확률값을 출력하였다. XGBoost와 LightGBM은 트리 기반 부스팅 알고리즘으로, 표형 데이터(tabular data)에 최적화된 성능을 보이는 모델들이다. XGBoost는 강력한 정규화 및 과적합 방지 기능을 제공하며, LightGBM은 XGBoost보다 가벼운 구조를 가지고 있어 대규모 데이터에서도 빠른 학습이 가능하다. 두 모델은 각각 클래스별 확률값을 계산하도록 설정하여 BI-LSTM과 동일한 다중 분류 문제를 해결하였다.

모델 학습 후, Soft Voting 앙상블 기법을 적용하기 위해 각 모델의 출력값을 통합하였다. Soft Voting은 모델별로 예측된 클래스 확률값을 평균 내어 최종 확률을 계산하는 방법이다. 이를 위해 각 모델의 예측 확률값을 동일한 형식으로 정렬하고, 각 클래스에 대한 확률값의 평균을 구하였다. 이 과정에서 입력 데이터가 정확히 일치하는지 확인하기 위해, 각 모델의 첫 번째 샘플 데이터를 비교하였다. Soft Voting을 통해 도출된 최종 확률값은 각 클래스에 대해 평균화한 값으로, 가장 높은 확률을 갖는 클래스를 최종 예측 값으로 설정하였다.

3.2.2 앙상블 결과

Soft Voting 앙상블 기법을 적용한 결과, 훈련 데이터셋에서 정확도, 재현율, 정밀도, F1-score 모두 0.9956으로 매우 높은 성능을 보였으며, 검증 데이터셋에서도 약 0.95의 우수한 성능을 기록하였다. Soft Voting 기법을 통해 각 모델의 예측 확률을 평균내어 최종 예측을 결정함으로써, 개별 모델의 성능을 뛰어넘는 결과를 얻을 수 있었다. 이로써 앙상블 모델이 BI-LSTM, XGBoost, LightGBM 모델 각각의 특성을 결합하여, 각 모델의 약점을 보완하고 더 신뢰성 있는 예측을 도출한다는 것을 볼 수 있다.

Accuracy	Precision	Recall	F1 score
0.9956	0.9956	0.9956	0.9956

[표 8] 앙상블 모델의 Train 데이터셋 성능

Accuracy	Precision	Recall	F1 score
0.9514	0.9519	0.9514	0.9515

[표 9] 앙상블 모델의 Validation 데이터셋 검증


제 3 절 LIME 알고리즘

3.3.1 LIME 개요

LIME(Local Interpretable Model-agnostic Explanations)은 모델의 복잡성과 상관없이 개별 데이터 샘플에 대한 예측 결과를 해석할 수 있도록 설계된 모델-독립적(Model-Agnostic) 설명 알고리즘이다. 복잡한 머신러닝 모델은 "블랙박스"로 간주되는 경우가 많으며, 이러한 특성은 모델의 신뢰성과 실무 적용 가능성을 제한한다. LIME 은 모델의 국소적인(local) 행동을 단순화된 선형 모델로 근사하여, 사용자가 모델의 예측을 이해할 수 있도록 돕는다. 이를 통해 각 입력 데이터의 특징(feature)이 모델 예측에 얼마나 기여했는지 설명하며, 의료, 금융 등 예측 결과의 해석 가능성이 중요한 분야에서 널리 활용되고 있다.

3.3.2 알고리즘 원리

LIME 알고리즘은 다음과 같은 과정을 통해 개별 예측 결과를 설명한다. 첫째, 원래 데이터 샘플 주변에 다양한 변형 데이터(perturbed data)를 생성하여 새로운 데이터 공간을 구성한다. 이 과정은 데이터 샘플의 국소적(local) 영역에서의 모델 동작을 탐색하기 위함이다. 둘째, 생성된 변형 데이터에 대해 모델의 예측값을 계산하고, 이를 바탕으로 가중치를 부여하여 국소적 중요도를 반영한 가중치 데이터셋을 만든다. 셋째, 이 가중치 데이터셋을 사용하여 단순한 선형 모델을 학습시킨다. 선형 모델은 해당 샘플 주변에서의 모델 동작을 근사한 것으로, 이를 통해 각 특징이 모델의 예측에 기여한 정도를 수치화한다. 이 과정을 통해 LIME 은 개별 샘플에 대한 예측 결과를 해석 가능하게 만들며, 이를 기반으로 모델이 예측을 내린 근거를 시각적으로 제시한다.




[그림 5] LIME 알고리즘 작동 원리

3.3.3 앙상블 모델에 LIME 적용


본 연구에서는 각각의 클래스에서 하나씩 인스턴스를 임의로 선택한 뒤 LIME 을 통해 설명을 하였다. LIME 설명기 객체를 구성하는 과정에서 파라미터를 지정하였는데, “discretize_continuous”는 True 로 설정하여 수치형 변수의 경우 이산적으로 학습하도록 하였다. 예를 들어 10HZ 변수의 수치들을 50 보다 큰지 아닌지 두 경우로 이산화 하여, “10HZ 변수의 값이 2% 영향을 준다.”가 아니라 “10HZ 변수의 값이 50 보다 큰 것이 결과에 2% 영향을 준다.”와 같은 방식으로 설명을 제공하게끔 하였다. 또한, “sample_around_instance”를 True 로 설정하여, 설명가능한 모델을 학습할 때 해당 인스턴스 근처에서 샘플을 생성하여 학습하게 하였다. 이를 통해 더 지역적으로 충실한 설명을 만들 수 있도록 하였다. 또한 설명가능한 모델은 기본 값인 릿지 회귀모델(alpha 값은 1.0)을 사용하였고, 10 개의 변수로 설명을 제공하도록 하였다.

[그림 6] 옥내누수(in)에 대한 LIME 설명




옥내 누수로 분류된 인스턴스 중 하나에 대한 설명으로 “340HZ” 값이 467 로 72 보다 크고, “370HZ” 값이 78 로 73 보다 큰 것이 옥내 누수로 분류되는데 영향을 각각 3%, 2% 미쳤다고 해석할 수 있다. 전체적으로 350Hz 전후의 값이 큰 것이 주요하게 작용했음을 확인할 수 있다.

[그림 7] 옥외누수(out)에 대한 LIME 설명




옥외누수로 분류된 인스턴스 중 하나에 대한 설명으로 “120HZ” 값이 5 로 5 보다 같거나 작고, “400HZ” 값이 72 로 66 보다 큰 것이 옥외누수로 분류되는데 영향을 각각 5%, 3% 미쳤다고 해석할 수 있다. 전체적으로 200 대의 Hz 값이 작고, 400 대의 Hz 에서 값이 큰 점이 주요하게 작용했음을 확인할 수 있다.

[그림 8] 정상(normal)에 대한 LIME 설명




정상으로 분류된 인스턴스 중 하나에 대한 설명으로 “370HZ” 값이 5 로 9 보다 작고, “380HZ” 값이 6 으로 8 보다 작은 것이 정상으로 분류되는데 영향을 각각 3%, 2% 미쳤다고 해석할 수 있다. 전체적으로 모든 Hz 의 값이 다른 클래스에 비해 작은 점이 주요하게 작용했음을 확인할 수 있다. 정상의 경우 누수나 잡음의 영향이 없기 때문에 유추할 수 있다.

[그림 9] 환경음(other)에 대한 LIME 설명



환경음으로 분류된 인스턴스 중 하나에 대한 설명으로 “120HZ” 값이 24 로 18 보다 크고, “4310HZ” 값이 15 로 6 보다 큰 것이 환경음으로 분류되는데 영향을 각각 2%, 1% 미쳤다고 해석할 수 있다. 전체적으로 모든 Hz 의 값이 다른 클래스에 비해 큰 점이 주요하게 작용했음을 확인할 수 있다. 환경음의 경우에는 전체 Hz 에 걸쳐 외부 잡음이 많이 영향을 미친다고 볼 수 있다.



기계, 전기음으로 분류된 인스턴스 중 하나에 대한 설명으로 “280HZ” 값이 365 로 97 보다 크고, “290HZ” 값이 255 로 80 보다 큰 것이 기계, 전기음으로 분류되는데 영향을 각각 4%, 3% 미쳤다고 해석할 수 있다. 전체적으로 200 후반 Hz 의 값이 큰 것, 1000 보다 큰 특정 Hz 구간의 값이 일정 범위 내인 점이 주요하게 작용했음을 확인할 수 있다. 이렇게 LIME 을 적용하면 개별 분류 값에 대한 모델의 작동 과정에 대해 알 수 있다.

제 4 장 결론

제 1 절 연구 결과 종합 및 시사점 도출

본 연구는 상수관로 누수탐지를 위해 머신러닝 및 딥러닝 모델을 종합적으로 분석하고, 앙상블 기법과 XAI 방법론을 적용하여 모델의 성능과 해석 가능성을 향상시키고자 하였다. 개별 모델 분석 결과, XGBoost, LightGBM, Bi-LSTM 각 모델은 고유한 특성을 보였으며, 특히 LightGBM 이 상대적으로 우수한 성능을 나타냈다. 앙상블 모델 적용을 통해 개별 모델의 한계를 극복하고 예측 정확도를 높였다는 점에서 의의가 있다.

LIME 을 통한 모델 해석 결과, 누수탐지에 영향을 미치는 주요 특징들을 시각적으로 확인할 수 있었으며, 이는 실무자들에게 모델의 의사결정 과정에 대한 통찰력을 제공한다. 특히 인공지능 기술을 활용한 누수탐지 방법론은 전통적인 방식에 비해 높은 정확성과 효율성을 보여, 물 손실 관리의 새로운 접근 방식을 제시하였다.

제 2 절 한계점 및 향후 연구 방향성 제언

4.2.1 연구의 한계점

본 연구는 다음과 같은 한계점을 지닌다. 첫째, 데이터의 제한성이다. AI hub 에서 제공된 제한된 데이터셋을 사용함으로써 실제 현장의 모든 상황을 완벽하게 반영하기 어려웠다. 둘째, 모델링 과정에서의 제약이 존재한다. 선택된 모델들의 하이퍼파라미터 튜닝이 충분히 깊이 있게 이루어지지 못했으며, 모델 간 성능 비교에 일부 한계가 있었다. 셋째, XAI 방법론인 LIME 의 한계가 존재한다. LIME 은 모델의 국소적 해석은 제공하지만, 전체적인 모델 동작에 대한 완전한 이해를 제공하지는 못한다.

4.2.2 향후 연구 방향성 제언

이러한 한계점을 보완하기 위해 다음과 같은 향후 연구 방향을 제안한다. 첫째, 더욱 다양하고 포괄적인 데이터셋 확보가 필요하다. 다양한 지역, 환경, 관로 조건을 반영하는 데이터를 수집하여 모델의 일반화 성능을 높일 수 있다. 둘째, 고급 머신러닝 및 딥러닝 기법의 탐색이 요구된다. 최신 앙상블 기법, 자동화된 하이퍼파라미터 최적화 기법 등을 적용하여 모델의 성능을 더욱 개선할 수 있다. 셋째, 보다 정교한 XAI 방법론의 적용이 필요하다. SHAP(SHapley Additive exPlanations)와 같은 다른 설명 가능한 AI 기법을 활용하여 모델의 해석력을 높일 수 있다.

마지막으로, 본 연구는 실제 현장 적용을 위한 추가 검증 연구를 제안한다. 실제 상수관로 환경에서의 실증적 검증을 통해 개발된 모델의 실용성과 신뢰성을 확보해야 한다. 이를 통해 상수관로 누수탐지 기술의 실질적인 적용 가능성을 높이고, 물 자원 관리의 효율성을 증대시킬 수 있을 것이다.

참고문헌

- [1] 상수관로 누수 감지 데이터 (2020). AI HUB
(<https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=data&dataSetSn=138>)
- [2] 김병학, 전제성, 이수안. (2022) 상수관로 진동 센서 데이터를 이용한 누수 감지 머신러닝 모델. 한국소프트웨어종합학술대회 논문집 1,361~1,363
- [3] 최준규, 임성빈. (2023). 누수 잡음 크기 스펙트럼을 이용한 SVM 기반의 상수관로 누수 감지 및 분류. 대한전자공학회 전자공학회논문지 60(2) 6~14
- [4] 최석윤, 김광주. (2023). 진동센서를 이용한 AI 기반 상수관로 누수 판별 기술 비교. 한국통신학회 동계종합학술발표회 논문집 1,226~1,227
- [5] 이수현, 고상근, 이수한. (2024) 진동 센서 기반 상수관 누수 감지 및 분류 모델. 한국컴퓨터종합학술대회 논문집 1,871~1,873

