

DAT 4기 캡스톤 프로젝트 보고서

2025 MLB 타자 유형별 스카우팅 모델 개발

: 로지스틱 회귀분석을 중심으로

DAT 4기

회귀분석팀 회귀본능

여채환, 서수민, 김지윤, 김동호



Data Analysis & Technology



DAT 4기 캡스톤 프로젝트 보고서

2025 MLB 타자 유형별 스카우팅 모델 개발

: 로지스틱 회귀분석을 중심으로

The Development of 2025 MLB Hitter Type
Scouting Model

: Focus on Logistic Regression Analysis

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2024년 12월 03일

DAT 4기

회귀분석팀 회귀본능

여채환, 서수민, 김지윤, 김동호



Data Analysis & Technology



DAT 4기 캡스톤 프로젝트 보고서

2025 MLB 타자 유형별 스카우팅 모델 개발

: 로지스틱 회귀분석을 중심으로

국문 요약

많은 프로스포츠 구단들은 시즌이 종료되면 선수 영입을 통해 전력을 보강하고자 한다. 구단들은 팀의 특성에 맞는 선수 영입을 위해 선수 데이터를 면밀히 분석한다. 그래서 본 연구에서는 미국 프로야구(MLB) 스카우터임을 가정하여 타자 유형별 2025년 스카우팅 모델을 구축하였다. 모델은 득점 생산형 모델, 출루형 모델, 그리고 장타형 모델 총 3가지로 구성되었으며, 로지스틱 회귀분석과 가상 데이터 샘플링을 중심으로 모델을 생성하였다. 분석 결과, 득점력 모델에서는 Michael Conforto, 출루형 모델에서는 Jose Abreu, 그리고 장타형 모델에서는 Jeff McNeil이 종합적으로 우수한 선수로 스카우팅 후보로 선정되었다. 또한, 세부적인 타격 지표에 따라 언급된 선수들 이외에도 팀의 특성에 따른 선수들을 스카우팅 후보로 선정할 수 있다.

Abstract

Many professional sports teams aim to strengthen their roster through player acquisitions after the season ends. Teams carefully analyze player data to recruit athletes that match their team characteristics. Therefore, this study assumes the role of an MLB scout and develops a scouting model for 2025 based on hitter types. The model consists of three categories: a scoring model, an on-base model, and a power-hitting model. The model was created using logistic regression analysis and synthetic data sampling. The analysis results identified Michael Conforto as the top prospect in the scoring model, Jose Abreu in the on-base model, and Jeff McNeil in the power-hitting model. Additionally, based on specific hitting metrics within the model, other players may also be selected as scouting candidates depending on the team's characteristics.

DAT 4기

회귀분석팀 회귀본능

여채환, 서수민, 김지윤, 김동호



Data Analysis & Technology



목 차

제 1장 서론	1
제 1절 연구 배경	1
제 2절 연구 목적 및 보고서 구성	1
제 2장 데이터 소개	2
제 1절 분석 데이터 소개	2
제 2절 데이터 전처리	4
제 3장 분석 결과	7
제 1절 연구 모형 설계	7
제 2절 데이터 샘플링	12
제 4장 결론	18
제 1절 연구 결과 종합 및 시사점 도출	18
제 2절 한계점 및 향후 연구 방향성 제언	19
참고문헌	21



표 목차

[표 1].....	2
[표 2].....	3
[표 3].....	4
[표 4].....	7
[표 5].....	13
[표 6].....	15
[표 7].....	17

그림 목차

[그림 1].....	5
[그림 2].....	5
[그림 3].....	8
[그림 4].....	9
[그림 5].....	9
[그림 6].....	10
[그림 7].....	10
[그림 8].....	11
[그림 9].....	11
[그림 10].....	13



[그림 11].....	15
[그림 12].....	17



제 1장 서론

제 1절 연구 배경

해마다 프로 야구에서 시즌이 종료되면, 각 구단들은 선수 영입을 통해 전력을 보강하고자 한다. 이전에는 타율, 홈런, 타점 등과 같은 단순 기록을 참고하여 선수를 영입했다. 그러나, 2000년대 이후 세이버메트릭스(Sabermetrics)라는 선수 분석 접근법이 알려지기 시작하면서 빅데이터를 활용한 다양한 관련 지표들이 개발 및 발표되었다.(조선미, 김주학, 강지연, 김상균, 2023) 이러한 스포츠 빅데이터는 경기기록으로 제한적이었던 스포츠 과학에 혁신을 가져오며 새로운 정보원으로서 시각과 통찰, 예측에 대한 가능성을 제시한다.(조선미, 김주학, 강지연, 2022) 이처럼 데이터 기반의 선수 분석은 MLB 구단들에게는 필수적인 요소가 되었다.

각 구단들은 데이터 분석을 통해 구단의 타선 유형에 맞는 선수, 또는 약점 유형을 보충하기 위한 선수 등 유형 별로 선수를 영입한다. 구단에 맞는 적절한 유형의 선수 영입은 팀 전력 상승에 큰 보탬이 되며, 다음 시즌 포스트시즌 진출 및 우승을 위한 기반을 마련할 수 있기에 매우 중요한 사안이다.

제 2절 연구 목적 및 보고서 구성

본 연구에서는 MLB 스카우터가 되어 MLB 데이터를 기반으로 한 타자 스카우팅 프로그램을 구축하고자 한다. 득점 생산형 타자, 출루형 타자, 그리고 장타형 타자 총 3가지 유형으로 구분한 후, 로지스틱 회귀 분석 기반 예측 모델을 활용한 프로그램을 통해 유형별로 스카우트 후보 선수 리스트를 작성하고자 한다.

본 보고서의 구성은 다음과 같다. 2절에서는 수집 데이터 및 관련 변수들을 소개한 뒤 전처리 과정을 설명한다. 3절에서는 전처리된 데이터를 로지스틱 회귀 모델에 적용한다. 이후, 2025년 가상 데이터를 샘플링하고 스카우팅 모델을 구축하여 유형별 스카우트 후보 선수들을 선정한다. 4절에서는 스카우팅에 대한 결론을 맺은 뒤, 한계점 및 제언을 서술함으로써 본 보고서를 마무리한다.



제 2장 데이터 소개

제 1절 분석 데이터 소개

본 보고서에서 다룬 데이터는 MLB 공식 홈페이지 내 통계 사이트인 Baseball Savant에서 수집하였다. 2021년부터 2024년까지 300타석 이상을 소화한 선수들의 데이터만을 사용하여 총 79개의 열과 1118개의 행으로 구성된 데이터를 수집하였다.

첫 번째 스카우팅 모델은 타자의 득점 생산형 모델로, 타격지표가 타자의 전반적인 득점 생산력에 어떻게 기여하는지 분석하고자 했다. 해당 모델에 사용된 변수는 다음과 같다. 분석에 사용될 종속변수는 woba로 가중 출루율을 의미한다. 가중 출루율은 안타, 2루타, 3루타, 홈런과 같은 출루 이벤트에 다른 가중치를 부여함으로써 실제 득점 가치에 비례하여 출루율을 계산한다. 따라서, 득점 생산력을 설명하기에 적합한 변수라 판단하여 선정하였다.

<u>k_percent</u>	삼진율	<u>xiso</u>	기대 순수 장타율
<u>bb_percent</u>	볼넷율	<u>wobacon</u>	컨택시 가중 출루율
<u>hard_hit_percent</u>	강타율	<u>xwobacon</u>	컨택시 기대 가중 출루율
<u>sweet_spot_percent</u>	스윙 스팟 타구 비율	<u>xba</u>	기대 타율
<u>barrel_batted_rate</u>	배럴 타구 비율	<u>xbacon</u>	컨택시 기대 타율
<u>avg_best_speed</u>	최고 배트 스피드	<u>linedrives_percent</u>	라인드라이브 타구 비율
<u>exit_velocity_avg</u>	평균 타구 속도	<u>avg_hyper_speed</u>	조정 타구 속도
<u>launch_angle_avg</u>	평균 발사 각도	<u>hp_to_1b</u>	홈에서 1루까지 속도
<u>isolated_power</u>	순수 장타율	<u>sprint_speed</u>	스프린트 속도
<u>woba</u>	가중 출루율		

[표 1] 전처리 이전 모델1 변수 설명

두 번째 스카우팅 모델은 출루형 모델로, 타자의 출루 능력에 집중하여 스트라이크존 내외에서의 스윙 효율이 출루에 미치는 영향을 분석하고자 했다. 해당 모델에 사용된 변수는 다음과 같다. 분석에 사용될 종속 변수는 on_base_percent(OBP)로 출루율을 의미한다. 출루율은 출루 이벤트에 모두 동일한 가치를 부여하기에 타자의 출루 능력만을 독립적으로 파악할 수 있다고 판단하였다.

<u>k_percent</u>	<u>삼진율</u>	<u>walk</u>	<u>볼넷 수</u>
<u>bb_percent</u>	<u>볼넷율</u>	<u>swing_percent</u>	<u>스윙률</u>
<u>oz_contact_percent</u>	<u>아웃존 컨택율</u>	<u>in_zone_percent</u>	<u>인존 비율</u>
<u>iz_contact_percent</u>	<u>인존 컨택율</u>	<u>out_zone_percent</u>	<u>아웃존 비율</u>
<u>oz_swing_percent</u>	<u>아웃존 스윙률</u>	<u>whiff_percent</u>	<u>헛스윙률</u>
<u>iz_swing_percent</u>	<u>인존 스윙률</u>	<u>on_base_percent</u>	<u>출루율</u>

[표 2] 전처리 이전 모델 2 변수 설명


세 번째 스카우팅 모델은 장타형 모델로, 장타력 있는 타자의 특성을 규명하고자 타자의 공격 성향이 장타력에 어떻게 기여하는지 분석하고자 했다. 해당 모델에 사용된 변수는 다음과 같다. 분석에 사용될 종속변수는 slg_percent(SLG)로 장타율을 의미한다. 장타율은 출루 이벤트에 모두 다른 가중치를 두고, 볼넷은 포함하지 않기 때문에 타자의 파워를 평가하는데 적합한 지표 중 하나이다. 따라서, 장타력을 설명하기에 적합한 변수라 판단하여 선정하였다.

<u>whiff_percent</u> ↵	<u>헛스윙률</u> ↵	<u>straightaway_percent</u> ↵	<u>정중앙 비율</u> ↵
<u>swing_percent</u> ↵	<u>스윙률</u> ↵	<u>opposite_percent</u> ↵	<u>밀어치기 비율</u> ↵
<u>hard_hit_percent</u> ↵	<u>강타율</u> ↵	<u>meatball_swing_percent</u> ↵	<u>좋은 공 스윙률</u> ↵
<u>sweet_spot_percent</u> ↵	<u>스윙 스팟 타구 비율</u> ↵	<u>xiso</u> ↵	<u>기대 순수 장타율</u> ↵
<u>barrel_batted_rate</u> ↵	<u>배럴 타구 비율</u> ↵	<u>groundballs_percent</u> ↵	<u>땅볼 비율</u> ↵
<u>avg_best_speed</u> ↵	<u>최고 배트 스피드</u> ↵	<u>flyballs_percent</u> ↵	<u>뜬공 비율</u> ↵
<u>exit_velocity_avg</u> ↵	<u>평균 타구 속도</u> ↵	<u>linedrives_percent</u> ↵	<u>라인드라이브 타구 비율</u> ↵
<u>launch_angle_avg</u> ↵	<u>평균 발사 각도</u> ↵	<u>babip</u> ↵	<u>인플레이 타구 타율</u> ↵
<u>pull_percent</u> ↵	<u>당겨치기 비율</u> ↵	<u>slg_percent</u> ↵	<u>장타율</u> ↵

[표 3] 전처리 이전 모델3 변수 설명

제 2절 데이터 전처리

변수 별로 결측치는 없는 것으로 확인되어 결측치 처리 과정은 생략하였다. 다만, 이상치 확인 결과 변수마다 상당수의 이상치가 있는 것으로 파악되었는데, MLB 기록 특성 상 이상치 역시 선수의 플레이스타일을 나타내는 데이터라고 판단하여 1%~99% 범위에서 벗어난 이상치들만 제거하였다.



[그림 1] 변수 이상치 확인

한편, 로지스틱 회귀 분석에 사용되지 않는 선수이름 및 연도 변수는 추후에 스카우팅 모델에 활용할 수 있도록 데이터프레임을 따로 생성한 뒤 삭제했다. 그리고, 나머지 변수들에 관련된 통계 정보를 확인하였다. 평균, 표준편차, 최소값, 최대값, 25~75%의 데이터 프레임 생성하여 관련 정보를 확인할 수 있었다.

	k_percent	bb_percent	xbt	woba	xiso	xbacon	launch_angle_avg	sweet_spot_percent	hard_hit_percent	linedrives_percent	hp_to_1b	sprint_speed
count	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000	1118.000000
mean	21.910644	8.476565	0.249356	0.320854	0.165396	0.330535	13.031216	33.985249	39.063599	23.920583	4.467065	27.297496
std	5.716803	2.801871	0.024503	0.034659	0.053655	0.029617	13.521335	3.593069	7.224418	2.858725	0.194473	1.321672
min	10.017000	3.200000	0.191340	0.245000	0.066000	0.269170	2.800000	25.734000	21.634000	16.951000	4.110000	23.700000
25%	17.725000	6.400000	0.233000	0.298000	0.127250	0.310000	10.000000	31.500000	35.400000	21.825000	4.330000	26.400000
50%	21.600000	8.300000	0.249000	0.319500	0.161000	0.329000	13.150000	34.000000	40.150000	23.900000	4.430000	27.400000
75%	25.800000	10.300000	0.265000	0.343000	0.200000	0.350000	16.100000	36.375000	44.900000	25.900000	4.600000	28.300000
max	35.183000	15.900000	0.312830	0.419000	0.316660	0.411830	22.600000	42.900000	55.883000	30.900000	5.036600	30.100000

[그림 2] 모델 1 변수 통계 정보

로지스틱 회귀 분석 예측 모델에 사용될 변수를 선택하고자 상관관계가 0.8 이상인 변수들을 확인하였고, 변수들 간에 다중공선성 문제가 발생할 것이라는 판단하였다. 다중공선성이란, 독립 변수들 간에 높은 상관관계가 존재할 때 발생하는 문제로, 특정 변수의 영향이 다른 변수로 인해 왜곡되어 모델의 신뢰성과 해석 가능성을 저하시킨다는 개념이다. 따라서, 모델 별로 상관관계가 0.85 이상인 변수들을 군집화하여 군집마다 한 개의 변수만을 선택하고 나머지 변수들은 삭제했다.

모델 1에서는 다음과 같은 군집이 형성되었다.

- 1) exit_velocity, best_speed, avg_hyper_speed, hard_hit_percent
- 2) xiso, isolated_power, wobacon, barrel_batted_rate
- 3) xbacon, xwobacon

1)에서는 hard_hit_percent(하드히트%)를 선택하였다. hard_hit_percent는 타구 속도가 95마일 이상인 타구 비율을 의미한다. 변수 자체가 매우 빠른 타구 속도의 의미를 가지며, 빠른 타구 속도는 강한 타구를 생산하는 타자라는 것을 의미하기에 다른 변수와 비교했을 때, 득점 생산에 가장 긍정적인 영향을 끼치는 변수라고 판단하였다.

2)에서는 xiso(기대 순수 장타율)을 선택하였다. xiso는 순수 장타율의 기댓값으로 여기서 순수 장타율은 장타율 - 타율로 계산된다. 즉, 단타를 제외한 선수의 장타의 기댓값을 나타낸다. 장타 역시 팀 득점에 높은 기여를 할 수 있고, 기댓값 지표는 타 변수에 비해 다음 시즌의 예측이 반영될 수 있어 스카우팅에 효과적인 변수라고 판단하였다.

3)에서는 xbacon(컨택 시 기대 타율)을 선택하였다. 다른 변수인 xwobacon의 경우 컨택시 기대 가중 출루율을 의미하여 woba 변수와 지나치게 높은 상관관계가 있을 것이라 우려되어 제거하였다.

모델 2에서는 누적 기록인 walk(볼넷)을 삭제하고 상관관계를 확인했을 때, swing_percent가 iz_swing_percent, oz_swing_percent와 0.85 이상의 상관관계를 보이고 있어 삭제하였다.

모델 3에서는 다음과 같은 군집이 형성되었다.

- 1) exit_velocity_avg, hard_hit_percent, avg_best_speed, avg_hyper_speed
- 2) barrel_batted_rate, isolated_power, xiso

1),2)에서도 모델 1과 마찬가지로 hard_hit_percent와 xiso 변수를 선택하였다. hard_hit_percent가 높다는 것은 타구 속도가 매우 빨라 강한 타구를 만들어낼 확률이 높다는 것이기에 장타 생산에 매우 유리하다. xiso는 단타를 제외한 순수 장타 생산의 기댓값을 나타내는 지표라 장타 유형의 타자를 스카우팅하는데 매우 유용한 변수이기에 선택했다.

상관관계 확인 후 다중공선성을 막기 위한 변수 선택 과정을 거친 결과, 모델 별로 다음과 같은 변수들이 최종 선택되었다.



모델 1 ↵	X ↵	k_percent, bb_percent, xba, xiso, xbacon, launch_angle_avg, sweet_spot_percent, hard_hit_percent, ↵ linedrives_percent, hp_to_1b, sprint_speed ↵
	y ↵	woba ↵
모델 2 ↵	X ↵	k_percent, bb_percent, iz_swing_percent, oz_swing_percent, oz_contact_percent, iz_contact_percent, whiff_percent ↵
	y ↵	on_base_percent ↵
모델 3 ↵	X ↵	babip, launch_angle_avg, sweet_spot_percent, hard_hit_percent, meatball_swing_percent, whiff_percent, swing_percent, pull_percent, straightaway_percent, opposite_percent, groundballs_percent, flyballs_percent, linedrives_percent ↵
	y ↵	slg_percent ↵

[표 4] 모델별 최종 선택 변수

마지막으로, 최종 선택된 변수들을 가지고 스케일링을 진행하였다. 본 연구에서 쓰이는 변수들은 이상치가 존재하기에 데이터 불균형 우려가 있어 Standard Scaler를 통해 데이터 평균이 0이고 표준편차가 1인 정규분포로 변환했다.

제 3장 분석 결과

제 1절 연구 모형 설계

선수 스카우팅 모델 구축을 위한 첫 번째 단계로 로지스틱 회귀분석 모델을 생성하였다. 데이터 특성 상 전처리 과정에서 최소한의 이상치만을 제거하여 이상치가 다수 존재하기 때문에 종속 변수의 실제 값을 예측하는 것은 무리가 있다고 판단하였다. 그래서, 2025년 가상 데이터 샘플링 및 모델별 종속변수가 높은 값을 기록할 확률을 계산하기 위한 로지스틱 회귀분석 모델을 설계했다.

1.1 로지스틱 회귀분석

로지스틱 회귀분석은 일반적인 회귀 분석과 동일한 목적으로 독립변수와 종속변수 간의 관계를 구체화된 함수로 나타내어 예측 모델을 형성하는 분석 기법이다. 이때, 종속변수의 범주는 2개(0,1)여야 하며 확률 이론을 따르기에 분석 결과 값은 0과 1 사이 값으로 계산된다.(정용찬, 2022) 로지스틱 회귀 모형의 수식은 다음과 같다.


$$\log \left[\frac{p(x)}{1-p(x)} \right] = \alpha + \beta_1 x_1 + \dots + \beta_p x_p = \alpha + X^T \beta$$

[그림 3] 로지스틱 회귀 모형


선형 회귀 모형을 사용하여 $E(Y|x)=p(x)$ 즉, 독립변수 x 에 대하여 종속 변수 y 의 확률을 계산하면 y 의 범위는 $[0,1]$, x 의 범위는 $[-\infty, \infty]$ 이므로 y 의 확률이 $[0,1]$ 을 벗어날 우려가 있다.. 이때, $p(x)$ 를 $p(x)/(1-p(x))$ 로 변환하고 로짓 함수를 적용한 것이 좌측의 식이다. 이로써 y 의 범위가 $[-\infty, \infty]$ 로 변환되어 $[0,1]$ 의 범위에 있는 y 확률값을 생성할 수 있다.(황보연, 2023)

먼저 종속변수를 범주형 범주(0,1)로 변환하기 위해, 종속변수가 변수의 중앙값보다 큰 데이터는 1, 그렇지 않은 데이터는 0이 되는 ‘high_(종속변수 이름)’ 변수를 생성하여 로지스틱 회귀 모형의 종속 변수로 사용한다. 훈련 데이터와 테스트 데이터의 비율은 8:2로 구성되었으며, 과적합을 방지하고자 L2 정규화를 적용 후 모델을 학습시켰다. 그리고, 학습시킨 모델을 사용하여 예측을 수행하고 성능을 확인하고자 모델 평가를 진행하였다. 이때, ROC 곡선과 Precision-Recall Curve를 이용하여 모델 평가 결과를 시각화하였다. 마지막으로, 학습시킨 모델을 사용하여 변수별 중요도를 계산하고 이를 막대 그래프를 통해 시각화하였다.

1.2 로지스틱 회귀분석 모델 1 성능 평가




[그림 4] 모델 1 성능 지표 시각화




[그림 5] 모델 1 변수 중요도 시각화

모델 1은 클래스별 f1-score가 0.8, 0.81로 모델 자체가 좋은 성능을 가지고 있다. 또한 Accuracy 역시 0.8로 우수한 성능을 보이고 있다. [그림 4]를 보면, 모델 1은 AUC가 0.88로 매우 신뢰할 만한 분류 성능을 보이고 있다. 또한, [그림 5]를 보면, xiso, hp_to_1b 등이 높은 변수 중요도를 보였다. 이는 득점 생산에는 장타력과 주루 능력을 견비해야 하기 때문에 높은 중요도를 보인다고 할 수 있다.

1.3 로지스틱 회귀분석 모델 2 성능 평가




[그림 6] 모델 2 성능 지표 시각화




[그림 7] 모델 2 변수 중요도 시각화

모델 2는 클래스별 f1-score가 0.7로 모델 자체가 좋은 성능을 가지고 있다. 또한 Accuracy 역시 0.7로 무난한 성능을 보이고 있다. [그림 6]을 보면, 모델 2는 AUC가 0.79로 신뢰할 만한 분류 성능을 보이고 있다. 또한, [그림 7]을 보면, bb_percent, whiff_percent 등이 높은 변수 중요도를 보였다. 이는 출루 능력은 나쁜 공에 대한 헛스윙을 줄여 볼넷 비율을 높여 선구안을 강화하는 것과 연관되기 때문에 높은 중요도를 보인다고 할 수 있다.

1.4 로지스틱 회귀분석 모델 3 성능 평가



[그림 8] 모델 3 성능 지표 시각화



[그림 9] 모델 3 변수 중요도 시각화


모델 3은 클래스별 f1-score가 0.72, 0.71로 모델 자체가 좋은 성능을 가지고 있다. 또한 Accuracy 역시 0.72로 무난한 성능을 보이고 있다. [그림 8]을 보면, 모델 3은 AUC가 0.83으로 신뢰할 만한 분류 성능을 보이고 있다. 또한, [그림 9]를 보면, babip, hard_hit_percent 등이 높은 변수 중요도를 보였다. 이는 장타력은 인플레이 타구에 대하여 강한 타구를 생성함으로써 타구의 발사 각도를 높이는 것과 연관되기 때문에 높은 중요도를 보인다고 할 수 있다.

제 2절 데이터 샘플링

현재 2025년 데이터는 존재하지 않기 때문에, 스카우팅 모델을 적용한 가상 데이터를 생성해야 한다. 우선, 2021~2024년 데이터에서 선수 번호(player_id)가 동일한 연도끼리 그룹화한 후 변수 별로 평균을 계산한 데이터를 생성한다. 이로써 특정 선수의 평균 능력치를 파악할 수 있다. 그리고, 새로 생성한 선수 데이터의 순서대로 평균 및 표준편차를 구해 정규분포를 따르는 가상의 데이터를 랜덤으로 샘플링한다. 이로써 총 265개의 가상 데이터가 기존 데이터의 순서대로 생성된다. 이후 각 스카우팅 모델마다 로지스틱 회귀 모델을 적용하여 종속변수가 범주 1일 확률 즉, 종속변수가 중앙값 이상으로 상위에 속할 확률을 계산한 'prob' 변수를 가상 데이터에 추가한다. 그리고, prob 변수 기준으로 상위 선수들을 추출하는 시뮬레이션을 500번 반복 후 빈도를 계산하여 그 빈도의 상위 선수들을 추출한다. 이때, 상위 선수들의 빈도, 능력치를 같이 추출하여 2025년 예상 기록을 보여준다. 또한, 최근 2년 연속 출장 기록이 없는 경우를 제거하기 위해 2023년~2024년에 데이터가 없을 경우를 필터링하는 과정을 거친다. 마지막으로, 필터링된 선수 데이터와 이름을 연결하여 모델별 최종 스카우트 후보 리스트를 작성한다. 이때, 필터링된 선수는 MLB 공식 사이트 및 기사 검색을 통해 정보를 확인하여 2024년까지 데이터가 존재하나, 2025년 은퇴 예정이거나, 타 리그 이적 등 2025년에 MLB에서 활약할 수 없는 선수들은 제거하여 리스트를 작성하였다.

2.1 스카우팅 모델 1(득점 생산력 모델)

모델 1의 경우, 빈도가 높은 상위 선수는 일관되게 높은 woba 확률을 예측한다. 변수 중요도를 고려하면 이 선수들의 공통점은 장타 능력의 xiso, 주루 능력의 hp_to_1b, 그리고 컨택 능력의 xbacon 등의 다양한 유형의 타격 지표들이 높은 조합을 이룬 완성형 타자라는 점이다. 타자로서 다양한 툴(Tool)을 보유할수록 다양한 득점 상황에서 득점을 창출하기 유리한 타자라는 것이다. 이에 해당하는 선수들은 다음과 같다.



[그림 10] 모델 1 상위 선수 빈도 그래프

[그림 10]을 토대로 높은 woba를 기록할 확률이 높은 선수들을 추출했다. 빈도 수와 모델 1의 변수 중요도가 높았던 변수 3개를 고려한 최종 스카웃 후보 리스트는 다음과 같다.

순위↵	Frequency↵	이름↵
1↵	52↵	Pete Alonso↵
		Michael Conforto↵


순위	<u>xiso</u>	Hp_to_1B	<u>xbacon</u>
1	Brandon Belt (0.2459)	Brandon Belt (4.0336)	Brandon Belt (0.3824)
2	Eugenio Suarez (0.2455)	Travis d'Arnaud (4.1201)	Michael Conforto (0.3808)
3	Joey Meneses (0.1877)	Joey Meneses (4.3054)	Justin Turner (0.3788)

[표 5] 모델 1 최종 스카웃 후보 리스트

높은 woba를 기록할 확률을 가진 상위 2인은 52회의 Pete Alonso, Michael Conforto이다. 변수 중요도가 가장 높았던 xiso의 상위 3인은 Brandon Belt, Eugenio Suarez, Joey Meneses이다. 변수 중요도가 2번째로 높았던 hp_to_1b의 상위 3인은 Brandon Belt, Travis d'Arnaud, Joey Meneses이다. 마지막 xbacon의 상위 3인은 Brandon Belt, Michael Conforto, Justin Turner이다.

2.2 스카우팅 모델 2(출루형 모델)

모델 2의 경우, 빈도가 높은 상위 선수는 일관되게 높은 OBP 확률을 예측한다. 변수 중요도를 고려하면 이 선수들의 공통점은 bb_percent, whiff_percent, iz_contact_percent 등의 선구안 지표에서 강점을 갖춘 타자라는 점이다. 볼에는 스윙하지 않고, 스트라이크존에 들어오는 공은 타격하는 등 좋은 공을 선별하는 능력을 통해 출루를 우선시하는 타자라는 것이다. 이에 해당하는 스카웃 후보 선수들은 다음과 같다.



[그림 11] 모델 2 상위 선수 빈도 그래프

[그림 11]을 토대로 높은 OBP를 기록할 확률이 높은 선수들을 추출했다. 빈도 수와 모델 2의 변수 중요도가 높았던 변수 3개를 고려한 최종 스카웃 후보 리스트는 다음과 같다.

순위↵	Frequency↵	이름↵
1↵	53↵	Jose Abreu↵
		Michael Conforto↵


순위	BB %	Whiff %	IZ_contact %
1	Michael Conforto (12.8895)	Robbie Grossman (10.5477)	Travis d'Arnaud (87.6348)
2	Jose Abreu (9.6036)	Danny Jansen (18.4734)	Jose Abreu (87.4274)
3	Jace Peterson (8.3596)	Orlando Arcia (20.2351)	Orlando Arcia (87.0260)

[표 6] 모델 2 최종 스카웃 후보 리스트

높은 OBP를 기록할 확률을 가진 상위 2인은 53회의 Jose Abreu, Michael Conforto이다. 변수 중요도가 가장 높았던 bb_percent의 상위 3인은 Michael Conforto, Jose Abreu, Jace Peterson이다. 변수 중요도가 2번째로 높았던 whiff_percent의 상위 3인은 Robbie Grossman, Danny Jansen, Orlando Arcia이다. 마지막 iz_contact_percent의 상위 3인은 Travis d'Arnaud, Jose Abreu, Orlando Arcia이다.

2.3 스카우팅 모델 3(장타형 모델)

모델 3의 경우, 빈도가 높은 상위 선수는 일관되게 높은 SLG 확률을 예측한다. 변수 중요도를 고려하면 이 선수들의 공통점은 linedrives_percent, babip, hard_hit_percent 등 타구 특성과 관련된 지표에서 강점을 갖춘 타자라는 점이다. 타격 시 타구 속도가 매우 빠르거나 라인드라이브와 같은 타구들은 강한 타구를 의미하므로 타구가 강할수록 장타를 생산하기에 유리한 타자라는 것이다. 이에 해당하는 스카웃 후보 선수들은 다음과 같다.



[그림 12] 모델 3 상위 선수 빈도 그래프

[그림 12]를 토대로 높은 SLG를 기록할 확률이 높은 선수들을 추출했다. 빈도 수와 모델 3의 변수 중요도가 높았던 변수 3개를 고려한 최종 스카웃 후보 리스트는 다음과 같다.

순위↩	Frequency↩	이름↩
1↩	51↩	Michael Conforto↩
2↩	50↩	Jeff McNeil↩

순위↵	BABIP↵	Hard Hit %↵	<u>Linedrive %↵</u>
1↵	Tyrone Taylor↵ (0.3520)↵	Daniel Vogelbach↵ (52.7892)↵	Corey Seager↵ (29.1658)↵
2↵	Daniel Vogelbach↵ (0.3343)↵	Tyrone Taylor↵ (52.5169)↵	Jeff McNeil↵ (27.8365)↵
3↵	Yan Gomes↵ (0.3281)↵	Enrique Hernández↵ (50.5948)↵	Daniel Vogelbach↵ (25.8021)↵

[표 7] 모델 3 최종 스카웃 후보 리스트

높은 SLG를 기록할 확률을 가진 상위 2인은 51회의 Michael Conforto, 50회의 Jeff McNeil이다. 변수 중요도가 가장 높았던 babip의 상위 3인은 Tyrone Taylor, Daniel Vogelbach, Yan Gomes이다. 변수 중요도가 2번째로 높았던 hard_hit_percent의 상위 3인은 Daniel Vogelbach, Tyrone Taylor, Enrique Hernández이다. 마지막 linedrives_percent의 상위 3인은 Corey Seager, Jeff McNeil, Daniel Vogelbach이다.

제 4장 결론

제 1절 연구 결과 종합 및 시사점 도출

모델별로 높은 종속 변수가 높은 확률을 가지는 빈도 수를 통해 유형마다 종합적으로 우수한 선수를 우선적으로 파악할 수 있었다. 그리고, 변수 중요도가 높았던 3개의 변수들마다 상위 3인 역시 리스트에 선정되어 구단의 타격 특성에 맞는 선수들을 영입하는 데 도움을 줄 수 있었다.

특점 생산력 모델에서는 Pete Alonso, Michael Conforto, Brandon Belt 등이 종합적으로 팀의 득점 창출에 보탬이 선수인 것으로 파악되었다. 또한, 득점 생산에 장타력을 중시하는 팀이라면 Eugenio Suarez를, 컨택을 중시하는 팀이라면 Brandon Belt, Michael Conforto 등이 영입 후보가 될 수 있다. 출루형 모델에서는 Jose Abreu, Michael Conforto 등이 높은 볼넷 비율을 토대로 종합적으로 높은 출루율을 기록할 수 있는 선수들인 것으로 파악되었다. 그리고, Robbie Grossman은 압도적으로 낮은 헛스윙율을 기록할 것이라 예상되는 선수이므로 선구안과 컨택을 타자가 필요한 팀들은 영입을 고려해볼 수 있다. 장타형 모델에서는 Jeff McNeil, Daniel Vogelbach 등이 종합적으로 장타 생산 능력이 좋은 선수들인 것으로 파악되었다. Daniel Vogelbach은 가장 높은 하드 히트 비율을 기록할 것이라 예상되는 선수로 강한 타구를 통해 라인드라이브성 타구를 만들어내는 선수이다. 또한, Jeff McNeil도 역시 상대적으로 높은 라인드라이브 비율을 보여주고 있기에 거포가 아니더라도 2루타를 다수 생산할 수 있는 중장거리형 타자를 원하는 팀이라면 영입 후보가 될 수 있다.

제 2절 한계점 및 향후 연구 방향성 제언

2.1 한계점

본 연구는 다음과 같은 한계를 지닌다. 첫째, 모델을 적용시키기에는 데이터의 표본 수가 상대적으로 적었다. 본 연구에서는 2021~2024년의 데이터만을 수집하였는데, 2020년의 경우는 코로나로 인해 60경기 단축시즌으로 진행되었다. 그래서, 2020년의 데이터가 다른 연도에 비해 소표본이기 때문에 포함시킨다면 결측치가 상당수 발생하고, 예측 신뢰도를 크게 떨어뜨릴거라 판단하여 제외하였다. 그리고, 2020년을 제외하고 2019년부터 이전 데이터를 넣는 것 또한 연속성 측면에서 문제를 발생시켜 신뢰도를 크게 떨어뜨릴 우려가 있어 역시 제외하였다. 이러한 과정을 거치면서 2020년대의 4년치 데이터만을 가져오게 되었고, 표본의 수가 매우 적어져 4년 중 1년만 우수한 성적을 거두게 되더라도 상대적으로 좋은 예측 결과가 나오게 되어 모델 예측의 신뢰성에 의문이 생길 수 있다는 한계를 지닌다. 둘째, 변수 내에서 다른 요인들을 완벽하게



통제하지 못했다. 모델마다 선택된 변수들 중에서 순수 타격 능력 요인으로 계산되는 변수는 소수이다. 대부분의 변수가 상대팀의 수비력, 구장 환경 등의 영향을 받는 변수들이기에 모델의 예측 확률이 높게 나온 선수일지라도 특정 스카우팅 모델에서 요구하는 능력치가 뛰어나다고 단정 지어 말하기에는 다른 요인들의 영향도 있을 수 있다는 한계를 지닌다. 또한, 해당 모델에서는 추세가 반영되지 않았기 때문에 나이에 의한 성적 하락 요소를 고려하지 못했다. 실제로, 예측 결과가 우수했던 Jose Abreu, Michael Conforto 등은 현재 노쇠화로 인해 성적이 대폭 하락했거나 은퇴를 앞두고 있는 선수들인 것을 보면 예측에 한계가 있다는 것을 알 수 있다. 셋째, 선수별 이적료 및 연봉, 그리고 구단 예산 등 경제적 지표에 대하여 반영하지 못했다. 실력이 좋은 선수라도 구단이 감당할 수 없는 고액 연봉자이거나, 영입 시 경쟁으로 인해 이적료가 크게 상승하는 경우에는 영입이 불가능하다. 또한, 구단 별로 재정 상황이 차이가 많이 나기 때문에, 비용과 관련된 정보 없이 스카우팅 모델에 따른 선수 영입은 한계가 있다.

2.2 향후 연구 방향성 제언

위와 같은 한계점들을 보완하기 위해 다음과 같은 향후 연구를 진행해볼 수 있다. 2020년 데이터를 기존 정규시즌 162경기에 맞춰 데이터를 예측 혹은 변환 후 추가할 수 있다. 2020년의 데이터를 기존 데이터에 맞게 변환할 수 있다면, 2020년뿐만 아니라 2019년 이전 데이터들도 함께 수집이 가능하기 때문에 연속성이 보장되고 데이터 표본 수 역시 안정적으로 확보할 수 있다. 데이터의 표본 수를 늘리고, 추세까지 반영할 수 있다면, 예측 결과에 대한 신뢰성 역시 크게 상승할 수 있다. 또한, 타격능력 뿐만 아니라 포지션과 수비력 등을 반영한 스카우팅 모델을 구축해볼 수 있다. 타자의 경우 소화할 수 있는 수비 포지션에 따라 평가가 달라진다. 그래서, 타자의 수비 요인도 함께 반영한 새로운 스카우팅 모델을 만든다면, 이전 모델 보다 유용한 모델을 생성할 수 있을 것이다. 마지막으로, 선수별 연봉 데이터를 수집하여 금액 범위에 따른 스카우팅 방식을 추가할 수 있다. 비용 정보를 반영할 수 있다면, 실질적으로 적용 가능한 스카우팅 모델을 구축할 수 있을 것이다.

참고문헌

- 1) 조선미, 김주학, 강지연, 김상균, “머신러닝(XGBoost) 기반 미국프로야구(MLB)의 투구별 안타 및 홈런 예측 모델 개발, 한국체육측정평가학회지, 2023.
- 2) 조선미, 김주학, 강지연, “야구 경기 승패 예측을 위한 합성곱 신경망(CNN) 최적화 연구”, 한국체육측정평가학회지, 2022.
- 3) 이기봉, 황수웅, “MLB 타자의 경기력 유형에 따른 팀 승률 변화 분석”, 한국체육측정평가학회지, 2023.
- 4) 정용찬, “범죄 데이터를 활용한 재범 예측통계 기법 비교 분석”, 경기대학교 대학원 범죄심리학과 석사학위논문, 2022.
- 5) 황보연, “로지스틱 회귀 분류에서 모형 선택 방법과 비교”, 서울시립대학교 일반 대학원 통계학과 석사학위논문, 2023.

