



AI모델의 해석 가능성을 통한 카드사 고객 인사이트 탐색

: ML/DL w/ LIME & SHAP



Motivation

: XAI / eXplainable AI





- Gradient Boost 모델, 인공 신경망과 같은 일부 ML/DL 모델은 블랙박스 모델임.

블랙박스(black-box) 모델: 내부 작동 방식이나 결정 과정을 사람이 직관적으로 이해하거나 설명하기 어려운 모델

- 금융 도메인에선 단순히 예측/분류 모델보다 결과를 통해 인사이트를 도출할 수 있는 설명 가능한, XAI가 필요하다고 생각.
- XAI(eXplainable AI)는 ML/DL 알고리즘이 생성한 결과와 아웃풋을 인간이 이해하고 신뢰할 수 있도록 하는 일련의 프로세스와 방법

Motivation

: XAI / LIME & SHAP



- LIME과 SHAP 분석을 통해 각 특성이 개별 고객 예측에 미치는 영향을 확인하고, 주요 변수를 파악해 인사이트를 도출
- 분석을 통해 도출한 인사이트를 개별 고객에게 제공하거나 정책 결정에 사용함으로써 모델 신뢰성과 활용도를 높일 수 있음

Data

: dacon 신용카드 사용자 데이터

신용카드 고객 세그먼트 분류 AI 경진대회

알고리즘 | 월간 데이콘 | 정형 | 금융 | 분류 | F1 Score

₩ 상금 : 데이스쿨 프로 구독권

🕒 2025.03.10 ~ 2025.04.30 09:59

[+ Google Calendar](#)

👤 1,167명 📅 D-17



- 회원 정보, 신용 정보, 승인매출 정보, 청구입금 정보, 잔액 정보등 카드사 고객에 대한 변수들을 포함한 (2400000, 858) 사이즈의 Tabular data
- 이런 정보들로 A~E 세그먼트로 분류하는 것이 dacon 신용카드 사용자 데이터의 주 목적

EDA (Exploratory Data Analysis)

: dacon 신용카드 사용자 데이터

- 데이터 구조
 - 신용카드 사용자에 대한 정보가 8개로 나뉘어 parquet 형태로 제공
 1. 회원정보 (77개 칼럼) + Segment
 2. 신용정보 (42개 칼럼)
 3. 승인매출정보 (406개 칼럼)
 4. 청구입금정보 (46개 칼럼)
 5. 잔액정보 (82개 칼럼)
 6. 채널정보 (105개 칼럼)
 7. 마케팅정보 (64개 칼럼)
 8. 성과정보 (49개 칼럼)

Table

Data type by columns


Dtype	Number of columns
int64	747
float64	61
object	50

- Object type의 약 40%의 열에서 결측치 발견
 - **CatBoost, XGBoost**의 경우 자동 결측치 처리
 - **TabNET**의 경우, 보간법을 사용해 결측치 처리

EDA (Exploratory Data Analysis)

: dacon 신용카드 사용자 데이터

- 타깃 변수인 Segment 분포 시각화 결과
 - 일정한 순서가 존재하도록 구성
- But, 순서에 대한 구체적인 정보 X
- 다섯 개의 클래스(A~E)로 구성
 - Segment A, B는 극히 적은 수로 구성되어 있음
- > 모델링때, 클래스 불균형 문제에 대한 고려 필요



Methods

: XGBoost / CatBoost / TabNet



CatBoost

TabNet: Attentive Interpretable Tabular Learning

Sercan Ö. Arık, Tomas Pfister

Google Cloud AI
Sunnyvale, CA

soarik@google.com, tpfister@google.com

- Tabular Data 분류에서 높은 성능을 보이는 CatBoost, XGBoost 사용

Rank	Model	Accuracy	↑ Paper	Code	Result	Year
1	CatBoost	86.39 ± 0.04	Hopular: Modern Hopfield Networks for Tabular Data			2022
4	XGBoost	84.58 ± 0.00	Hopular: Modern Hopfield Networks for Tabular Data			2022


Methods

: XGBoost / CatBoost / TabNet

TabNet: Attentive Interpretable Tabular Learning

Sercan Ö. Arik, Tomas Pfister

Google Cloud AI
Sunnyvale, CA
soarik@google.com, tpfister@google.com




- 2019년 구글에서 개발한 Tabular data 분석을 위한 딥러닝 아키텍처
- Tabular data에서도 트리 모델 수준의 성능을 보여줌
- Gradient Boosting 모델과 경쟁 가능한 딥러닝 대안으로 제시됨


Models: Strategy



CatBoost




- 계층적 다단계(hierarchical multi-stage) 접근법을 채택
- 다중 클래스 간의 상이한 특성 및 분포를 효율적으로 고려하고자 고안
- AB그룹과 CDE그룹의 비즈니스적 의미 차이가 존재할 것으로 예상
- AB, CDE그룹을 분류하는 1단계 Binary Classification, 하위 그룹을 분류하는 2단계 Multi-class Classification
- 1단계 분류에선 Random Forest, 2단계 분류에선 CatBoost 사용



Models: Strategy



CatBoost



- 이진 분류(AB v.s. CDE)에는 Random Forest 사용
 - Random Forest가 여러 Decision Tree를 앙상블하기 때문에, 노이즈에 강하고, 과적합 방지에 효과적
∴ 전체 데이터셋에 대해 학습할 때, 보다 안정적 예측이 가능하다고 판단
- 하위 그룹 (AB, CDE)엔 CatBoost Classifier 사용
 - AB 그룹에서 Segment B에 해당하는 샘플 수가 매우 적어 클래스 가중치를 도입하여 과소학습 방지

Models: Strategy



CatBoost

하이퍼파라미터 튜닝

- Optuna 패키지 기반 하이퍼파라미터 튜닝을 수행함
 - 목표 함수: Stratified 3-Fold를 활용한 교차검증 평균 Macro F1-Score
 - 각 하위 그룹별로 20회 반복 수행됨

Table

Best paramaters of CatBoost (obtained from Optuna)

Parameter	Optimal value	
	Group AB	Group CDE
learning rate	0.099	0.147
Depth	10	8
L2 leaf reg	0.003	2.475
border count	50	

Models: Strategy



CatBoost

Review

Foundations and Innovations in Data Fusion and Ensemble Learning for Effective Consensus

Ke-Lin Du¹, Zhenyu Zhang², Jiangbingchun³, Jiaxin⁴ and Jiabin⁴

최종 예측 결합

¹ School of Mechanical and Electrical Engineering, Guangdong University of Science and Technology, Guangzhou 523668, China; kedu@gdut.edu.cn
² Zhejiang Yugong Information Technology Co., Ltd., Changhe Road 475, Hangzhou 310002, China; zrg@yugwig.com
³ Shenzhen Feng Xing Tai Bao Technology Co., Ltd., Shenzhen 518063, China; zj@fxtb.cc
⁴ Faculty of Electromechanical Engineering, Guangdong University of Technology, Guangzhou 510006, China; lujiabin@gdut.edu.cn
* Correspondence: jiangbingchun@gdut.edu.cn

- Du et al. (2025)에 따르면, 다수결 투표는 복수의 분류기를 결합하는 가장 직관적이고 효과적인 방법
- 복수의 분류기에서 동일 ID에 대해 여러 예측 결과가 존재 시, 가장 많이 등장한 세그먼트를 최종 예측값으로 채택
- 최종 모델의 견고성과 예측 성능 향상에 기여

Models: Performance




CatBoost

Table

Classification performance by segment

Segment	Precision	Recall	F1 Score
A	1.00	1.00	1.00
B	1.00	1.00	1.00
C	0.82	0.72	0.77
D	0.80	0.75	0.77
E	0.96	0.98	0.97




- Segment A와 B는 Precision, Recall, F1 Score 모두 1.00으로 완벽하게 분류됨.
- Segment E 역시 F1 Score 0.97로 높은 예측력을 보임.
- 다만 Segment C와 D는 일부 오분류가 존재함.

Models: Strategy



클래스 불균형



- Segment 당 샘플 수의 비율에 반비례하는 값으로 class에 가중치를 부여

Table

Class counts

Segment	Count
A	972
B	144
C	127590
D	349242
E	1922052

$$w_c = \frac{N}{n_c}$$

(C: set of all classes,
N: total number of samples)

Table


Weights by segment

Segment	Weight
A	2469.14
B	16666.67
C	18.81
D	6.87
E	1.25

Models: Strategy



핵심 특성 선택



- 'gain' 값을 기준으로 특성 중요도(Feature Importance) 상위 90%에 해당하는 특성 채택
(gain: 트리 기반 모델에서 노드 split할 때 정보 획득량)
- 핵심 특성을 채택하여 최종 모델을 학습


※ Feature Importance v.s. SHAP value

Feature Importance: 어떤 특성이 전체적으로 성능 개선에 기여했는가
SHAP value: 이 샘플에서 이 특성이 예측 결과에 어떻게 영향을 미쳤는가

Models: Strategy



교차 검증 기반 앙상블 모델링



- 모델의 일반화 성능과 안정성을 확보하기 위해 5-Fold Stratified Cross-Validation을 적용
- 총 5개의 개별적인 XGBoost 모델을 학습
- 최종 예측은 각 모델의 예측 확률을 평균하여 결정하는 방식


Models: Performance



Table


Classification performance by segment

Segment	Precision	Recall	F1 Score
A	0.99	0.94	0.96
B	0.97	1.00	0.98
C	0.84	0.91	0.88
D	0.77	0.91	0.83
E	0.99	0.95	0.97



Models: Strategy

TabNET



weights (*either 0, 1, dict or iterable*) –

if 0 (default) : no **weights** will be applied if 1 : classification only, will balanced class with inverse frequency if dict : keys are corresponding class values are sample weights if iterable : list or np array must be of length equal to nb elements

in the training set

- TabNET 학습 과정에서 weights 파라미터를 1로 설정하여 클래스 가중치 부여

Models: Strategy

TabNET

하이퍼파라미터 튜닝

- TabNET은 하이퍼파라미터 튜닝이 중요하다고 언급됨
 - Attentive Transformer를 통해 중요한 feature를 선택하는데, 이 attention을 적절하게 제어하기 위해 하이퍼파라미터가 사용됨
- 튜닝한 하이퍼파라미터
 - Categorical Embedding Dimension: 범주형 변수 임베딩 벡터 차원 수
 - Learning rate: Optimizer가 가중치 업데이트할 때 이동하는 크기
 - Step size: feature를 반복적으로 선택하고 처리하는 반복 단계
 - Gamma: step마다 선택된 feature를 다음 step에서 얼마나 억제할지에 대한 값

Table

Hyper-parameters of TabNET (obtained from Optuna)

Categorical embedding dimension	34
learning rate	0.0001623
step size	89
weights	1
gamma	0.3629426

Models: Performance


TabNET

Table

Classification performance by segment (TabNET)

Segment	Precision	Recall	F1 Score
A	0.85	0.92	0.88
B	0.67	0.97	0.79
C	0.64	0.89	0.75
D	0.52	0.79	0.63
E	0.98	0.87	0.92

Note. Macro F1 Score: 0.7936



- Segment A와 B는 소수 클래스임에도 불구하고 높은 F1-Score, 재현율을 달성함
- Segment E 역시 F1 Score 0.92로 높은 예측력을 보임.
- 다만 Segment C와 D는 일부 오분류가 존재함.

Models: Performance

Table

Model Performance

Model	Accuracy	Macro F1 Score
CatBoost	0.93	0.90
XGBoost	0.94	0.93
TabNET	0.85	0.79


- 정확도, Macro F1 스코어 모두 XGBoost가 가장 높음
- XGBoost > CatBoost >> TabNET

EXplainable AI

:LIME result by Segment

세그먼트 A 고객 예시 (idx=1242)

Prediction probabilities




NOT B

B

정상입금원금_B2M
0.00
청구금액_B0
0.00
정상청구원금_B2M
0.00
정상청구원금_B5M
0.00
정상입금원금_B0M
0.00
정상청구원금_B0M
0.00
월중평잔_CA
0.00
잔액_현금서비스_B1M
0.00
잔액_할부_B0M
0.00
이용금액_할부_무이...


Feature	Value
정상입금원금_B2M	75393.00
청구금액_B0	79205.00
정상청구원금_B2M	75393.00
정상청구원금_B5M	71995.00
정상입금원금_B0M	57067.00
정상청구원금_B0M	57067.00
월중평잔_CA	32074.00
잔액_현금서비스_B1M	32263.00
잔액_할부_B0M	27142.00
이용금액_할부_무이자_R3M	20425.00

Prediction probabilities



NOT 0

0



- XGBoost
 - 금액 중심 (정상입금원금, 청구금액 등)
 - Segment A는 상대적으로 입금 및 청구 금액이 낮거나 특정 패턴을 따름
- TabNET
 - 리볼빙 잔액이 없고, 무이자 사용이 적은 경우 A로 분류될 확률이 낮아짐
 - 유이자 할부 사용 이력이 있는 경우 A일 가능성 높아짐

EXplainable AI

:LIME result by Segment

세그먼트 B 고객 예시 (idx=14256)

Prediction probabilities

A	0.00
B	1.00
C	0.00
D	0.00
E	0.00

NOT B

B

할부금액_무이자_3M...
0.02
할부금액_3M_R12M
0.01
포인트_포인트_월적...
0.01
이용금액_할부_무이자...
0.01
정상입금원금_B2M
0.01
포인트_포인트_월적...
0.01
이용금액_할부_R12M
0.01
할부건수_무이자_3M...
0.01
정상청구원금_B2M
0.01
포인트_포인트_건...
0.01

Feature	Value
할부금액_무이자_3M_R12M	110814.00
할부금액_3M_R12M	110814.00
포인트_포인트_월적립_B0M	18719.00
이용금액_할부_무이자_R12M	110814.00
정상입금원금_B2M	50627.00
포인트_포인트_월적립_R3M	31111.00
이용금액_할부_R12M	110814.00
할부건수_무이자_3M_R12M	30.00
정상청구원금_B2M	50627.00
포인트_포인트_건별_R3M	17742.00

Prediction probabilities

0	0.00
1	1.00
2	0.00
3	0.00
4	0.00

NOT 1

1



여유_항공이용금액 >...
0.09
이용건수_D페이_B0M...
0.07
이용금액_D페이_B0M...
0.07
RP건수_가스_B0M >...
0.03
승인거절건수_기타_R...
0.03
_3순위여유업종_이용...
0.02
포인트_마일리지_환산...
0.02
IB문의건수_BL_R6M ...
0.00
한도요청거절건수 <=...
0.00
연체잔액_현금서비스_...
0.00



- XGBoost
 - 포인트 중심 (포인트 월적립, 건별 등)
 - Segment B는 포인트와 리워드 중심의 소비 성향을 보임
- TabNET
 - 항공/디지털 페이/포인트 관련 Feature가 높으면 Segment B로 분류될 확률이 높아짐
-> 활동적이고 혜택을 중시하는 소비자



EXplainable AI

:LIME result by Segment



Feature	Value
이용금액_일시불_R12M	194256.00
입회일자_신용	20040601.00
연체입금원금_B0M	11648.00
잔액_신판최대한도소진율_r6m	0.71
이용금액_R3M_신용	80998.00
이용금액_선결제_B0M	7620.00
이용금액_할부_R3M	16399.00
연체입금원금_B2M	11589.00
이용금액_오프라인_R3M	120918.00
이용금액_선결제_R6M	80440.00

Prediction probabilities



- XGBoost

- 일시불 이용금액이 큼
- 선결제 성향, 연체가 없음


- TabNET

- 고객센터 문의가 적은 경우 오히려 C로 분류될 가능성이 낮음
- 정상청구원금, 일시불 이용금액이 높은 경우 Segment C에 기여함
-> 자주 문의하고, 일시불 거래와 정상청구액이 많은 사용자

EXplainable AI


:LIME result by Segment

Prediction probabilities



NOT B

B




Feature

Value


변동률_일시불평잔	1.46
거주시도명	1.00
마일_이용포인트_R12M	12114.00
마일_적립포인트_R12M	8978.00
포인트_마일리지_환산_B0M	148.00
_1순위여유업종_이용금액	2713.00
포인트_마일리지_건별_R3M	2532.00
마일_이용포인트_R3M	2604.00
증감_RP건수_전월	-1.00
여유_항공이용금액	2713.00

Prediction probabilities



NOT 3

3




- XGBoost
 - 금액 중심 (정상입금원금, 청구금액 등)
 - Segment A는 상대적으로 입금 및 청구 금액이 낮거나 특정 패턴을 따름
- TabNET
 - 리볼빙 이월이 낮고, 문의건수가 적은 경우 Segment D일 가능성이 높음
 - 금융 상품 활용 빈도가 낮고 소극적이고 보수적인 성향일 수 있음

EXplainable AI

:LIME result by Segment

세그먼트 E 고객 예시 (idx=1)

>prediction probabilities




NOT B

B



Feature	Value
이용금액_체크_R12M	46255.00
이용개월수_할부_유이자_R6M	1.00
최종이용일자_CA	20170710.00
잔액_카드론_B4M	33934.00
이용금액_할부_무이자_B0M	3882.00
이용개월수_체크_R3M	3.00
이용개월수_체크_R6M	6.00
할부건수_무이자_3M_R12M	16.00
이용개월수_카드론_R12M	1.00
이용금액_B페이_R3M	1264.00

Prediction probabilities



NOT 4

4



- XGBoost

- 체크카드 위주 소액 거래 반복
- 최종 이용일자가 과거임
- 할부 건수도 적음

- TabNET


- 일시불 이용금액이 적고, 한도 감액 요청이나 학습비와 같이 특수 지출이 없는 고객
-> 완전 소극적 소비 성향 또는 휴면 고객일 가능성이 높음

EXplainable AI

:SHAP result (Global)

- 이용금액_일시불_R6M은 Segment E를 분류할 때 가장 중요한 변수
-> 일전의 LIME 결과 참고

- 최종카드론 대출금액은 Segment A를 분류할 때 가장 기여하는 변수
-> Segment A 고객들이 카드사의 상품을 자주 사용하는 고객이라는 점을 생각하면 타당함



LIME 결과와 어느 정도 일맥상통하는 부분이 있음

Insight



- **Segment A:**

VIP 고객/ 카드사의 금융 상품을 적극적으로 사용하는 고객

- 리볼빙 잔액이 높음
- 유이자 할부 사용액이 높음
- 카드론 대출 금액이 가장 큰 영향을 미침

-> **고객의 재무 스트레스 상황을 파악해 추가 금융 상품 제안 기회로 활용 가능**

Insight



- **Segment B:**

활동적이고 혜택을 중시하는 소비자

- 항공 이용 금액이 높음
- 디지털 페이 사용 금액이 높음
- 포인트, 마일리지 환산 금액이 높음

-> 해외, 디지털 소비 성향을 기반으로, 맞춤형 리워드 및 제휴 혜택 제공 기회

Insight



- **Segment C:**
 - 거래량도 많고 문의가 많은 고객
 - 문의건수가 높음
 - 일시불 거래와 정상청구액이 많음

➔ 거래 활동이 활발하고 서비스 기대 수준이 높은 고객
➔ 맞춤형 상담, 서비스 제공을 통해 충성고객으로 유치할 가능성

Insight



- **Segment D:**
비활성/보수형 고객군
 - 리볼빙 이월이 낮음
 - 문의건수가 적음
 - 금융 상품 사용 자체가 적은 고객군

-> 유인형 혜택이나 재활성화 캠페인을 통해 잠재적 수요 발굴 필요

Insight



- **Segment E:**

비활성 사용자 또는 휴면 전환 직전 고객

- 일시불 이용금액이 적음
- 한도 감액 요청
- 학습비와 같은 특수 지출이 적음

-> 소비 활동과 금융 니즈 모두 낮아, 휴면 해지 관리 대상으로 분류 필요
최소비용 리마케팅이 필요

감사합니다