

DAT 5기 캡스톤 프로젝트 보고서

fMRI 기반 이야기 등급 자동 분류 모델 개발

: 트랜스포머 모델 기반 fMRI 이야기 등급 판별 연구

DAT 5기

Neuro – pamine

김동휘

하수연

한지현



Data Analysis & Technology



DAT 5기 캡스톤 프로젝트 보고서

fMRI 기반 이야기 등급 자동 분류 모델 개발

: Transformer 모델 기반 fMRI 이야기 등급 판별 연구

fMRI-Based Story Rating Classification Model

:Transformer-Based fMRI Story Rating Classification Study

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2024년 6월 3일

DAT 5기

Neuro – pamine

김동휘

하수연

한지현

DAT 5기 캡스톤 프로젝트 보고서



Data Analysis & Technology



fMRI 기반 이야기 등급 자동 분류 모델 개발

: Transformer 모델 기반 fMRI 이야기 등급 판별 연구

국문 요약

본 연구는 345명의 피험자가 다양한 이야기텔링을 청취할 때 수집된 기능적 자기공명영상(fMRI) 반응 데이터를 활용하여, 각 이야기의 연령 등급(전체, 15세, 19세)을 자동으로 분류하는 딥러닝 기반 모델을 개발하는 데 목적이 있다. 기존의 영상물 등급제와 달리, 본 연구는 음성 콘텐츠의 등급 분류에 fMRI 데이터를 직접 적용한 점에서 차별성을 가진다. 정교한 데이터 전처리와 체계적인 모델 훈련 과정을 거쳐, 최종 성능 평가 결과 개발된 모델이 각 이야기의 연령 등급을 높은 정확도로 자동 예측할 수 있음을 확인하였다. 이번 연구는 뇌신경 반응을 활용한 콘텐츠 등급 자동 분류의 가능성을 제시하였으며, 이는 향후 폭증하는 미디어 콘텐츠를 사람이 일일이 구별하는 데 한계가 있다는 현실적 문제를 보완할 수 있는 새로운 접근법이다. 특히, 기존 등급 분류 체계에서 주관적 판단이 개입될 수 있는 점을 고려할 때, 본 연구의 성과는 음성 및 다양한 미디어 등급 분류의 자동화와 객관성 제고에 기여할 수 있을 것으로 기대된다.

Abstract

This study aimed to develop a deep learning-based model that automatically classifies the age rating (General, 15+, 19+) of each story using functional magnetic resonance imaging (fMRI) response data collected from 345 participants while listening to various storytelling. Unlike conventional rating systems for visual content, this research differentiates itself by directly applying fMRI data to the age classification of audio content. Through meticulous data preprocessing and systematic model training, the final performance evaluation demonstrated that the developed model could accurately and automatically predict the age rating of each story. This study presents the potential for automatic content classification using neural responses, offering a new approach to address the practical limitation of manually classifying the ever-increasing volume of media content. In particular, given the subjectivity that can influence traditional rating schemes, the achievements of this research are expected to contribute to the automation and objectivity of age classification systems for audio and various media content in the future.

DAT 5기

Neuro – pamine

김동휘

하수연

한지현



Data Analysis & Technology



목차

제1장 서론.....	3
제1절 연구 배경 및 연구 목적.....	3
1.1.1 연구 배경.....	3
1.1.2 연구 목적.....	3
제2장 데이터소개.....	4
제1절 데이터셋 개요.....	4
제2절 전처리 과정.....	4
2.1.1 이야기 오디오와 트랜스크립트의 구간 정렬.....	4
2.1.2 이야기별 연령 등급 라벨링.....	5
2.1.3 텍스트-뇌 시계열 정렬 및 분할.....	5
제3장 연구 방법론.....	6
제1절 모델 전체 파이프라인 개요.....	6
제 2절 학습 설정 및 하이퍼파라미터 & 평가 지표 및 실험 환경.....	7
3.2.1 학습 설정 및 하이퍼파라미터.....	8
3.2.1 평가 지표 및 실험 환경.....	8
제 4장 결론.....	10
제 1절 연구 결과 및 보고.....	10
4.1.1 최종 모델 (fMRI + 텍스트 동시 입력).....	10
4.1.2 텍스트 임베딩만 입력.....	10
4.1.3 fMRI feature만 입력.....	12
4.1.4 성능 비교 요약.....	13
제 2절 한계점 및 향후 연구 방향.....	13
4.2.1 해당 연구의 한계점.....	13
4.2.2 향후 연구 방향.....	14
참고 문헌.....	15



표 목차

표1. 실험별 주요 성능 지표 비교.....	14
--------------------------	----

그림 목차

그림 1. fMRI 기반 이야기 등급 분류 모델 파이프라인.....	7
그림 2. 최종 모델 결과.....	11
그림 3. 텍스트 임베딩만 사용한 경우 - 실험 A.....	12
그림 4. 텍스트 임베딩만 사용한 경우 - 실험 B.....	12
그림 5. fMRI feature만 사용한 경우 - 실험 C.....	13
그림 6. fMRI feature만 사용한 경우 - 실험 D.....	13
그림 7. SwiFUN 모델 아키텍처.....	15



제1장 서론

제1절 연구 배경 및 연구 목적

1.1.1 연구 배경

최근 인공지능과 신경과학의 발전에 따라, 인간의 뇌 신호를 활용한 다양한 데이터 분석 및 예측 연구가 활발하게 이루어지고 있다. 특히, 기능적 자기공명영상(functional Magnetic Resonance Imaging, fMRI)은 비침습적으로 인간의 뇌 활동을 측정할 수 있다는 장점 덕분에, 신경생물학, 심리학, 그리고 인지과학 등 다양한 분야에서 중요한 도구로 활용되고 있다. 한편, 사회 전반에서 콘텐츠의 연령 등급 분류는 청소년 보호와 미디어 이용의 적절성 측면에서 필수적으로 요구되고 있다. 영화, 게임, 방송 등 시각 매체에 대한 등급제도는 잘 정립되어 있으나, 음성 기반의 이야기텔링이나 오디오북, 팟캐스트 등에는 체계적인 등급 분류 기준이 미흡한 실정이다. 기존의 등급 분류는 주로 내용 분석에 의존하고 있어, 수용자(청취자)의 실제 뇌 반응을 반영하지 못하는 한계가 있다. 이러한 배경에서, 본 연구는 이야기텔링을 듣는 동안 측정된 fMRI 반응 데이터를 활용하여, 각 이야기의 연령 등급(전체, 15세, 19세)을 자동으로 분류하는 딥러닝 기반 모델을 개발하고자 한다. 뇌 반응을 통한 등급 분류는 기존 평가 방식과 차별화되는 시도로, 뇌신경 신호의 객관적 분석을 통해 보다 과학적이고 신뢰도 높은 등급 판별이 가능할 것으로 기대된다.

1.1.2 연구 목적

본 연구의 목적은 이야기텔링을 청취하는 동안 피험자들에게 측정된 기능적 자기공명영상(fMRI) 데이터를 활용하여, 각 이야기의 연령 등급(전체, 15세, 19세)을 자동으로 분류할 수 있는 딥러닝 기반 모델을 개발하는 데 있다. 이를 위해, fMRI 신호와 이야기 텍스트의 특징 벡터를 결합하고, 회귀와 분류를 동시에 학습하는 다중 MLP(Multi-Layer Perceptron) 구조를 적용함으로써 신경 신호의 연속적 특성과 등급 구분의 명확성을 모두 반영하고자 하였다. 신경 신호와 자연어 정보를 통합하여 콘텐츠 등급을 예측하는 새로운 방법론을 제시함으로써, 뇌신경 반응을 기반으로 한 인공지능 미디어 분석 분야의 발전에 기여한다. 또한, 뇌 반응을 활용한 객관적 등급 분류 모델이 청소년 보호와 건전한 미디어 환경 조성에 실질적으로 기여할 수 있음을 보여주고, 향후 음성 기반 콘텐츠, 오디오북, 팟캐스트 등 미디어 다양화 시대에 적합한 새로운 등급 평가 체계의 가능성을 제시하는 데 그 의의가 있다.

제2장 데이터소개

제1절 데이터셋 개요

해당 프로젝트에서는 인간의 자연언어 이해 과정에서의 뇌 활성 패턴을 분석하고자, 공개된 대규모 fMRI 데이터셋인 Narratives Dataset를 활용하였다. 해당 데이터셋은 프린스턴 대학교 Princeton Neuroscience Institute의 Nastase et al. (2021)에 의해 수집되었으며, 자연스러운 이야기(narrative)를 청취하는 동안의 뇌 반응을 기록한 고해상도 fMRI 데이터를 포함한다. Narratives 데이터셋은 총 345명의 피험자가 참가하였다. 참가자들의 연령은 18세~53세 사이로 이루어져 있으며, 모두 영어를 유창하게 구사하며 정상적인 청력을 가지고 있다고 보고하였다. 모든 참가자는 Princeton University Institutional Review Board에서 승인된 실험 절차에 따라 데이터를 수집하기 전에 정보에 입각한 서면 동의를 제공하였다. 각 피험자는 총 27개의 서로 다른 이야기 중 일부를 들으며 fMRI 스캔을 진행하였다. 각 피험자는 스캐너 안에서 이야기를 듣는 동안 움직이지 않도록 하였으며, 모든 오디오 자극은 MRI 소음 환경에서도 들을 수 있도록 조정되어 있다. 이야기의 길이는 4~15분이며, 이야기 자극은 주로 전문 연사와 방송 자료를 기반으로 제작되었다. 데이터 특징으로는 BIDS 포맷에 맞춰 정리되었으며, fMRIPrep을 통해 전처리가 수행되었다. (움직임 보정, 시공간 정렬, 노이즈 제거 등) 각 피험자에 대해 시간 분해능 1.5초(TR=1.5s)의 fMRI 시계열 데이터(.nii.gz 형식)와 함께, 각 이야기의 오디오 파일이 함께 제공된다. 더불어 이야기별 자극 메타정보(*_bold.json)에는 스캔 길이, 자극 길이, 볼륨 수 등 분석에 필요한 핵심 정보가 포함되어 있어 feature extraction에 용이하다. 이처럼 Narratives 데이터셋은 자연어 이해의 뇌 표현을 정량적으로 분석하고, 딥러닝 기반의 텍스트-뇌 정보 매핑 모델을 개발하는 본 캡스톤 프로젝트에 적합한 고품질의 다중 모달 신경 데이터셋이라 할 수 있다.

제2절 전처리 과정

본 연구에서는 Narratives Dataset의 fMRI 시계열 데이터와 대응되는 이야기 오디오 및 텍스트 데이터를 효과적으로 결합하여, 신경 반응 기반 이야기 등급 분류 모델의 입력 데이터를 구축하였다. 전체 전처리 과정은 (1) 이야기 오디오와 트랜스크립트의 구간 정렬, (2) 연령 등급 라벨링, (3) 텍스트-뇌 시계열 정렬의 3단계로 구성된다.

2.1.1 이야기 오디오와 트랜스크립트의 구간 정렬

각 이야기의 오디오 파일(.wav)은 해당 이야기의 전사본(Transcript)과 매칭된다. 원본 전사본은



일반적으로 .txt 형식이지만, 후처리 및 자연어 처리 효율성을 위해 문장 단위로 구분하여 .csv 파일로 저장하였다. 이 과정에서 시간 정보(타임스탬프)를 기반으로 각 문장에 해당하는 오디오 구간을 정확히 지정하였다. 추후 텍스트 임베딩 및 fMRI 프레임 매핑 시, 문장별 위치 정보가 유지되도록 하였다.

2.1.2 이야기별 연령 등급 라벨링

각 이야기에는 “전체”, “15세”, “19세(청소년 열람 불가)”의 3단계 연령 등급 라벨을 부여하였다. 등급 분류 기준은 실제 영상물 등급제와 유사한 원칙을 참고하였으며, 각 이야기의 내용, 표현 수위, 사회적 함의 등을 반영하였다. 라벨링 결과는 추가적인 데이터 파일(.csv)에 이야기별 메타데이터로 정리되어, 이후 딥러닝 분류 모델의 지도 학습(label supervised learning)에 사용된다.

2.1.3 텍스트-뇌 시계열 정렬 및 분할

효율적인 feature extraction을 위해 각 이야기의 텍스트 파일(txt) 역시 시간 정보를 기준으로 fMRI 시계열 프레임에 맞추어 분할하였다. 각 이야기의 Repetition Time(TR) 및 *_bold.json 파일의 자극 길이, 볼륨 수 등의 메타정보를 참고하여, Pretrained된 fMRI feature extraction model의 프레임 단위인 20프레임(1.5초 * 20) 단위로 텍스트 대본을 분할하였다. 각 분할 구간에 해당하는 문장(또는 문장 묶음) 정보를 기록해, 향후 text feature 추출 및 뇌 반응 매핑 과정에서 자동으로 매칭될 수 있도록 구성하였다. 이 과정은 뇌 반응 데이터와 언어 자극이 정밀하게 정렬되어 입력 벡터를 만들 수 있도록 하는 데 핵심적이다.

이처럼 다단계 전처리 과정을 통해, fMRI 시계열 신호와 정제된 텍스트 피쳐, 그리고 연령 등급 라벨이 일관성 있게 연결된 고품질의 학습 데이터를 구축할 수 있었다. 본 전처리 과정은 자연어-신경 신호 매핑 및 이야기 등급 분류 모델 개발의 기반이 되었다.

제3장 연구 방법론

제1절 모델 전체 파이프라인 개요




그림 1. fMRI 기반 이야기 등급 분류 모델 파이프라인

본 연구에서는 fMRI 기반 이야기 등급 분류를 위해, 뇌 반응 데이터와 텍스트 정보를 통합적으로 활용하는 딥러닝 기반 모델 파이프라인을 설계하였다. 전체 파이프라인은 (1) fMRI feature vector 추출, (2) 텍스트 임베딩 추출 및 매칭, (3) 회귀 기반 뇌 반응 예측, (4) 등급 분류의 4단계로 구성된다.

(1) fMRI Feature Vector 추출

먼저, 각 피험자의 fMRI 시계열 데이터(4D 볼륨)는 96×96×96의 공간 해상도로 리샘플링된다. 이후, 실험 이야기의 자극 정보(onset, duration)를 참고하여, 20 프레임(윈도우) 단위로 시계열 구간을 슬라이딩 윈도우 방식으로 분할한다. 구간별 4D fMRI 볼륨은 SwiFT(Swin 4D fMRI Transformer) 모델에 입력되어, 각 구간별로 고차원 feature vector가 추출된다. SwiFT 모델은 3D 패치 파티셔닝, 계층적 self-attention, 글로벌 시공간 임베딩 등 첨단 구조를 활용하여 뇌 반응의 복잡한 패턴을 효과적으로 벡터화한다.

(2) 텍스트 임베딩 추출 및 구간 매핑

각 이야기의 전사본(Transcript)은 fMRI 데이터의 시간 구간과 정확히 매칭될 수 있도록, TR(1.5초) 단위로 분할된다. 각 구간의 문장 텍스트는 Sentence-BERT(SBERT) 네트워크에 입력되어 768차원의 임베딩 벡터로 변환된다. 이렇게 구간별로 얻어진 텍스트 임베딩과 fMRI feature vector를 1:1로 매칭하여, 자연어 정보와 뇌신경 반응 정보를 통합적으로 입력 데이터로 구성한다.

(3) 회귀 기반 뇌 반응 예측(Regression)

텍스트 임베딩을 입력으로, 해당 시간 구간의 fMRI feature를 예측하는 회귀 모델(MLP 구조)을 학습한다. 입력-정답 쌍(텍스트 임베딩, 실제 fMRI feature)을 활용해 회귀 손실함수로 파라미터를 업데이트한다. 이를 통해, 이야기 텍스트로부터 뇌 반응 feature를 예측할 수 있는 모델을 구축한다.

(4) 등급 분류(Classification)

회귀 모델을 통해 예측된(또는 실제 측정된) fMRI feature vector는 mean pooling을 통해 이야기 단위로 요약된다. 이후, 이 요약 feature와 이야기의 연령 등급 라벨(전체, 15세, 19세)을 입력-정답 쌍으로 하여 분류기(MLP 기반)를 학습한다. 분류 손실함수(cross-entropy 등)를 활용해 모델을 최적화한다. 최종적으로, 새로운 이야기의 텍스트 임베딩만으로 뇌 반응을 예측하고, 이를 기반으로 연령 등급을 자동 분류하는 파이프라인이 완성된다.

(5) 파이프라인의 기술적 의의

본 연구의 파이프라인은 뇌신경 반응과 자연어 정보라는 이질적인 두 데이터를 시계열 동기화와 벡터화 과정을 통해 통합적으로 처리함으로써, fMRI 기반 콘텐츠 등급 분류라는 새로운 연구 방향을 제시한다는 데 그 기술적 의의가 있다. 특히, 최신 4D Swin Transformer(SwiFT)와 Sentence-BERT(SBERT) 모델을 각각 fMRI 데이터와 텍스트 데이터에 적용하여, 인간의 뇌 반응과 언어 표현의 복합적인 패턴을 고차원 임베딩 벡터로 추출하였다. 또한, 회귀와 분류를 동시에 다루는 멀티태스크 딥러닝 구조를 구현함으로써, 실제 뇌 반응을 예측하는 정량적 회귀와 사회적 의미가 담긴 등급 분류를 결합한 새로운 자동화 모델을 개발하였다. 이러한 기술적 시도는 뇌 신호 기반 미디어 평가 체계의 가능성을 실증적으로 입증할 뿐만 아니라, 향후 다양한 모달리티의 융합 인공지능 연구와 실생활에서의 실용적 적용 가능성까지 제시한다는 점에서 의의가 크다.

제 2절 학습 설정 및 하이퍼파라미터 & 평가 지표 및 실험 환경

본 연구에서 구현한 딥러닝 모델은 회귀(Regression)와 분류(Classification) 모두 2계층 MLP 구조를 사용하였다. 텍스트 임베딩(769차원)을 입력받아 512차원 은닉층을 거쳐 fMRI feature(288차원)를 예측하는 fMRI prediction model과, 예측된 fMRI feature를 512차원 은닉층을 통해 3개의 연령 등급으로 분류하는 Classification model로 각각 구성하였다. 모델 파라미터 및 차원 설정 등은 최적의 학습 및 예측 성능을 도출하기 위해 실험적으로 결정되었다.

3.2.1 학습 설정 및 하이퍼파라미터

본 연구에서는 사전에 전처리된 fMRI feature와 이야기 텍스트 임베딩 데이터를 사용하였다. 각 데이터셋은 .pt 파일 형태로 저장되어 있으며, 실험 시작 시 해당 데이터를 불러와 메모리로 로딩한다. 데이터는 전체, 15세, 19세 등급 라벨과 함께 각각의 이야기 혹은 시간 구간 단위로 정렬되어 있다. 이후 학습, 검증, 테스트 세트로 분할하여 모델의 성능 평가에 활용한다. 모델은 크게 회귀(Regression) 헤드와 분류(Classification) 헤드로 이루어진 멀티태스크 구조로 설계되었다. 회귀 헤드는 텍스트 임베딩(예: SBERT, 769차원)을 입력으로 받아, fMRI feature(288차원)를 예측하는 역할을 한다. 분류 헤드는 예측된 fMRI feature에 대해 Mean pooling을 통해 시계열 정보를 요약하여 하나의 feature vector로 만들어 Classification MLP를 통해 최종적으로 3개 등급(전체, 15세, 19세) 중 하나로 분류한다. 각 헤드는 fully connected 레이어와 비선형 ReLU 활성화 함수로 구성되어 있으며, 중간 은닉 레이어(512차원)를 통해 복잡한 패턴 학습을 가능하게 하였다. 학습 과정에서는 배치(batch)마다 텍스트 임베딩을 회귀 헤드에 입력해 fMRI feature를 예측하고, 동시에 예측된 feature로 분류 헤드에서 등급 예측을 수행한다. 회귀에는 MSE(평균 제곱 오차) 손실 함수를, 분류에는 CrossEntropy 손실 함수를 사용하며, 두 손실값을 합산해 Total loss를 구성하였으며 CrossEntropy 손실에 가중치 Alpha를 두어 분류 과정의 학습을 조절하며 파라미터를 업데이트한다. Optimizer로는 Adam을 사용하여, 학습률, 베타 등 주요 하이퍼파라미터는 실험적으로 결정하였다. 학습 과정에서 에폭(epoch)별로 손실값, 분류 정확도 등을 기록하여 모델의 수렴 여부를 확인하였다. 최종 학습된 모델의 가중치는.pth파일 형태로 저장하였다. 이를 통해 연구 결과의 재현성을 확보하고, 후속 연구에 용이하게 활용할 수 있도록 하였다.

3.2.1 평가 지표 및 실험 환경

본 연구에서는 개발된 모델의 성능 평가를 위해 다음과 같은 지표를 활용하였다.

- 정확도(Accuracy): 모델이 다양한 등급(전체, 15세, 19세)에 대해 얼마나 신뢰성 있게 예측을 수행하는지를 확인하는 기본 지표로 활용하였다.
- 정밀도(Precision) : 모델이 특정 등급(예: 15세)으로 예측한 사례 중에서 실제로도 해당 등급에 속하는 비율을 의미한다. 잘못된 등급 판정을 최소화하는 능력을 보여주며, 특히 오탐(False Positive)을 줄이는 데 중점을 둘 때 중요한 지표이다.
- 재현율(Recall): 실제로 특정 등급에 해당하는 데이터 중에서 모델이 그 등급을 얼마나 잘

찾아냈는지를 의미한다. 놓치는 등급이 적은지(즉, 누락된 판정이 적은지)를 판단하는 데 사용된다.

- F1-score: 정밀도와 재현율의 조화 평균으로, 두 지표의 균형을 한눈에 평가할 수 있다. 본 연구처럼 각 등급이 골고루 잘 예측되어야 하는 분류 문제에서, 단일 지표로 모델의 효율성을 평가할 수 있다.
- 매크로 평균(Macro Average), 가중 평균(Weighted Average): 매크로 평균은 각 등급의 지표를 단순 평균한 값으로, 클래스 불균형 상황에서도 모든 등급의 성능을 고르게 반영하는 데 의미가 있다. 가중 평균은 각 등급의 데이터 수를 반영하여 전체적인 평균 성능을 나타낸다.
- 혼동행렬(Confusion Matrix): 실제 등급과 모델의 예측 등급 간의 관계를 시각적으로 표현한 표로, 어떤 등급에서 오분류가 발생하는지, 각 등급이 얼마나 정확하게 예측되었는지 상세하게 분석할 수 있다.
- MSE(Mean Squared Error) Loss: fMRI feature 벡터 예측에서, 실제 값과 예측값 간의 차이의 제곱 평균을 나타낸다. 본 연구의 회귀 모델이 뇌 신호 패턴을 얼마나 정확하게 복원했는지를 정량적으로 평가하는 지표이다.
- Cross Entropy Loss: 분류 문제에서, 모델이 실제 정답 등급과 예측 확률 분포가 얼마나 가까운지를 평가한다. 낮은 손실값은 모델이 등급 분포를 더 정확히 예측했음을 의미한다.

실험 결과, 본 연구에서 개발한 모델은 테스트 데이터셋에서 모든 지표에서 1.00의 값을 기록하며 매우 정확한 분류 성능을 보였다. 추가적으로, 회귀 손실(MSE)과 분류 손실(Cross-Entropy) 역시 낮은 수치를 기록하여, fMRI feature 예측과 등급 분류 모두에서 우수한 성능을 달성하였다. 다만 fMRI feature만 단독 입력하거나, 텍스트 임베딩만 단독 입력했을 때의 분류 성능은 동시에 입력했을 때와 비교적 낮은 성능을 보이는 것을 확인하였다. 모든 실험은 Linux Ubuntu 22.04 운영체제에서 수행되었으며, GPU는 4070 ti super를 사용하였다. 최신 버전의 딥러닝 프레임워크와 주요 라이브러리를 활용하여 모델 개발을 진행하였다.



제 4장 결론

제 1절 연구 결과 및 보고

4.1.1 최종 모델 (fMRI + 텍스트 동시 입력)

```
Test Accuracy: 1.0000
Test MSE Loss: 0.1030
Test CrossEntropy Loss: 0.4524

Confusion Matrix:
[[ 46  0  0]
 [ 0 103  0]
 [ 0  0 46]]

Classification Report:

```

	precision	recall	f1-score	support
all	1.00	1.00	1.00	46
15	1.00	1.00	1.00	103
19	1.00	1.00	1.00	46
accuracy			1.00	195
macro avg	1.00	1.00	1.00	195
weighted avg	1.00	1.00	1.00	195




그림 2. 최종 모델 결과

fMRI feature와 텍스트 임베딩을 함께 활용한 모델은 테스트 데이터 전체에서 단 한 건의 오분류 없이 모든 이야기 등급(전체관람가, 15세, 19세)을 정확하게 분류하였다(Test Accuracy: 1.00). 모든 클래스에서 precision, recall, f1-score가 1.00으로 나타났으며, 혼동 행렬 역시 완벽한 분류 결과를 보여주었다. 또한 MSE Loss(0.1030)와 CrossEntropy Loss(0.4524) 역시 낮은 값을 기록했다. 이는 신경 반응 정보와 의미 정보를 동시에 활용할 때 이야기 등급 판별에서 탁월한 성능을 달성할 수 있음을 보여준다.

4.1.2 텍스트 임베딩만 입력




그림 3. 텍스트 임베딩만 사용한 경우 - 실험 A




그림 4. 텍스트 임베딩만 사용한 경우 - 실험 B

실험 A(learning rate = 0.00002)에서는 텍스트 임베딩만 입력한 모델이 테스트 데이터에서 전체 정확도 0.7385를 기록하였다. 혼동 행렬을 보면 전체관람가 샘플 중 41개만 올바르게 분류하고 5개는 모두 15세 등급으로 오분류했으며, 15세와 19세 등급은 각각 103개, 46개 모두 완벽하게 분류하였다. 분류 리포트 결과, 전체관람가의 precision은 1.00, recall은 0.89, f1-score는 0.94로 비교적 높은 값을 보였으나, 15세 등급은 precision 0.67, recall 1.00, f1-score 0.80, 19세 등급은 precision 0.00, recall 0.00, f1-score 0.00으로 집계되어 등급 간 불균형이 나타났다. 전체 accuracy는 0.74, macro 평균은 0.56, weighted 평균은 0.59로, 일부 등급에서 편향된 분류 경향이 확인된다.

실험 B(learning rate = 0.000005)에서는 테스트 정확도가 0.5282로 더 낮게 나타났다. 전체관람가 샘플은 단 한 건도 올바르게 분류하지 못했고(전부 15세 등급으로 오분류), 15세와 19세 등급만 각각 103개, 46개로 완벽하게 예측했다. 분류 리포트에서는 전체관람가의 precision, recall, f1-score가 모두 0.00으로 기록되었으며, 15세 등급은 precision 0.53, recall 1.00, f1-score 0.69, 19세 등급 역시 precision 0.00, recall 0.00, f1-score 0.00으로 집계되었다. 전체 accuracy는 0.53, macro 평균은 0.18, weighted 평균은 0.28로, 낮은 학습률에서 텍스트 정보만으로는 효과적인 등급 분류가 어려움을 보여준다.

즉, 실험 A에서는 텍스트만으로 15세, 19세 등 일부 클래스는 완벽히 분류하였으나 ‘전체’ 등급의 경우 5건 오분류가 발생하였으며, 19세 등급은 아예 분류가 되지 않는 것을 확인할 수 있었다. 실험 B에서는 학습률을 더 낮췄기에 전체/19세 등급을 아예 구분하지 못 하고 모든 테스트 샘플을 15세로만 예측하는 극단적 불균형 현상이 나타났다.

4.1.3 fMRI feature만 입력




그림 5. fMRI feature만 사용한 경우 - 실험 C




그림 6. fMRI feature만 사용한 경우 - 실험 D

실험 C(learning rate = 0.00002)에서는 fMRI feature만을 입력으로 활용한 모델이 테스트 데이터에서 정확도 0.4872를 기록하였다. 전체관람가 등급에서는 단 하나의 샘플도 올바르게 분류하지 못했으며, 15세 등급에서는 103개 중 95개만 정확히 예측(precision 0.51, recall 0.92, f1-score 0.66)하고, 8건을 전체관람가로 오분류하였다. 19세 등급은 46개 모두 완벽하게 예측했으나, 전체 및 19세 등급의 precision, recall, f1-score는 모두 0.00으로 집계되었다. 전체 accuracy는 0.49, macro 평균 0.17, weighted 평균 0.27로, 텍스트 임베딩만 활용한 경우보다 성능 저하가 뚜렷하게 나타났다.

실험 D(learning rate = 0.000005)에서는 정확도 0.5282로 소폭 개선된 결과를 보였으나, 전체관람가와 19세 등급 모두 단 한 건도 올바르게 분류하지 못했다. 15세 등급에 대해서만 103개 모두 정확히 예측(precision 0.53, recall 1.00, f1-score 0.69)하였으며, 전체 및 19세 등급의 precision, recall, f1-score는 모두 0.00으로 나타났다. 전체 accuracy는 0.53, macro 평균 0.18, weighted 평균 0.28로, 모든 샘플을 15세로만 예측하는 클래스 편향이 극명하게 드러났다.

결론적으로, fMRI feature만 단독으로 입력한 경우 전체 등급과 19세 등급에 대한 분류 성능이 급격히 저하되며, 대부분의 테스트 샘플을 15세 등급으로 예측하는 클래스 편향 현상이 두드러지게 나타났다. 특히, 텍스트 임베딩만 입력했을 때보다도 성능 저하가 뚜렷하다는 점에서 fMRI 신경 반응 정보만으로는 이야기 등급을 효과적으로 판별하기 어렵다는 한계가 드러난다.

4.1.4 성능 비교 요약

실험 조건	학습률	정확도	전체 F1	15세 F1	19세 F1	주요 특징
최종 모델 (fMRI+text)	0.00002	1.00	1.00	1.00	1.00	모든 등급에서 오분류 없음
Only text (A)	0.00002	0.74	0.94	0.80	0.00	19세 등급 분류 실패, ALL 일부 오분류
Only text (B)	0.000005	0.53	0.00	0.69	0.00	모든 샘플을 15세로 예측 (단일 클래스 쏠림)
Only fMRI (C)	0.00002	0.49	0.00	0.66	0.00	15세만 일부 분류, ALL/19세 분류 불가
Only fMRI (D)	0.000005	0.53	0.00	0.69	0.00	모든 샘플을 15세로 예측 (단일 클래스 쏠림)

표1. 실험별 주요 성능 지표 비교

이러한 결과는 fMRI feature만을 입력으로 활용할 경우, 15세 등급만 일부 맞추고 나머지 등급은 거의 구분하지 못하는 등 전반적으로 분류 성능이 매우 저하됨을 보여준다. 실험 B와 D 모두에서 전체 및 19세 등급을 전혀 예측하지 못하고, 모든 샘플을 15세로만 분류하는 극단적 편향 현상이 반복적으로 관찰되었다. 반면, fMRI feature와 텍스트 임베딩을 모두 입력으로 활용한 모델에서는 정확도, 정밀도, 재현율, F1-score 모두 1.00으로 테스트셋의 모든 등급을 완벽하게 분류하는 성능을 보였다. 이는 두 정보원이 상호 보완적으로 작용함으로써, 단일 정보원 사용에서 발생한 클래스 편향과 분류 실패 현상을 효과적으로 해소하고 모델의 분류 신뢰도를 극대화할 수 있음을 시사한다.

제 2절 한계점 및 향후 연구 방향

4.2.1 해당 연구의 한계점

본 연구는 fMRI 신경 신호와 텍스트 정보를 융합하여 이야기 등급 분류 모델을 개발하였으나, 다음과 같은 한계점을 내포하고 있다.

첫째, 사용 가능한 데이터의 양이 제한적이어서, 대규모 뇌영상 데이터를 활용한 심층 학습 모델의 일반화 성능을 충분히 검증하는 데 제약이 있었다.

둘째, 등급 라벨링 과정에서 객관적이고 표준화된 지표의 부재로 인해, 등급 기준의 일관성과 신뢰성 확보에 어려움이 있었다. 특히 라벨링 작업을 관련 분야의 전문가가 아닌 연구자 본인이 직접 수행함에 따라, 실제 영상물 등급 기준(전체, 13세, 15세, 19세)과는 다르게 전체, 15세, 19세의 3개 등급으로만 분류할 수밖에 없었던 한계가 존재한다. 이에 따라 등급 간 경계가 모호해지거나, 일부 데이터에 대한 라벨링의 주관성이 성능 평가에 영향을 미쳤을 가능성이 있다.

4.2.2 향후 연구 방향




그림 7. SwiFUN 모델 아키텍처

본 연구는 현재 fMRI와 텍스트 임베딩을 융합해 등급 분류를 수행하였으나, 향후에는 텍스트 데이터만을 입력으로 사용하여 fMRI 신경 반응을 예측하는 모델로의 발전 가능성이 있다. 최근 제안된 SwiFUN 모델 구조는(그림 7) resting-state fMRI와 task fMRI 간의 변환을 Transformer 기반 구조로 구현하여, 병목(bottleneck) feature를 중심으로 정보의 변환 및 압축을 효과적으로 수행한다는 점에서 주목할 만하다. 특히, 본 연구에서 구축한 텍스트→fMRI feature 회귀 모델을 통해 생성된 fMRI feature를 SwiFUN 구조의 병목 구간에 삽입하는 방식은, 기존의 resting-state를 대체하여 텍스트 기반으로 뇌 활성 패턴을 재구성할 수 있는 새로운 가능성을 제시한다. 이러한 방식은 SwiFT 및 SwiFUN의 다중 해상도 피쳐 통합, 시공간적 attention, residual 연결 구조의 장점을 그대로 활용할 수 있으면서, 자연어 자극만으로 뇌 반응을 예측하고 복원하는 end-to-end 신경망 설계로 확장될 수 있다. 결국, 텍스트만을 이용해 fMRI feature를 예측한 뒤 이를 SwiFUN의 bottleneck에 입력하게 되면 예상되는 결과는 다음과 같다. 다양한 자연어 자극에 대한 뇌 활성 예측의 정확도를 높이고, 실제 fMRI 데이터를 대체/보완할 수 있는 데이터 효율적 모델 학습이 가능하며, 향후 task fMRI가 없는 상황에서도 대규모 뇌 반응 시뮬레이션 및 미디어 등급 분류 등 새로운 응용 연구가 가능할 것으로 기대된다. 따라서, 향후 연구에서는 본 프로젝트의 멀티모달 회귀 모델과 SwiFUN 구조를 접목해, 텍스트만으로도 task fMRI 활성 패턴을 생성·복원하고, 실제 뇌 반응 예측, 인지 신경과학 해석, 미디어 자동 등급화 등 다양한 분야로의 확장 가능성을 모색할 계획이다.

참고 문헌

1. Huang, T., Liu, J., Li, X., Li, Q., Zhou, L., & Zhang, Z. (2024). Predicting task-related brain activity from resting-state brain dynamics with fMRI Transformer. *bioRxiv*.
2. Nastase, S. A., Liu, Y. F., Hillman, H., Norman, K. A., & Hasson, U. (2021). The “Narratives” fMRI dataset for evaluating models of naturalistic language comprehension. *Scientific Data*, 8, Article 250.
3. Kim, P., Kwon, J., Joo, S., Bae, S., Lee, D., Jung, Y., ... & Moon, T. (2023). Swift: Swin 4d fmri transformer. *Advances in Neural Information Processing Systems*, 36, 42015-42037.
4. Reimers, N., & Gurevych, I. (2019). Sentence-bert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*.

