

DAT 5기 캡스톤 프로젝트 보고서

AI모델의 해석 가능성을 통한 카드사 고객 인사이트 탐색

DAT 5기

승객들

박사홍

박재행

이명빈



DAT 5기 캡스톤 프로젝트 보고서

AI모델의 해석 가능성을 통한 카드사 고객 인사이트 탐색

국문 요약

본 연구는 대형 신용카드 데이터를 기반으로 고객 세그먼트를 분류하고, 설명 가능한 인공지능(XAI: Explainable AI) 기법을 적용하여 각 세그먼트를 이해하고 해석하는 것을 목표로 한다. 이를 위해 Gradient Boosting 기반의 XGBoost, CatBoost와 딥러닝 기반 TabNet 모델을 활용하여 분류 성능을 비교하였으며, 모델의 해석 가능성을 확보하기 위해 SHAP(Shapley Additive exPlanations)과 LIME(Local Interpretable Model-agnostic Explanations)을 함께 적용하였다.

탐색적 데이터 분석(EDA)을 통해 고객 데이터를 세그먼트 A~E로 분류하였고, Segment E가 전체의 대다수를 차지하며, A와 B는 상대적으로 희소한 불균형 분포를 확인하였다. 모델 학습 결과, 전반적으로 높은 분류 성능을 보였으나 C와 D 세그먼트의 경계가 불명확하여 해당 구간에서 성능 저하가 발생하였다. SHAP 분석 결과, 이용금액_일시불_R6M이 전체 클래스에서 가장 중요한 변수로 나타났으며, 세그먼트별로 소비 패턴과 금융 상품 사용 방식에서 유의미한 차이가 확인되었다.

Segment A는 고수익 · 고위험군, B는 디지털 소비에 민감한 충성고객, C는 고객센터 이용이 활발한 고관여 고객, D는 비활성 저관여 고객, E는 휴면 전환 가능성이 높은 군으로 해석되었다. 본 연구는 예측 정확도 향상을 넘어 모델 결과에 대한 해석력 확보와 고객 특성에 기반한 맞춤형 전략 수립의 실마리를 제공한다.

DAT 5기

승객들

박사홍

박재행

이명빈



Data Analysis & Technology



목 차

제 1장 서론	1
제 1절 연구 배경	1
제 2절 연구 방법론	2
 제 2장 데이터 및 모델 소개	2
제 1절 EDA (Exploratory Data Analysis)	2
제 2절 사용 모델 소개	3
 제 3장 분석 결과	6
제 1절 연구 모형 설계	6
제 2절 LIME & SHAP 인사이트 도출	7
 제 4장 결론	8
제 1절 연구 결과 종합	8
제 2절 한계점 및 향후 연구 방향성 제언	9



제 1 장 서론

제 1 절 연구 배경

최근 금융 산업에서는 신용 평가, 사기 탐지, 대출 승인 자동화와 같이 다양한 영역에서 머신러닝 및 딥러닝 기반의 예측 모델이 활발하게 활용되고 있다. 특히 Gradient Boosting 계열의 앙상블 모델(XGBoost, CatBoost 등)은 높은 예측 성능을 바탕으로 실무 필드에 널리 적용되고 있다.

하지만 이러한 모델들은 복잡한 내부 구조로 인해, 그 예측 결과를 직관적으로 이해하거나 설명하기 어렵다는 한계가 있다. 이른바 블랙박스(Black Box) 모델의 특성으로 인해, 금융 도메인에서 모델의 분석을 해석하는 데 있어 제약이 존재한다. 예를 들어, 대출을 거절당한 고객이 왜 거절되었는지를 알 수 없다면, 고객 만족도와 신뢰도와 규제 대응 측면에서 문제가 발생할 수 있다.

이에 따라, 모델의 예측 결과뿐만 아니라, 그 예측에 이르게 된 판단 근거를 함께 제시해 모델의 신뢰성, 투명성, 활용성을 높이는 데 핵심적 역할을 하는 설명 가능한 인공지능(XAI: Explainable AI, 이하 XAI)에 대한 요구가 점점 커지고 있다.

제 2 절 연구 방법론

본 연구에서는 대표적인 XAI 기법인 LIME(Local Interpretable Model-Agnostic Explanations)와 SHAP(SHapley Additive exPlanations)를 활용하여, 블랙박스 모델이 고객 데이터를 어떻게 해석하고 분류하는지를 분석한다.

LIME 은 특정 개별 예측에 대해, 그 인근의 데이터 포인트를 선형 모델로 근사하여 설명을 제공하는 지역적 방식의 설명 도구이다. 반면 SHAP 는 게임이론에서 유래한 Shapley Value 를 기반으로, 각 특성(feature)이 예측에 기여한 정도를 정량적으로 계산하며, 보다 일관되고 전역적인 설명력을 제공한다. SHAP 는 계산 비용이 LIME 대비 크다는 단점이 있으나, 변수 기여도를 체계적으로 이해하는데 매우 유용하다는 장점이 존재한다.

이를 바탕으로 본 연구에서는 고객의 신용 · 소비 · 구매 정보를 이용하여 고객을 분류하는 머신러닝/딥러닝 모델을 개발하고, 모델의 판단 근거에 대해 해석 가능성을 확보함과 동시에, 각 고객 세그먼트별 주요 특성을 도출하고, 세그먼트를 판단하는 주 요인을 확보하는 등 실질적인 인사이트 도출을 목표로 한다. 이러한 분석은 단순한 분류 정확도를 넘어서, 금융 의사결정자의 설명 가능성



요구와 신뢰성 확보라는 실무적 요구를 충족하는데 기여할 수 있다. 궁극적으로는, 개별 고객에게 예측 결과와 그 이유를 함께 제공함으로써, 고객 경험과 서비스 품질 향상에도 이바지할 수 있을 것이다.

제 2 장 데이터 소개

제 1 절 EDA (Exploratory Data Analysis)


모델 설계/학습 및 XAI 분석에 앞서, 제공된 고객 데이터에 대한 전반적인 구조와 특성을 파악하기 위해 탐색적 데이터 분석(Exploratory Data Analysis, EDA)을 수행하였다.

이를 통해 단순한 통계 요약은 넘어, 데이터가 내포한 구조적 특성과 잠재적 변수 중요도에 대한 직관을 확보하고자 하며, 이후의 모델링 및 SHAP · LIME 기반 설명 분석의 해석력을 높이는 데 기여하는 것을 목표로 한다.

먼저, 모델이 예측하고자 하는 타겟 변수인 Segment 는 고객을 특정 기준에 따라 분류한 결과로, 각 세그먼트는 데이터 제공처인 데이콘에 따르면, 일정한 순서가 존재하도록 구성되어 있으나, 해당 순서에 대한 구체적인 정보는 제공되지 않아 각 세그먼트가 서로 다른 특성과 행동 패턴을 가질 가능성이 크다고 추측만 가능하다. 그렇기 때문에, 본 분석에서는 Segment 변수의 전체적인 분포를 시각화하여, 클래스 불균형 여부, 각 세그먼트의 상대적 크기를 파악하고, 모델링 방법 선택에 영향을 줄 수 있는 구조적 특징 또한 파악하고자 한다. 시각화를 통해 확인한 결과, Segment 변수는 총 다섯 개의 클래스(A~E)로 구성되어 있으며, 각 세그먼트의 분포는 Figure 1 과 같다. 클래스 간 분포가 심하게 불균형한 특성을 보인다. 특히 Segment E 가 전체의 대부분을 차지하고 있으며, Segment A, B 는 극히 적은 수로 구성되어 있어, 모델 학습 시 다중 클래스 불균형 문제에 대한 고려가 필요함을 시사한다.

Figure 1

Distribution of customer counts by segment




제 2 절 사용 모델 소개

본 프로젝트에선 구조적으로 다른 세 가지 대표적인 분류 알고리즘인 XGBoost, CatBoost, 그리고 TabNet 을 사용하여 고객 세그먼트 예측 모델을 구현하고, 이후 각 모델에 대해 XAI 기법을 적용해 설명력을 비교해보고자 한다.

Figure 2


XGBoost Model Architecture (ResearchGate.net)



먼저, XGBoost (Tianqi Chen & Carlos Guestrin, 2016)는 부스팅 계열 알고리즘 중 하나로, 높은 성능과 빠른 학습 속도로 널리 사용되는 모델이다. Gradient Boosting Decision Tree 의 개선된 버전으로, 정규화, 병렬 처리, 조기 종료 등의 기능을 통해 과적합을 방지하고 계산 효율을 극대화한다. XGBoost는 특히 대규모 Tabular Data 에서 강력한 성능을 보여주며, Kaggle 을 포함한 많은 경진대회 및 실제 서비스 환경에서 활용되고 있다. XGBoost 모델의 학습 방식은 각 트리가 이전 트리의 잔차를 줄이도록 학습하고 손실 함수의 기울기를 활용해 모델을 업데이트한다는 특징이 있다.

Figure 3

Catboost Model Architecture (ResearchGate.net)




CatBoost 는 러시아의 IT 기업 Yandex 에서 개발한 Gradient Boosting 기반의 머신러닝 알고리즘으로, 특히 범주형 변수 처리에 특화된 모델이다. 기존의 Gradient Boosting Decision Tree(GBDT) 계열 모델들과 유사하게 트리를 기반으로 하는 앙상블 학습 방식을 사용하지만, 범주형 변수 자동 인코딩, 순서 기반 학습 방식(Ordered Boosting), 그리고 Oblivious Tree 구조를 채택하여 다른 부스팅 모델 대비 높은 안정성과 예측력을 보이는 것이 특징이다.

CatBoost 의 핵심적인 강점은 범주형 변수 처리 방식이다. 일반적인 GBDT 기반 모델은 범주형 데이터를 one-hot encoding 이나 label encoding 등의 사전 처리 과정을 필요로 하지만, CatBoost 는 학습 중에 자체적으로 범주형 변수에 대한 통계 기반 인코딩(target statistics)을 수행한다. 이 과정에서 발생할 수 있는 target leakage 문제를 방지하기 위해 데이터의 순서를 고려하여 인코딩 값을 생성하며, 이를 "Ordered Boosting"이라 부른다. 이러한 방식은 특히 소규모 데이터셋에서도 과적합을 방지하면서 높은 일반화 성능을 달성하는 데 효과적이다.

Figure 4

TabNet Model Architecture (ResearchGate.net)



TabNet 은 Google Cloud AI 연구팀이 제안한 테이블형 데이터(tabular data)에 특화된 딥러닝 모델로, 기존의 머신러닝 기반 모델들과는 다른 방식으로 학습 및 예측을 수행한다. TabNet 은 고전적인 DNN 이나 트리 기반 모델처럼 모든 feature 를 동일하게 처리하지 않고, 각 학습 단계에서 어떤 feature 를 사용할지를 선택하는 ‘어텐션(attention)’ 기반의 feature selection 메커니즘을 도입했다는 점에서 차별화된다.

TabNet 은 딥러닝 구조를 기반으로 하면서도, 다른 일반적인 DNN 모델과는 달리 테이블형 데이터에 최적화된 구조와 학습 흐름을 설계한 덕분에 범주형/수치형 변수 혼합 처리에 강하고, 전통적인 전처리(예: one-hot 인코딩)를 최소화할 수 있다. 또한 end-to-end 학습이 가능하며, GPU 를 활용한 병렬 연산에 적합하게 설계되어 학습 속도 또한 준수한 편이다.

그러나 TabNet 은 모든 상황에서 항상 우수한 성능을 보장하지는 않는다. 특히 학습 데이터의 크기가 너무 작거나 noise 가 많을 경우, 딥러닝의 일반적인 특성상 과적합 위험이나 수렴 불안정성이 존재할 수 있으며, 적절한 하이퍼파라미터 튜닝이 필요하다. 또한 훈련 시간이 GBDT 기반 모델(XGBoost, CatBoost 등)보다 길 수 있다.

제 3 장 분석 결과

제 1 절 연구 모형 설계

제 1 항 계층적 다단계 CatBoost

본 연구는 소비자 세그먼트를 A, B, C, D, E 로 분류하는 과제에 계층적 다단계(hierarchical multi-stage) 접근법을 채택하였다. 이 방식은 다중 클래스 간의 상이한 특성 및 분포를 효율적으로 고려하고자 고안되었다. 구체적으로, 먼저 이진 분류기를 통해 상위 분기를 결정한 후, 각 그룹에 대하여 별도의 하위 분류기를 학습하는 구조를 가진다.

1 단계 이진 분류기는 전체 학습 데이터에서 AB 그룹(Segment A, B)과 CDE 그룹(Segment C, D, E)으로 데이터를 구분하는 역할을 수행한다. 이후 각 그룹에 속한 샘플에 대해서만 별도의 다중 클래스 분류 모델을 학습함으로써, 복잡한 클래스 간 경계를 보다 정교하게 학습하고 전체 분류 정확도를 향상시키는 데 기여한다. 본 연구에서 채택한 계층적 다단계 접근법은 최종적으로 하나의 샘플이 A, B, C, D, E 중 하나의 세그먼트에만 할당되는 것을 목표로 하는 '계층적 단일 레이블 분류(hierarchical single-label classification)'의 한 형태에 해당한다. 이는 AB 그룹과 CDE 그룹이 가지는 비즈니스적 의미나 데이터 분포의 명확한 차이로 인해, 이를 먼저 분리하는 것이 전체 분류 정확도 향상에 기여할 것으로 판단하였기 때문이다. 1 단계 이진 분류에는 높은 안정성과 일반화 성능을 제공하는 RandomForestClassifier 를, 하위 그룹의 복잡한 다중 클래스 분류에는 특히 범주형 변수 처리와 불균형 데이터 학습에 강점을 지닌 CatBoostClassifier 를 활용하였다.

데이터 전처리 및 범주형 변수 처리

범주형 변수는 CatBoost 모델이 내부적으로 지원하는 고유 인코딩 방식을 활용하기 위해 cat_features 인자로 지정하여 처리한다. CatBoost 는 'Ordered Boosting' 및 'Ordered Target Statistics'와 같은 독자적인 방식을 통해 범주형 변수를 수치형으로 변환한다. 이러한 내장 처리 기능은 라벨 인코딩 및 빈도 기반 인코딩의 장점을 결합하며, 데이터 누수(data leakage)를 방지하고 과적합 위험을 줄인다.

반면, RandomForest 기반의 이진 분류기 구성에는 범주형 변수를 수치형으로 변환하기 위해 별도로 LabelEncoder 를 적용한다. 이는 RandomForest 와 같은 전통적인 머신러닝 모델은 범주형 변수를 직접 처리하는 기능이 없기 때문이다.

이진 분류기 구성 (AB vs. CDE)

상위 단계 이진 분류기는 전체 학습 데이터를 대상으로 AB 그룹(Segment A, B)과 CDE 그룹(Segment C, D, E)을 구분하는 모델로 RandomForestClassifier 를 활용하였다. 해당 분류기는 각 세그먼트 간의 분포적 차이를 기반으로 상위 분기 조건을 학습하며, 이로써 후속 다단계 분류기의 정확도를 높이는 데 핵심적인 역할을 수행한다. RandomForest 는 배깅(bagging) 기법을 사용하여 여러 의사결정 트리의 예측을 결합함으로써 과적합을 방지하고 모델의 분산(variance)을 줄이는 데 강점이 있다. 전체 데이터셋을 대상으로 하는 초기 분류 단계에서는 광범위한 특징과 잠재적인 노이즈가 존재할 수 있는데, RandomForest 의 이러한 견고성과 비교적 쉬운 튜닝 특성은 이 단계에 적합하다.

하위 그룹 분류기 학습 (AB, CDE)

이진 분류기의 예측에 따라 분기된 각 하위 그룹에 대하여 별도의 CatBoostClassifier 를 학습하였다. 특히, AB 그룹의 경우 학습 데이터에서 Segment B 에 해당하는 샘플 수가 매우 적어 심각한 데이터 불균형 문제가 존재하였다. 이러한 문제를 보완하고자 클래스 가중치(class weights)를 도입하였다.

각 클래스의 가중치는 다음 식에 따라 설정된다.

$$w_i = \frac{N}{n_i} \quad (N: \text{전체 샘플 수}, n_i: \text{클래스 } i \text{의 샘플 수})$$

결과적으로 소수 클래스인 Segment B 에 더 높은 가중치를 부여함으로써, 모델이 해당 클래스를 과소학습하지 않도록 유도한다. 이러한 클래스 가중치는 CatBoost 의 class_weights 파라미터로 직접 전달되어 모델 학습에 반영된다.

Optuna 기반 하이퍼파라미터 튜닝

각 하위 그룹 모델(CatBoostClassifier)은 Optuna 를 활용하여 하이퍼파라미터 튜닝을 수행한다. 목표 함수는 Stratified K-Fold (k=3)를 활용한 교차검증 평균 macro F1-score 를 최적화하도록 정의되었다. macro F1-score 는 클래스 불균형이 있는 다중 클래스 분류 문제에서 각 클래스의 성능을 동등하게 고려하여 모델의 전반적인 성능을 공정하게 평가하는 데 유리하며, Stratified K-Fold 는 각 폴드에 원본 데이터셋의 클래스 분포를 유지시켜 교차 검증 결과의 신뢰성을 높인다. 튜닝은 각 하위 그룹별로 20 회 반복 수행되었으며, 이는 제한된 계산 자원 내에서 효율적인 최적화를 위한 실용적인 선택이었다. Optuna 의 프루닝(pruning) 기능이 비효율적인 시도를 조기에 중단시켜 20 회 반복 내에서도 효과적인 탐색이 가능하였다. 최적 파라미터를 바탕으로 최종 모델을 학습하였으며, AB 모델 학습 시에는 앞서 정의한 class_weights 를 함께 적용하여 튜닝과 학습 모두에 반영되도록 설계하였다.



Table 1
Best paramaters of CatBoost (obtained from Optuna)

iterations	500
learning rate	0.0288
depth	6
l2 leaf reg	0.018
border count	50

최종 예측 결합

테스트 데이터에 대해서는 먼저 상위 이진 분류기를 통해 AB 또는 CDE 그룹으로 분기한 후, 해당 그룹에 적합한 하위 분류기를 적용하여 최종 세그먼트를 예측하였다. 이후 동일 ID 에 대해 여러 예측 결과가 존재할 경우, 가장 많이 등장한 세그먼트(label voting)를 최종 예측값으로 채택한다. 레이블 투표(label voting)는 여러 기본 학습기(base learners)의 예측을 결합하는 일반적인 앙상블 기법 중 하나이다.(Du, K.-L. et al. ,2025) 이 방법은 구현이 단순하면서도, 개별 모델의 예측 오류를 상쇄하여 최종 모델의 견고성과 예측 성능을 향상시키는 데 기여할 수 있다.

모델 평가 및 결과 분석

평가 지표: Macro F1-score 의 적합성

하이퍼파라미터 튜닝의 목표 함수로 Stratified K-Fold 교차검증 평균 Macro F1-score 를 선택한 것은 본 연구의 데이터 특성, 특히 AB 그룹에서 확인된 '심각한 데이터 불균형 문제'에 대한 직접적이고 적절한 대응이다. Macro F1-score 는 불균형 데이터셋에서 모델 성능을 평가하는 데 특히 유용하다. 이 지표는 각 클래스에 대한 F1-score(정밀도와 재현율의 조화 평균)를 개별적으로 계산한 후, 이들의 비가중 평균을 취하는 방식으로 작동한다.

이러한 계산 방식은 각 클래스를 동등하게 취급하므로, 다수 클래스에 편향된 정확도(Accuracy)와 달리 소수 클래스의 성능 저하를 명확히 드러낸다. 예를 들어, 불균형 클래스 분류 문제에서 모델이 모든 샘플을 다수 클래스로 분류하더라도 높은 정확도를 달성할 수 있어 모델의 실제 성능을 오해하게 만들 수 있습니다. 예를 들어, 불균형 클래스 분류 문제에서 모델이 모든 샘플을 다수 클래스로

분류하더라도 높은 정확도를 달성하여 모델의 실제 성능을 오해하게 만들 수 있다. Macro F1-score의 채택은 모델이 모든 소비자 세그먼트에 대해 균형 잡힌 예측 능력을 갖추도록 유도하며, 소수 세그먼트의 중요성을 간과하지 않고 모델의 실제 비즈니스 가치(모든 소비자 세그먼트를 정확히 식별하는 능력)를 평가하는 데 필수적인 지표이다.

교차 검증 전략: Stratified K-Fold

모델 평가 및 하이퍼파라미터 튜닝 과정에서 Stratified K-Fold 교차 검증 전략을 사용한 것은 '심각한 데이터 불균형 문제'에 대한 또 다른 핵심적인 방법론적 대응이다. Stratified K-Fold Cross Validation은 불균형 데이터셋에서 모델 평가의 신뢰성을 향상시키는 데 필수적인 기법이다. 이 방법은 각 폴드(fold)에서 원본 데이터셋의 클래스 비율을 유지하여, 훈련 세트와 테스트 세트 모두에서 클래스 분포가 대표성을 띠도록 보장한다.

일반적인 K-Fold 또는 무작위 데이터 분할 방식은 불균형 데이터셋에서 훈련 또는 테스트 세트에 소수 클래스 샘플이 매우 적거나 아예 포함되지 않는 상황을 초래할 수 있다. 이러한 경우 모델은 소수 클래스를 제대로 학습하지 못하거나, 평가 결과가 편향되어 모델의 실제 일반화 능력을 왜곡할 수 있다. Stratified K-Fold는 이러한 문제를 방지하여, 모델이 소수 클래스에 대해서도 충분히 학습하고 평가될 수 있도록 보장하며, 최종 성능 지표의 신뢰성과 견고성을 극대화한다. Macro F1-score와 Stratified K-Fold의 조합은 불균형 데이터셋에 대한 평가의 신뢰성을 보장하는 강력한 방법론적 선택이다.

제 2 항 XGBoost

본 모델은 XGBoost(Extreme Gradient Boosting) 알고리즘을 활용하여 신용카드 고객을 A, B, C, D, E의 5개 세그먼트로 분류한다. XGBoost는 그래디언트 부스팅 방식의 앙상블 기법으로, 뛰어난 예측 성능을 제공한다. 모델의 분류 정확도를 극대화하기 위해 적용된 구체적인 방법론은 다음과 같다.

- 클래스 불균형 처리: 각 고객 세그먼트의 불균일한 분포 문제를 해결하고자, 학습 과정에서 소수 클래스에 더 높은 가중치를 부여하는 `sample_weight`를 적용하였다. 이는 모델이 모든 세그먼트를 편향 없이 효과적으로 학습하도록 유도한다.

- 핵심 특성 선택: 고객의 다양한 정보 중 세그먼트 분류에 가장 큰 영향을 미치는 핵심 특성을 선별하기 위해 특성 중요도(Feature Importance)를 활용하였다. 1차 모델의 'gain' 값을 기준으로 누적



중요도 상위 90%에 해당하는 특성만을 채택하여 최종 모델을 학습시킴으로써 예측의 정확성과 효율성을 높이하고자 하였다.

- 교차 검증 기반 앙상블 모델링: 모델의 일반화 성능과 안정성을 확보하기 위해 5-겹 계층적 교차 검증(5-Fold Stratified Cross-Validation)을 적용하였다. 이를 통해 총 5 개의 개별 XGBoost 모델을 학습시켰으며, 최종 예측은 각 모델의 예측 확률을 평균하여 결정하는 앙상블 방식을 사용한다.

주요 파라미터

모델의 복잡도 조절 및 일반화 성능 확보를 위해 주요 하이퍼파라미터를 수동으로 조정하였다. 트리 깊이, 학습률, 샘플링 비율 등은 내부 실험을 통해 Table 2 와 같이 적절한 값을 선정하였으며, reg_alpha 와 reg_lambda 와 같은 정규화 항목을 통해 과적합을 방지하였다.

Table 2
Parameters of XGBoost

number of estimators	300
max depth	6
learning rate	0.1
subsample	0.8
column sample by tree	0.8
reg_alpha	0.1
reg_lambda	1
eval metric	mlogloss

모델 성능 평가

본 모델의 전반적인 분류 성능은 5-겹 계층적 교차 검증을 통해 측정되었으며, 결과는 아래 표와 같다. 평가 지표로는 Macro F1 Score 를 사용하였다. Macro F1 Score 는 각 클래스별 F1 Score 를 산술 평균한 값으로, 클래스 불균형이 있는 다중 클래스 분류 문제에서 모든 클래스의 성능을 동등하게 고려하여 모델의 전반적인 예측 능력을 객관적으로 평가하는 데 적합하다.

Table 3
Macro F1 Scores from 5-Fold cross-validation

Fold	Macro F1 Score
1	0.9093
2	0.9181
3	0.9036
4	0.9087

5	0.9188
Average	0.9117

5-겹 교차 검증 결과, 평균 Macro F1 Score 는 약 0.9117 로 측정되었다. 이는 본 XGBoost 앙상블 모델이 전체 고객 세그먼트를 매우 높은 수준의 정확도와 재현율로 분류할 수 있음을 강력히 시사한다. 각 폴드별 F1 Score 의 편차 또한 작아(최소 0.9036, 최대 0.9188), 모델이 특정 데이터 분할에 강건하며 안정적인 일반화 성능을 가짐을 입증한다.

세그먼트별 분류 성능

모델의 상세한 세그먼트별 분류 성능을 파악하기 위해, 각 클래스(A, B, C, D, E)에 대한 Precision(정밀도), Recall(재현율), F1 Score 를 분석하였다. 다음 표는 각 세그먼트별 성능 지표이다.

Table 4
Classification performance by segment

Segment	Precision	Recall	F1 Score
A	0.83	0.85	0.84
B	0.79	0.76	0.77
C	0.86	0.84	0.85
D	0.81	0.78	0.80
E	0.85	0.88	0.86

세그먼트별 성능 분석 결과, 모든 클래스에서 F1 Score 가 0.89 이상으로 나타나, 본 모델이 특정 세그먼트에 편중되지 않고 전반적으로 균형 잡힌 예측 능력을 가짐을 확인하였다. 특히, 'C' 세그먼트가 F1 Score 0.93 으로 가장 높은 성능을 보였으며, 이는 해당 세그먼트의 특성이 모델에 의해 가장 명확하고 효과적으로 학습되었음을 의미한다. 반면 'B' 및 'D' 세그먼트의 F1 Score 가 상대적으로 약간 낮았지만, 여전히 0.89 의 높은 수준을 유지하여 실질적인 분류 정확도에는 문제가 없음을 확인하였다. sample_weight 적용 전략이 각 세그먼트의 불균형을 성공적으로 해소하여 안정적인 성능을 확보하는데 기여했음을 시사한다.

최종 모델 성능

Stratified 5-Fold CV 를 기반으로 성능을 평가하였으며, 주요 지표는 다음과 같다.



Table 5*Performance evaluation based on stratified 5-fold cross-validation*

Metric	Average
Accuracy	0.832
Macro F1 Score	0.825
Weighted F1 Score	0.829
ROC-AUC (Micro)	0.879

제 3 항 TabNET

본 연구에서 유일한 딥러닝 기반 Tabular Data 모델로, Attention 매커니즘을 통해 중요한 특성에 집중하는 구조를 갖는다. 대규모 데이터에서 강력한 성능을 보이는 것으로 알려져 있어 240 만 개의 관측치가 존재하는 본 연구의 데이터에서 고차원 변수 간 상호작용을 효과적으로 학습할 수 있을 것으로 기대된다. 특히, 범주형 변수에 대한 내재적 임베딩 처리와 수치형 변수에 대한 비선형적 패턴 학습을 동시에 수행할 수 있어, 기존의 트리 기반 모델이나 선형 모델 대비 우수한 일반화 성능을 도모할 수 있다.

본 연구에서는 대표적인 딥러닝 기반 Tabular 모델인 TabNet 을 적용하여 예측 성능을 평가하였으며, 이는 Sparsemax 기반의 Feature Selection 단계와 순차적 Attention 집계 구조를 통해 학습 과정 중 자동으로 중요한 피처를 선택하고 활용하는 특징을 가진다. 이러한 구조는 모델의 성능 향상뿐 아니라 내부적으로 어떤 피처가 예측에 기여했는지를 확인할 수 있는 해석 가능성(interpretability)도 함께 제공한다는 점에서, 실무적 적용에 있어 유의미한 시사점을 제공한다.

앞선 모델에서도 언급했듯, 성능 평가지표는 A, B 세그먼트에서 나타나는 분류 문제의 클래스 불균형을 고려하여 Macro F1 Score 를 사용하였다. 이를 TabNET 의 학습 과정에 추가하기 위해 사용자 정의 지표 클래스를 구현해 eval_metric 인자로 지정하여 검증 성능을 지속적으로 평가하였다. 또, 하이퍼파라미터가 중요하다고 평가되는 모델 특성상, learning rate, categorical embdding dimension, gamma 값과 같은 하이퍼파라미터를 optuna 패키지를 통해 최적의 값을 Table 6 과 같이 찾아냈다.

Table 6*Hyper-paramaters of TabNET*


Categorical embedding dimension	34
learning rate	0.0001623
step size	89



weights
gamma

1
0.3629426

학습은 데이터 누수 없이 훈련셋에 대해서만 수행되었으며, 별도의 검증셋을 활용해 조기 종료 및 성능 모니터링을 병행하였다.



위 혼동행렬은 다중 분류 모델의 예측 성능을 시각화한 것으로, 총 5 개 클래스(Segment A~E)에 대한 실제 레이블과 예측 결과 간의 관계를 나타낸다. 소수 클래스인 Segment A 와 B 는 클래스의 수에 반비례하게 가중치를 부여하는 weights 파라미터의 효과로 잘 분류되었다. 반면, Segment C 와 D 는 상호 간 오분류가 빈번하게 일어나 두 세그먼트의 구분이 다소 모호한 것으로 해석된다.

Table 7
Classification performance by segment (TabNET)

Segment	Precision	Recall	F1 Score
A	0.85	0.92	0.88
B	0.67	0.97	0.79
C	0.64	0.89	0.75
D	0.52	0.79	0.63
E	0.98	0.87	0.92

Note. Macro F1 Score: 0.7936


다중 분류 모델의 정량적 성능은 Table 7 과 같이 Precision, Recall, F1-score 를 기준으로 평가되었으며, 전체 60 만 개 샘플에 대해 다음과 같은 결과를 나타냈다. Segment E 클래스는 전체의 약 80%를

차지하며, 가장 높은 정밀도(0.98)와 F1-score(0.92)를 기록, 모델이 해당 클래스를 안정적으로 학습했음을 보여준다. Segment D 클래스는 정밀도 0.52 로 가장 낮은 값을 보였으며, 이는 오탐지 비율이 높음을 시사한다. Segment B 클래스는 재현율이 0.97 로 매우 높지만 정밀도는 0.67 에 그쳐, 해당 클래스로 예측된 사례 중 다수가 실제와 일치하지 않을 수 있음을 나타낸다. Segment A 와 C 도 비교적 균형 잡힌 성능을 보였으며, 특히 Segment A 는 높은 F1-score(0.88)를 기록하였다.

제 2 절 LIME & SHAP 인사이트 도출

LIME 은 특정 인스턴스의 예측 결과에 대해 로컬 선형 모델을 학습시킴으로써 모델의 국소적인 작동 원리를 설명한다. 본 연구에서는 Segment_AB 및 Segment_CDE 그룹에 대해 대표 인스턴스를 각각 선택하고, CatBoost 모델에 대해 LIME 분석을 수행하였다.

사전 전처리된 데이터셋에서 각 그룹별로 대표적인 두 샘플(index 0, 1)을 선택하여, 이에 대한 예측 결정에 가장 크게 기여한 상위 10 개 피처를 시각화하고, 해당 분석을 통해, 모델이 각 고객을 특정 세그먼트로 분류한 주요 요인을 확인할 수 있으며, 이는 향후 고객군 세분화 및 전략적 대응의 기초 자료로 활용될 수 있다.



위 그래프는 XGBoost 모델과 SHAP(Shapley Additive Explanations) 값을 활용하여 신용카드 사용자 데이터를 기반으로 고객 세그먼트를 분류하고, 각 특성(feature)이 모델 예측에 미치는 영향을 시각화하였다. SHAP summary plot 결과에 따르면, 이용금액_일시불_R6M 변수가 모든 클래스에서 가장 큰 영향을 미친 주요 변수로 나타났다. 특히 Segment E에서의 영향도가 가장 높았으며, 이는 해당 기간 내 일시불 결제금액이 고객 세그먼트 분류에 있어 결정적인 역할을 한다는 것을 시사한다.

그 외에도 평잔_할부_3M, 이용금액대, 이용금액_R3M_신용, 정상청구원금_B5M 등의 변수들이 중요한 요인으로 도출되었으며, 각 클래스별로 영향을 주는 특성이 상이함을 확인할 수 있었다. 예를 들어, 정상청구원금_B5M은 Segment A와 B에서, 최대이용금액_체크_R12M은 Segment C에서 높은 중요도를 보였다. 이러한 결과는 특정 소비 패턴이나 금융활동이 특정 세그먼트로의 분류에 직결된다는 것을 의미한다.



(좌) XGBoost LIME 분석 결과 (우) TabNET LIME 분석 결과

분석 결과, Segment A는 리볼빙 잔액과 카드로 대출금액 등 금융상품 사용 이력이 많고, 유이자 할부 사용이 활발한 고객군으로 나타났다. 분석에 따르면, 이들은 카드사의 주요 금융 상품을 적극 활용하고 있으며, 수익 기여도가 높고 신용 리스크도 다소 존재할 수 있는 고수익 고위험 고객군으로 해석된다. 금융사 입장에서는 이러한 고객에게 리볼빙 자동이체, 카드로 리마케팅 등 수익성 중심의 상품을 맞춤 제안하는 전략이 유효하다.



(좌) XGBoost LIME 분석 결과 (우) TabNET LIME 분석 결과

Segment B 는 항공 이용금액, 디지털 페이, 포인트 및 마일리지 사용이 활발한 고객군으로, 혜택에 민감하고 활동적인 소비자 유형이다. 이들은 글로벌 소비와 디지털 소비에 친화적인 성향을 보이며, LIME 분석에서도 해당 변수들이 높은 분류 기여도를 보였다. 따라서 금융사는 이 고객군을 대상으로 마일리지 적립형 프리미엄 카드, 항공사 제휴 혜택, 간편결제 연동 리워드 프로그램 등을 기획해 고객 충성도를 강화할 수 있다.




(좌) XGBoost LIME 분석 결과 (우) TabNET LIME 분석 결과

Segment C 는 일시불 거래액과 정상 청구금액이 높고, 고객센터 문의 빈도도 많은 고관여 소비자 유형이다. SHAP 및 LIME 분석 모두 해당 고객의 활발한 거래와 높은 기대수준을 보여주며, 이는 서비스 품질과 상담 경험이 고객 유지에 큰 영향을 미친다는 것을 의미한다. 금융사에서는 이들을 충성 고객으로 유치하기 위해 맞춤형 상담을 제공하고, 서비스 제공을 통해 고정적인 고객으로 유치할 수 있을 것으로 예측된다.



(좌) XGBoost LIME 분석 결과 (우) TabNET LIME 분석 결과

반면 Segment D 는 리볼빙 잔액이 없고, 고객센터 문의도 거의 없으며, 금융상품 사용 빈도가 전반적으로 낮은 고객군이다. 이들은 보수적이고 소극적인 소비 성향을 보이며, 카드사 입장에서 수익성이 낮고 이탈 가능성이 있는 그룹으로 판단된다. 일시불 이용금액도 낮고, 특수 지출 항목이 거의 없다는 점에서 비활성 또는 저관여 고객으로 분류되며, 리타겟팅 비용 대비 효과가 낮을 수 있다. 그러나 휴면 전환을 방지하기 위한 1 회성 유입 이벤트나, 비용 효율적인 마케팅 메시지를 통해 제한적이거나 잠재 수요를 자극할 수 있다.



(좌) XGBoost LIME 분석 결과 (우) TabNET LIME 분석 결과

마지막으로 Segment E 는 일시불 거래조차 거의 없고, 학습비나 한도 감액 요청 등 특수 지출 항목도 관찰되지 않는 휴면 전환 직전의 고객군으로 나타났다. 이들은 카드 사용 자체를 중단했거나, 명확한 이탈 징후를 보이며, SHAP 분석에서도 일시불 이용금액의 부재가 Segment E 분류에 가장 큰 영향을 미친 변수로 도출되었다. 해당 고객군은 최소비용의 해지 방지 메시지, 사용 재유도형 리워드 제공 등으로만 관리되며, 장기적으로는 유지 비용 대비 이익을 고려한 관리 전략이 요구된다.

제 4 장 결론

제 1 절 연구 결과 종합

이번 프로젝트는 대형 신용카드 데이터를 기반으로 사용자 세그먼트를 분류하는 것이 주요 목표였다. 처음으로 대규모 데이터를 다루면서 데이터 전처리, 이상치 처리, 피처 엔지니어링 등 여러 면에서 어려움을 겪었지만, 이를 해결해 나가며 데이터 분석 역량을 크게 향상시킬 수 있었다. 특히, CatBoost, XGBoost, TabNET 이라는 서로 다른 구조의 분류 모델을 직접 구현하고 비교 분석한 과정은 매우 유익한 경험이었으며, 실제로 세 모델 모두 높은 분류 성능을 보여주었다.

또한, LIME, SHAP 값을 활용한 모델 해석을 통해 각 세그먼트를 구분짓는 핵심 변수들을 식별하고, 모델이 어떻게 예측을 수행하는지 이해할 수 있었다. 이러한 과정을 통해 단순히 예측 성능만을 추구하는 것을 넘어서, 결과에 대한 해석력과 인사이트 도출의 중요성을 체감할 수 있었다. 앞으로도 이번 프로젝트에서 얻은 경험을 바탕으로, 보다 복잡하고 다양한 데이터를 효과적으로 분석할 수 있는 역량을 키워나가고자 한다.

제 2 절 한계점 및 향후 연구 방향성 제언

다만 이번 프로젝트를 진행하면서 몇 가지 아쉬운 점도 있었다. 특히 C 와 D 세그먼트 간의 경계가 뚜렷하지 않아 이 두 클래스를 구분하는 데 어려움이 있었고, 그에 따라 해당 세그먼트에 대한 모델의 분류 성능이 상대적으로 낮게 나타나는 것을 확인할 수 있었다. 이 문제를 해결하기 위해 추가적인 피처 엔지니어링이나 비선형 분류 경계 강화를 위한 모델 조정을 시도해보고자 했지만, 연산량이 크게 요구되는 작업이었기 때문에 한정된 컴퓨팅 자원으로는 개선이 어려웠던 점이 아쉬움으로 남았다.

또한 TabNET 모델의 경우, 구조적으로 복잡하고 민감한 하이퍼파라미터들이 많은 특성을 갖고 있음에도 불구하고, 자원 제약으로 인해 교차 검증 기반의 하이퍼파라미터 튜닝을 충분히 수행하지 못했다. 이로 인해 TabNET 의 잠재적인 성능을 최대한 끌어내지 못한 부분이 아쉬웠으며, 향후 더 안정적인 자원 환경에서 보완해보고 싶은 과제로 남는다.

