

DAT 5기 캡스톤 프로젝트 보고서

기업 디폴트 리스크 스코어링 시스템

: 재무 데이터 기반 조기 경보 플랫폼

DAT 5기

채광채

여채환 신광혁 김채린



DAT 5기 캡스톤 프로젝트 보고서

기업 디폴트 리스크 스코어링 시스템

: 재무 데이터 기반 조기 경보 플랫폼

Corporate Default Risk Scoring System

: An Early Warning Platform Based on Financial Data

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2025년 06월 03일

DAT 5기

채광채

여채환 신광혁 김채린



DAT 5기 캡스톤 프로젝트 보고서

기업 디폴트 리스크 스코어링 시스템

: 재무 데이터 기반 조기 경보 플랫폼

국문 요약

본 연구는 미국 상장기업(1999-2018) 재무 데이터를 활용하여 파산 리스크 예측 모델을 개발하고, 이를 기반으로 한국 기업의 디폴트 리스크 스코어를 산출하는 조기 경보 시스템을 구현하는 것을 목표로 한다. 원저라이징과 RobustScaler를 적용한 후 부채비율·Altman Z-Score 파생변수를 추가하고, Optuna 최적화를 통해 학습된 랜덤포레스트, XGBoost, LightGBM, CatBoost 모델을 소프트 보팅 앙상블 및 등각 보간 캘리브레이션으로 통합하였다. 교차검증 결과 앙상블 모델은 ROC-AUC와 Brier Score에서 단일 모델 대비 우수한 성능을 보였으며, XGBoost 서로게이트 모델($R^2 \approx 0.96$)과 SHAP 분석을 통해 주요 위험 변수들을 확인하였다.

Abstract

This study develops a Korean companies' default-risk early warning system using U.S. public firms' financial data (1999-2018). After winsorization and RobustScaler scaling, debt ratio and Altman Z-Score were added. Random Forest, XGBoost, LightGBM, and CatBoost models were optimized via Optuna and combined with soft-voting ensemble and isotonic calibration to improve prediction. In cross-validation, the ensemble outperformed single models in ROC-AUC and Brier Score, and cost-benefit analysis identified the optimal threshold. An XGBoost surrogate ($R^2 \approx 0.96$) with SHAP analysis showed key risk factors. Finally, applying to Korean firms' data addressed domain shift and demonstrated automatic default-risk scoring with quarterly updates, enabling proactive risk management.

DAT 5기

채광채

여채환 신광혁 김채린



Data Analysis & Technology



목 차

제 1장 서론	1
제 1절 연구 배경	1
제 2절 연구 목적 및 논문 구성	2
제 2장 데이터 소개	3
제 1절 분석 데이터 소개	3
제 2절 데이터 전처리	3
제 3장 예측 모델 개발 및 성능 평가	7
제 1절 연구 모형 개발 및 평가	7
제 2절 모델 성능 검증 및 시각적 분석	13
제 4장 한국 상장기업 실증분석	17
제 1절 예측 모델의 한국 기업 적용 및 한계	17
제 2절 한국 상장기업 등급 분포 및 결과 해석	18
제 5장 결론	22
제 1절 연구 결과 종합 및 시사점 도출	22
제 2절 한계점 및 향후 연구 방향성 제언	22
참고문헌	23
국내문헌	23
국외문헌	23

표 목차

[표 1].....	3
[표 2].....	6
[표 3].....	16
[표 4].....	17
[표 5].....	19
[표 6].....	19
[표 7].....	19
[표 8].....	19
[표 9].....	20

그림 목차

[그림 1].....	4
[그림 2].....	5
[그림 3].....	11
[그림 4].....	13
[그림 5].....	14
[그림 6].....	15
[그림 7].....	18



제 1 장 서론

제 1 절 연구 배경

최근 몇 년 사이 세계 경제는 예상치 못한 충격과 불확실성에 지속적으로 노출되고 있다. 글로벌 공급망이 복잡하게 얽혀 있는 상황에서, 한 기업의 재무 위기는 이제 단순히 해당 기업만의 문제가 아니라 산업 전반과 금융시장, 더 나아가 실물경제 전체에까지 광범위한 영향을 미치고 있다. 2016년 한진해운의 법정관리 신청은 대형 해운사의 파산이 협력사, 금융기관, 그리고 국내외 물류망까지 연쇄적인 충격을 일으킬 수 있음을 여실히 보여준 대표적 사례다. 더불어 2020년 이후 코로나19 팬데믹의 여파로 일부 제조업과 유통업체가 단기 유동성 위기에 직면하면서, 기업 디폴트(부도) 위험이 더욱 현실적인 위협으로 다가오고 있다.

이처럼 기업의 파산 위험은 단순히 개별 기업의 재무 건전성 문제에 그치지 않고, 금융시장의 신용경색, 자금경로 마비, 투자심리 위축 등 다양한 부정적 파급효과로 확산될 수 있다. 그럼에도 불구하고, 지금까지 기업의 부도 가능성 평가는 주로 회계 전문가나 애널리스트의 경험과 정성적 판단에 의존해 온 것이 현실이다. 이러한 평가 방식은 객관성과 실시간성이 부족해, 대규모 기업 군을 대상으로 위험 신호를 신속하게 포착하거나 급변하는 시장 상황을 효과적으로 반영하는 데 한계가 뚜렷하다.

최근에는 빅데이터와 머신러닝 등 첨단 데이터 분석 기법의 발전으로, 기업 재무 데이터를 체계적이고 정량적으로 분석해 ‘디폴트 리스크 스코어’를 산출하고, 이를 기반으로 조기 경보 시스템을 구축하는 것이 가능해졌다. 미국 상장기업 데이터를 활용한 다양한 선행 연구에서는 회귀분석이나 앙상블 기반 분류 모델을 통해 과거 파산 기업과 생존 기업 간 재무 패턴의 차이를 학습하고, 일정 기간 내의 부도 확률을 이전보다 정밀하게 예측할 수 있음을 확인한 바 있다. 데이터 기반의 접근법은 전문가 경험에만 의존하는 평가 방식의 한계를 보완하고, 실시간 또는 분기별로 변화하는 시장 환경을 더욱 유연하게 반영할 수 있다는 강점이 있다.

이에 본 연구는 미국 상장기업의 1999~2018년 장기 재무 데이터를 활용하여, 기업별 디폴트 위험을 정량적으로 평가하는 예측 모델을 구축하고, 이를 기반으로 ‘디폴트 리스크 스코어링 시스템’을 개발하는 것을 목표로 한다. 더불어, 이렇게 개발된 분석 프레임워크와 예측 모델을 한국 상장기업의 재무 데이터에 적용해, 국내 시장 환경에서도 실질적이고 신뢰할 수 있는 조기 경보 성능을 발휘할 수 있는지 검증하고자 한다. 궁극적으로는 정기적으로 업데이트되는 최신 재무 데이터를 바탕으로 각 기업의 위험 신호를 실시간으로 포착하고, 금융기관·투자자·기업 경영진 모두가 신속하게 리스크에 대응할 수 있는 조기경보 플랫폼을 제시하는 것이 본 연구의 지향점이다.

제 2절 연구 목적 및 보고서 구성

본 연구의 주요 목적은 기업의 재무 데이터를 기반으로 디폴트(부도) 위험을 정량적으로 평가하고, 이를 조기에 감지할 수 있는 '디폴트 리스크 스코어링 시스템'을 개발하는 데 있다. 구체적으로는, 미국 상장기업의 장기 재무 데이터를 활용하여 기업별 부도 위험도를 수치화하는 예측



모델을 설계하고, 이 모델을 한국 상장기업 데이터에 적용함으로써 국내 환경에서도 실효성 있는 조기 경보 시스템의 가능성을 검증하고자 한다. 본 보고서는 총 5장으로 구성된다. 2장에서는 데이터셋과 전처리 과정을 설명한다. 3장에서는 디폴트 리스크 예측 모델의 개발 방법 및 성능 평가 결과를 다룬다. 4장에서는 산출된 리스크 스코어를 기반으로 한 조기 경보 시스템의 적용 사례와 실제 한국 상장기업 데이터에 대한 실증적 분석 결과를 제시한다. 마지막으로 제5장에서는 연구의 주요 성과를 정리하고, 한계점과 향후 연구 과제를 논의함으로써 보고서를 마무리한다.



제 2 장 데이터 소개

제 1 절 분석 데이터 소개

본 연구에서 활용한 데이터는 미국 뉴욕증권거래소(NYSE)와 나스닥(NASDAQ)에 상장된 8,262개 기업의 1999년부터 2018년까지 재무정보를 담고 있다. 총 78,682개의 기업-연도 단위 관측치로 구성되어 있으며, 18개의 핵심 재무 변수(X1~X18)와 부도 여부를 나타내는 이진 타깃 변수로 이루어져 있다. 부도는 미국 증권거래위원회(SEC)의 기준에 따라 Chapter 11(사업 재조정) 또는 Chapter 7(사업 종료) 파산 신청이 접수된 전 회계연도를 부도로 간주하며, 데이터셋에서는 부도 발생 연도의 전년도 데이터를 ‘부도’(1)로 표시하고, 정상 영업 중인 경우는 ‘정상’(0)으로 표기하였다. 본 데이터셋은 결측치가 없으며, 실제 기업 재무 데이터를 기반으로 한다. 학습과 검증, 테스트를 위해 1999년부터 2011년까지를 학습용, 2012년부터 2014년까지를 검증용, 2015년부터 2018년까지를 테스트용으로 구분하였다.

Current_Assets	유동자산	Total_Assets	자산총계
Cost_of_Goods_Sold	매출원가	Long_Term_Debt	장기차입금
Depreciation	감가상각비	EBIT	EBIT
EBITDA	EBITDA	Gross_Profit	매출총이익
Inventory	재고자산	Current_Liabilities	유동부채
Net_Income	당기순이익	Retained_Earnings	이익잉여금
Accounts_Receivable	매출채권	Total_Revenue	총수익
Market_Capitalization	시가총액	Total_Liabilities	부채총계
Net_Sales	수익	Operating_Expenses	판매비와관리비

표 1

제 2절 데이터 전처리

본 데이터셋은 결측치 처리 과정은 생략하였다. 다만, 원저라이징 기법을 사용하여 하위1%미만의 데이터는 하위1%의 값으로, 상위1%초과 데이터는 상위1%값으로 대체하여 이상치를 처리하였다.



Winsorized Feature Distributions (1-99%)




그림 1

본 연구에서는 원본 재무 변수들의 값 범위가 매우 다양하고, 일부 변수는 이상치의 영향을

크게 받을 수 있어, 이상치에 RobustScaler를 사용하여 스케일링을 수행하였다.




그림 2

스케일링 후 변수별 분포를 히스토그램으로 시각화한 결과, 대부분의 변수들이 극단적인 값에 의해 왜곡된 분포에서 중앙 집중화된 형태로 변환되어, 모델 학습 시 안정적인 특성 입력이 가능

함을 확인하였다. 이는 특히 매출원가(Cost_of_Goods_Sold), 감가상각비(Depreciation), 순이익(Net_Income) 등에서 두드러졌으며, 스케일 조정을 통해 변수 간 비교 가능성과 학습 효율성을 높일 수 있었다. 또한 원본 변수(X1~X18) 외에 두 가지 핵심 파생변수를 추가하였다. 첫째, 부채비율(debt_ratio)은 부채총계(Total_Liabilities)를 자산총계(Total_Assets)으로 나눈 값으로, 기업의 재무 건전성을 나타내는 주요 지표이다. 둘째, Altman Z-Score(altman_z)는 기업의 재무 안정성과 부도 위험을 종합적으로 평가하는 지표로, 당기순이익(Net_Income) 대비 유동자산, 매출원가, 감가상각비, EBITDA, 재고자산 등을 가중합하여 산출하였다. 이 두 파생변수는 부도 예측 성능 향상에 중요한 역할을 하는 것으로 알려져 있다. 마지막으로, 원본 변수들과 파생변수를 합친 후 다시 RobustScaler를 수행하였다.

Current_Assets	유동자산	Total_Assets	자산총계
Cost_of_Goods_Sold	매출원가	Long_Term_Debt	장기차입금
Depreciation	감가상각비	EBIT	EBIT
EBITDA	EBITDA	Gross_Profit	매출총이익
Inventory	재고자산	Current_Liabilities	유동부채
Net_Income	당기순이익	Retained_Earnings	이익잉여금
Accounts_Receivable	매출채권	Total_Revenue	총수익
Market_Capitalization	시가총액	Total_Liabilities	부채총계
Net_Sales	수익	Operating_Expenses	판매비와관리비
debt_ratio	부채비율	Altman Z-Score	altman_z

표 2



제 3 장 데이터 소개

제 1 절 연구 모형 개발 및 평가

3.1.1 랜덤 포레스트 베이스라인 모델 구축 및 평가

본 연구에서는 우선적으로 재무 데이터 기반 부도 리스크 예측의 출발점으로 랜덤 포레스트(Random Forest) 분류기를 적용하였다. 랜덤 포레스트는 다수의 결정 트리(Decision Tree)를 조합하여 예측의 정확도와 안정성을 높이는 대표적 앙상블 기법으로, 각 트리가 서로 다른 데이터 샘플과 변수 집합을 사용함으로써, 개별 트리의 과적합(overfitting) 문제를 완화하고 데이터의 잡음, 이상치에 대해 견고한 특성을 지닌다. 특히 변수 간 복잡한 상호작용이 존재하는 재무 데이터에 적합하다는 점에서 본 연구의 베이스라인 모델로 선정하였다. 모델 평가 과정에서는 금융 시계열 데이터의 특성을 반영하기 위해 TimeSeriesSplit 기반의 5겹 교차검증을 적용하였다. 이 방법은 전체 데이터를 시간 순서에 따라 다섯 구간으로 나누고, 각 구간별로 과거 데이터를 훈련에, 미래 데이터를 검증에 활용함으로써 실제 실무 환경과 유사한 조건을 구현하였다. 이러한 설계는 미래 데이터가 훈련에 노출되는 데이터 누수(look-ahead bias)를 방지한다는 점에서 금융 리스크 예측 분야에서 중요한 의미를 지닌다. 모델 성능 평가는 판별력 지표인 ROC-AUC와, 예측 확률의 정확성을 평가하는 Brier Score를 중심으로 이루어졌다. 실험 결과, 마지막 Fold에서의 ROC-AUC는 0.7058, Brier Score는 0.0600으로 집계되었다. 또한 5개 Fold 전체의 평균 ROC-AUC는 0.6561, 평균 Brier Score는 0.0635로 나타났다. 이러한 결과는 랜덤 포레스트가 재무 변수의 복잡한 상호작용과 시계열 구조를 일정 수준 이상 학습할 수 있음을 보여준다. 하지만, 부도 예측이라는 고난이도 분류 문제 특성상 추가적인 성능 개선의 필요성도 함께 확인되었다.

3.1.2 부스팅 계열 모델 개발 및 하이퍼파라미터 최적화

랜덤 포레스트 베이스라인의 한계를 극복하고 예측력을 향상시키기 위해, 본 연구는 최신 Gradient Boosting 계열의 트리 기반 앙상블 모델인 XGBoost, LightGBM, CatBoost를 추가적으로 도입하였다. 이들 모델은 각기 다른 방식의 경사하강법 기반 앙상블 구조를 사용하며, 잔차(오류)를 반복적으로 줄여가며 복잡한 비선형 패턴을 효과적으로 포착하는 것이 특징이다. 특히 불균형 클래스 문제, 이상치, 변수 간 상호작용이 강한 데이터 환경에서 강건한 성능을 발휘하는 것으로 잘 알려져 있다. 각 부스팅 모델의 성능을 극대화하기 위해 Optuna 베이지안 최적화 프레임워크를 활용한 하이퍼파라미터 탐색을 실시하였다. XGBoost는 `n_estimators`, `max_depth`, `learning_rate`, `scale_pos_weight` 등 주요 파라미터를, LightGBM은 `n_estimators`, `num_leaves`, `learning_rate`, `class_weight`를, CatBoost는 `iterations`, `depth`, `learning_rate`, `auto_class_weights`를 대상으로 20회 반복 실험을 수행하여 최적 조합을 산출하였다. 모든 부스팅 계열 모델의 성능 평가는 앞서와 동일하게 TimeSeriesSplit 기반 3겹 교차검증을 통해 이루어졌다. 이 결과, XGBoost의 최적 파라미터는 `n_estimators=226`, `max_depth=4`, `learning_rate=0.0294`, LightGBM은 `n_estimators=233`, `num_leaves=28`, `learning_rate=0.0181`, CatBoost는



iterations=131, depth=6, learning_rate=0.0348로 각각 도출되었다. 모델별 3-Fold 평균 ROC-AUC는 XGBoost 0.6637, LightGBM 0.6596, CatBoost 0.6676으로 모두 베이스라인 모델보다 향상된 성능을 기록하였다. 이로써 최신 부스팅 계열 기법이 재무 데이터 기반 부도 예측에 보다 적합함을 확인할 수 있었다.

3.1.3 소프트 보팅 앙상블(Soft Voting Ensemble) 모델 개발 및 확률 보정

단일 모델 기반 예측의 한계를 보완하고 모델의 예측력을 극대화하기 위해, 본 연구에서는 앞서 개발한 XGBoost, LightGBM, CatBoost 세 모델을 조합한 소프트 보팅(soft voting) 앙상블을 구축하였다. 소프트 보팅 앙상블은 각 모델이 산출한 예측 확률값을 가중합하여 최종 예측값을 산출하는 방식으로, 개별 모델의 구조적 다양성과 예측 신호의 상호 보완성을 최대한 활용할 수 있다는 장점이 있다. 특히 앙상블 모델 내에서 각 개별 모델의 영향력(가중치) 산정에 있어, 기존 방식과 달리 교차검증(3-Fold CV)에서 산출된 ROC-AUC 값을 정규화하여 가중치 인자로 할당하였다. 즉, 모델별 AUC 점수를 합이 1이 되도록 정규화함으로써, 더 높은 예측력을 가진 모델이 앙상블에서 더 큰 영향력을 행사하도록 설계하였다. 이 방식은 앙상블 해석의 일관성과 수치적 안정성까지 보장하며, 특정 모델의 편향에 의해 전체 예측이 왜곡되는 현상을 효과적으로 방지할 수 있다. 데이터 분할 전략 또한 차별화하였다. 전체 데이터셋을 시계열 순서에 따라 80%의 교차검증(CV) 구간과 20%의 최종 테스트 구간으로 분리하였으며, 모델별 가중치 산정은 오직 80% CV 구간 내에서 3겹 교차검증을 통해 이루어졌다. 이렇게 산출된 가중치로 학습된 앙상블 모델은, 독립적인 20% 테스트 구간에서만 최종 평가를 수행함으로써 데이터 중복으로 인한 평가 편향(bias)을 방지하고 최종 결과의 신뢰도를 극대화하였다. 테스트 구간에서 산출된 ROC-AUC는 0.7265, Brier Score는 0.0599로 베이스라인 및 단일 부스팅 모델 대비 예측력과 확률 신뢰도가 모두 크게 향상된 결과를 확인할 수 있었다.

머신러닝 분류 모델에서 산출하는 예측 확률은 실제 사건 발생 확률과 다를 수 있기 때문에, 실제 금융 실무에서는 확률값의 정확성(=calibration)이 매우 중요하다. 본 연구에서는 Isotonic Regression 기반의 캘리브레이션 기법을 도입하여, 앙상블 모델의 확률 예측이 현실에 더욱 부합하도록 확률값을 보정하였다. 추가적으로, 복잡한 앙상블 모델의 해석력을 강화하고 이후 변수 영향도 분석에 활용하기 위해 서로게이트(surrogate) 모델을 구축하였다. 서로게이트 모델은 앙상블 모델이 도출한 확률 예측값을 목적 변수로 설정하고, 단일 XGBRegressor로 이를 근사하도록 훈련하는 방식이다. 이를 통해 실제 앙상블 모델의 복잡한 예측 논리를 단일 트리 모델의 해석 가능한 구조로 치환할 수 있다. 서로게이트 모델의 근사 성능은 테스트 데이터 기준 $R^2 = 0.9613$ 으로 매우 높은 수준을 기록하였으며, 이는 서로게이트 모델이 앙상블의 예측 메커니즘을 거의 완벽하게 재현함을 의미한다. 따라서 이후 변수 중요도 및 SHAP 분석에서도 원 앙상블 모델의 의사결정 구조가 신뢰성 있게 해석될 수 있음을 보장한다.

3.1.4 SHAP(Shapley Additive exPlanations) 기반 변수 영향도 분석

머신러닝 모델의 실무 적용에서 가장 큰 한계 중 하나는 “블랙박스(Black-box)” 문제, 즉 모델이 실제로 어떠한 논리와 근거로 결과를 도출하는지 해석이 어렵다는 점이다. 특히 금융 리스크 평가처럼 높은 투명성과 설명책임이 요구되는 영역에서는 모델의 해석 가능성이 신뢰 확보와 정

책적 활용의 전제조건이 된다. 본 연구에서는 소프트보팅 앙상블의 복잡한 예측 구조를 해석하기 위해 SHAP(Shapley Additive exPlanations)기법을 적용하였다. SHAP는 게임이론의 샤플리 값(Shapley Value)에 근거한 변수 중요도 산출법으로, 각 샘플별 예측에서 모든 특성이 얼마나 “공정하게” 기여했는지 수치로 분해할 수 있다. 이는 변수 간 비선형 상호작용이 많은 앙상블 및 복잡한 모델에서 가장 폭넓게 채택되는 해석 기법 중 하나다.

SHAP 분석 적용 과정

(서로게이트 모델 활용) 직접적으로 해석이 어려운 소프트보팅 앙상블의 예측 확률을 XGBRegressor로 근사하는 서로게이트 모델을 먼저 학습시켰다. 이때 서로게이트 모델의 테스트 R^2 는 0.9613으로, 앙상블 모델의 예측 논리를 충분히 신뢰성 있게 모사할 수 있음을 확인하였다. (SHAP 값 산출) 이후 서로게이트 모델에 대해 SHAP 값(각 특성의 기여도)을 계산하였고, 테스트 데이터셋 전체에 대해 summary plot 등 시각적 분석을 수행하였다.

SHAP Summary Plot 해석법

Y축: 변수명(중요도 순 정렬; 위로 갈수록 예측에 더 큰 영향)

X축: SHAP 값(해당 변수의 기여 크기; 0 기준으로 +/- 방향)

각 점: 한 샘플(기업)의 해당 변수에 대한 SHAP 값

색상:빨강=해당 변수값이 높은 경우, 파랑=낮은 경우

위치:오른쪽(+)은 부도확률 증가, 왼쪽(-)은 부도확률 감소에 기여

예를 들어, debt_ratio(부채비율)는 변수값이 높을수록(빨강) 오른쪽에 넓게 분포해 해당 기업의 부도위험 예측에 크게 기여한다는 것을 시각적으로 보여준다. 반대로 Market_Capitalization(시가총액)은 변수값이 높을 때(빨강) 왼쪽에 분포해 부도위험을 낮추는 요인임을 쉽게 파악할 수 있다. SHAP 값의 분포 폭이 넓을수록 해당 변수가 예측 결과에 미치는 영향력이 크다는 뜻이다. 실무적 해석 및 의의 이러한 SHAP 기반 해석을 통해 모델 신뢰성: 부도 예측 모델이 실제로 핵심 재무지표(예: 부채비율, 시가총액, 순이익 등)의 경제적 논리를 반영하고 있음을 확인할 수 있다. 변수의 영향 방향: 각 변수의 값이 높아질 때/낮아질 때 부도확률이 어떻게 변하는지 정량적·시각적으로 직관적으로 해석할 수 있다. 투명성 및 설명책임: 실제 신용평가나 조기경보 시스템에서 결과에 대한 설명 책임(Explainability)을 명확히 할 수 있다. 결과적으로, 본 연구에서 제안한 SHAP 기반 해석은 복잡한 앙상블 예측의 논리를 경제적 의미와 연계하여 실제 금융 실무와 정책 결정에 신뢰성 있게 활용될 수 있는 기반을 제공한다.




그림 3

[그림 3] SHAP Summary Plot 주요 변수 해설 위 그림은 SHAP 값을 이용하여 각 재무 변수별로 부도(디폴트) 위험 예측에 미치는 영향력을 시각화한 결과이다. 특히 아래의 변수들이 두드러진 영향력을 보였다.

debt_ratio (부채비율)

부채비율은 해당 기업의 부도 위험 예측에서 가장 큰 영향을 미치는 변수로 나타났다. 변수값이 높을수록(빨간 점), SHAP 값이 오른쪽으로 크게 분포하여 부도 확률을 유의하게 증가시키는 경향을 보인다. 반면, 부채비율이 낮을 때(파란 점)는 SHAP 값이 음수(왼쪽)에 분포하여 부도 위험을 낮추는 효과가 뚜렷하게 관찰된다. 이는 전통적 신용위험 평가 논리와도 부합하는 결과로, 부채비율이 높을수록 부도 위험이 커진다는 경제적 직관을 모델이 정확히 반영하고 있음을 시사한다.

Market_Capitalization (시가총액)

시가총액 역시 부도 예측에 매우 중요한 변수로 작용한다. 변수값이 높을수록(빨강), SHAP 값이 음수(왼쪽) 방향으로 넓게 분포하며 부도 위험을 유의하게 낮추는 효과가 있음을 보여준다. 반대로 시가총액이 낮은 기업(파랑)은 부도 위험이 증가하는 경향이 있다. 즉, 규모가 큰(자본력이 풍부한) 기업일수록 부도 위험이 낮다는 신용 평가의 통념을 모델이 학습했음을 알 수 있다.

Net_Income (당기순이익)

당기순이익 변수 역시 높은 영향력을 보인다. 변수값이 높을수록(빨강), SHAP 값이 대체로 음수(왼쪽)에 분포하며 부도 위험을 감소시키는 역할을 한다. 반면, 순이익이 낮거나 적자(파랑)인 경우에는 SHAP 값이 오른쪽(+)에 나타나 부도 위험 증가에 기여한다. 수익성이 좋은 기업일수록 부도 위험이 낮음을 정량적으로 반영한 결과라 할 수 있다.

Inventory (재고자산)

재고자산 변수도 상대적으로 넓은 SHAP 분포를 보인다. 일반적으로 재고자산이 높은 경우(빨강), 부도 위험 예측에 다소 부정적(+)인 영향을 줄 수 있다. 반면, 재고가 낮은 경우(파랑)는 SHAP 값이 음수로 이동하여 부도 위험이 낮아지는 경향을 보인다. 이는 업종 특성 및 재고 운영의 효율성과도 관련이 있을 수 있음을 시사한다.

Long_Term_Debt (장기차입금)

장기부채 역시 값이 높을수록(빨강) 부도 위험을 높이는 방향으로, 낮을수록(파랑) 부도 위험을 낮추는 방향으로 SHAP 값이 분포한다. 장기채무 구조가 취약할 경우 기업의 신용위험이 증가할 수 있음을 모델이 반영하고 있는 것이다. 이 외에도 Accounts_Receivable, EBIT, Current_Assets 등 주요 재무지표들이 부도 위험 예측에 일정 수준 이상의 영향력을 미치는 것으로 나타났다.

종합적으로, SHAP summary plot을 통해 모델이 부채비율, 시가총액, 수익성, 자산 규모 등 핵심 재무 지표를 근거로 기업의 부도 리스크를 정교하게 판단하고 있음을 확인할 수 있다. 이는 모델 예측의 경제적 논리와 실무적 신뢰성을 뒷받침하는 근거로 활용될 수 있다.

제 2절 모델 성능 검증 및 시각적 분석

소프트보팅 앙상블 모델의 최종 성능 평가는 독립적으로 분리된 테스트 구간(20%)을 대상으로 실시하였다. 모델의 종합적 성능과 실무 활용 가능성을 다각도로 점검하기 위해 판별력, 확률 예



측 정확성, Calibration(확률 보정), 비용-편익 구조 등 다양한 관점에서 성과를 분석하였다.




그림 4

3.2.1 ROC Curve 및 판별력(ROC AUC)

[그림 4]은 테스트 데이터에서 산출된 ROC 곡선을 제시한다. ROC AUC는 0.7265로, 본 연구의 소프트웨어 양상불이 부도기업과 정상기업을 상당한 수준으로 효과적으로 구별하고 있음을 보여 준다. ROC 곡선이 대각선(무작위 예측선) 대비 명확히 위쪽에 위치한다는 점은 모델이 실질적으로 신용위험 분류 문제에 유의미한 예측력을 지님을 시사한다.




그림 5

3.2.2 Precision-Recall Curve 및 PR AUC

불균형 데이터 상황에서 더욱 적합한 성능지표로 활용되는 Precision-Recall 곡선(그림 5) 역시 함께 제시하였다. PR AUC는 0.1240으로, 양성(부도) 클래스의 탐지 난이도가 높음을 반영한다. 특히, threshold=0.5 기준에서는 양성(부도) 클래스를 전혀 탐지하지 못하는 현상이 나타났으며 이는 부도 발생 빈도가 매우 희소한 상황에서 threshold 조정의 필요성을 뒷받침한다.

3.2.3 Brier Score 및 Confusion Matrix

예측 확률의 정확도를 평가하는 Brier Score는 0.0599로 예측 확률이 실제 부도 발생률에 상당히 근접함을 의미한다. 한편, threshold=0.5 기준의 Confusion Matrix는 (TN=14,674, FP=0, FN=1,063, TP=0)으로 집계되어 양성 예측이 전무(precision=0, recall=0)함을 알 수 있다. 이는 불균형 데이터에 대한 threshold 전략의 중요성을 재확인시켜 준다.




그림 6

3.2.4 Calibration Curve

[그림 6]의 Calibration Curve는 예측 확률이 실제 부도 발생률과 어느 정도 일치하는지를 시각적으로 나타낸다. 예측 확률과 실제 확률이 45도 직선(Peak Calibration)과 근접함을 보이며, 모델의 확률 산출 신뢰도가 실제 금융 실무에서 활용 가능한 수준임을 확인할 수 있다.

3.2.5 종합 해석 및 시사점

이상의 결과를 종합하면, 소프트보팅 앙상블 모델은 (1) 우수한 판별력(ROC AUC 0.7265), (2) 높은 예측 확률 신뢰도(Brier Score 0.0599, Calibration Curve 적합), (3) 실제 손실 최소화를 위한 비용-편익 기반 threshold 최적화를 달성하였다. 다만, 극단적 불균형 데이터 상황에서는 threshold=0.5 기준의 양성 탐지 한계가 존재함을 명확히 인지해야 하며 현업에서는 threshold 조정, 비용구조 반영 등 실무적 튜닝이 필수적임을 확인할 수 있다.

다음은 미국 상장기업 테스트 데이터에서 소프트보팅 앙상블 모델의 예측 확률에 기반해 등급을 할당한 결과, 각 등급별로 분포한 기업 수를 요약한 것이다.

등급	샘플 수
A+	524
A0	1040
B+	1955
B0	2448
C+	2433
C0	2403
D	1479

표 3

퍼센타일 기반의 등급 매핑을 적용함에 따라 대부분의 등급 구간에 기업이 고르게 분포하며, 특히 B0, C+, C0 등 중간 등급에 상대적으로 많은 기업이 집중되어 있다. 이는 등급 체계가 실제 표본 내에서 균등 분포를 유도함과 동시에, 관측·예측 부도를 모두 등급이 낮아질수록 점진적으로 증가하는 계층 구조가 명확히 드러난다는 점에서 모델이 신용위험 분류 논리를 효과적으로 학습했음을 확인할 수 있다.

제 4 장 한국 상장기업 실증분석

제 1절 예측 모델의 한국 기업 적용 및 데이터 전처리 한계

본 장에서는 앞서 미국 상장기업 재무데이터를 기반으로 개발한 디폴트 리스크 예측 모델을, 실제 한국 상장기업(코스피) 재무 데이터에 적용한 실증 사례를 제시한다. 분석에 사용된 데이터는 VALUESearch에서 수집한 2022~2024년 코스피 주요 상장사의 재무지표(18개 항목 기준)로 구성되어 있다. 특히, 본 연구에 사용한 표본은 코스피 기업 전체에서 대형주, 중형주, 소형주별로 60%씩 무작위로 추출하였으며, 이후 금융업(은행, 증권, 보험 등)을 제외한 517기업의 각 연도별로 시트가 구분되어 있다. 이 과정에서 실제 분석 환경의 현실적 한계가 여러 차례 확인되었다. 주요 난점은 다음과 같다.

첫째, 한국 기업의 재무 공시자료는 회사별, 연도별, 공시 기준별로 재무항목의 명칭과 세부 구조가 상이하여, 미국식 피쳐 구조와 완벽히 일치하지 않았다. 변수명 매핑과 데이터 정합성을 맞추기 위해 각 항목의 명칭과 구조를 일일이 확인하였으며, 불일치하는 항목은 대체 변수 또는 보조 데이터를 활용해 최대한 일관성을 확보하였다.

Current_Assets	유동자산	Total_Assets	자산총계
Cost_of_Goods_Sold	매출원가	Long_Term_Debt	장기차입금
Depreciation	감가상각비	EBIT	EBIT
EBITDA	EBITDA	Gross_Profit	매출총이익
Inventory	재고자산	Current_Liabilities	유동부채
Net_Income	당기순이익	Retained_Earnings	이익잉여금
Accounts_Receivable	매출채권	Total_Revenue	총수익
Market_Capitalization	시가총액	Total_Liabilities	부채총계
Net_Sales	수익	Operating_Expenses	판매비와관리비
debt_ratio	부채비율	Altman Z-Score	altman_z

표 4

둘째, 업종별·연도별로 일부 핵심 재무지표가 공시되지 않거나 아예 누락된 사례가 빈번했다. 예를 들어 Current_Assets(유동자산), Current_Liabilities(유동부채) 등 일부 변수는 대형 상장사조차 결측이 존재해 파생변수(예: Altman Z-Score) 산출이 제한되는 경우가 있었다. 결측치는 해당 연도·해당 변수 전체를 NaN 처리하거나 파생변수 결측으로 남겨두어, 모델 입력의 신뢰성을 보수적으로 유지하였다.

셋째, 실제 파일에서도 연도별 데이터(2022, 2023, 2024)가 모두 존재하지만, 기업별 결산 시점과 업종별 공시 특성 등으로 인해 일부 연도 또는 변수에서 완전한 데이터가 확보되지 않았다. 따라서 3개 연도 전체에서 일관된 통계와 완전한 비교를 산출하는 데 근본적 한계가 있었다. 이러한 사정으로 보고서에서는 대표성이 가장 높은 최신 연도(2024년) 결과를 중심으로 등급 분포, 부도확률 통계, 주요 기업별 사례 등을 제시하였다.

이와 같은 한계를 감안하더라도, 동일한 전처리 및 분석 방법론을 적용하면 2022년, 2023년 결과 역시 추가로 산출·해석할 수 있다. 향후에는 보다 표준화된 재무 데이터셋 구축, 결측치 보완, 업종별 특성 반영, 그리고 변수 정의의 국내 회계 기준 정교화 등이 보완될 필요가 있음을 제언한다.

제 2절 한국 상장기업 등급 분포 및 결과해석

본 절에서는 전처리된 한국 상장기업(코스피) 재무데이터에 대해 미국 상장기업 데이터 기반으로 학습된 디폴트 리스크 예측 모델을 적용한 최신 연도(2024년) 중심의 실증 결과를 제시한다.

4.2.1. 2024년 등급 분포 및 Default 확률 통계



그림 7

그림 [7]은 2024년 한국 상장기업 전체의 디폴트 리스크 등급 분포를 나타낸다.

등급	기업 수
A0	58
B+	95
B0	101
C+	106
C0	104
D	53
총	517

표 5

등급별 부도확률 통계는 다음과 같다

등급	평균 Default 확률	표준편차	최소	25%	50%	75%	최대
A	0	0	0	0	0	0	0
B+	0.0004	0.0023	0.0004	0.0004	0.0026	0.0026	0.0057
B0	0.0097	0.0111	0.0067	0.0111	0.0111	0.0111	0.0171
C+	0.0362	0.0296	0.0216	0.0278	0.0304	0.0311	0.0343
C0	0.0565	0.0463	0.0358	0.0392	0.0492	0.0502	0.0597
D	0.0929	0.0868	0.0602	0.0653	0.0732	0.1030	0.1455

표 6

등급이 낮을수록(default 확률이 높을수록) 기업 수는 감소하고, 평균 부도확률은 명확하게 증가하는 경향을 보였다. 이는 미국 상장기업 모델의 신용 위험 구분 논리가 국내 시장에서도 일정 부분 적용 가능함을 시사한다.

4.2.2 주요 기업별 사례 분석

본 절에서는 2024년 기준으로 한국 상장기업 중 대형주, 중형주, 소형주 각 그룹에서 대표적인 2개 기업을 선정하여, 모델 적용 결과(등급, default 확률, 주요 재무지표)와 함께 모델 해석 관점에서의 시사점을 구체적으로 제시한다.

기업명	등급	Default 확률	등수	부채비율
LG	A0	0.0	1	0.11
카카오	B0	0.0111	165	0.46

표 7(대형주)

LG는 전체 표본 중 1위로, 매우 낮은 부채비율과 안정적인 자산, 시가총액, 순이익 등을 바탕으로 부도 위험이 사실상 0에 수렴하는 최상위 등급(A0)을 받았다. 반면 카카오는 대형 IT 기업임에도 불구하고 비교적 높은 부채비율과 영업비용, 그리고 낮은 순이익 등이 반영되어 등급이 B0로 하락했다. 이는 기업 규모와 상관없이 재무구조와 수익성 등 핵심 지표가 등급 산출에 큰 영향을 미침을 보여준다.

기업명	등급	Default 확률	등수	부채비율
한화	B0	0.0111	221	0.84
농심	B+	0.0026	98	0.26

표 8(중형주)

한화는 높은 부채비율(0.84)과 상대적으로 낮은 영업이익률이 반영되어 B0 등급으로 평가되었다. 반면 농심은 부채비율이 낮고, 식품업 특성상 현금흐름이 안정적으로 유지되어 중상위 등급(B+)을 기록했다. 특히 두 기업은 업종 및 재무구조 차이에 따라 동일 중형주 내에서도 등급과 부도 확률이 뚜렷이 다를 수 있음을 확인할 수 있다.

기업명	등급	Default 확률	등수	부채비율
한국단자	A0	0.0	6	0.31
대교	B0	0.0111	208	0.48

표 9(소형주)

한국단자는 소형주임에도 불구하고 안정적인 수익성과 낮은 부채비율, 높은 이익잉여금 등으로 최상위 등급(A0)에 올랐다. 반면 대교는 당기순이익 적자 등 지표상 위험요인이 다수 반영되어 B0 등급으로 평가되었다. 특히 대교처럼 소형주 중 일부는 특정 연도에 영업실적 부진 등으로 인해 위험군에 가까운 결과가 산출될 수 있음을 시사한다.

4.2.3 결과 해석 및 실무적 시사점

본 결과를 통해, 미국 재무데이터 기반 머신러닝 신용위험 모델이 미국 상장기업 신용 위험의 계층화(등급화)에 효과적으로 적용될 수 있음을 확인하였다. 실무에서는:등급 하락/부도 위험이 높은 기업군에 대한 조기 모니터링, 주요 신용 위험 요인에 대한 심층 분석이 가능하다. 투자자·금융기관:등급 분포와 주요 지표 변동에 따라 대출 및 투자 전략을 유연하게 조정할 수 있다. 모델 한계:국내 기업의 산업·경영 특성, 데이터 결측 문제, 일부 변수의 국내 회계 기준 불일치 등은 후속 연구로 보완이 필요하다. 본 분석 결과는 데이터 기반 조기경보 시스템이 한국 기업 시장에도 충분히 실무적으로 적용될 수 있음을 보여주며, 추가적으로는 데이터 표준화, 결측치 처리, 업종별 특성 반영 등 지속적인 보완이 필요하다.



제 5 장 결론

제 1절 연구 결과 종합 및 시사점 도출

본 연구는 미국 상장기업의 장기 재무 데이터를 기반으로 디폴트(부도) 위험을 예측하는 머신러닝 모델을 개발하고, 이를 한국 상장기업(코스피) 재무 데이터에 적용하여 조기경보 시스템의 실효성을 실증적으로 분석하였다. 미국 상장기업 8,262개(1999~2018년) 재무정보로 XGBoost, LightGBM, CatBoost 기반의 소프트보팅 앙상블 예측모델을 구축하였으며, 변수명 매핑·파생변수 추가·결측치/이상치 처리 등 통일된 전처리 절차를 적용했다. 완성된 모델을 2022~2024년 코스피 주요 상장사 표본에 적용한 결과, 최신 연도(2024년) 기준 등급 분포 및 개별 기업 사례를 통해 미국식 데이터 기반 리스크 평가 프레임워크가 국내 시장에도 일정 수준의 설명력과 실무적 적용 가능성을 가짐을 확인하였다. 이로써 기존의 정성적·경험적 신용평가 방식 대비, 대규모 기업군에 대해 정량적이고 신속한 리스크 계층화 및 조기 위험 신호 탐지가 가능함을 보여주었다.

제 2절 한계점 및 향후 연구 방향성 제언

본 연구는 다음과 같은 한계점을 가진다. 첫째 데이터 품질 및 결측 문제 한국 상장기업 데이터는 일부 변수의 결측, 공시 기준 차이 등으로 인해 모든 기업·연도에서 완전한 분석이 어려웠으며, 특히 핵심 변수(Current_Assets, Current_Liabilities 등)의 결측은 파생변수 산출과 모델 해석에 제약을 주었다. 둘째 제도·산업적 도메인 차이 미국과 한국 기업의 회계 기준, 산업 구조, 기업 규모 차이 등으로 인해 변수 해석과 예측 결과의 국내 적용성에 한계가 있다. 셋째 모델 외적 한계비재무적 요인(거시경제, 업종별 특수성, 경영 이슈 등)이 반영되지 않았으며, 모델 성능도 외부 환경 변화에 따라 달라질 수 있다. 넷째 신용등급 산정 방식의 한계 본 연구에서는 부도 확률에 대한 등급 변환 과정에서, map_prob_to_rating 함수를 통해 각 기업의 부도확률을 단순 퍼센타일 기준(cuts)에 따라 A+, A0, B+, B0, C+, C0, D 등급으로 매핑하였다. 그러나 이 방법은 실제 신용평가에서 활용되는 절대적 위험기준이나 외부 신용평가 기관의 등급 체계와는 달리, 표본 내 상대적 위치(퍼센타일)에만 기반하고 있어 다음과 같은 한계가 존재한다. 동일한 위험수준이라도 표본 분포에 따라 등급 경계가 임의적으로 변동될 수 있다. 실제 신용등급과의 일치도가 낮을 수 있으며, 외부 벤치마크나 업계 표준과의 비교가 어렵다. 절대적 리스크 기준(예: 특정 default 확률 이상은 무조건 D 등급) 없이 등급이 산출되므로, 투자자 및 금융기관 실무 적용 시 해석상 혼란을 야기할 수 있다. 향후 연구에서는 등급 산정의 절대 기준 도입, 외부 신용평가 기관과의 비교·검증, 실제 부도율과의 연계성 강화등을 통해 신용등급 변환 방법의 실효성과 신뢰도를 높일 필요가 있다.

참고문헌

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 3146–3154.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased Boosting with Categorical Features. *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*, 6638–6648.
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 4765–4774.
- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting Good Probabilities with Supervised Learning. *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, 625–632.
- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631.

