

DAT 6기 캡스톤 프로젝트 보고서

가계대출 연체율 예측

: 머신러닝과 딥러닝을 활용한 금융 리스크 예측

DAT 6기

빛투더퓨처

오성민 강민서 이가은 이수현



Data Analysis & Technology



DAT 6기 캡스톤 프로젝트 보고서

가계대출 연체율 예측

: 머신러닝과 딥러닝을 활용한 금융 리스크 예측

Household Loan Delinquency Rate Forecast

: Financial Risk Prediction Using Machine Learning and Deep Learning

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2025년 11월 30일

DAT 6기

빛투더퓨처

오성민 강민서 이가은 이수현

DAT 6기 캡스톤 프로젝트 보고서

가계대출 연체율 예측

: 머신러닝과 딥러닝을 활용한 금융 리스크 예측



Data Analysis & Technology



국문 요약

보고서 요약

본 프로젝트는 급변하는 거시경제 환경 속에서 가계대출 연체율을 선제적으로 예측하고자 하는 목적에서 출발하였다. 이를 위해 2005~2025년의 거시경제 지표와 대출 건전성 데이터를 기반으로, 전통적 시계열 모형(ARIMAX), 머신러닝(Random Forest·XGBoost), 딥러닝(GRU)을 폭넓게 적용하여 연체율 변동을 분석하고 각 모형의 예측 성능을 비교하였다. 분석 결과, 로그 변환을 통한 ARIMAX는 통계적 가정을 충족하며 구조적 해석에 강점을 보였고, GRU는 비선형 상호작용을 효과적으로 학습하여 가장 우수한 예측 정확도를 달성하였다. 본 연구는 모형별 장단점을 종합적으로 검토하며 금융 리스크 예측에 대한 실증적 근거를 제시하였다는 점에서 의의가 있으며, 향후 금융기관의 리스크 관리 체계 고도화와 조기 경보 시스템 구축에 기여할 수 있을 것으로 기대된다.

Abstract

보고서 요약(영문)

This project was initiated with the goal of proactively forecasting household loan delinquency in a rapidly changing macroeconomic environment. Using monthly macroeconomic indicators and loan soundness data from 2005 to 2025, we applied a comprehensive set of predictive approaches—including the traditional ARIMAX model, machine learning methods (Random Forest and XGBoost), and a deep learning-based GRU model—to analyze delinquency patterns and compare model performance. The results showed that the log-transformed ARIMAX model satisfied key statistical assumptions and provided strong structural interpretability, while the optimized GRU model effectively captured nonlinear interactions and achieved the highest prediction accuracy. By evaluating the relative strengths and limitations of each modeling approach, this study provides empirical evidence for improving financial risk prediction. The findings are expected to contribute to the advancement of risk management frameworks and the development of early warning systems within financial institutions.

DAT 6기

빛투더퓨처

오성민 강민서 이가은 이수현



Data Analysis & Technology



목 차(예시)

제 1장 서론	1
제 1절 연구 배경	1
제 2절 연구 목적 및 논문 구성	1
제 2장 데이터 소개.....	2
제 1절 선행연구 분석	2
제 2절 조사 및 분석 데이터 소개.....	3
제 3장 분석 결과.....	5
제 1절 연구 모형 설계.....	5
제 2절 모델 예측 결과.....	8
제 4장 결론	14
제 1절 연구 결과 종합 및 시사점 도출	14
제 2절 한계점 및 향후 연구 방향성 제언	15
참고문헌	16
국내문헌	16
국외문헌	16



그림 목차

[그림 3-1]	8
[그림 3-2]	10
[그림 3-3]	10
[그림 3-4]	10
[그림 3-5]	11
[그림 3-6]	13



제 1 장 서론

제 1 절 연구 배경

2025년 11월 현재, 대한민국 경제는 '고환율'과 '가계부채'라는 이중고에 직면해 있다. 한국은행 금융통화위원회는 지난 5월 기준금리를 2.50%로 인하한 이후, 11월 27일 올해 마지막 회의까지 4회 연속 동결을 결정하였다. 이는 원/달러 환율이 1,470 원대를 위협하는 외환 시장의 불안정과 수도권 중심의 주택 가격 상승세가 여전하기 때문이다.

비록 2024년의 고금리(3.50%) 기조에 비해서는 금리가 낮아졌으나, 가계의 이자 상환 부담은 여전히 높다. 특히 경기 회복세가 더디게 나타나면서 자영업자와 취약 차주를 중심으로 연체율 상승 압력이 지속되고 있다. 과거에는 단순한 신용등급이 대출 심사의 기준이었다면, 현재는 환율, 주택가격지수(HPI) 등 거시경제 변수가 가계의 상환 능력에 미치는 복합적인 영향을 분석하는 것이 금융 리스크 관리의 핵심 과제로 대두되었다.

이에 본 프로젝트팀 <빛투더퓨처>는 거시경제 지표와 가계 특성 데이터를 머신러닝 및 딥러닝 기법으로 분석하여, 향후 가계대출 연체율의 변동을 선제적으로 예측하는 모델을 구축하고자 한다.

제 2 절 연구 목적 및 논문 구성

본 프로젝트는 2005년부터 2025년까지의 시계열 데이터를 바탕으로 가계대출 연체율 예측을 위한 다양한 방법론을 적용해보고, 그 적용 가능성을 탐색하는 데 주된 목적이 있다. 이를 위한 구체적인 연구 목표는 다음과 같다.

우선, 전통적 통계 모형(SARIMAX)과 최신 머신러닝(RandomForest, XGBoost) 및 딥러닝(GRU) 모델 간의 예측 성능을 비교 분석한다. 동일 데이터셋 하에서 각 모델의 예측 오차(RMSE, MAE)를 정량적으로 평가함으로써, 비선형적인 금융 시계열 데이터 학습에 있어 머신러닝 기반 접근법이 기존 통계적 방법론 대비 어느 정도의 유효성과 실효성을 가지는지 고찰하고자 한다.

또한, 거시경제 충격의 시차 효과(Time-Lag)를 반영한 데이터 전처리의 영향을 분석한다. 기준금리 변동 등 외부 요인이 가계 상환 능력에 미치는 지연 효과를



고려하여 1~3 개월의 시차 변수를 구축하고, 이러한 시차 정보의 추가가 모델의 예측 안정성 및 성능 변화에 어떠한 영향을 미치는지 실증적으로 검토한다.

마지막으로, 연체율 변동과 주요 변수 간의 관계를 재조명한다. 예측 모델 내 변수 중요도 산출을 통해 금리, 주택가격지수(HPI), 물가 등 다차원적 요인들이 실제 연체율 예측에 기여하는 상대적 비중을 파악하고, 이를 통해 데이터 기반의 리스크 관리 시사점을 도출해보고자 한다.

제 2 장 데이터 소개

제 1절 선행연구 분석

가계대출 연체율 예측에 관한 선행연구는 크게 개별 차주의 신용 위험을 평가하는 미시적 접근과 거시경제 지표를 활용한 시계열 분석으로 구분된다. 먼저 『가계대출 연체 고객 예측 모형에 관한 연구』는 개별 차주의 부도 가능성 판별에 집중하여 금리 변동과 같은 시장 전체의 거시적 시계열 충격을 포착하는 데 한계가 있었다. 이를 보완하기 위해 『딥러닝을 활용한 기업·가계 연체율 결정 요인 분석』 등에서는 거시 데이터를 활용해 LSTM 모델을 적용하였으나, 월별 시계열과 같은 소규모 데이터셋에서는 과적합 위험과 높은 연산 비용 문제가 존재한다. 또한 『설명 가능한 인공지능을 활용한 은행대출연체 예측 모델 연구』에서는 모델의 해석력을 강조하였으나, 본 프로젝트는 예측의 정확도와 연산 효율성에 더 큰 주안점을 두었다. 이에 본 프로젝트는 LSTM 대비 효율적인 GRU(Gated Recurrent Unit) 모델을 도입하고, 단순 거시지표뿐만 아니라 LTV·DTI와 같은 대출 건전성 지표를 통합적으로 고려하며 시차(Lag) 및 차분(Diff) 변수를 적용해 경제 충격의 지연 효과까지 반영했다는 점에서 선행연구들과 차별성을 갖는다.

제 2절 조사 및 분석 데이터 소개

본 프로젝트는 한국은행 경제통계시스템(ECOS), 국가통계포털(KOSIS), 한국주택금융공사(K-MBS) 등 공신력 있는 기관에서 제공하는 월별 시계열 데이터를 수집하여 분석 데이터셋을 구축하였다. 데이터의 공간적 범위는 대한민국 전체를 대상으로 하며, 시간적 범위는 2005년 5월부터 2025년 6월까지의 약 20년 기간을 포괄한다. 분석에 활용된 최종 데이터셋은 총 242개의 관측치(Row)와 33개의 변수(Column)로 구성되어 있으며, 수집된 원천 변수와 이를 바탕으로 생성한 시차 변수(Lag 1~3)를 모두 포함하고 있다.

연구 모형에 투입된 변수는 크게 종속변수와 독립변수로 구분된다. 종속변수는 가계대출 연체율(HLDR)이며, 독립변수는 다시 거시경제 지표와 대출 특성 지표로 나뉜다. 거시경제 지표로는 기준금리, 소비자물가지수, 주택가격지수, 실업률 등이 포함되며, 대출 특성 지표로는 대출금리, 주택담보대출비율(LTV), 총부채상환비율(DTI) 평균 등이 활용되었다.

수집된 시계열 데이터는 변수별 수집 주기의 불일치와 결측치, 그리고 비정상성(Non-stationarity)을 포함하고 있어, 분석의 신뢰도를 확보하기 위해 정교한 전처리 과정을 수행하였다. 가장 먼저 시계열 데이터의 기본인 시간 연속성을 확보하기 위해 날짜(Date)를 기준으로 오름차순 정렬을 수행한 후, 변수 간의 시점 불일치 문제를 해결하는 작업을 선행하였다. 특히 주택담보대출비율(LTV)과 총부채상환비율(DTI) 데이터의 경우, 타 거시지표와 달리 월별로 3~4 개의 관측치(예: 5 월 10 일, 15 일 등)가 혼재되어 있는 구조였다. 이에 해당 변수들을 월별 평균값으로 산출하여 월 1 개의 유효값을 가지는 정형 데이터로 변환하고, 전체 변수들의 공통 분석 기간을 기준으로 필터링을 적용하였다.

그러나 이 과정에서 LTV와 DTI 변수에 약 66 개월 분량의 데이터가 누락되어 있음이 확인되었으며, 이는 전체 기간의 약 27%에 달하는 높은 결측률이었다. 단순 평균 대치나 선형 보간법을 적용하기에는 결측 구간이 광범위하여 데이터의 편향이 우려되는 상황이었다. 이에 본 프로젝트는 결측치가 다수 포함된 시계열 데이터 복원에 탁월한 성능을 보이는 칼만 필터(Kalman Filter)를 우선적으로 적용하여 전체적인 추세를 복원하였다(Niako et al., 2024). 다만, 칼만 필터가 2008년 금융위기나 2020년 팬데믹과 같은 급격한 변동 구간을 지나치게 평활화(Smoothing)하는 한계를 보완하기 위해, 급격한 구조적 변화(Peak)를 포착하는 데 강점이 있는 행렬 완성(Hankel Matrix Completion) 기법을 위기

구간에 결합하여 적용하였다(Poudevigne & Jones, 2024). 결과적으로 평시에는 칼만 필터의 안정성을, 위기 시에는 Hankel 기법의 민감도를 반영하는 하이브리드 보간을 통해 27%에 달하는 결측 공백을 신뢰성 있게 메울 수 있었다.

다음으로, 데이터의 통계적 안정성을 확보하기 위해 단위근 검정(Augmented Dickey-Fuller Test, ADF Test)을 실시하였다. 검정 결과, 가계대출 연체율(HLDR)을 비롯하여 기준금리, 대출금리, 실업률, 주택가격지수(HPI) 등 대다수 변수는 1 차 차분(1st Differencing)만으로도 P-value 가 0.05 미만으로 떨어져 정상성(Stationarity)이 확보되었다. 반면, 소비자물가지수(CPI)는 1 차 차분 후에도 비정상성을 띠는 것으로 나타나 추가적인 처리가 필요하였다. 이에 1 차 로그 차분(Log-Difference)을 적용한 결과 P-value 가 0.07 로 도출되었으며, 2 차 로그 차분 적용 시 P-value 가 0.00 으로 완전한 정상성을 보였다. 그러나 본 연구는 2 차 차분이 데이터의 정보 손실과 모델의 과적합(Overfitting)을 유발할 수 있다는 점을 고려하여, 유의수준 0.05 를 소폭 상회하더라도 경제적 해석이 용이하고 데이터의 본질적 정보를 유지할 수 있는 1 차 로그 차분 데이터를 최종 선택하였다.

데이터의 정상성이 확보된 이후에는 경제 충격의 지연 효과를 모델링하기 위해, 모든 주요 변수에 대해 1 개월(Lag1)부터 3 개월(Lag3)까지의 시차 변수(Lag Variable)를 파생 변수로 추가하였다. 전처리 과정에서 필연적으로 발생하는 결측 행은 지도 학습의 정확도를 위해 전량 제거(Drop)하였으며, 최종적으로 결측치 보간과 정상성 검증이 완료된 데이터셋을 학습에 활용하였다.

제 3 장 분석 결과

제 1 절 연구 모형 설계

3.1.1 ARIMA 모형

본 연구는 가계대출 연체율의 시계열적 특성을 반영하기 위해 ARIMAX 모형을 적용하였으며, 종속변수는 로그 변환한 HLDR(HLDR_log)로 설정하였다. 초기 모델은 외생변수로 HPI(주택가격지수)의 변동분만을 포함했으나, mean_DTI 및 loan_rate_diff 까지 포함한 확장 모델에서는 일부 변수의 통계적 유의성이 낮고 잔차의 정규성이 확보되지 않는 문제가 확인되었다. 이에 외생변수를 HPI_diff 와 mean_DTI 두 개로 재조정하여 모델을 단순화하였으며, auto_arima 를 통해 최종적으로 ARIMA(4,1,4) 차수를 선택하였다.

해당 모형은 HLDR_log 에 대한 두 외생변수의 구조적 영향을 안정적으로 추정하였다. HPI_diff 는 계수 $-0.0226(P=0.003)$ 으로 통계적 유의성이 매우 높았으며, mean_DTI 는 $0.0017(P=0.041)$ 로 유의수준 5% 내에서 유의미한 양의 관계를 보였다. 이는 담보가치 상승이 연체 위험을 완화하고, 총부채상환비율 상승이 연체 위험을 확대한다는 금융경제적 직관과 일치한다. AR 과 MA 계수는 모두 P-value 0.000 수준으로 모델 내 자기회귀적 구조가 충분히 설명되고 있음을 나타냈다.

또한 모델의 적합도(AIC)는 -957.216 으로, 이전 버전 대비 더 낮은 값을 기록하며 데이터 설명력이 향상되었다. 더불어 Jarque-Bera 검정 결과가 $P=0.07$ 로 정규성을 충족하고, Ljung-Box Q 검정에서도 자기상관이 없는 것으로 나타나(Prob=0.72), 모형의 잔차가 시계열적 패턴을 제거한 백색잡음에 가까운 형태임을 확인하였다.

3.1.2 RandomForest

본 프로젝트는 전통적 시계열 모형뿐만 아니라 비선형 구조를 포착하는 머신러닝 기법인 Random Forest 를 활용하여 가계대출 연체율 예측 가능성을 검토하였다. Random Forest 는 다수의 의사결정나무를 결합해 예측을 수행하는 앙상블 모델로, 변수 간 복잡한 상호작용과 비선형적 관계를 학습하는 데 강점을 가진다. 특히, 거시경제 변수와 대출 건정성 지표처럼 다양한 스케일과 형태를 지닌 데이터가 공존하는 환경에서 안정적으로 작동할 것으로 기대되었다.

모델 단순화를 위해 초반에는 변수 중요도(Feature Importance)를 기준으로 핵심 변수만을 선별한 단순화 모델을 구축하였다. 그러나 예측력이 오히려 저하되거나 Full Model 과 큰 차이가 없었다.

이와 같은 점을 개선하기 위해 시계열 특성을 중점적으로 반영한 변수 재선정 전략을 적용하였다. CCF 와 Granger 인과분석을 활용해 연체율 변동과 강한 시차적 연관성을 지닌 변수들만을 추출하고, 이를 기반으로 Random Forest 모델을 다시 설계하였다. HPI_diff, CPIlogdiff 및 각각의 시차 변수, 그리고 HLDR_lag1 등이 최종 변수 세트로 선택되었으며, 이러한 구성은 연체율 변화가 단기적 충격에 지연 효과를 통해 나타난다는 금융 경제적 구조와도 부합한다.

3.1.3 XGBoost

본 프로젝트에서는 가계대출 연체율(HLDR)의 비선형적 변동 특성을 포착하기 위해 머신러닝 기법 중 하나인 XGBoost(eXtreme Gradient Boosting)를 활용하였다. 초기 단계에서 차분 데이터 기반 모델을 구축하였으나, R^2 값이 음수로 도출되는 등 모델 안정성에 한계가 확인되었다. 이에 따라 본 연구는 원본 시계열 데이터를 활용한 재학습 및 하이퍼파라미터 튜닝을 통해 보다 신뢰성 높은 예측 모형을 재구축하였다.

튜닝 과정에서는 RandomizedSearchCV 를 활용하여 max_depth, learning_rate, n_estimators, subsample 등 주요 파라미터를 조정함으로써 모델 복잡성과 일반화 성능을 균형 있게 개선하였다. 또한, XGBoost 의 feature importance 분석을 수행하여 경제적·해석적 중요도가 높은 변수들을 식별하고, 불필요한 노이즈 변수를 제거함으로써 예측 안정성을 확보하였다. 최종적으로 HLDR 의 1~3 개월 시차(lag), HPI·CPI 의 변화분 및 고용·정책금리 관련 지표가 선택되었으며, 이는 연체율이 거시경제 충격에 지연된 형태로 반응한다는 기존 금융경제 연구와 일치한다.

이와 같은 변수 최적화와 튜닝을 기반으로 재구축된 XGBoost 모형은 기본 모델 대비 예측 성능이 크게 개선되었으며, 전반적인 모형의 설명력($R^2=0.51$)도 양수로 전환되면서 통계적 신뢰성이 확보되었다. 본 절의 설계는 HLDR 예측에서 XGBoost가 가질 수 있는 구조적 문제(시계열 구조 부재, 급변 구간 민감도 부족)를 최소화하고, 머신러닝 기반 접근이 금융 시계열 분석에서도 유의미한 결과를 도출할 수 있음을 입증하는 기반을 제공한다.

3.1.4 GRU

연체율 데이터를 더 깊이 있게 해석하기 위해 시계열 특화 딥러닝 구조인 GRU(Gated Recurrent Unit)를 적용하였다. 초기 GRU 모델은 복잡한 구조(Window 12 개월, Units 64)로 설계되었으나, 데이터의 크기에 비해 모델 용량이 지나치게 커 과적합이 발생하고 새로운 데이터에 대한 예측력이 크게 저하되는 문제가 발견되었다. 이러한 진단을 기반으로 본 연구는 GRU 구조를 전면 재설계하는 방향을 선택하였다.

모델 최적화를 위해 윈도우 크기를 최근 6 개월로 단축하고, Units 를 32 로 축소하는 경량화 전략을 적용하였다. 이는 연체율이 1 년 전의 먼 과거보다 최근 3~6 개월의 흐름에 더 민감하게 반응한다는 금융 시계열의 특성과도 부합하는 설정이었다. 또한 Dropout 을 적용해 잡음을 제거하고 과적합을 방지함으로써, 학습 및 검증 과정에서 손실값이 안정적으로 동반 하락하는 구조를 확보했다. 결과적으로 GRU 모델은 변수 간 비선형 상호작용을 포착하면서도, 과적합 없이 안정적인 구조적 학습을 수행할 수 있는 최적의 형태로 정리되었다.


제 2 절 모델 예측 결과

3.2.1 ARIMA 모형

최종 ARIMAX(4,1,4) 모형의 예측 성능을 테스트 데이터에 적용한 결과, 모델은 전반적인 연체율의 수준과 방향성을 안정적으로 추정하는 것으로 나타났다. 예측 오차는 로그 변환된 연체율을 원본 스케일로 환산하여 평가하였으며, MAE 는 0.1514, MSE 는 0.0291 로 산출되었다. 절대오차 수준만 보면 GRU 모델보다 높은 수치이지만, ARIMAX 가 로그 변환을 활용하는 구조적 특성상 단순 수치 비교에는 한계가 있다. ARIMAX 는 예측값의 절대적 정확도보다는 변수 간 구조적 관계를 명확하게 드러내는 데 강점을 가진다.

잔차 진단 결과도 모델의 안정성을 뒷받침한다. Ljung-Box 검정의 p-value 는 0.72 로 자기상관이 존재하지 않아, 모형이 시계열 패턴을 효과적으로 포착했음을 확인하였다. 또한 개선된 ARIMAX 모형은 Jarque-Bera 검정에서 $p=0.07$ 로 정규성을 확보하여, 이전 모델에서 나타났던 뾰족한(heavy-tailed) 잔차 분포 문제가 해소되었다. 이는 신뢰구간 추정 및 예측 분포 해석의 정확성을 크게 향상시키는 결과이다. 다만 이분산성 검정에서는 p-value 0.00 으로 여전히 시간 변동적 오차폭이 존재하는 것으로 나타났으나, 금융 시계열에서 흔히 나타나는 특성이며 모델의 실용적 활용에는 큰 제약이 되지 않는다.

종합적으로, 최신 ARIMAX 모형은 예측 정밀도 측면에서는 GRU 대비 다소 열위에 있으나, 주택가격 변동과 부채 상환 능력(mean_DTI)의 구조적 영향을 통계적으로 검증하고, 연체율의 경제적 메커니즘을 해석할 수 있는 모형으로서 높은 가치가 있다.




[그림 3-1] ARIMAX 모형의 실제값 대비 예측값 비교

3.2.2 RandomForest


Random Forest 의 전체 변수 기반 Full Model 은 테스트 데이터에서 MAE 0.1143, RMSE 0.1433, R^2 -1.0760 을 기록하며 전반적으로 낮은 설명력을 보였다. 안정적 구간에서는 실제 연체율의 흐름을 따라갔으나, 연체율이 급격히 상승하는 스파이크 구간에서는 예측선이 평탄하게 유지되며 변동성을 전혀 반영하지 못했다. 이는 시계열 데이터의 구조적 변동을 포착하기 어렵다는 Random Forest 의 근본적 한계를 그대로 드러낸 결과였다.

변수 중요도 기반으로 상위 10 개 변수만을 사용한 단순화 모델은 오히려 성능이 악화되었다(MAE 0.1257, RMSE 0.1596, R^2 -1.5747). Full Model 대비 해석 구조는 단순해졌지만, 결정계수 감소와 스파이크 예측 실패가 그대로 유지되었다는 점에서 Random Forest 는 일정 수준 이상의 변수 다양성을 확보해야만 평균적 추세를 유지할 수 있는 모델임이 확인되었다.


이후 CCF 와 Granger 분석 기반으로 시차성이 강한 변수만을 선별한 모델은 성능이 크게 개선되었다. 해당 모델은 MAE 0.0302, RMSE 0.0478 까지 오차를 줄이며 전체 추세를 가장 안정적으로 따라갔다. 다만 결정계수(R^2)는 -0.027 로 여전히 0 에 미치지 못해, 급격한 변동성을 설명하는 데는 한계가 남아 있었다. 변수 축소 버전 역시 MAE 0.031, RMSE 0.050 으로 유사한 성능을 유지하며, 불필요 변수를 제거해도 모델 안정성에는 큰 변화가 없음을 보여주었다. 잔차 분석에서는 평균이 0 에 가깝고 자기상관도 발견되지 않아 구조적 편향은 없었으나, 모든 모델이 급격한 스파이크 구간을 포착하지 못한 점은 Random Forest 의 시계열 비적합성이 명확하게 드러난 결과로 해석된다.



[그림 3-2] Random Forest(Granger+CCF 기반 변수 기반) 모델의 실제값 대비 예측값 비교(HLDR_diff)



[그림 3-3] Random Forest(상위 중요 변수 10 개) 모델의 실제 HLDR 과 예측 HLDR 비교




[그림 3-4] Random Forest(Full Model) 모델의 실제 HLDR 과 예측 HLDR 비교

3.2.3 XGBoost

원본 데이터를 활용한 기본 XGBoost 모델은 RMSE 약 0.125, MAE 약 0.099의 성능을 보였으나, HLDR의 급변 시점을 효과적으로 반영하지 못하는 등 예측력이 제한적이었다. 이후 하이퍼파라미터 튜닝을 적용한 결과, RMSE는 약 0.069로, MAE는 약 0.046으로 감소하였으며, 결정계수(R^2) 또한 0.51로 크게 개선되었다. 이는 모델이 전체 추세와 패턴을 보다 정교하게 학습하였음을 의미하며, 기본 모델 대비 예측 안정성과 적합도가 모두 향상되었음을 확인할 수 있다.

추가적으로, feature importance 기반 변수 선택 기법을 적용한 모델에서는 RMSE 약 0.045, MAE 약 0.031로 수치상 예측 오차가 더 낮게 나타났으나, MAPE가 약 26.5%로 상승하면서 특정 시점의 예측 불안정성이 다시 증가하였다. 이는 HLDR 값 자체가 낮은 수준(0.2~0.5 구간)에 위치함에 따라 작은 절대 오차에도 MAPE가 과도하게 변동하는 구조적 제약에서 비롯된 결과로 해석된다.

시각화 분석 결과, 튜닝된 XGBoost 모델은 전체적인 상·하향 흐름은 비교적 안정적으로 추종하였으나 HLDR의 최근 급등 구간에서는 여전히 예측이 완만하게 형성되는 경향이 확인되었다. 즉, Gradient Boosting 기반 모델 특성상 “완만한 추세 구간”에서는 높은 정확도를 보이나, 금융정책 변화나 외생적 충격으로 인한 급격한 변동구간에서는 예측 성능이 제한적임을 확인하였다. 이러한 한계점에도 불구하고, 튜닝된 XGBoost 모델은 본 연구에서 구축한 머신러닝 기반 모델 중 가장 안정적이고 균형 잡힌 성능(RMSE·MAE· R^2 기준)을 보인 최적 모델로 평가할 수 있다.




[그림 3-5] XGBoost(하이퍼파라미터 튜닝 후) 모델 실제값 대비 HLDR_diff 예측 결과 비교

3.2.4 GRU

본 프로젝트의 GRU(Gated Recurrent Unit) 기반 예측모형은 가계대출 연체율(HLDR)을 MinMax Scaling 을 적용한 후 종속변수로 사용하였으며, 기준금리(policy_rate), 대출금리(loan_rate), 실업률, 소비자물가(CPI), 주택가격지수(HPI), 평균 LTV, 평균 DTI 등 총 7 개의 거시경제 변수를 입력변수로 포함하여 학습하였다. 최적화된 모델은 6 개월의 윈도우(Window Size=6)를 사용해 최근 시점의 단기 흐름을 집중적으로 반영하도록 구성되었으며, 32 개의 GRU 유닛과 0.2 의 Dropout 을 적용해 과적합을 방지한 경량 구조로 설계되었다. 학습 과정에서 Training Loss 는 0.003~0.004 수준에서 안정적으로 수렴하였고 Validation Loss 와의 차이가 거의 발생하지 않아 초기 GRU 모델에서 나타났던 과적합 문제가 효과적으로 해소되었다.

테스트 데이터에 대한 예측 성능(RMSE 0.0602)은 기존 통계모형인 ARIMAX 의 MAE 0.1514 와 비교해 절대적 예측 오차가 절반 이하로 감소한 결과이며, 이는 GRU 가 선형적 구조의 범위를 벗어나 변수 간 복잡한 비선형 상호작용을 성공적으로 학습했음을 보여준다. 특히 이 최적화된 GRU 모델은 Heavy GRU(Window 12 개월, Units 64)의 RMSE 0.1934 대비 약 69%의 오차를 감소시키며 성능과 구조적 안정성 모두에서 크게 개선되었다. 반면 Units 수를 지나치게 축소한 경량 모델(Window 6, Units 8)은 테스트 RMSE 가 0.04 로 표면적으로는 더 우수했으나, 미래의 경제 충격이나 구조적 전환점을 학습할 용량(Capacity)이 부족해 과소적합될 가능성이 확인되었다. 이에 본 연구는 단순 수치뿐 아니라 경제 환경 변화 대응력을 고려하여 Units 32 를 가장 신뢰도 높은 설정으로 채택하였다.

잔차 분석을 통해 모델의 구조적 타당성을 추가로 검증한 결과, 예측 오차는 특정 시점에 치우치지 않고 안정적 분포를 보였으며, 패턴이나 자기상관이 관찰되지 않았다. 이는 GRU 가 시계열의 단기 변동성을 충분히 반영하면서도 특정 구간의 노이즈를 과도하게 학습하지 않았음을 의미한다. 종합적으로 GRU 모델은 통계적 모형(ARIMAX)이 가지는 해석 가능성은 부족하나, 예측 정확도 면에서는 본 연구의 모든 모델 중 가장 우수한 성능을 보여주었으며, 금융 시계열 데이터에서 요구되는 비선형 구조·시차 효과·복합적 경제 변수의 상호작용을 효과적으로 학습한 최적의 예측 모델로 평가된다.



[그림 3-6] GRU 모델 실제값 대비 예측값 예측 결과 비교

제 4 장 결론

제 1 절 연구 결과 종합 및 시사점 도출

본 프로젝트는 2005 년부터 2025 년까지의 거시경제·대출 건전성 지표를 기반으로 가계대출 연체율 예측 모델을 구축하고, 통계 기반 모형부터 머신러닝·딥러닝 기반 방법론까지 다양한 접근법을 비교·검증하였다. 분석 결과, 모형에 따라 예측 성능과 구조적 해석 가능성에서 뚜렷한 차이가 존재함을 확인하였다.

ARIMAX 는 로그 변환된 연체율을 기반으로 HPI_diff 와 mean_DTI 를 외생변수로 포함한 ARIMA(4,1,4) 모형을 최종 선정하였으며, AIC 가 -957.216 까지 하락하고 잔차 정규성을 확보하는 등 통계적으로 가장 적합한 구조를 갖추었다. 특히 주택가격 변동(계수 -0.0226)과 DTI(계수 0.0017)의 영향이 통계적으로 유의미하게 나타나, 연체율을 결정하는 경제적 메커니즘을 정량적으로 확인할 수 있었다.

머신러닝 기반 모델 가운데 Random Forest 는 안정적 구간에서는 일정 수준의 예측 성능을 보였으나, 연체율 급등 구간에서는 예측값이 평균 방향으로 수렴하는 경향을 보이며 구조적 한계를 드러냈다. 반면 XGBoost 는 원본 데이터를 활용한 하이퍼파라미터 튜닝 후 RMSE 0.069, MAE 0.046, R^2 0.51 을 기록하며 머신러닝 모델 중 가장 균형 잡힌 성능을 달성하였다. 특히 트리 기반 모델 특유의 변수 단순화 기능을 통해 HPI_diff, CPI_lag1, HLDR_lag1 등 주요 거시 변수의 상대적 영향력을 파악할 수 있었다는 점은 해석 측면에서 의의가 있다. 다만 시계열적 구조를 직접 반영하지 못해 HLDR 의 급격한 변동을 포착하는 데에는 여전히 한계가 존재하였고, MAPE 가 구간에 따라 크게 변동하는 등 작고 불안정한 시계열을 다루는 데 구조적 제약이 확인되었다.

반면 GRU 는 다변량 입력 구조를 기반으로 금리·실업률·주택가격·LTV·DTI 등 다양한 경제 변수를 동시에 학습함으로써, 복잡한 비선형 관계와 시계열적 맥락(Temporal Dependency)을 효과적으로 포착하였다. 최적화된 GRU 모델은 RMSE 0.0602 로 ARIMAX 대비 더 낮은 예측 오차를 기록하였으며, 이 과정에서 별도의 차분이나 로그 변환을 요구하지 않고 원본 데이터의 특성을 보존한 채 학습이 가능하다는 장점을 보였다. 이는 GRU 가 금융 시계열의 장기 의존성, 변수 간 상호작용, 비정상성 등 ARIMAX 가 처리하기 어려운 구조적 특성을 우수하게 반영함을 보여준다.

결론적으로, ARIMAX는 경제적 해석과 변수의 구조적 영향 분석에 강점을 가지며, GRU는 예측 정확도와 비선형 학습 능력에서 탁월하였다. 두 모델의 상보적 특성은 금융기관의 리스크 모니터링 체계에서 ARIMAX는 정책 변화 해석과 리스크 신호 구조 분석에, GRU는 조기 경고(Early Warning) 및 단기 예측 정확도 향상에 각각 유효하게 활용될 수 있음을 시사한다. 본 연구는 이러한 통합적 비교 분석을 통해 금융 리스크 예측의 실증적 근거를 제시했다는 점에서 의의를 가지며, 향후 신용리스크 조기 경고 시스템 개발과 대출 포트폴리오 위험 관리 고도화에 기여할 것으로 기대된다.

제 2 절 한계점 및 향후 연구 방향성 제언

다양한 기법을 적용해 연체율 예측 가능성을 포괄적으로 검토하였으나, 여러 측면에서 추가적인 개선 여지가 존재한다. 첫째, 본 연구에서 활용한 데이터는 월별 시계열 자료로 관측치 수가 240 개 내외에 불과하다. 이는 딥러닝과 같은 대규모 파라미터 기반 모델이 충분히 학습하기에는 제한적인 환경으로, GRU의 학습 안정화 역시 윈도우 단축 및 모델 경량화를 통해 겨우 확보된 측면이 있다. 향후 연구에서는 일 단위·주 단위의 고빈도 데이터를 확보하거나, 금융기관 내부의 미시적 차주 데이터를 결합함으로써 딥러닝 모델의 성능 향상을 기대할 수 있을 것이다.

둘째, 본 연구는 거시경제 및 평균적 대출 건전성 지표에 기반한 분석이라는 점에서, 개별 차주의 이질성(Heterogeneity)을 반영하지 못했다. 실제로 연체율 상승은 특정 계층(자영업자·저신용층·변동금리 비중이 높은 가구 등)에서 집중적으로 발생하는 경향이 있으므로, 향후에는 신용·소득·대출 조건 등 개별 차주 수준의 패널 데이터를 통합한 다층적 분석이 필요하다. 이러한 접근은 예측 정확도뿐 아니라 정책적·실무적 활용도까지 크게 높일 수 있다.

셋째, 랜덤탐색(Grid Search) 기반의 하이퍼파라미터 튜닝 범위가 제한적이었고, GRU와 같은 딥러닝 모델 역시 더 다양한 구조(LSTM, Transformer 기반 시계열 모형 등)에 대한 비교가 충분히 수행되지 못했다. 향후 연구에서는 Bayesian Optimization, Optuna와 같은 고도화된 하이퍼파라미터 탐색 기법을 도입해 모델 성능을 체계적으로 고도화할 필요가 있다.

마지막으로, 본 연구는 예측 정확도 중심의 평가에 초점을 맞추었기 때문에, 실제 금융기관이 활용하는 조기경보(Early Warning) 체계와의 정합성을 확인하는 과정은 제한적이었다. 향후 연구에서는 예측 오류의 경제적 비용, 정책 충격 시나리오 분석, 위기 상황에서의 스트레스 테스트 등 실무적 요소를 추가함으로써 보다 현실적인 리스크 관리 모델로 발전시킬 수 있을 것이다.

참고문헌

국내문헌

- 금융감독원, "2025 년 9 월말 국내은행의 원화대출 연체율 현황(잠정)", 금융감독원 보도자료, 2025.
- 김광린·안혜영·정현우·김성환, "가계대출 연체 고객 예측 모형에 관한 연구", 한국데이터정보과학회지, 제 30 권 제 6 호, pp. 1197-1207, 2019.
- 이종화, "딥러닝을 활용한 기업·가계 연체율 결정 요인 분석", 인터넷전자상거래연구, 제 24 권 제 4 호, pp. 135-149, 2024.
- 최봉진·이성우·김연국, "설명 가능한 인공지능을 활용한 은행대출연체 예측 모델 연구", 전산회계연구, 제 22 권 제 2 호, pp. 43-61, 2024.
- 통계청(KOSIS), "2025 년 11 월 소비자물가동향 및 주요 거시경제 지표", 2025.
- 한국은행, "2025 년 11 월 통화정책방향 결정문", 한국은행 보도자료, 2025.
- 한국은행 경제통계시스템(ECOS), "가계신용 및 연체율 통계(2005~2025)", 2025.

국외문헌

- **Niako, N., et al.**, "Effects of missing data imputation methods on univariate blood pressure time series data analysis and forecasting with ARIMA and LSTM", **BMC Medical Research Methodology**, 24, 2024.
- **Poudevigne, T., & Jones, O.**, "Time-series imputation using low-rank matrix completion", **arXiv preprint arXiv:2408.02594**, 2024.

