

포트폴리오 최적화를 위한 변동성 추정

DAT 6th 박사홍, 이예현, 이지수, 이제학

개요 Abstract

본 연구는 KOSDAQ 주식시장 데이터를 대상으로, 변동성 예측과 포트폴리오 최적화 문제를 통합적으로 다루는 Decision-Focused Learning(DFL) 프레임워크의 실증적 성능을 평가한다. 기존 연구들은 변동성이나 공분산 행렬을 별도의 예측 문제로 설정한 뒤, 추정된 공분산을 이용해 글로벌 최소분산 포트폴리오(Global Minimum Variance Portfolio, GMVP)를 구성해 왔다. 그러나 예측 정확도의 향상이 반드시 포트폴리오 성과 개선으로 이어지지 않는다는 점이 반복적으로 보고되었다. 이에 본 연구는 KOSDAQ 종목들의 일별 가격, 실현 변동성, 거래·재무·거시 변수로 구성된 패널 데이터를 기반으로, (1) GMVP 분산을 직접 최소화하는 DFL(Decision-Focused) 모델, (2) 실현 변동성에 대한 평균제곱오차(MSE)를 최소화하는 GRU 기반 순수 예측 모델, (3) 선형 변동성 예측 모델, (4) 전통적 shrinkage 추정기를 활용한 베이스라인을 비교한다.

실험 결과, GRU-MSE 모델은 변동성 예측 MSE 관점에서 가장 낮은 오차를 달성하였으나, 해당 예측치를 바탕으로 구성한 GMVP 포트폴리오의 연환산 수익률과 샤프 비율은 DFL 모델보다 현저히 낮았다. 반면, DFL 모델은 변동성 예측 오차가 다소 큰 편임에도, 포트폴리오 분산을 직접 최소화하도록 학습한 결과 KOSDAQ 시장에서 유의미한 양(+)의 연환산 수익률과 우수한 리스크 조정 수익(Sharpe ratio)을 기록하였다. Shrinkage 기반 베이스라인은 과도한 리스크를 억제하여 보수적인 성과를 보였으나, DFL 대비 Sharpe 비율은 낮은 수준에 머물렀다. 이러한 결과는 실증 데이터 환경에서도 “예측 문제의 성능”과 “의사결정(포트폴리오) 성과” 간의 괴리가 상당하다는 점을 재확인하며, 공분산 추정 혹은 변동성 예측을 포트폴리오 목적함수와 직접 연결하는 DFL 접근법의 실무적 유용성을 시사한다.

Keywords: Portfolio Optimization, Realized Volatility, Decision-Focused Learning, Deep Learning, GRU

1. Introduction

1.1 연구 배경

현대 포트폴리오 이론에서 글로벌 최소분산 포트폴리오(Global Minimum Variance Portfolio, GMVP)는 주어진 자산군에 대해 기대수익을 명시적으로 가정하지 않고, 포트폴리오 분산을 최소화하는 해로 정의된다. 이때 핵심 입력은 자산 수익률의 공분산 행렬이며, 이 공분산을 얼마나 정확하고 안정적으로 추정하는가는 GMVP의 실무적 성과를 좌우하는 중요한 요소이다. 전통적으로는 과거 수익률에 기반한 표본 공분산(sample covariance)을 사용하거나, Ledoit-Wolf와 같은 수축(shrinkage) 기법을 통해 추정 오차를 줄이는 방향으로 연구가 진행되어 왔다. 이러한 접근은 “공분산 추정 문제”를 1차적인 목표로 간주하고, 그 결과물로 부터 GMVP를 도출하는 2단계 구조를 가진다.

하지만 최근 수 차례의 연구에서, 예측 정확도(예: 공분산 추정 MSE 혹은 변동성 예측 MSE)가 향상되더라도 실제 포트폴리오 성과(예: Sharpe 비율, 최대 낙폭)가 반드시 개선되지 않는다는 사례가 보고되고 있다. 특히 고차원 자산군과 제한된 표본 수라는 현실적인 제약 아래에서, 표본 공분산 또는 그 변형만으로는 실전 운용에서 안정적인 성과를 내기 어렵다는 문제가 제기된다. 이는 “예측 문제의 손실 함수”와 “실제 투자자가 관심을 가지는 목적함수(예: GMVP 분산, Sharpe 비율)”가 구조적으로 다르기 때문에 발생하는 간극으로 이해할 수 있다.

이와 같은 문제의식에서 출발한 것이 Decision-Focused Learning(DFL) 접근법이다. DFL은 예측 단계와 의사결정 단계를 분리하지 않고, 예측 모델의 출력이 실제로 사용될 의사결정 문제(예: 포트폴리오 최적화)를 미분가능한 형태로 포함시켜, 의사결정 성능을 직접 최적화하도록 학습하는 프레임워크이다. 예를 들어, 변동성 예측 모델의 출력으로 구성한 공분산($\hat{\Sigma}$)로부터 GMVP 가중치($w^*(\hat{\Sigma})$)를 계산하고, 실제 공분산 혹은 실현 수익률을 사용해 평가한 포트폴리오 분산(또는 regret)을 손실로 정의함으로써, 예측 모델이 “GMVP의 실현 리스크”를 최소화하는 방향으로 학습되도록 만들 수 있다. 이러한 관점은 “예측 그 자체가 목적이 아니라, 예측이 사용되는 최종 의사결정의 성능이 곧 목적”이라는 점을 분명히 한다.

1.2 연구 목적

본 연구의 목적은 KOSDAQ 주식시장을 대상으로, 변동성 예측과 GMVP 포트폴리오 최적화를 통합한 Decision-Focused Learning 프레임워크의 효과를 실증적으로 검증하는 것이다. 구체적으로는 다음과 같은 질문에 답하고자 한다.

변동성 예측 정확도(MSE)를 극대화하도록 학습한 순수 예측 모델(GRU-MSE baseline)과, GMVP 분산을 직접 최소화하도록 학습한 DFL 모델은 실제 포트폴리오 성과 측면에서 어떤 차이를 보이는가?

전통적인 공분산/변동성 추정 접근법(예: 단순 선형 모델, shrinkage 추정기)과 대비하여, DFL이 리스크 조정 수익(Sharpe 비율)이나 최대 낙폭 측면에서 어떤 우위 또는 한계를 가지는가?

한국 중소형주 시장(KOSDAQ)이라는 상대적으로 변동성이 크고 종목 수가 많은 환경에서,

DFL 접근법이 여전히 실질적인 성능 향상을 제공하는가?

이를 위해, 본 연구는 KOSDAQ 종목들의 일별 가격 데이터, 실현 변동성 지표, 거래·재무·거시 변수 등으로 구성된 패널 데이터를 기반으로, 다음 네 가지 실험군을 구성한다.

DFL(GMVP): 예측된 변동성으로 구성된 공분산으로부터 글로벌 최소분산 포트폴리오를 계산하고, 실제(타겟) 공분산 하에서의 포트폴리오 분산을 직접 최소화하도록 학습한 모델.

GRU-MSE baseline: 동일한 GRU 구조를 사용하되, 실현 변동성에 대한 평균제곱오차(MSE)를 최소화하도록 학습한 순수 예측 모델.

Linear baseline: 선형 변동성 예측 모델로, 비선형 구조와 대비되는 단순 기준선.

Shrinkage baseline: 최근 실현 변동성을 크로스 섹션 평균 쪽으로 수축(shrinkage)하여 변동성을 추정한 뒤 GMVP를 구성하는 비학습형 전통 추정기.

본 연구는 위 네 가지 접근을 동일한 데이터셋과 백테스트 환경에서 비교함으로써, (1) 예측 정확도와 의사결정 성능 간의 괴리를 실증적으로 확인하고, (2) DFL이 전통적인 추정 기법과 비교하여 어느 정도까지 실무적으로 의미 있는 성능 개선을 가져오는지를 분석한다.

1.3 연구 범위 및 기여

본 연구의 범위는 다음과 같이 한정된다.

자산군: KOSDAQ 상장 종목 중 유니버스 필터를 통과한 종목들

빈도 및 호라이즌: 일별(log) 수익률 및 일정 길이의 포워드 호라이즌(예: H일)

포트폴리오 유형: 글로벌 최소분산 포트폴리오(GMVP)

계약 조건: 현재 구현은 숏 포지션을 허용하는 무계약 GMVP를 사용하며, 롱 온리(long-only) 제약은 향후 과제로 남긴다.

이러한 설정 하에서, 본 연구의 기여는 다음과 같이 요약할 수 있다.

한국 KOSDAQ 시장 데이터를 이용해 DFL, GRU-MSE, Linear, Shrinkage 네 가지 변동성·공분산 추정/포트폴리오 전략을 체계적으로 비교하였다.

예측 정확도(MSE) 관점에서 우수한 모델이 반드시 포트폴리오 성과에서 우수하지 않음을 실증적으로 제시하였으며, DFL 접근법이 GMVP 포트폴리오의 연환산 수익률 및 리스크 조정 수익 측면에서 의미 있는 개선을 제공함을 보였다.

전통적인 shrinkage 추정기와 비교했을 때, 학습 기반 DFL이 추가적인 성과 향상을 가져올 수 있음을 KOSDAQ 데이터라는 실무적 환경에서 확인하였다.

2. Data

본 연구에서는 한국 중소형주 시장을 대표하는 KOSDAQ 상장 종목을 대상으로, 일별 빈도의 패널 데이터를 구축하였다. 표본 기간은 20년 9월부터 25년 10월까지로 설정하였으며, 상장폐지·거래정지·극단적 유동성 부족 종목은 기본적인 필터링을 통해 제거하였다. 최종적으로 약 150개의 종목과 1,133개의 거래일에 대해 균형에 가까운 패널을 구성하였다. 종속 변수는 각 종목의 단기 실현 변동성(realized volatility)으로, 대신증권 api를 통해 얻은 5분 틱 단위의 종가 데이터를 통해 식 (1)과 같이 계산하였으며, 이를 목표 예측 대상(target)

으로 사용하였다.

$$RV_{day} = \sum_{i=1}^{78} (\ln(P_i/P_{i-1}))^2 \dots \text{식 (1)}$$

설명 변수(feature)는 가격 기반 기술 지표, 종목 및 업종 수준의 펀더멘털, 그리고 주요 거시·글로벌 리스크 지표를 포함하도록 설계하였다. 구체적으로는 과거 수익률과 거래대금, 변동성 관련 요인(과거 realized volatility, GARCH형 프록시 등), 밸류에이션 및 재무 비율(시가총액, PBR, PER, 부채비율 등), 국내 금리 및 환율, 글로벌 유가, VIX 등 다양한 요인을 결합하였다. 각 시점별로 고정 길이의 과거 관측 구간(window)을 사용해 시계열 피처를 구성하고, 이를 GRU 기반 모델이 처리할 수 있는 텐서 형태로 변환하였다.

변수 스케일 차이를 완화하고 학습 안정성을 확보하기 위해, 연속형 피처는 학습(train) 구간의 통계량을 이용해 평균 0, 분산 1이 되도록 표준화하였다. 로그 변환 또는 winsorizing은 극단치 처리가 필요한 일부 변수에 한정해 적용하였다. 데이터는 시간 순서를 유지한 상태에서 학습·검증·테스트 세트로 분할하였으며, 과거 구간을 학습 및 검증에, 가장 최근 구간을 독립적인 테스트 기간으로 활용하였다. 포트폴리오 백테스트는 오직 테스트 기간의 예측 결과만을 사용해 수행함으로써, 미래 정보 누출을 방지하고 실무적 해석 가능성을 확보하였다.

3. Methodology

본 연구의 목표는 단순히 실현 변동성을 정확히 예측하는 것이 아니라, 예측 결과를 활용해 구성되는 포트폴리오의 위험을 최소화하는 것이다. 이를 위해 전통적 예측-후-최적화(predict-then-optimize) 접근과 달리, 의사결정 포인트를 명시적으로 학습 과정에 포함하는 Decision-Focused Learning(DFL) 프레임워크를 적용하였다. 구체적으로, 각 시점에서 자산별 변동성을 예측하고, 이를 기반으로 글로벌 최소분산 포트폴리오(Global Minimum Variance Portfolio, GMVP)를 구성했을 때의 실현 분산(regret)을 손실 함수로 삼아 신경망 파라미터를 직접 최적화한다.




Figure 1. Architecture of Volatility Forecaster

예측 모듈로는 시계열 정보를 처리하기 위해 GRU 기반의 딥러닝 모델을 사용하였다. 각 자산-시점 쌍에 대해 과거 L일간의 피쳐 시퀀스를 입력으로 받고, GRU 인코더와 다층 퍼셉트론(MLP) 헤드를 통해 향후 기간의 조건부 변동성 추정치 $\hat{\sigma}$ 를 산출한다. 출력 계층에는 양수 제약을 위해 softplus 함수를 적용하였다. 예측된 변동성과 과거 상관관계 행렬로부터 추정 공분산 행렬 $\hat{\Sigma}$ 를 구성한 뒤, 이로부터 무제약 GMVP 해석해를 계산하여 포트폴리오 비중 $\hat{w}$ 를 얻는다. 손실 함수는 해당 비중을 실제 실현 공분산에 적용했을 때의 포트폴리오 분산과, 이상적인 GMVP 대비 초과 분산(regret)을 중심으로 식 (2)와 같이 정의된다. 이를 통해 모델은 예측 오차 자체보다는, 예측 오차가 포트폴리오 수준의 위험에 미치는 영향을 직접 학습하게 된다.

$$Regret_t = \hat{w}_t^\top \Sigma_t \hat{w}_t - (w_t^\star)^\top \Sigma_t w_t^\star \dots \text{식 (2)}$$

비교를 위해 전통적인 예측 중심 접근도 함께 고려하였다. 첫째, 동일한 GRU 구조를 사용하되, 손실 함수를 개별 자산의 실현 변동성과 예측치 간의 평균제곱오차(MSE)로 두는 GRU-MSE 모델을 구축하였다. 둘째, 시계열 구조를 무시하고 단일 시점 피쳐 벡터에 대해 선형 회귀를 수행하는 Linear baseline을 포함하였다. 마지막으로, 재무 분야에서 널리 쓰이는 shrinkage 기반의 공분산/변동성 추정기를 baseline으로 도입하였다. 이 방법은 최근 관측된 realized volatility를 횡단면 평균 쪽으로 수축(shrink)하는 간단한 구조로, 통계적 안정성을 확보하는 대신 개별 자산 특이성을 일부 희석시키는 특징이 있다.

이와 같이 DFL, GRU-MSE, Linear, Shrinkage의 네 가지 접근을 공통 데이터와 포트폴리오 구성 규칙 아래에서 비교함으로써, “예측 정확도 향상”과 “실제 포트폴리오 성과 개선” 사이의 괴리를 정량적으로 분석하고자 한다.

4. Experimental Setup

본 연구는 KOSDAQ 상장 150개 종목, 1,133개 거래일로 구성된 일별 패널 데이터를 사용한다. 데이터는 시간 순서를 유지한 채 학습 · 검증 · 테스트 구간으로 분할하였으며, 입력 피쳐는 각 자산-시점별로 고정 길이의 과거 윈도우(예: 직전 20일)의 시계열로 구성된다. 이 시계열 피쳐를 GRU 기반 모델의 입력으로 사용하고, 테스트 구간에서는 과거 정보만으로 예측을 생성해 미래 정보 누출을 방지하였다.

비교 대상 모델은 (i) GMVP variance regret을 최소화하도록 학습되는 DFL(GRU 기반), (ii) 동일 GRU 구조에 MSE 손실을 사용하는 GRU-MSE 모델이다. 두 모델은 은닉 차원, 레이어 수 등 네트워크 구조와 학습률 · weight decay · 배치 크기 등의 하이퍼파라미터를 공유하며, AdamW 최적화와 80 epoch 학습을 기본 설정으로 사용한다. 모든 실험에서 시드 고정과 데이터 분할은 동일하게 유지하였다.

학습 거동을 보다 정밀하게 관찰하기 위해, 별도의 실험을 구성하여 epoch별로 예측 손실과 의사결정 손실을 동시에 기록하였다. 구체적으로, 각 epoch 종료 시점마다 학습 데이터

전체(및 검증 데이터)에 대해 (1) 예측 변동성과 실제 실현 변동성간의 MSE, (2) 예측 공분산과 실제 공분산을 사용해 계산한 GMVP 분산 regret을 다시 계산하여 저장한다. 이로써 DFL과 GRU-MSE에 대해 “예측 손실(MSE) 곡선”과 “의사결정 regret 곡선”을 각각 epoch 축 위에서 직접 비교할 수 있도록 했다.

백테스트는 테스트 구간에서 일별로 동일한 절차를 적용한다. 각 모델이 산출한 자산별 변동성 추정치와 과거 상관 행렬로부터 추정 공분산을 구성하고, 이를 이용해 무제약 글로벌 최소분산 포트폴리오 비중을 계산한다. 해당 비중으로 다음 기간의 실현 수익률을 적용하여 일별 포트폴리오 수익률을 얻고, 이를 누적 곱하여 누적 수익률 곡선을 만든 뒤 연환산 수익률, 연환산 변동성, Sharpe 비율, 최대 낙폭(Maximum Drawdown)을 평가 지표로 사용한다. 거래 비용과 롱온리 제약은 기본 실험에서는 포함하지 않고, 모든 모델에 동일한 규칙을 적용해 상대적 성과 비교에 초점을 맞추었다.

5. Results




Figure 2. Prediction Loss & Decision Regret of DFL/GRU-MSE

실험 결과는 먼저 예측 관점과 의사결정 관점을 구분하여 분석하였다. 예측 정확도 측면에서, GRU-MSE 모델은 기대한 대로 변동성 예측 MSE가 가장 낮게 나타났다. Figure 2에서 epoch별 학습 곡선을 보면, GRU-MSE는 초기 몇 epoch 동안 급격히 MSE가 감소한 뒤 수준에서 매우 평탄하게 수렴한다. 반면, DFL 모델의 예측 오차는 학습이 진행될수록 완만하게 감소하지만, 전체 범위에서 GRU-MSE보다 훨씬 큰 수준에 머무르며, “예측만 놓고 보면 비효율적인” 모델임을 보여준다.

그러나 동일한 epoch에서 측정한 Decision Regret 곡선은 상반된 양상을 보인다. GRU-MSE는 예측 MSE가 충분히 낮아진 이후에도 GMVP 기반 decision regret이 거의 줄어들지 않고, 높은 수준에서 완만하게 감소하는 데 그친다. 반대로 DFL은 학습 초반부터 regret이 빠르게 감소해 이후 epoch에서는 매우 낮은 수준으로 수렴한다. 이는 DFL이 예측 정확도는 일정 부분 희생하더라도, 포트폴리오 관점에서 중요한 방향(분산·공분산 구조)에 맞춰 파라미터를 조정하고 있음을 시사한다.



Figure 3. Cumulative Returns of each models (daily rebalancing)

Table 1

Backtest Performance of Portfolio Strategies

Strategy	Annual Return	Annualized Volatility	SR	Max Drawdown
Shrinkage	0.01	0.18	0.16	-0.44
Linear	-0.13	0.22	-0.52	-0.68
GRU-MSE	-0.15	0.22	-0.63	-0.71
DFL	0.05	0.17	0.39	-0.28

Note. Annual return and annualized volatility are computed from daily portfolio returns over the test period. Sharpe ratio is excess return per unit of volatility; max drawdown is the largest peak-to-trough loss.

포트폴리오 백테스트 결과 역시 이러한 경향을 뒷받침한다. GMVP 규칙에 따라 테스트 구간에서 일별로 포트폴리오를 재구성한 결과, Table 1에서 볼 수 있듯 DFL 전략은 양(+)의 연환산 수익률과 상대적으로 높은 Sharpe 비율, 그리고 비교적 완만한 최대 낙폭을 기록했다. Figure 3에서 DFL 곡선은 테스트 기간 동안 1을 기준으로 꾸준히 우상향하는 반면, GRU-MSE 및 Linear baseline은 장기적으로 1 이하로 하락하거나 큰 낙폭을 겪는 모습을 보인다. Shrinkage baseline은 손실은 크지 않지만 수익도 거의 없는 보수적 전략으로 나타나, 학습 기반 방법과의 대비를 제공한다.

6. Conclusion & Limitations

본 연구는 KOSDAQ 변동성 예측 · 포트폴리오 구성 문제에서, 전통적인 예측-후-최적화 접근과 Decision-Focused Learning(DFL)을 정량적으로 비교하였다. 동일한 데이터, 동일한 네트워크 구조, 동일한 백테스트 규칙하에서, GRU-MSE 모델은 변동성 예측 MSE에서 가장 우수한 성능을 보였지만, GMVP 포트폴리오의 분산 · 수익률 · Sharpe 비율 측면에서는 DFL에 미치지 못했다. 반대로, DFL은 예측 정확도에서는 희생이 있음에도 불구하고, decision

regret 및 실제 투자 성과(누적 수익률, Sharpe, 최대 낙폭)에서 우월한 결과를 보여, “의사 결정 목표를 직접 학습에 포함시키는 것”의 실질적 가치를 입증하였다.

이러한 결과는 두 가지 중요한 시사점을 제공한다. 첫째, 금융 시계열에서 “예측 성능이 좋은 모델”이 반드시 “투자 성과가 좋은 모델”은 아니라는 점이다. 특히 분산·공분산과 같이 포트폴리오 목적함수에 직접 등장하는 양을 다룰 때는, MSE 기준 최적화가 포트폴리오 위험에 민감한 구조를 충분히 반영하지 못할 수 있다. 둘째, DFL과 같이 손실 함수 단계에서 의사결정 문제를 통합하는 접근은, 복잡한 시장 구조와 제약이 존재하는 실제 환경에서도 유망한 대안이 될 수 있음을 보여준다.

그럼에도 불구하고 본 연구에는 몇 가지 한계가 존재한다. 우선, 포트폴리오 구성은 무제약 GMVP를 가정하여 숏 포지션을 허용하였으며, 롱온리 제약·레버리지 제한·섹터/종목별 비중 제한 등 실무에서 중요한 제약 조건을 반영하지 않았다. 또한 거래 비용, 슬리피지, 유동성 제약을 고려하지 않았기 때문에, 백테스트 결과를 그대로 실거래 성과로 해석하기에는 무리가 있다. 둘째, 리밸런싱 주기는 1거래일로 고정되어 있어, 주간·월간 등 다른 주기에서의 속성이나 거래비용 영향을 충분히 탐색하지 못했다. 셋째, 모델 구조와 하이퍼파라미터 탐색은 제한된 범위 내에서 수행되었으며, 보다 다양한 네트워크 아키텍처(CNN, Transformer 등)나 정교한 튜닝 전략을 적용할 여지가 남아 있다.

향후 연구로는 (i) 롱온리 및 턴오버 제약을 포함한 현실적인 mean-variance 최적화 문제로 확장, (ii) 거래 비용과 유동성을 명시적으로 모델링한 decision-focused loss 설계를 통해, “예측 vs 의사결정” 간 괴리가 어디까지 일반화되는지 검증하는 것도 중요한 과제이다.