

DAT 6기 캡스톤 프로젝트 보고서

파킨슨병 환자 음성 데이터 기반 **UPDRS** 점수 예측
: 원격 모니터링을 위한 음성 기반 중증도 추정 (Voice-based Severity Tracking
for Telemonitoring)

DAT 6기

팀명: **Better**

한지현, 구다연, 이정민, 조하연



Data Analysis & Technology



DAT 6기 캡스톤 프로젝트 보고서

제목

파킨슨병 환자 음성 데이터 기반 **UPDRS** 점수 예측
: 원격 모니터링을 위한 음성 기반 중증도 추정 (Voice-based Severity Tracking
for Telemonitoring)

Predicting UPDRS Score Based on Voice Data for Parkinson's Disease
Patients
: Voice-based Severity Tracking for Telemonitoring

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2025년 12월 02일

DAT 6기

팀: Better

한지현, 구다연, 이정민, 조하연

DAT 6기 캡스톤 프로젝트 보고서

제목



Data Analysis & Technology



파킨슨병 환자 음성 데이터 기반 UPDRS 점수 예측 : 원격 모니터링을 위한 음성 기반 중증도 추정 (Voice-based Severity Tracking for Telemonitoring)

국문 요약

본 프로젝트는 파킨슨병 환자의 음성 데이터만을 활용하여 중증도 지표인 UPDRS 점수를 비대면·지속적으로 예측할 수 있는 원격 모니터링 시스템을 구축하는 것을 목표로 한다. 공개 데이터셋(UCI Parkinson's Telemonitoring)을 바탕으로 환자의 발성 신호에서 추출한 다양한 음성 지표와 시간 기반 동적 변수를 활용하여, 선형 회귀·트리 기반 모델을 포함한 다양한 머신러닝 기법을 적용하였다. 또한 환자 단위 일반화 성능 확보를 위해 Group-fold 평가를 수행하였으며, 시계열 기반 분석을 위한 LSTM 모델과 예측 해석력을 강화하기 위한 SHAP 기반 XAI 기법을 적용하여 임상적 활용 가능성을 검증하였다. 이를 통해 병원 방문 간 발생하는 진료 공백을 완화하고, 파킨슨병의 진행 변화를 조기 감지할 수 있는 비침습적 모니터링 솔루션의 잠재력을 확인하였다.

Abstract

This project aims to develop a remote monitoring system capable of estimating Parkinson's disease severity using only voice data obtained via common devices such as mobile phones or laptop microphones. Using the publicly available UCI Parkinson's Telemonitoring dataset, we extracted dysphonia measures and incorporated time-dependent variables to model the progression of UPDRS scores. Multiple machine learning approaches, including linear regression, tree-based models, and a patient-independent evaluation strategy, were applied to ensure reliable generalization to unseen patients. Additionally, an LSTM-based temporal prediction framework and SHAP-based explainable AI techniques were integrated to enhance interpretability and clinical applicability. The proposed system demonstrates the potential to reduce the burden of frequent hospital visits, enable continuous tracking of symptom progression, and provide a practical, non-invasive tool to support clinical decision-making in Parkinson's disease care.

DAT 6기

팀: Better

한지현, 구다연, 이정민, 조하연



Data Analysis & Technology



목 차

제 1장 서론	1
제 1절 연구 배경	1
제 2절 연구 목적	1
제 2장 데이터 및 모델 소개	2
제 1절 선행연구 분석	2
제 2절 조사 및 분석 데이터 소개	3
제 3장 분석 과정	5
제 1절 사용 모델 및 모델 설계 - 서브 프로젝트	5
제 2절 사용 모델 및 모델 설계 - 메인 프로젝트	6
제 4장 분석 결과 및 결론	14
제 1절 서브 프로젝트 결과	14
제 2절 메인 프로젝트 결과	18
참고문헌	24
국외문헌	24



그림 목차

[그림 3-1-1]-[그림3-1-4] 14

[그림 3-2-1]-[그림3-2-2] 16

[2]



제 1장 서론

제 1절 연구 배경

본 프로젝트는 별도의 특수 장비 없이 스마트폰이나 노트북 마이크만으로 수집 가능한 ‘음성 데이터’를 활용하여 파킨슨병 환자의 중증도(UPDRS)를 비대면으로 추정하는 시스템을 제안한다. 파킨슨병은 완치가 어렵고 시간이 지날수록 운동 능력이 소실되는 진행성 질환으로, 지속적인 추적 관찰이 필수적이다. 그러나 환자의 중증도가 심화될수록 보행 장애로 인한 내원 부담이 가중되며, 이는 외래 진료 사이의 긴 의료 공백을 초래하여 적절한 치료 시점을 놓치는 원인이 된다. 이에 본 연구는 비침습적이고 접근성이 높은 음성 데이터를 활용하여 이러한 시공간적 제약을 극복하고자 한다.

데이터 측면에서는 검증된 UCI Parkinson’s Telemonitoring 공개 데이터셋을 활용하여 신뢰성을 확보하였으며, 데이터 이해부터 모델링, 검증, 해석에 이르는 머신러닝의 전 과정을 체계적으로 구현하였다. 특히 본 연구는 기존의 정적인 음성 특징 분석에 그치지 않고, 녹음 경과일 및 증상 진행 패턴과 같은 ‘시계열 동적 변수’를 모델에 함께 결합하는 과정을 통해 기존 연구와의 차별화를 꾀하였다. 이를 위해 환자-독립(Patient-Independent) 검증 방식을 도입하고, 기존 A안(단일 음성 지표 특징) 대비 B안(음성 지표 + 동적 변수)의 성능 향상을 정량적으로 규명하였다. 나아가 SHAP 기반의 설명 가능한 AI(XAI) 방법론을 통합하여 예측 결과의 투명성과 임상적 해석력을 확보함으로써 실전 적용 가능성을 높였다.

제 2 절 연구 목적

본 프로젝트의 기술적 의의는 다음과 같다. 첫째, 환자-독립 평가이다. 환자 단위로 학습·검증을 분리하여 처음 보는 환자에게도 예측력이 유지되는지를 정직하게 입증한다. 둘째, 순수 음성 지표 특징만으로 가능한 예측의 한계(A안)와 녹음 시점 등 시간 변수를 포함했을 때의 현실 성능(B안)을 나란히 제시함으로써 모델의 효용성을 명확히 설명할 수 있어야 한다. 이는 음성 데이터만으로 가능한 예측의 진짜 한계치를 보여주는 역할을 한다. 셋째, 메인 프로젝트에서는 CART 또는 XGBoost와 같은 트리 기반 앙상블 모델을 활용하고, 예측 이후에는 SHAP 기법을 활용해 예측 결과의 투명성과 디버깅 가능성을 높인다.



본 연구의 메인 프로젝트는 환자가 병원 방문 없이도 가정 환경에서 녹음한 음성 데이터만으로 UPDRS 점수를 근접하게 예측하여 기존 임상 평가를 보조하는 것을 목표로 한다. 비침습적이고 접근성이 높은 음성 기반 예측 모델은 환자의 검사 부담을 감소시키고 장기적 추적 관찰 체계를 구축하는 데 기여할 것으로 기대된다.

한편, 서브 프로젝트는 LSTM 기반 모델을 사용하여 UPDRS 점수의 추후 패턴을 예측하고, 나아가 XAI를 도입하여 예측 결과의 임상적 해석 가능성을 제고하는 데 목적을 둔다. 구체적으로, 모델 예측에 가장 큰 영향을 미친 상위 음성 특징을 도출함으로써 증상 악화 또는 개선의 주요 원인을 명확하게 제시하고, 이를 기반으로 근거 기반의 분석 리포트를 산출하여 의료진의 의사결정을 지원할 수 있도록 설계하였다.

궁극적으로 본 연구는 임상 환경에 도입될 경우 의료진과 환자 모두에게 효율적이고 지속적인 모니터링 환경을 제공하여 진료 품질 향상에 기여할 수 있을 것으로 전망된다.

제 2장 데이터 및 모델 소개

제 1절 선행연구 분석

본 프로젝트는 기존 연구의 한계점을 보완하고 차별화된 결과를 도출하기 위해, 본 연구에서 사용된 데이터셋인 UCI Parkinson's Telemonitoring Dataset의 근간이 된 선행 연구를 분석하였다. 이 연구는 파킨슨병 환자 42명을 대상으로 6개월간 추적 관찰을 진행하며 음성 데이터를 활용하여 UPDRS(통합 파킨슨병 등급 척도) 점수의 예측 정확도를 평가하는 데 목적을 두었다. 환자들은 약물의 증상 영향을 배제하기 위해 투약을 금지한 상태였으며, 데이터 수집은 환자들의 모음 '아~' 소리를 하루 6회 녹음하는 것을 원칙으로 하였고, 원칙을 준수한 환자만을 최종 연구 자료에 포함하여 데이터의 일관성을 확보하였다.

연구 방법론 측면에서, 환자의 실제 UPDRS 점수는 연구 시작 시점, 3개월 차, 6개월 차에 임상 전문가가 직접 평가하였다. 녹음된 음성 데이터와 UPDRS 점수의 시점을 일치시키기 위해, 측정되지 않은 주간의 UPDRS 점수는 **신경망이 학습한 복잡한 비선형 구조에 따라 생성하여** 통계적으로 추정하는 방식을 택하였다. 모델의 예측력을 높이기 위해, 추출한 16개의 음성 지표 중 중복을 방지하고 예측에 유의미한 변수만을 선별하였다. 이



과정에서 AIC/BIC 기반 부분집합 선택(Subset Selection)을 통해 Jitter(Abs), Shimmer, NHR, HNR, DFA, PPE의 6가지 특징 조합을 최적으로 도출하였다. 또한 모델의 일반화 성능을 검증하기 위해 10-fold 교차 검증(Cross-validation)을 1,000회 반복하여 테스트하였으며, 성능 지표로는 예측 오차의 절대적인 크기를 측정하는 MAE(Mean Absolute Error)를 사용하였다.

사용된 모델로는 선형적 관계를 파악하는 LS(Least Squares), 이상치 영향을 줄이는 IRLS(Iteratively Re-weighted Least Squares), 변수 선택 및 단순화에 사용된 Lasso와 함께, 비선형적 관계를 파악하기 위한 분류 및 회귀 트리 모델인 CART(Classification and Regression Tree)가 포함되었다. 총 세 가지 모델을 사용하여 본 연구에서는 UPDRS 예측 정확도를 향상시키기 위해 음성 기반 특징 조합과 회귀 모델에 따른 성능 차이를 비교하였다. 먼저 전체 16개의 음성 특징을 적용한 선형 회귀 기반 실험에서 LS, IRLS, Lasso 모델 모두 유사한 수준의 오차를 보였으나 Motor-UPDRS 기준으로 IRLS가 MAE 6.7로 가장 우수하였고, Lasso가 MAE 6.8로 가장 낮은 성능을 보였다. Total-UPDRS 또한 IRLS가 MAE 8.4로 상대적으로 우수하였으며, Lasso는 MAE 8.6으로 가장 큰 오차를 기록하였다. 반면 동일한 특징 수를 사용한 비선형 CART 모델은 Motor-UPDRS MAE 5.8, Total-UPDRS MAE 7.5를 달성하여 선형 모델 대비 약 1~1.5점 개선된 예측력을 나타냈다. 이후 Lasso 기반 특징 선택을 적용한 선형 모델 실험에서는 특징 수 축소에 따라 예측 성능 저하 경향이 관찰되었으며, 특히 최소 subset 사용 시 MAE가 6.8 이상(총합 기준 8.6 이상)으로 증가하여 음성 특징 간 복합적 관계를 선형적으로 포착하는데 한계가 있는 것으로 판단되었다. 그러나 Lasso를 통해 도출된 6개의 핵심 특징만을 적용하고 CART 모델에 최적 가지치기를 수행한 경우 Motor-UPDRS MAE 5.8과 Total-UPDRS MAE 7.5로 최소 오차를 유지하였으며, 이는 입력 변수 수를 절반 이하로 축소하고도 최고 성능을 확보할 수 있음을 보여준다. 종합하면 CART 모델 기반의 비선형 접근과 핵심 특징 선정 전략이 가장 높은 예측 정확도를 제공하는 것으로 확인되었다.

제 2절 조사 및 분석 데이터 소개

본 프로젝트는 공개 접근이 가능한 파킨슨병 음성 데이터를 메인 과제(UPDRS 회귀)와 과거의 기록(음성+점수+시간)을 종합하여 병의 진행 패턴을 예측하고, 상태 변화의 원인을 규명하는 정밀 리포트를 제공하는 데 모두 활용할 수 있는 것을 목표로 한다. 우선 우리는 실제 추정 프로젝트 구상을 위해 UCI Parkinson's Telemonitoring Dataset을



사용하였다. 이 데이터는 파킨슨병 환자 42명, 음성에서 추출한 16개 지표+UPDRS 점수를 포함하고 있다.

주요 구성 변수로는 환자 식별/기본 정보인 subject#, age, sex(환자 ID(1~42), 나이, 성별(0=남, 1=여 추정))과 시간 정보인 test_time, 예측 대상인 motor_UPDRS, total_UPDRS(운동 증상 점수 / 종합 점수)가 있다. 이때 Motor-UPDRS는 보행, 떨림, 근육 강직 등 운동 기능 저하를 직접적으로 반영하는 척도로 0~108점 범위를 가지며, 파킨슨병의 대표적인 운동 증상 변화를 세밀하게 측정한다. 반면 Total-UPDRS는 Motor-UPDRS에 더하여 인지 및 정서 상태, 행동 변화, 일상생활 수행 능력 등 다양한 임상 항목을 포함하여 환자의 전반적인 장애 수준을 종합적으로 평가하는 지표로, 0~176점 범위를 갖는다. 이러한 두 점수를 대상으로 한 예측 분석은 음성 기반 비침습적 모니터링의 임상적 활용 가능성을 검증하는 데 핵심적인 근거를 제공한다.

그리고 음성 지표 16가지(발성 떨림, 음압 변화, 비주기/잡음 비율 등), 비선형 음성 패턴인 RPDE, DFA, PPE(시간축 복잡도 및 음성 불안정성 특징) 총 22개(16개는 음성 지표)로 이루어져 있다. Jitter 5종은 성대 진동의 불규칙한 떨림, 즉 음정 흔들림을 의미하고, Shimmer 6종은 목소리 성량의 불안정성을 의미한다. NHR/HNR 2종은 목소리에 섞인 거친 잡음의 비율을 의미한다. RPDE/DFA/PPE 3종은 파킨슨병 특유의 복잡하고 혼란스러운 발성 패턴을 의미한다. 그리고 이전 motor_UPDRS는 직전 방문 때 몇 점이었던지, days_diff는 지난 녹음 후 며칠 만에 녹음했는지를, 마지막으로 day는 프로젝트 시작 시점으로부터 경과한 '일' 단위의 상대적 시간을 의미한다.

데이터셋 구성 특징으로는 총 샘플 수 5,875개, 환자 수 42명, 환자당 평균 측정 수 약 140회이며 대상자는 병원 내 추적 관찰 환자이고, 측정 방식은 주기적 음성 녹음 + 임상 UPDRS 채점 방식이다. 데이터셋을 보면 가장 적게 측정된 환자가 101회, 가장 많이 측정된 환자가 168회로, 같은 데이터셋 안에서 측정 횟수 차이가 최대 67회 발생하는 것을 알 수 있다. 따라서 환자마다 시간 시계열 길이가 달라지고 모델이 특정 환자 데이터에 더 적합해질 위험이 있다. 이 때문에 데이터 불균형 문제가 야기된다. 그리고 test_time에 따른 시계열 구조를 따르고 있다. 환자별 최소 기록 수는 10회 이하이고, 환자별 최대 기록 수는 400+개 이상 기록한 환자이다. 평균 나이 분포는 36세~85세이고, 평균은 64.8세, 표준편차는 8.7이다. 성별 분포는 남성 28명(66.7%), 여성 14명(33.3%)이다.

환자들마다 측정을 위해 하루 여러 번 녹음하고 그 빈도 차이가 크기에 결측이 흔하다는 특징이 있어, 며칠 단위로 비는 경우가 존재한다. 우리는 서브 프로젝트에서 이와 같은 현상을 일일 단위 병합, 파생 변수 생성, 데이터 정규화를 통해 문제점을 해결하고자 하였다.



제 3장 분석 과정

제 1절 사용 모델 및 모델 설계 - 서브 프로젝트

본 서브 프로젝트는 음성 지표와 운동 기능 평가 지수인 motor_UPDRS를 활용하여, 일정 횟수의 과거 녹음 데이터를 기반으로 미래의 중증도 패턴을 예측하는 데 목적이 있다. 이를 위해 LSTM 기반 모델 위주로 개발 및 비교하였으며, 데이터 규모가 제한적인 조건에서 모델 복잡도가 높을수록 과적합 위험이 증가할 수 있다는 점을 고려하여 단일 모델 중심의 평가를 수행하였다. 그 결과 세 모델 중 가장 우수한 예측 성능을 보인 단일 LSTM 기반 모델을 최종 분석 대상으로 선정하였다.

모델 구축을 위해 먼저 데이터셋 구성 및 전처리를 수행하였다. 하루에 여러 차례 측정된 음성 데이터를 평균 집계 또는 정수형 변환을 통해 단기 측정 노이즈를 제거하여 모델이 본질적인 변화 추세에 집중할 수 있도록 하였다. 또한 파킨슨병 환자들의 내원 주기 특성상 측정 간격이 일정하지 않음을 고려하여, 각 측정 시점 간 날짜 차이를 나타내는 시간 기반 파생변수 $\text{days_diff}(\text{Day}_t - \text{Day}_{\{t-1\}})$ 를 생성하였다. 이 변수는 단순 변화뿐 아니라 시간 경과 대비 증상 악화 속도까지 반영할 수 있도록 돕는다. 이와 더불어 모든 입력 특성 간 스케일 차이로 인한 학습 불안정을 방지하기 위해 Min-Max Scaling을 적용하였으며, 입력 변수용 스케일러(scaler_x)와 타깃 변수 복원을 위한 스케일러(scaler_y)를 분리하여 예측 결과를 임상적으로 해석 가능한 원래 값으로 복원할 수 있도록 설계하였다.

시계열 구조 학습을 위해 Sliding Window 방식으로 과거 3시점의 데이터를 하나의 입력 시퀀스로 구성하였으며, 최종 입력 형태는 (Batch Size, 3, 19)로 설정하였다. 학습-검증 과정에서 환자 간 데이터 독립성을 보장하기 위해 환자 단위로 80%를 훈련, 20%를 테스트로 분할하는 방식의 환자 독립(patient-independent) 검증 전략을 적용하였다.

본 연구에서 사용한 LSTM 모델 구조는 입력층(Input Layer)과 64 units의 LSTM 은닉층(Hidden Layer), Dropout(0.2)을 통한 정규화, motor_UPDRS를 산출하는 Dense(1) 출력층으로 구성되었다. 최적화 알고리즘으로 Adam(learning rate = 0.001)을 사용하였으며, 손실 함수는 MSE, 성능 평가는 MAE 및 MAPE로 설정하였다. 이는 절대적



예측 오차(MAE)와 환자 상태 대비 상대적 오차(MAPE)를 모두 반영함으로써 임상적 신뢰도를 확보하기 위함이다.

예측 결과는 단순 수치 비교가 아니라 실제 임상적 의사결정에 활용할 수 있도록 세 단계 해석 분석을 수행하였다. 첫째, 패턴 인식 단계에서는 예측된 시계열 motor_UPDRS에 대해 2차 곡선 회귀를 적용하여 곡률 계수(a)의 수치에 따라 악화($a > 0.02$), 호전($a < -0.02$), 유지($a \approx 0$)로 환자의 추세를 분류하였다. 둘째, 위험 등급화 단계에서는 전체 환자군의 악화 속도 대비 상대적 위치에 따라 상위 20%를 위험군, 20-50%를 주의군, 하위 50%를 정상군으로 설정하였다. 셋째, 원인 규명 단계에서는 음성 지표와 motor_UPDRS 변화 간 상관 분석을 수행하여 각 환자의 주요 위험 기여 특징을 확인하였다.

종합하면, 본 프로젝트는 음성 기반 motor_UPDRS 예측을 위해 정교한 데이터 전처리 → 시계열 구조화 → LSTM 모델 학습 → 임상적 해석 및 응용까지 포함하는 일련의 분석 파이프라인을 구축하였다. 이는 비대면 환경에서 파킨슨병 환자의 증상 악화를 조기 감지하고, 개인별 위험 요인을 규명하는 데 기여할 수 있어 실제 임상 적용 가능성을 제시한다는 점에서 의의가 있다.

제 2절 사용 모델 및 모델 설계-메인 프로젝트

3.2.1 MinMax 스케일링(0-1 정규화)

입력 피쳐들의 값 범위 차이를 제거하고 모델 학습을 안정화하기 위해 MinMax 스케일링을 적용하였다.

스케일 변환은 다음 식으로 정의된다.

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

본 연구에서는 기존 논문에서 스케일링 방식이 명확히 정의되지 않은 점을 고려하여, 전체 데이터셋을 기반으로 단 한 번 fit한 스케일링 파라미터(min/max)를 모든 fold에서 동일하게 사용하였다. 즉, K-fold와 Group-fold 모두에서 fold별로 fit을 다시 수행하지 않고, 전체 데이터의 분포를 기준으로 transform만 적용하였다.



이 접근은 fold 간 스케일의 일관성을 보장하지만, 전체 데이터를 사용해 스케일링을 fit하는 과정에서 test fold의 정보가 스케일러에 간접적으로 포함되는 문제가 발생한다. 이로 인해 K-fold 평가에서 성능이 실제보다 높게 나타날 가능성이 존재한다.

※ fit의 의미 scaler.fit(X)는 X의 각 피처에 대해 최솟값(min)과 최댓값(max)을 학습하여 저장하는 과정이며, scaler.transform(X)는 저장된 min/max를 사용해 값을 0~1 범위로 변환한다.

3.2.2 변수 선택

본 연구에서는 논문에서 활용된 특징 중 Parkinson 음성 증상과 관련성이 높은 6개 dysphonia feature(Jitter(Abs), Shimmer, NHR, HNR, DFA, PPE)를 주요 입력 변수로 사용하였다. 이들 변수는 time-domain 및 frequency-domain 기반의 음성 불규칙성을 반영하는 핵심 피처로 구성되며, 모든 검증 방식에서 동일하게 적용하였다.

검증 방식(Cross-Validation Strategy)

3.2.3 K-fold 검증 (기존 논문 방식 재현)

데이터를 10개의 fold로 분할(K=10)하고 기존 논문과 동일하게 1000회 반복했다. subject 구분을 고려하지 않고 전체 데이터를 임의 분할했다. 데이터 사용량이 최대화되어 평균적으로 높은 성능을 보이지만 동일 환자의 샘플이 train과 test에 동시에 포함될 가능성이 있어 과적합 위험이 존재한다. 이는 특히 음성 기반 데이터처럼 subject-dependent pattern이 강한 경우, 성능을 실제보다 높게 평가하는 결과를 초래할 수 있다.

Group-fold 검증 (환자 단위 분리) subject ID를 기준으로 동일 환자의 샘플이 train/test에 동시에 등장하지 않도록 분리했다. 기존 논문에 나오는 모델로는 1000번 반복하였지만, 항상 모델로는 과부하가 와서 50회 반복 수행했다. Group-fold는 실제 환경을 더 잘 반영하는 평가 방식으로, 데이터 중복을 제거해 환자 단위 일반화 능력을 더 정확하게 검사할 수 있다. 그러나 환자 수가 42명으로 제한되어 있어 fold 단위 학습 데이터 다양성이 감소하고, 그에 따라 성능 하락이 나타날 수 있다.

3.2.4 사용 모델



기존 논문 모델 본 연구에서는 기존 논문에 사용된 네 가지 모델을 동일한 설정으로 재현하였다. LS(Least Squares Regression), IRLS(Iteratively Reweighted Least Squares), LASSO(L1-Regularized Regression), CART(Classification and Regression Tree) 사용

3.2.5 확장 모델 (트리 기반 앙상블·부스팅 모델)

기존 논문에서 가장 성능이 우수했던 CART를 기반으로, 트리 기반 확장 모델 3종을 추가 실험하였다. Random Forest, Extra Trees, XGBoost를 사용하였다. 세 모델은 공통적으로 다수의 트리를 조합하여 학습하는 구조를 가지며, CART의 구조적 한계(불안정성·과대적합)를 보완하는 효과가 있다. 그러나 Group-fold 환경에서는 환자 간 분포 차이가 크기 때문에 성능 향상이 제한적으로 나타날 수 있다.

3.2.6 데이터 증강 전략

원본 UCI Parkinson's Telemonitoring 데이터는 Motor-UPDRS 기준으로 경증(≤ 10 점), 중간(10-30점), 중증(> 30 점) 구간의 분포가 비대칭적이며, 특히 경증·중증 구간의 샘플 수가 부족한 특징을 보인다. 이러한 구조는 회귀 모델이 데이터가 많은 중간 구간을 중심으로 학습되는 문제를 유발하며, 실제 예측에서는 임상적으로 중요한 극단 구간(초기·말기 환자)에서 오차가 증가하는 경향을 갖는다. 본 연구는 이 문제를 완화하기 위해 구간별 균형을 목표로 한 단계적 데이터 증강 전략을 설계하였다. 해당 전략은 다음 네 단계의 절차로 구성된다.

(1) 시퀀스 기반 전처리 및 정규화

먼저 데이터 증강 및 생성 모델 학습을 위한 입력 구조를 마련하기 위해, 동적 변수(test_time, motor_UPDRS, total_UPDRS 및 16종 음성 지표)와 정적 변수(age, sex)를 분리하여 전처리를 수행하였다. 모든 연속형 변수는 Min-Max Scaling(0~1 변환)을 적용하여 변수 간 스케일 차이를 제거하였으며, 이후 subject# 기준으로 데이터를 그룹화해 환자 단위의 시계열 구조를 구성하였다. 환자별 시퀀스 길이가 서로 다르기 때문에 최대 길이에 맞추어 0-padding을 적용하였고, 이러한 절차를 통해 시계열 모델과 생성 모델이 처리할 수 있는 3차원 입력 구조(환자 수 $\times$ 시퀀스 길이 $\times$ 피쳐 수)를 완성하였다.



(2) 구간별 데이터 생성 및 보강 절차

Motor-UPDRS 분포의 불균형을 해결하기 위해 본 연구는 구간별 특성에 따라 서로 다른 방식의 데이터 생성 및 보강 전략을 적용하였다. 중간 구간(10-30점)은 관측치가 상대적으로 많고 패턴 다양성이 폭넓게 나타나는 특징이 있어, Variational Autoencoder(VAE)를 활용한 시퀀스 생성 방식을 적용하였다. VAE는 LSTM 기반 인코더와 디코더 구조를 사용하여 발성의 비주기성·잡음성·복잡도와 같은 파킨슨병 환자의 발성 특성을 잠재공간에 학습한 후, Gaussian Mixture Model을 통해 다양한 잠재 벡터를 샘플링하여 새로운 시계열을 생성하였다. 이 절차는 중간 구간의 패턴적 다양성을 확장하고, 모델이 보다 폭넓은 발성 변동성을 학습하도록 돕는 역할을 한다.

반면 경증(≤ 10 점)과 중증(> 30 점) 구간은 원본 데이터량이 매우 제한적이기 때문에, 생성 모델만으로는 실제 임상적 특성이 충분히 반영되지 않으므로 원본 환자 시퀀스를 직접 활용하는 방식으로 보강을 진행하였다. 해당 구간의 환자 시퀀스를 무작위 복원추출 방식으로 확장하되, 동일 시퀀스가 과도하게 반복되는 것을 방지하기 위해 시계열 신호에 소규모 노이즈를 주입하여 자연스러운 변형을 부여하였다. 또한 특정 구간에서 원본 환자 수가 지나치게 적을 경우, VAE로 생성한 시퀀스를 일부 보조적으로 포함해 최소한의 패턴 다양성을 확보하였다.

이와 같이 중간 구간은 생성 모델을 활용해 다양성을 증대하고, 경증·중증 구간은 원본 기반 보강을 통해 구간별 데이터 부족 문제를 보완함으로써, 전체 Motor-UPDRS 분포를 보다 균형적으로 재구성할 수 있었다. 이러한 전략은 특히 예측이 어려운 극단 구간에서 모델의 안정성과 민감도를 향상시키는 데 기여하였다.

(3) 역정규화 및 데이터 품질 검증

전 구간에 대한 생성·보강 절차가 완료된 후, 모든 시계열 샘플은 실제 모델 학습에 활용할 수 있도록 원본 스케일로 복원하는 과정을 거쳤다. 먼저 Min-Max Scaling에 사용한 동일한 스케일러를 적용하여 동적 음성 변수와 motor_UPDRS, age 등의 연속형 변수를 원래 값의 범위로 역정규화하였다. 성별(sex) 변수는 원본 값이 그대로 유지되도록 처리하였으며, 생성 및 보강 과정에서 값이 변형되지 않도록 관리하였다. 이후 생성된 시퀀스 중 일부에서 음수 값이 발생한 경우, 이는 실제 발성 지표의 물리적 특성과 맞지 않기 때문에 모두 0으로 보정하였다.

역정규화된 데이터는 동일한 패턴이 반복되는 것을 방지하고, 원본 데이터의 변동 폭을 적절히 반영하기 위해 구간별로 강도가 다른 노이즈를 주입하였다. 중간 구간에는 원본 분포의 표준편차를 기준으로 비교적 작은 범위의 변동을 적용하여 발성 패턴의



자연스러운 다양성을 확보하였으며, 경증과 중증 구간에는 더 큰 폭의 변화가 가능하도록 표준편차 비율을 다소 높여 보정하였다. 이러한 노이즈 조정은 원본과 생성 데이터가 과도하게 분리되지 않으면서도, 동일 시퀀스의 기계적 반복을 방지하는 데 목적이 있다. 또한 motor_UPDRS는 임상적 특성을 고려해 0~100 범위에서 클리핑하여 비현실적인 점수 생성 가능성을 차단하였다.

마지막으로, 구간별 생성 및 보강 과정을 통해 구성된 모든 시퀀스는 행 단위의 데이터프레임으로 변환되어 하나의 통합 학습용 데이터셋으로 정리되었다. 이 과정에서 결측 여부를 점검하고, 음수 값·비정상치 처리, 변수 타입 일관성 검증 등을 수행하여 최종적으로 CSV 형태의 학습용 증강 데이터셋을 구축하였다. 결과적으로, 최종 데이터는 구간 간 샘플 수의 불균형이 크게 완화되었고, 원본 분포의 범위와 변동성을 유지한 상태에서 극단 구간의 예측 민감도를 향상시킬 수 있는 구조를 갖추게 되었다.

3.2.7 파생 변수 설계

본 연구는 원본 23개 음성 지표만으로는 파킨슨병 환자의 발성에서 나타나는 비주기성, 잡음성, 신호 복잡도, 주파수·진폭의 불안정성과 같은 핵심 음성 특성을 충분히 설명하기 어렵다는 한계를 확인하였다. 이에 따라 모델이 이러한 특성을 구조적으로 학습하도록 하기 위해 총 14개의 파생 피처를 추가로 설계하였다. 파생 피처는 비율 기반 피처, 상호작용 항, 변환 피처, 변동성 기반 통계 피처, 그리고 종합 음질 지표로 구성되며, 이는 원본 변수만으로는 포착되지 않는 비선형적 관계와 발성 패턴의 복합적 변화를 정량적으로 반영하는 데 목적이 있다.

우선 비율 기반 피처는 음성 지표의 절대량보다 상대적 크기가 임상적 변화를 더 민감하게 반영한다는 점에 착안하여 구성하였다. 파킨슨 환자에서 흔히 나타나는 진폭 변동 증가를 반영하기 위해 Jitter 대비 Shimmer의 상대적 비율을 나타낸

$$\text{Jitter_Shimmer_ratio} = \frac{\text{Jitter}}{\text{Shimmer}}$$

를 생성하였다. 또한 조화음 대비 잡음 비중의 변화를 정량화하기 위해 HNR과 NHR의 비율을 구성하였으며, Jitter와 Shimmer의 상대적 기여도를 파악하기 위해 두 값을 각각 Jitter+Shimmer로 정규화한 비율 피처를 추가하여 발성 불안정성의 구조를 보다 세밀하게 반영하였다.

음성 지표 간 상호작용을 포착하기 위해 구성한 결합 항은 발성의 무작위성, 장기 상관성, 잡음성, 조화음 안정성 간의 복합적 패턴을 반영하는 데 사용되었다. 대표적으로 RPDE와 DFA의 곱은 신호의 무작위성과 장기 구조를 동시에 고려한 지표로서

$$RPDE_DFA = RPDE \times DFA$$

와 같이 계산하였다. 이와 함께 Jitter $\times$ HNR, Shimmer $\times$ NHR, HNR $\times$ DFA와 같은 상호작용 항을 생성하여 파킨슨 중증도가 상승할 때 동시에 변화하는 음성 지표들의 비선형적 관계를 모델에 반영하였다.

변환 피처는 음성 지표의 비대칭적 분포를 안정화하고 극단값의 영향을 완화하기 위해 도입하였다. 특히 잡음 대비 조화음 비율(HNR)의 민감도를 강화하기 위해 HNR 제곱항

$$HNR_squared = (HNR)^2$$

을 구성하였으며, 오른쪽으로 치우친 NHR의 분포를 정규화하기 위해

$$\log_NHR = \log(1 + NHR)$$

를 적용하였다. 동일한 방식으로 Jitter에도 로그 변환을 적용하여 경증 구간에서 나타나는 미세한 진동 신호를 안정적으로 반영할 수 있도록 하였다. 시간축 변동성을 반영하기 위한 통계 기반 파생 피처는 Jitter, Shimmer, HNR의 최대·최소값 차이 또는 표준편차를 활용하여 구성하였다. 파킨슨 환자의 발성은 평균값의 변화보다 오히려 변동성 자체가 중증도와 더 강한 상관을 나타내므로, 이러한 변동성 피처는 모델이 발성 불안정성을 세밀하게 학습하는 데 기여한다. 마지막으로 여러 발성 불안정성 지표를 하나의 구조적 신호로 통합하기 위해 종합 음질 지표인 Voice Quality Index(VQI)를 설계하였다. 이는 다음과 같이 정의된다.

$$VQI = \frac{Jitter + Shimmer + NHR}{HNR}$$

VQI는 발성 흔들림(Jitter·Shimmer)과 잡음성(NHR)의 증가, 그리고 조화음 안정성(HNR)의 감소가 동시에 나타나는 파킨슨병의 특성을 하나의 수치로 요약하며,



실제 모델에서도 높은 설명력을 보였다.

이와 같은 파생 피처 설계는 원본 음성 지표만으로는 포착하기 어려운 비선형적·복합적 발성 패턴을 구조화하여 모델의 학습 효율을 높였으며, Motor-UPDRS 예측 성능 향상에 유의미한 기여를 하였다

3.2.8 4중 앙상블 회귀 모델 설계

본 연구는 단일 모델이 Motor-UPDRS 전 구간(경증-중간-중증)의 변동성을 균등하게 학습하기 어렵다는 점에 주목하였다. 특히 파킨슨병 환자의 발성 신호는 구간별로 서로 다른 패턴적 특성을 보이며, 특정 모델은 특정 구간에 강점을 보이는 경향이 있다. 이에 따라 본 연구는 예측 안정성을 확보하고 극단 구간(초기·말기)의 민감도를 높이기 위해 서로 다른 구조적 특성과 학습 메커니즘을 갖는 네 개의 회귀 모델로 구성된 4중 앙상블(4-Model Ensemble) 방식을 채택하였다. 이 방식은 Stacked Generalization 기법을 적용하여 각 모델이 개별적으로 산출한 예측값을 메타 학습기(meta-learner)를 통해 최적 조합함으로써 최종 Motor-UPDRS를 추정하는 구조로, 단일 모델 대비 변동성과 오차 편향을 효과적으로 완화하는 장점이 있다.

본 연구에서 사용하는 네 가지 기본 모델(base learners)은 Support Vector Regression(SVR), LightGBM, CatBoost, XGBoost로 구성되며, 각 모델은 서로 다른 학습 원리와 최적화 전략을 기반으로 상보적 역할을 수행한다.

Support Vector Regression(SVR)은 커널 기법을 활용한 비선형 매핑과 ϵ -insensitive loss function을 통해 작은 샘플 크기에서도 구조적 안정성을 제공하는 모델이다. 본 연구에서는 RBF(Radial Basis Function) 커널을 사용하였으며, 하이퍼파라미터는 $C = 0.185$, $\epsilon = 0.145$ 로 설정하여 지나친 복잡도를 억제하고 일반화 성능을 확보하였다. SVR은 음성 지표 간 전역적 관계(global relationship)를 포착하는 데 강점을 보이며, 특히 극단값에 대한 과민 반응을 제한하는 robust한 예측 경계를 형성한다. 이는 파킨슨 음성 데이터에서 발생할 수 있는 이상치(outlier)에 대한 내성을 제공하며, 앙상블 내에서 기준선(baseline) 역할을 수행한다.

LightGBM은 Gradient-Based One-Side Sampling(GOSS)과 Exclusive Feature Bundling(EFB) 기법을 통해 학습 효율성을 극대화한 경량 부스팅 모델이다. 본 연구에서는 $n_estimators = 917$, $learning_rate = 0.0057$, $max_depth = 11$, $num_leaves = 134$ 로 설정하여 깊은 트리 구조를 통한 세밀한 패턴 학습을 가능하게 하였다.



LightGBM은 leaf-wise 성장 방식을 채택하여 정보 이득(information gain)이 큰 경로를 우선적으로 확장함으로써, 음성 지표 간 복잡한 비선형 상호작용을 효과적으로 포착한다. 특히 중간 구간(10~30점)에서 안정적인 예측 성능을 보이며, L1/L2 정규화(reg_alpha = 8.14, reg_lambda = 0.026)를 통해 과적합을 방지한다.

CatBoost는 Ordered Boosting과 Oblivious Decision Trees 구조를 기반으로 범주형 변수 처리 및 극단값 학습에 강건성을 나타내는 모델이다. 본 연구에서는 iterations = 1000, learning_rate = 0.03, depth = 6, loss_function = 'MAE'로 설정하여 절대오차 최소화에 집중하였다. CatBoost의 핵심 강점은 prediction shift 문제를 해결하는 Ordered Boosting 메커니즘으로, 이는 동일 샘플에 대한 반복적 잔차 학습 시 발생할 수 있는 편향을 제거한다. 또한 symmetric tree 구조는 모든 노드에서 동일한 분할 조건을 사용하여 과적합을 억제하며, 이는 샘플 수가 상대적으로 적은 극단 구간(≤ 10 점, ≥ 30 점)에서의 예측 민감도 향상에 기여한다. 실제로 Feature Importance 분석에서 CatBoost는 DFA, RPDE 등 복잡도 관련 지표에 높은 가중치를 부여하며, 이는 중증 환자의 음성 단조로움(monotony) 패턴 포착에 유리하게 작용한다.

XGBoost는 Second-Order Taylor Expansion을 활용한 손실 함수 근사와 Regularized Learning Objective를 통해 정교한 예측 최적화를 수행하는 모델이다. 본 연구에서는 n_estimators = 1000, learning_rate = 0.03, max_depth = 6, objective = 'reg:absoluteerror'로 설정하여 MAE 기준 최적화를 수행하였다. XGBoost는 level-wise 트리 성장 방식을 채택하여 각 깊이에서 균형 잡힌 분할을 수행하며, 이는 구간 간 예측 편향을 완화하는 데 기여한다. 또한 Column Subsampling(0.8)과 Row Subsampling(0.8)을 통해 모델 다양성을 확보하고, 이는 앙상블 내에서 다른 모델과의 예측 상관성을 낮추어 독립적 오차 분산 효과를 강화한다.

네 모델의 선정 기준은 다음과 같은 구조적 상보성에 기반한다. 첫째, 학습 메커니즘의 다양성으로, SVR의 커널 기반 비선형 매핑, LightGBM의 leaf-wise 성장, CatBoost의 ordered boosting, XGBoost의 level-wise 성장이 서로 다른 관점에서 데이터를 해석한다. 둘째, 손실 함수 최적화 전략의 차이로, SVR은 ϵ -insensitive, CatBoost와 XGBoost는 MAE, LightGBM은 정보이득 기반 분할을 사용하여 오차 측정 방식이 상이하다. 셋째, 정규화 메커니즘의 다양성으로, SVR의 C 파라미터, LightGBM의 L1/L2 정규화, CatBoost의 symmetric tree, XGBoost의 second-order regularization이 각기 다른 방식으로 과적합을 제어한다.

이러한 구조적 차이는 각 모델이 음성 지표의 서로 다른 측면을 학습하게 하며, 이는 앙상블 시 예측 다양성(diversity)을 극대화하여 편향-분산 트레이드오프를 효과적으로 관리한다.

각 기본 모델은 동일한 전처리·증강 데이터셋을 기반으로 개별 학습되며, 학습된 네



모델의 예측값은 StackingRegressor 구조의 메타 학습기로 전달된다. 본 연구에서는 메타 학습기로 Ridge Regression($\alpha = 1.0$)을 채택하였으며, 이는 L2 정규화를 통해 기본 모델 간 예측값의 과적합을 방지하고 최적의 선형 결합 계수를 학습한다. 최종 예측은 다음과 같이 정의된다.

$$\hat{y}_{final} = \text{Ridge}(\hat{y}_{SVR}, \hat{y}_{LGBM}, \hat{y}_{CatBoost}, \hat{y}_{XGBoost})$$


여기서 $\hat{y}_i$ 는 각 기본 모델의 예측값이며, Ridge 회귀는 이들의 가중 선형 결합을 학습하여 최종 예측값 $\hat{y}_{final}$ 을 산출한다. 이러한 Stacking 기법은 단순 평균 앙상블 대비 각 모델의 상대적 강점을 데이터로부터 학습하여 반영할 수 있다는 점에서, 보다 적응적(adaptive)이고 정교한 결합 방식을 제공한다. 특히 Ridge의 정규화 항은 특정 모델에 과도한 가중치가 부여되는 것을 방지하며, 이는 교차검증 시 fold 간 안정성을 향상시킨다. 본 연구에서는 5-Fold GroupKFold 교차검증을 통해 환자 단위의 데이터 누수를 방지하며 앙상블 성능을 평가하였다. 이와 같이 네 가지 상이한 모델의 구조적 장점을 Stacked Generalization 기법으로 결합한 4중 앙상블 방식은 파킨슨 음성 기반 Motor-UPDRS 예측에서 변동성 완화, 극단 구간 민감도 개선, 구간 간 예측 균형 유지에 기여한다.

제 4장 분석 결과 및 결론

제 1절 서브 프로젝트 결과


4.1.1 환자별 시계열 예측 분석

본 프로젝트에서는 환자별 시계열 음성 지표를 입력하여 Motor-UPDRS 점수를 예측하였다. 그 결과는 다음과 같다.




[그림 3-1-1]

Patient-1의 경우 MAE: 0.51로 예측 결과가 실제 추세를 거의 완전하게 따라감을 확인할 수 있다. 점수 증가 속도 또한 높은 정합성을 보인다. MAPE 1.5%, 방향적 정확도 100%로 임상적으로 활용 가능성 또한 높게 나타난다. 결국 장기적 악화 패턴을 효과적으로 학습한 사례라고 할 수 있다.




[그림 3-1-2]

Patient-39의 경우 MAE: 0.44로 Recording Sequence 전반에서 지속적 증가 추세를 정확하게 추정한다. 단기 변동 없이 꾸준히 악화되는 패턴을 잘 반영하였음을 확인할 수 있다. 이를 통해 명확한 질환 진행 패턴 환자에서 높은 추세 모사 능력이 확인되었고, 완전한 단조 증가 패턴에서 예측력이 특히 우수함을 알 수 있다.




[그림 3-1-3]

Patient-36의 경우 MAE: 0.82로 초기에는 상승하다가 후반에 하락하는 비선형 패턴을 보여준다. Peak 이후 감소 시작 시점 및 속도 예측은 다소 오차가 존재하나 악화에서 완화하는 전환의 전반적 흐름은 모사하였다. 이를 통해 복잡한 비선형 회복 패턴에서도 일정 수준 예측이 가능함을 확인하였다.



[그림 3-1-4]

Patient-24의 경우 MAE: 0.36으로 UPDRS 점수가 거의 변동 없이 안정 상태를 유지함이 나타난다. 예측 곡선 역시 작은 폭으로 안정적 증가만 보여 일치도 또한 높음이 보인다. 임상적으로 안정화 단계 환자로 해석이 가능하다. 이를 통해 변동성이 낮은 환자에서 매우 정확한 추정이 나타남을 확인하였다.



[그림 3-1-1]

결론적으로 우리 서브 프로젝트의 모델은 절대값 예측보다 질병 진행 방향 파악에 강점을 가지고, 단기 예측과 달리 장기 추세 기반 모니터링 도구로서 활용 가능성이 높다. 그리고 병원 방문 간격 사이에 발생하는 질환 상태의 소폭 변화도 감지할 수 있다.


4.1.2 서브 프로젝트의 한계 및 개선방향

본 서브 프로젝트는 LSTM 기반 시계열 예측 모델을 활용하여 UPDRS의 일자별 변화를 추정하는 접근을 시도하였다. 그러나 소규모 시계열 데이터의 한계로 인해, 모델이 특정 시점의 극단적 변동에 과도하게 반응하거나 해석 가능성이 저하되는 문제점이 존재하였다. 이를 보완하기 위해 첫째, LSTM 기반 예측 구조에 어텐션 메커니즘을 결합함으로써 예측에 기여도가 높은 핵심 구간에 가중치를 부여하고, 결과 해석력을 동시에 확보하고자 하였다. 둘째, 전통적인 MSE 기반 손실함수가 시간적 오차 패턴을 충분히 반영하지 못하는 문제를 해결하기 위해 Soft-DTW(Soft Dynamic Time Warping) 손실을 도입하였다. Soft-DTW는 시계열 간 변형(Shape)과 시차(Lag)를 고려한 유연한 매칭을 제공하여 실제 환자 상태 변화의 시간축 왜곡을 자연스럽게 반영할 수 있다. 이러한 개선 방향은 모델이 단순히 직전 관측치에 대한 회귀를 수행하는 데 그치지 않고, 환자의 증상 진행 패턴을 구조적으로 학습하도록 지원하여 임상적 활용 가능성을 제고할 수 있을 것으로 기대된다.

제 2절 메인 프로젝트 결과

본 프로젝트는 원래 논문을 기반으로 성능이 잘 나오는 모델을 찾아 성능을 실험해보는 것이었다.

4.2.1 K-fold 결과




[그림 3-2-1]

기존 연구와 동일하게 K-fold 1000회 반복 평가를 수행한 결과, 네 가지 모델 모두 논문과 유사한 성능을 보였다. LS는 $MAE = 6.799$, IRLS는 $MAE = 6.603$, LASSO는 $MAE = 6.6135$, CART는 $MAE = 6.0859$ CART가 가장 우수한 성능을 보였으며, K-fold에서는 전체 데이터 기반 스케일링과 샘플 중복으로 인해 성능이 상대적으로 높게 나타난 것으로 해석된다.

Random Forest는 $MAE = 4.835$, Extra Trees는 $MAE = 4.967$, XGBoost는 $MAE = 4.754$ 이 나왔다. 세 모델 모두 기본 CART보다 크게 향상된 성능을 보였으며 이는 앙상블·부스팅 기법을 통해 비선형적 구조와 복잡한 패턴을 안정적으로 학습했기 때문이다.

4.2.2 Group-fold 결과



[그림 3-2-2]

Group-fold에서는 모든 모델의 MAE가 증가하였다. LS $\rightarrow$ MAE = 7.4244, IRLS는 MAE = 7.2756, LASSO는 MAE = 7.2315, CART는 MAE = 8.0835가 나왔다. 특히 CART는 K-fold 대비 성능이 크게 저하되었다.

Group-fold 성능 저하의 원인을 분석해보자. 먼저 동일 subject 중복 제거되어 과적합 억제되고 성능 감소하였다. 또한 환자 수(42명) 제한되어 fold당 학습 데이터 다양성 부족했다. 그리고 트리 기반 모델의 구조적 특성도 있다. 트리 모델은 개별 sample의 미세한 값(예: jitter = 0.012 vs 0.013)에 따라 완전히 다른 leaf로 분기된다. 즉, 훈련 데이터 분포에 맞춘 규칙이 생성되어 새로운 환자가 훈련 데이터의 분포와 다르면 leaf 매칭 실패하여 예측 성능 저하된다. 작은 변화에도 의사결정 경로가 달라지는 high-variance 구조이다.

따라서 Group-fold에서 트리 모델의 성능이 떨어진 것은 음성 특성이 환자마다 크게 다르고 샘플 기반 분기 규칙이 새로운 환자에게 일반화되지 못한 결과로 해석된다.

4.3.2 확장 모델 Group-fold 결과

Random Forest는 MAE = 7.359, Extra Trees는 MAE = 7.287, XGBoost는 MAE = 7.478이 나왔다. 확장 모델 역시 Group-fold에서는 성능 향상이 제한적으로 나타났으며 특히 XGBoost는 환자 단위 분포 차이에 민감하여 MAE가 증가하는 경향을 보였다.

한계 및 보완 전략

한계 및 보완 전략으로는 데이터 증강이 필요하다. 전체 샘플 수는 많아 보이나, 실제 고유 환자 수가 42명에 불과하여 환자별 음성 특성의 다양성을 충분히 반영하기 어렵다. 이는 새로운 환자 예측 시 일반화 성능 저하로 이어진다. 따라서 jitter/shimmer perturbation, pitch shifting, amplitude scaling 같은 기법을 제안한다. 이들은 pathological speech에서 흔히 사용되는 방법으로 소량의 환자 수 문제를 완화할 수 있다.


두 번째로는 멀티모달·동적 피쳐 확장이다. 현 연구의 dysphonia feature는 모두 발화 전체를 평균화한 정적 스칼라 값으로 파킨슨 음성의 핵심 특징인 시간적 불규칙성을 충분히 반영하지 못한다. 그래서 Multi-resolution feature extraction을 사용해 다양한 window 길이(25 ms, 100 ms 등)에서 반복 분석하거나 짧은 떨림부터 긴 주기 tremor까지 포착할 수 있다. 또한 Window-based sliding feature를 사용해 전체 발화를 일정 길이로 구간화할 수 있다.

마지막으로 Dynamic feature computation을 이용해 피쳐 시퀀스의 변화량·변동성 기반 특징을 파킨슨 특유의 vocal irregularity를 반영하여 모델이 환자의 음성 변화를 세밀하게 학습하도록 도와 Group-fold 기반 평가에서도 더 높은 일반화 성능을 확보할 수 있다.

양상별 결과


본 연구에서는 Feature Engineering, 구간 기반 데이터 증강 전략, 그리고 SVR-LightGBM-CatBoost-XGBoost 4종 양상별을 결합한 모델의 성능을 GroupKFold(5-Fold) 구조에서 평가하였다. 그 결과 모델의 평균 MAE는 5.4787 ± 0.7519 로 나타났으며, 최소 MAE는 4.2652, 최대 MAE는 6.4449를 기록하였다. 이는 기존 단일 모델(예: LightGBM 단독 사용 시 MAE 6.8~7.2) 대비 약 15~20%의 성능 향상을 의미하며, fold 간 표준편차 또한 상대적으로 낮아 환자 간 일반화 성능이 개선되었음을 시사한다.





[Figure1]


Figure 1의 환자별 시계열 예측 그래프에서는 전체 42명 중 대부분의 환자에서 실제 Motor-UPDRS 변화 경향을 비교적 안정적으로 추적하는 모습을 확인할 수 있었다. 특히 중간 구간(UPDRS 10~30)의 변동성 패턴은 실제 값과 유사한 형태를 보였으며, 경증과 중증 구간은 절대값 오차는 존재하나 시간에 따른 추세선은 비교적 유사하게 재현되었다. 다만 전체 환자 중 약 14%(6명)에서는 예측값의 분산이 실제보다 과도하게 증가하거나, 반대로 변화량이 축소되는 경향이 확인되어 시계열적 민감도 측면에서 추가 보완이 필요함을 시사한다. 이는 특히 환자 ID 12, 16, 22 등에서 두드러졌으며, 해당 환자들은 측정 회차가 상대적으로 적거나(평균 8회 미만) 측정 간격이 불규칙한(표준편차 15일 이상) 특징을 보였다.



[Figure2]

Figure 2의 실제값-예측값 산포도에서도 전체적으로 선형 증가 추세를 잘 따르고 있으나, 예측값이 다소 중심 구간(15~25점)으로 수렴하는 현상이 관찰되었다. 이는 Motor-UPDRS 분포가 중간 범위에 밀집되어 있기 때문에(중앙값 21.0, IQR 14.5~27.0), 모델이 극단 구간에서 보수적으로 예측하는 경향이 반영된 결과로 해석된다. 실제로 UPDRS 10 이하 구간에서는 평균 +2.3점의 과대예측 경향이, 35 이상 구간에서는 평균 -2.8점의 과소예측 경향이 확인되었다. Figure X의 오차 분포는 평균 -0.37로 편향이

거의 없었으나, +10 이상 과대예측이 발생하는 사례가 전체의 3.2%, -10 이하 과소예측이 2.8% 존재해 개별 환자군에서의 차등적 보정 전략의 필요성을 보여준다.



[Figure3]

Figure 3의 Feature Importance 분석에서는 age(14.85%), DFA(7.76%), PPE(5.33%), RPDE_DFA_interaction(5.18%), RPDE(5.13%), HNR(5.09%)이 상위권을 차지하였다. 특히 age가 2위 DFA의 약 2배에 달하는 중요도를 보인 것은 Motor-UPDRS가 고령층에서 상승하는 임상적 경향과 일치하나, 음성 기반 모델 관점에서는 특정 인구학적 변수가 예측 전체를 지배하는 구조적 편향 가능성을 시사한다. 또한 본 연구에서 새롭게 설계한 파생 Feature들인 Jitter_Shimmer_ratio(11위, 4.11%), RPDE_DFA_interaction(4위, 5.18%), Jitter·Shimmer 통계량(평균·표준편차·range) 역시 상위 20위권에 복수 포함되며 음성 신호의 비선형적·복합적 특성을 반영하는 데 기여함을 확인하였다. 특히 RPDE_DFA_interaction이 원본 RPDE(5위)보다 높은 순위를 기록한 것은 Feature Engineering의 효과를 직접적으로 입증한다.

종합적으로 본 모델은 파생 Feature와 구간 기반 증강 전략을 통해 Motor-UPDRS 예측 안정성을 확보하였으나, 여전히 극단 구간 예측 정밀도(경증 +2.3점, 중증 -2.8점 편향), 특정 변수의 중요도 편중 현상(age 14.85%), 그리고 측정 회차가 적은 환자에 대한 시계열 민감도 저하 문제가 존재하며 이를 보완하기 위한 후속 연구가 필요하다.

연구의 한계 및 개선 방향

첫째, 본 연구의 Feature Engineering은 연구자가 직접 정의한 수동 규칙 기반으로 이루어졌다는 점에서 한계가 존재한다. 음성 신호의 잠재적 패턴 중 일부는 도메인 지식 기반 설계만으로는 포착되지 않을 가능성이 있으며, Jitter 5종, Shimmer 6종과 같이 유사 계열 Feature가 다수 포함되면서 중복 정보가 모델에 영향을 줄 위험이 있다. 이러한 한계를 보완하기 위해 향후에는 CNN 기반 스펙트로그램 학습, Transformer 기반 시계열 자동 특징 추출, LASSO·Elastic Net 기반 Feature Selection 등 자동화된 Feature Learning·Feature Selection 전략을 적용할 필요가 있다.

둘째, 합성 데이터를 활용한 학습 과정에도 구조적 한계가 존재한다. 본 연구에서 사용한 Beta-VAE 기반 증강 기법은 기존 데이터의 분포를 모방하는 방식이므로, 원본 데이터에 존재하지 않는 새로운 패턴을 생성하지는 못한다. 또한 UPDRS 정답지 자체가 의료진의 고정적 평가 지표에 기반하고 있고 환자별 측정 회차가 평균 14회로 제한적이기 때문에, 실제 환자의 미세한 기능 변화가 정답지에 충분히 반영되지 않을 가능성이 있다. 이를 보완하기 위해서는 정답지의 시간 해상도를 높이는 작업이 선행되어야 하며, 추가 측정 회차 확보, 스플라인 보간 기법 적용, 혹은 웨어러블 장치를 통한 연속적 신호 수집 등 정답지 밀도 강화 전략이 필요하다.

셋째, Feature Importance에서 age가 전체의 14.85%를 차지하며 가장 높은 비중을 보인 것은 Motor-UPDRS가 고령층에서 상승하는 경향과 일치하나, 음성 기반 알고리즘의 목적을 고려했을 때 특정 인구학적 변수에 지나친 의존성이 발생한 것일 수 있다. 이는 모델이 음성 자체의 변화를 완전히 학습하지 못한 신호일 가능성이 있으며, 향후 연구에서는 나이 보정(age-adjusted) 모델, 혹은 음성 Feature만으로 학습한 비교군 실험을 통해 해당 편향의 존재를 검증하고 보정하는 과정이 필요하다.

넷째, 본 연구는 42명의 환자, 5,875개의 음성 샘플을 기반으로 하였으나, 딥러닝 기반 end-to-end 학습이나 대규모 사전학습 모델(pre-trained model) 활용을 위해서는 최소 수천 명 이상의 환자 데이터가 필요하다. 현재 데이터 규모로는 복잡한 신경망 구조 적용 시 과적합 위험이 크며, 이는 본 연구에서 전통적 머신러닝 앙상블 기법을 채택한 주요 이유이기도 하다. 향후 다기관 공동 데이터 수집, 공개 데이터셋 통합, transfer learning 기법 등을 통해 데이터 규모를 확장할 필요가 있다.

다섯째, 본 연구는 단일 데이터셋(UCI Parkinson Dataset)에서만 검증되었으며, 다른 언어권, 녹음 환경, 의료기관에서의 일반화 성능은 검증되지 않았다. 특히 Jitter, Shimmer와 같은 음성 지표는 녹음 장비의 품질, 주변 소음, 발화 과제의 종류에 따라 민감하게 변할 수 있으며, 이는 실제 임상 환경 적용 시 성능 저하로 이어질 가능성이 있다. 향후 cross-dataset validation, 다기관 공동 연구, 그리고 다양한 녹음 조건에서의 robustness 평가를 통해 모델의 실용성을 검증할 필요가 있다.



참고문헌

Athanasios Tsanas 외 3인, “음성 기반 비침습적 파킨슨병 진행도 원격 모니터링,” IEEE Biomedical Engineering, 59(4):1264–1273, 2012.

Tsanas, A., Little, M. A., McSharry, P. E., & Ramig, L. O. (2012). *Accurate telemonitoring of Parkinson’s disease progression by non-invasive speech tests*. IEEE Transactions on Biomedical Engineering, 59(4), 1264–1273.

Nandhini, M., Sujithra, R., & Venkatesan, P. (2024). Determining the severity of Parkinson’s disease in patients based on voice analysis using deep learning techniques. *Multimedia Tools and Applications*, 82, 32851–32873.

