

[1주차] 프로젝트 주제 선정 보고서

2026년 2월 8일

말모이 | 길다인 오성민 이승민 배진형

1. 프로젝트 개요 및 주제 선정 배경

프로젝트명 : 승정원일기 온디바이스 자연어 번역기

프로젝트 개요 : 조선 국정 기록인 승정원일기 영조 10-20년대(변경 가능) 미번역 부분을 대상으로, 조선왕조실록 병렬 데이터를 학습 데이터로 활용해 한문→자연스러운 한국어 번역 경량 모델을 개발합니다. 학술 연구자와 학생을 대상으로 스마트폰에서 오프라인 실시간 번역 앱을 제공하며, MobileBERT 기반 4bit 양자화로 성능 저하 없이 온디바이스 실행을 목표로 합니다.

주제 선정 동기 : 승정원일기는 실록의 4배 분량(3,243책)으로 조선 제도사 핵심 사료지만, 2024년 기준 37.4%만 번역되어 접근성이 낮은 편입니다. 2025년 국정감사에서 40% 언급되었으나 출간이 지연되고 있습니다. 기존 AI 연구는 서버급 모델로 전체 초벌 번역에 치중하였고, 오프라인에서 사용 불가능하거나 미번역된 자료 존재 및 시기 특화가 부족합니다. 본 프로젝트는 조선사 중 특정 시기 초점을 맞춰 정확도가 높고 실용적인 모바일 도구로 차별화하고자 합니다.

2. 핵심 목표 및 분석 방향

핵심 가설은 다음과 같습니다.

→ 실록 병렬 데이터 사전학습 + 승정원 영조 10-20년대 미번역 fine-tune를 거친 온디바이스 경량 모델(MobileBERT-4bit)은, 기존 서버 NMT(고전번역원) 대비 BLEU 점수 5% 이내 저하로 오프라인 실시간(2초 이내) 자연스러운 번역을 달성합니다.

필요 데이터 :

조선왕조실록 병렬 코퍼스

<https://www.data.go.kr/data/15053647/fileData.do>

승정원일기

<https://www.data.go.kr/data/15064218/fileData.do>

분석 목표 : 번역 정확도, 온디바이스 성능, 통계적 유의성

번역 정확도 측면에서는 BLEU-4 점수 35 이상을 목표로 하며, 이는 기존 한국고전번역원 NMT 시스템의 38점 대비 5% 이내 저하 수준입니다. 추가로 KoreanBERTScore(F1) 0.85 이상을 달성해 의미적 유사도를 보장하며, 특히 영조대 제도 용어 정확도는 90% 이상으로 도메인 특화 성능을 강조합니다. 테스트셋은 영조 10-20년대 미번역 일기 2,000문장에 전문가 국역을 레퍼런스로 사용합니다.

온디바이스 성능 측면에서는 스마트폰 기준 평균 50자 정도의 단일 문장추론 시간을 2초 이내로 제한하고, 모델 메모리 사용량을 100MB 이하로 최적화합니다. 배치 처리 시에도 5문장/5초 이내를 목표로 실시간성을 확실히 합니다. TFLite 벤치마크로 CPU/GPU 성능을 측정합니다.

통계적 유의성은 경량 모델(4bit 양자화 MobileBERT)과 베이스라인(비양자화 KoBERT)을 동일 테스트셋에서 비교해 t-test p-value < 0.05로 성능 열위 여부를 입증하고, 연도별(영조 10년대 vs 20년대) 성능 차이를 ANOVA로 분석해 도메인 적응 효과를 통계적으로 확인합니다.

3. 기대 효과 및 활용 방안

학술적 가치 : 기존 승정원일기 AI 연구는 서버급 NMT로 전체 초벌 번역에 집중했으나, 미번역된 부분 번역 및 특정시기나 제도 용어등 도메인 특화와 매끄러운 번역, 온디바이스 실시간성은 아직 선행연구가 많지 않은 상황입니다. 본 프로젝트는 "도메인 적응 경량 모델의 실용성"을 입증해 한문 고전 NLP 분야에 기여하며 후속 연구의 기반을 마련하는 것이 목표입니다. 영조대 병역개혁 문맥에서 제도 용어 번역 패턴 분석으로 조선 제도사 새로운 인사이트 도출 가능성도 큼니다.

기술적 역량 : 본 프로젝트를 통해 팀원들은 데이터 엔지니어링과 관련한 프로젝트 파이프라인을 습득하게 됩니다. 병렬 코퍼스 구축, 모델 개발 등등