

[2주차] 선행 연구 조사 보고서

2026년 2월 14일

Multi-Sense | 이제학 정주희 허다교

1. 프로젝트 조사 개요 및 방법

1.1. 프로젝트명: 구음장애인의 의사소통 지원을 위한 LLM 기반 의도 추론 및 환각 제어 시스템

1.2. 프로젝트 개요

본 프로젝트는 뇌병변 및 신경 질환으로 인해 발생하는 구음장애 환자의 불완전한 발화를 대상으로 한다. 기존 음성 인식(ASR) 모델의 한계를 극복하기 위해 LLM을 결합한 2단계 파이프라인을 구축한다.

Main Task (성능 향상): ASR 모델이 생성한 상위 N개의 후보 문장을 LLM에 입력하고, 문맥과 음운적 유사성을 고려하여 화자의 실제 의도를 가장 잘 반영한 문장을 복원한다.

Sub Task (안전성 확보): LLM이 문맥을 과도하게 해석하여 없는 말을 지어내는 '환각(Hallucination)' 현상을 방지하기 위해, 복원된 문장의 신뢰도를 측정한다. 임계값 미만의 결과는 무리하게 출력하지 않고 재질의를 유도함으로써 의료·돌봄 환경에서의 시스템 신뢰성을 확보한다.

1.3. 주제 선정 동기

ASR은 정확한 조음을 전제로 하기 때문에 비정형 발화에서 높은 단어 오류율을 보인다. 또한, 음성 데이터만으로는 화자의 상태와 맥락 파악이 어렵기 때문에 생체신호와의 결합이 필수적일 것으로 보인다. 이에 단순한 받아쓰기를 넘어, 사용자의 실제 의도에 초점을 맞추어 접근하고자 한다.

2. 주요 선행 연구 및 사례 분석

2.1. LLM-Agent Post-ASR Correction Beyond WER (Ma et al., 2026)

핵심 아이디어: ASR이 생성한 top-k 가설을 보고, LLM이 Judge-Editor 구조로 동작한다. 즉, 가설들 사이에서 합의가 높은 span은 유지하고, 불확실한 구간만 rewrite/fuse하여 최종 전사를 만든다.

평가 지표: WER 외에도 semantic 지표 및 SLU 지표로 의미 보존과 업무 효용을 함께 평가한다.

주요 결과: Err 구간에서 파인튜닝된 Judge-Editor가 WER을 낮추는 동시에 의미/SLU 지표도 함께 개선한다. 또한 특정 설정에서는 WER은 나빠져도 의미/SLU가 좋아질 수 있음을 보여주며, WER만으로는 실사용 성능을 대변하기 어렵다는 점

을 강조한다.

한계점 및 시사점: top-k 기반 에이전트는 ASR 후보 품질에 영향을 받으며, 데이터셋 및 정규화의 차이에 따라 WER이 불안정하게 움직일 수 있다. 본 프로젝트도 정확한 전사만이 아니라 의도 및 슬롯 기반 지표를 포함해 평가 체계를 설계해야 하며, 특히 명령어 데이터라면 SLU 평가가 자연스럽게 붙어야 한다.

2.2. Exploring Generative Error Correction for Dysarthric Speech Recognition (La Quatra et al., Interspeech 2025)

핵심 아이디어: 2-stage로 구성: (1) 강력한 ASR로 N-Best를 만들고, (2) Flan-T5 기반 GER가 후보들을 활용해 최종 전사를 생성한다.

평가 지표: WER과 함께 SemScore를 사용해 의미 보존을 함께 보려는 흐름을 따른다.

주요 결과: GER을 추가하면 WER이 감소하고 SemScore가 증가하는 경향이 나타난다. 특히 구조화된 명령어/문장 유형에서 교정이 효과적이며, 음향 모델 적응과 GER의 결합이 상보적으로 작동할 수 있음을 보여준다.

한계점 및 시사점: 단어 단독 유형에서는 여전히 개선이 제한되거나 어려움이 남는다. 본 프로젝트가 명령어를 대상으로 한다면 GER/Agent 후처리가 특히 적합할 수 있고, 동시에 짧은 발화 및 단어 단위에서 성능이 떨어지는 원인을 별도 분석하는 것이 연구 기여가 될 수 있다.

2.3. He et al., Robust Dysarthric Speech Recognition with GAN Enhancement and LLM Correction (Advanced Intelligent Systems, 2025).

핵심 아이디어: Enhanced CycleGAN으로 건강 음성을 구음장애 발화 스타일로 변환해 학습 데이터를 증강한다(건강 음성은 UA-Speech 전사와 동일 문장을 TTS로 합성해 내용은 같고 발화 특성만 다르게 구성). 이후 도메인 적응된 Whisper-medium 인코더로 음성 특징을 추출하고 LLM을 결합해 문맥 기반으로 전사를 보정한다. 마지막으로 빔서치로 얻은 N-best 후보를 LLM이 의미 일관성 기준으로 재랭킹하고, 비현실적 후보는 조기에 제거해 실시간성을 고려한다.

평가 지표: 주요 평가는 단어 오류율(WER, %)로 수행되며, UA-Speech 데이터에서 명료도(VL/L/M/H)별 성능을 비교한다.

주요 결과: 제안 모델(Llama*-DSR)은 UA-Speech에서 명료도별 WER이 VL 48.69, L 19.84, M 11.79, H 2.11로 보고되며, 특히 매우 저명료(VL) 구간에서 기존 비교 모델 대비 개선 폭이 크다고 주장한다. 또한 LLM 기반 후처리(재랭킹/가지치기)만으로도 상대 WER 8% 개선 효과가 있다고 서술한다.

한계점 및 시사점: 본 연구는 WER 중심으로 효과를 제시하므로, 실제 사용 맥락

(명령 수행 가능성, 의도 전달)에서의 의미 보존 성능을 직접 측정하는 지표(SLU 등)는 상대적으로 약하게 다뤄질 수 있다. 또한 UA-Speech 중심의 설정에서 성능을 강조하므로 데이터/환경이 바뀌는 상황에서의 도메인 편향 가능성은 추가 검증이 필요하다.

2.4. Bridging ASR and LLMs for Dysarthric Speech Recognition: Benchmarking Self-Supervised and Generative Approaches

핵심 아이디어: LLM을 디코딩 단계에 통합하여 언어적 맥락을 반영함으로써, 인식 정확도와 전사 결과의 가독성을 높일 수 있는지 검증한다. 4가지 형태의 모델 아키텍처를 사용하는데, Whisper 인코더와 대형 언어 모델인 Vicuna를 통합한 Large LLM-Integrated 모델을 포함한다.

평가지표: TORGO와 UASpeech 두 가지 데이터셋을 통해 성능 측정, WER를 평가지표로 한다.

주요 결과: Whisper-Vicuna 모델이 압도적인 성능을 보였다. LLM 기반 모델은 구음장애가 심한경우에도 언어적 맥락을 활용해 음소 왜곡을 보정함으로써 낮은 오류율을 유지했다. 단순 수치뿐만 아니라, 실제 전사 결과에서도 "The hotel owner shrugged"와 같이 문법적으로 완벽하고 의미가 통하는 문장을 생성하는 능력이 탁월한 것으로 보인다.

한계점 및 시사점: 학습하지 않은 데이터셋에 적용했을 때 성능이 저하되는 교차 데이터셋 일반화(Cross-dataset generalization) 문제는 여전히 해결해야 할 과제로 남았다. LLM을 디코딩에 활용하는 것이 구음장애 음성의 음소 복원과 문법적 정확도 향상에 매우 효과적임을 입증했다.

2.5. Applying ChatGPT to Automatic Speech Recognition for Dysarthric Speech (Seonwoo Lee, et al., 2024)

핵심 아이디어: 구음장애 음성에서 ASR(Whisper, XLS-R)을 (부분) 파인튜닝한 뒤, 출력 전사문을 ChatGPT로 후처리해 "인식 오류를 교정"할 수 있는지 검증한다. 후처리는 기본 프롬프트 외에 2가지 변형(한국어로 말 되게 / 한국어 단어와 발음이 유사하게)도 비교해서, 프롬프트 형태가 교정 성능에 영향을 주는지도 함께 본다.

평가지표: 주 지표는 SER(syllable error rate, 음절 오류율)로, ASR 전사와 교정 결과를 정답과 비교해 음절 단위 편집거리 기반 오류율을 계산한다. 보조 지표로 Perplexity(PPL)를 사용해 "교정된 문장이 언어적으로 얼마나 그럴듯한지"를 확인하며, Polyglot-ko-1.3b로 PPL을 계산했다.

주요 결과: 전반적으로 ChatGPT 후처리는 PPL을 낮춰 문장 형태를 더 자연스럽게

게 만드는 경향은 있으나, 대부분의 모델 출력에서는 SER이 유의미하게 개선되지 않았다. 예외적으로 “Whisper No FT(파인튜닝 없는 원 모델)” 전사에서는 SER이 감소하는 케이스가 관찰되며(예: 표에서 2.57 → 1.28 등), 반대로 일부 파인튜닝 모델 전사에서는 SER이 오히려 증가하기도 한다.

한계점 및 시사점: LLM이 문법적으로 그럴듯하게 고치더라도 “정답 레퍼런스와 동일한 내용”을 맞히는 방향으로 교정되지 않을 수 있어, SER 관점에서는 악화될 수 있음에 한계를 보인다. 또한, XLS-R No FT 출력처럼 2-3음절 반복 시퀀스가 포함되면 후처리 자체가 불가능해지는 등, 반복/루프 형태의 오류가 파이프라인의 취약점으로 드러난다. 연구에서 프롬프트(지시문) 형태가 결과에 크게 영향을 준다고 보고하므로, 후처리 성능은 모델 자체보다 “제약을 어떻게 걸어 환각을 줄이고, 음운 단서를 얼마나 보존하게 하는지”가 핵심이라고 볼 수 있다.

3. 프로젝트의 차별성

본 프로젝트가 기존 연구 대비 가지는 차별성은 다음과 같이 정리할 수 있다.

- 1) LLM을 ASR을 대체하는 모델이 아니라, ASR의 한계를 보완하는 보조 도구로 활용한다. ASR이 생성한 상위 N개의 후보 문장을 입력으로 받아 LLM이 문맥과 음운적 유사성을 함께 고려해 화자의 의도를 복원하며, 단순 전사 정확도 향상보다 실제 의사소통 성공을 목표로 한다.
- 2) 구음장애에서 발생하는 음성 왜곡을 단순 잡음이 아니라 구조적 오류로 보고 체계적으로 다룬다. 특히 오류가 집중되는 구간에서 어떤 유형의 왜곡이 발생하는지 분해하고, 후보 간 합의가 높은 부분은 보존하며 불확실한 부분만 수정하는 방식으로 안정적인 복원을 시도한다.
- 3) 의미 추론의 이점과 위험을 동시에 연구 대상으로 삼는다. LLM이 과도한 문맥 추론으로 없는 내용을 생성하는 환각을 방지하기 위해 출력 신뢰도를 산출하고, 신뢰도가 낮으면 무리한 출력을 피하고 재질의를 유도하는 안전장치를 포함한다.
- 4) 데이터 차별성 측면에서 텍스트 중심 접근을 넘어 호흡 관련 생체 신호를 맥락 정보로 결합한다. 음성만으로는 구분하기 어려운 발화의 불안정성을 호흡 패턴(예: 호흡 주기, 휴지, 불규칙성)과 함께 해석함으로써 의도 추론의 근거를 보강하고 오탐을 줄이는 방향을 제안한다.
- 5) 가치 차별성 측면에서 ‘받아쓰기’가 아니라 ‘의도 달성’을 중심으로 평가한다. 전사 오류율만으로 성능을 판단하지 않고, 최종 출력이 실제 명령 수행으로 이어졌는지에 초점을 맞춘 지표로 시스템의 실사용 효용을 측정한다.