

[3주차] 방학 스터디 최종 보고서

2026년 2월 21일

Multi-Sense | 이제학 정주희 허다교

1. 주요 결과물 요약

1.1. 데이터 개요 및 인사이트

AI 허브의 구음장애 음성인식 데이터 중 뇌신경장애 라벨링 데이터(JSON) 1207건에 대해 탐색적 데이터 분석(EDA)을 수행하였다. 텍스트 내에서 조음 수정 및 더듬음을 의미하는 '+' 기호를 추적한 결과, 29건의 데이터에서 유의미한 구조적 오류 패턴을 추출하였다. 이외에도 '*' 기호는 발음 불분명을, '/' 기호는 추임새를 의미하며, 향후 분석 시 활용될 여지가 있다. 원천 데이터(wav)는 길이 최대 30분가량의 음성 데이터로, ASR을 통해 음성을 전사하고 휴지 등을 분석하고자 한다. 분석한 라벨링 데이터는 이러한 원천 데이터 분석의 전과정으로써 역할을 할 수 있을 것으로 본다.

	folder_type	age	sex	transcript_length	speech_error_count	error_pairs
0	11. 중풍	56	M	509	0	[]
1	11. 중풍	56	M	1399	0	[]
2	11. 중풍	56	M	1521	1	[(넋이, 넋이)]
3	11. 중풍	56	M	658	0	[]
4	11. 중풍	56	M	2068	0	[]

[표 1] json 파일 일부 분석 결과

1.2. 활용 모델 및 고도화 계획

구음장애 음성인식 시스템의 정확도와 안전성을 동시에 확보하기 위해 Whisper 기반의 ASR과 LLM 에이전트가 결합된 2-Stage 파이프라인 아키텍처를 채택한다.

우선 Stage 1에서는 음향 모델링의 안정성이 검증된 Whisper LARGE-V2를 미세 조정하여 구음장애 특화 음성 인식기로 활용한다. 이때 발화자의 조음 오류나 비유창성을 잡음으로 오인하여 삭제하지 않도록, 괄호나 '+' 등의 표지를 활용한 활용한 있는 그대로의 전사(Verbatim Transcription) 방식을 적용함으로써 모델이 이를 불완전한 발화 구간으로 명확히 인지하게 유도한다.

Stage 2에서는 Llama-3 혹은 Qwen2.5-72B 기반의 Judge-Editor 에이전트를 구축하여 N-best 가설들 간의 일관성을 분석한다. 에이전트는 가설들 사이에서 합의가 높은 형태소는 유지하되, 차이가 큰 구간에 대해서만 음운 단서를 바탕으로 문맥적 타당성을 검토하여 재구성한다. 특히 호흡 신호의 불규칙성을 LLM의 어텐

선 메커니즘에 입력값으로 넣는 Late Fusion 방식을 시도하여 발화 구간 검출과 인식 결과의 신뢰도를 정밀하게 보정한다. 최종적으로 LLM의 교정 결과와 원본 가설 간의 의미론적 거리를 측정하여 환각 위험이 높다고 판단될 경우, 사용자에게 재질의(Reject)를 요청하는 안전 트리거 로직을 구현하여 실제 돌봄 현장에서 의 오작동 위험을 최소화한다.

2. 이론적 배경 및 심화 학습

2.1. LLM 기반 N-Best 후보 교정 및 Judge-Editor 아키텍처

기존 ASR 시스템은 구음장애 발화 처리 시 Top-1 가설에서 오류를 범하기 쉽고, 하위 N-Best 후보군에 올바른 대안이 포함되는 경향이 있다(La Quatra et al., 2025). 최근 연구에서는 LLM을 활용하여 N-Best 가설을 종합적으로 평가하는 방식이 도입되고 있다. 특히, 가설 간 합의가 높은 정상 발화 구간은 보존하고, 더듬음이나 인식이 엇갈리는 불확실한 구간만 선택적으로 재작성하거나 융합하는 Judge-Editor에 이진트 구조의 효용성이 입증된 바 있다. 데이터 탐색 과정에서 추출된 반복 토큰을 식별하고 병합하도록 지시한 프롬프트 파이프라인 설계는 이러한 학술적 접근과 궤를 같이 한다.

2.2. 구음장애 발화의 구조적 오류와 의미적 환각 제어

데이터 분석을 통해 식별된 중풍 등 뇌신경장애 환자의 발화는 조음의 부정확성, 시간적 불규칙성, 음소 왜곡 등의 고유한 특징을 지닌다. 이로 인해 기존 ASR 모델은 발음상으로는 유사하나 문맥상으로는 이치에 맞지 않는 의미적 환각 결과를 출력할 위험이 높다(He et al., 2025). 따라서 LLM의 문맥 추론 능력을 활용하여 단순한 단어 오류율 개선을 넘어 화자의 최종 의도를 보존하는 교정이 요구된다. PoC 시뮬레이션을 통해 의미 연결이 불가능한 가설들에 대해서는 무리한 추론을 차단하고 재질을 반환하도록 로직을 설계함으로써 오인식을 방지할 수 있다.

2.3. 멀티모달 특성 융합과 데이터 희소성 극복을 위한 생성적 접근

구음장애 음성 인식의 주요 장애물 중 하나는 고품질 라벨링 데이터의 절대적인 부족이다. 이를 해결하기 위해 최신 연구에서는 적대적 생성 신경망(GAN)을 활용하여 정상 음성을 구음장애 특유의 조음 왜곡 음성으로 변환하는 데이터 증강 기법을 도입하고 있다. 또한, 단순히 음향적 특징에만 의존하지 않고 Whisper와 같은 음향 인코더와 Llama와 같은 대형 언어 모델을 결합한 멀티모달 아키텍처를 통해, 음향 신호의 결손을 언어적 문맥으로 보완하는 연구가 활발히 진행 중이다. 이는 본 프로젝트에서 추진하는 ASR과 LLM의 2단계 파이프라인 구조가 데이터 부족 상황에서도 모델의 강건성을 확보할 수 있는 이론적 근거가 된다.

2.4. 평가 지표의 전환

음성 인식 분야의 전통적 지표인 단어 오류율(WER)은 구음장애 발화 교정 시스템

의 실질적 효용성을 온전히 반영하지 못한다는 한계가 있다. 교정 과정에서 단어의 형태가 일부 변경되더라도 화자의 실제 의도나 문맥적 의미가 정확히 복원되었다면, 보조 도구로서의 가치는 더 높다고 평가할 수 있다. 이에 따라 최근 학계에서는 단순 텍스트 일치율을 넘어 BERTScore나 자연어 추론(NLI)을 기반으로 한 의미 스코어(Semantic Score), 그리고 실제 명령 이행 성공률을 측정하는 Slot Filling 성능 등을 결합한 다면적 평가 프레임워크를 도입하는 추세이다.

3. 수행 내용 상세

3.1. 주요 활동 내역

3.1.1. 이제학

ASR이 생성한 N-Best 후보군 사이의 음운적 유사성과 실제 정답 간의 상관 관계를 분석하였으며, 이를 통해 단순 텍스트 교정이 아닌 화자의 조음 특성을 반영한 의도 중심 복원 가이드라인을 정립하였다. 한국어의 조사와 어미 변화가 의사소통 성공률에 미치는 영향을 분석하였으며, 영어권 연구와 달리 한국어 환경에서는 문맥적 타당성이 확보되지 않을 경우 의도가 완전히 왜곡될 수 있다는 언어적 특이점을 지표로 증명하였다. 시각화된 호흡 주기 데이터와 ASR 신뢰도 점수를 대조 분석하여, 호흡의 불규칙성이 발화의 불확실성을 예측하는 유의미한 지표임을 확인하였고, 이를 향후 모델의 Attention 메커니즘에 가중치로 반영하는 융합 로직의 근거를 마련하며 최종 결론과 분석 내용 정리를 맡아서 제안하였다. 음성 데이터만으로는 발화 의도와 단순 소음을 구분하기 어려움을 발견하고, 호흡 신호의 불규칙성을 발화 구간 검출 및 신뢰도 점수의 가중치로 활용할 근거를 확인하며 전반적인 상황을 해설하고 검증하고자 하였다. LLM으로 영어가 들어가면 안정적이라는 얘기가 있는데 한국어를 사용하는 데이터 특성상 한국어로 음성 데이터가 들어가고 한국어로 출력이 나와야 편하다는 특성을 고려한 전반적인 사용자 편의성을 우선하며 전반적인 분석을 진행했다

3.1.2. 정주희

AI 허브의 구음장애 음성인식 데이터 중 뇌신경장애 라벨링 데이터(JSON) 1,207건을 대상으로 파이썬 기반의 탐색적 데이터 분석(EDA)을 수행하였다. 데이터 내 정규표현식을 활용해 조음 수정 및 더듬음을 의미하는 '+' 기호를 전수 추적하였으며, 이를 통해 29건의 파일에서 유의미한 구조적 오류 패턴을 추출하였다. 또한, 분석 대상 데이터의 TestMethod 메타데이터를 전수 조사하여 현재 활용 중인 데이터셋이 모두 Read aloud scripts로 구성되어 있음을 기술적으로 확인하였다. 이는 단순 인식 성능 평가를 넘어 실제 의료 현장의 '자유 발화' 데이터와의 난이도 격차를 인지하고 향후 연구 방향을

설정하는 결정적 근거가 되었다.

2024~2026년 사이에 발표된 최신 학술 문헌들을 직접 수집 및 분석하여 프로젝트의 기술적 로드맵을 고도화하였다. 특히 Whisper LARGE-V3의 미세 조정 시 불안정성을 지적한 연구 사례를 바탕으로 안정적인 LARGE-V2 기반의 미세조정 전략을 제안하였으며, 더듬음을 노이즈로 제거하지 않고 음향적 증거로 보존하는 '있는 그대로의 전사' 학습법의 학술적 근거를 확보하였다. 또한, LLM을 단순 교정 도구가 아닌 가설 간 일관성을 판단하는 'Judge-Editor' 에이전트로 정의하고, 시스템의 안전성과 전문성을 확보하는 데 기여하였다.

3.1.3. 허다교

구음장애 발화 데이터를 활용한 부분에서 기존의 개인별 맞춤 학습 방식이 신규 화자 유입 시마다 재학습이 필요하다는 한계를 지적하고, 데이터가 누적될수록 구음장애 발화 전반의 의미 이해 성능이 확장되는 범용 모델 구조로 연구 방향을 전환할 것을 제안했다. 또한 발화 분류 정확도 중심의 평가에서 벗어나, 사용자의 의도를 실제로 이해하고 실행하는지를 보는 Task Success 기반 평가 지표로 고도화할 필요성을 강조했다. LLM 기반 의미 복원 과정에서 발생할 수 있는 할루시네이션 문제를 해결하기 위해 신뢰도 임계값 이하에서는 실행을 거부하거나 재확인을 수행하는 안전 메커니즘을 제안했다. 더 나아가 구음장애 음성 분석을 단일 음성 인식 문제가 아닌 멀티모달 인간 상태 인지 프레임의 핵심 트랙으로 통합하는 구조적 확장 방향을 제시했다. 이러한 기여 내용은 회의록에 연구 방향 전환, 평가 체계 개선, 안전성 확보 전략, 멀티모달 확장 구조로 정리되어 반영되었다.

4. 차후 본 학기 계획

본 학기에는 기술적 고도화와 실무적 검증을 위해 다음과 같은 4단계 이행 로드맵을 추진한다.

1단계: ASR 오류 구조 정밀 분석 및 N-best 불확실성 모델링

수집된 구음장애 발화 데이터를 바탕으로 음향 모델의 오류 패턴을 정형화하고, N-best 가설들이 지니는 통계적 불확실성을 수치화하여 보정 모델의 기초 데이터를 구축한다.

2단계: LLM 기반 Judge-Editor 교정 모듈 고도화

LLM이 음운론적 유사성과 문맥적 완성도를 동시에 고려하도록 프롬프트 엔지니어링을 최적화하며, 반복 발화나 생략된 조음이 환각으로 이어지지 않도록 하는 제약 조건을 강화한다 .

3단계: 환각 제어를 위한 거절 임계값 최적화 및 피드백 루프 구축

인식 신뢰도가 특정 임계값 이하일 때 무리한 교정 대신 사용자에게 재발화를 유도하는 로직을 강화한다. 재발화된 데이터는 이전 발화의 문맥 정보를 힌트로 활용하여 정답을 추론하는 다중 턴 교정 방식으로 결합하여 정확도를 높인다.

4단계: 의미 보존 및 다운스트림 작업 중심 평가 지표 확장

단순한 단어 오류율(WER) 측정을 넘어 BERTScore 및 자연어 추론을 통한 의미 보존 정도를 평가한다. 또한 명령 이행 성공률과 같은 실질적인 자연어 이해(SLU) 성능을 핵심 지표로 설정하여 시스템의 실효성을 검증한다.