

말모이 최종 보고서

2026년 3월 4일

말모이 | 길다인 오성민 이승민 배진형

1. 서론

1.1 연구 배경 및 필요성

기존 고전 한문 번역 분석은 인간 방식의 인력·예산 부족으로 승정원일기는 미번역 (번역을 37.4%, 완역 2062년 예상)비율이 높으며, AI 모델 (Transformer, AnchiLm)은 BLEU 0.37-0.54를 달성하나 인칭대명사나 고유명사 해석 정확도가 8.3%, 문법 생략·허사 오류 누적, 문체 재현 미흡 등으로 신뢰성이 낮다. 따라서 이러한 기존 연구의 한계점을 보완해보고자 주제를 선정하게 되었다.

1.2 연구 목적

본 프로젝트는 도메인 적응형 사전 학습(DAPT: 조선왕조실록 데이터로 한문 도메인 적응)과 과업 적응형 사전 학습(TAPT: 승정원일기 영조 10-20년대 미번역 데이터 fine-tuning)을 통해 단계적 모델 학습을 진행한다. 공유 인코더를 활용하여 한문 사료의 훼손된 부분을 복원하는 MLM(Masked Language Modeling)과 현대어 번역인 NMT를 동시에 학습시키는 멀티태스크 학습을 통해 승정원일기 영조 10~20년대 미번역 구간을 고품질로 번역하는 경량화 모델 개발을 최종 목표로 한다.

2. 데이터 개요

2.1 조선왕조실록

원문-국문 코퍼스 구축 위해 크롤링 진행중

URL 구조: k?a_1YYMMDDD_NNN

해당 왕의 순서를 알파벳으로 치환(ex. 태조 a, 정종 b)

YY: 해당 실록이 쓰인 연(ex. 정종 1년이면 01)

MM: 해당 실록이 쓰인 월

DDD: 해당 실록이 쓰인 일

NNN: 해당 날짜의 N번째 기사(첫번째면 001)

2.2 조선왕조실록 인물-관직 코퍼스

정규화 목적

- 동일 관직의 표기 차이(공백, 괄호, 한자 병기 등)로 인한 중복 집계 문제 해결
- 빈도 분석 및 NLP 적용을 위한 표준 관직명 통일

정규화 내용

- 공백 제거 및 괄호 표기 통일
- 동일 관직 표기 통합
- 한글 표기 / 한자 표기 분리
- 관직 빈도 사전 및 기관 분류 생성

범위

- 영조 시기 데이터만 필터링하여 구성

코퍼스 구성 방식

- 각 관직 레코드를 텍스트 한 줄로 변환
- 포함 정보: 왕명, 연월일, 인물아이디, 관직명, 형태
- NLP 분석(TF-IDF, 임베딩 등)에 바로 활용 가능하도록 구성

2.3 승정원일기

실록 코퍼스 완료 후 작성 시작

3. 분석 방법론 및 모델링

3.1 활용 모델

SikuBERT(SikuROBERTa) : SikuBERT는 사고전서(Siku Quanshu)와 같은 방대한 고전 문헌 코퍼스를 기반으로 사전 학습된 Transformer 기반의 고전 특화 모델이다. 이 모델은 일반적인 언어 모델이 파악하기 힘든 고전 한문 특유의 다기능 허사 처리와 복잡한 구문 분석에서 뛰어난 성능을 보여줍니다. 저희는 이러한 SikuBERT를 활용해 인코더를 초기화함으로써, 고전 문헌이 가진 풍부한 의미 정보를 모델에 미리 내재시키고자 한다.

Solar Pro 3 : 최대 12만 8천 토큰의 컨텍스트 창을 지원함으로써 하루치 기록이 매우 길고 방대한 승정원일기의 전체 맥락을 한 번에 파악하여 번역의 일관성을 유지하는 데 매우 유리하다. 또한 복잡한 문장 구조와 생략이 잦은 고전 한문의 특성상, 문맥을 논리적으로 재구성하는 능력이 필수적인데, 강화된 추론 능력을 통해 인물 간의 관계와 사건의 인과관계를 더 정확하게 짚어낼 수 있다. 마지막으로 한국어 기반의 지시 이행 능력과

전문 도메인 지식 습득력이 뛰어나 조선왕조실록 같은 방대한 사료 데이터를 학습하기에 적합하다.

3.2 모델 아키텍처

graph TD

subgraph "Input Layer"

A[승정원일기 원문] --> B["SentencePiece (BPE-drop)"]

B --> C["인물-관직 어휘집(Vocab) 추가"]

end

subgraph "Encoder: The Skeleton (SikuBERT)"

C --> D["SikuBERT Encoder (고전 한문 구문/의미 분석)"]

D --> E["Multi-task Learning (MLM 복원 + NMT 인코딩)"]

end

subgraph "Knowledge Bridge (RAG)"

D --> F["Entity Linking (인물/관직 추출)"]

F --> G["인물-관직 코퍼스 (외부 지식 DB)"]

G --> H["Context Injection (영조 시대 맥락 주입)"]

end

subgraph "Decoder: The Flesh (Solar Pro 3)"

D -- "Cross-Attention" --> I["Solar Pro 3 Decoder (현대 한국어 생성)"]

H -- "Prompting" --> I

I --> J["Fine-tuning (실록 & 승정원일기 기번역 데이터)"]

end

```
subgraph "Output Layer"
```

```
    I --> K["최종 번역본 (현대 한국어 + 영조 시대 문체)"]
```

```
end
```

3.3 토큰화 전략

Entity-Anchored BPE:

—>개체명 보호 기반 토큰화 사용

—>인명, 관직명, 지명 사전을 구축 후 단어들을 SentencePiece의 user_defined_symbols로 등록하여 BPE 분절 과정에서 쪼개지지 않게 보호

—>토큰화 단계에서 지식 베이스 결합

고유명사 처리: Dynamic Knowledge-Base Injection (RAG-MT):

—>영조 시대 전용 지식 베이스(KB) 구축: 인물 아이디화, 관직 이름을 시간 순서로 정리

—>번역할 문장이 들어오면, 문장 속 한자 키워드를 추출해 KB에서 관련 정보를 검색

4. 프로젝트 마일스톤

3월 1-2주차

실록 코퍼스 구축 (영조 근처 먼저)

이름-관직 코퍼스 구축

미번역 한문 단독 코퍼스 확보해서 복원용비지도 학습 데이터 준비

3월 3-4주차

sikuBERT로 인코더 초기화

인물/관직명이 분절되지 않도록 User-Vocab을 추가한 BPE-drop 기반 토크나이저를 최적화

4월 1-2주차

멀티태스크 전략: 공유 인코더를 통해 한문 훼손 복원(MLM)과 기계 번역(NMT)을 동시에 학습

실록 데이터를 중간 기착지로 활용해 모델이 고전 한문 도메인에 완전히 적응하게 합니다

4월 3-4주차

승정원일기 영조 시대 미번역 구간을 타겟으로 삼아 Fine-tuning을 진행

인물-관직 태깅 정보를 바탕으로 고유명사 복원 정확도(기존 8.3%)를 비약적으로 높이는 학습에 집중

5월 1-2주차

Teacher 모델인 Solar Pro 3가 생성한 고품질 번역문과 문체 정보를 Student 모델에 전수합니다.

Solar Pro 3의 뛰어난 한국어 추론 능력을 빌려 승정원일기 특유의 격식과 어조를 학습 시킴

5월 3-4주차

경량화를 위해 4-bit 양자화(Quantization)를 적용하고 모델 크기를 최적화

BLEU, BERTScore 및 인물-관직 복원 정확도를 측정하여 기존 연구(BLEU 0.37~0.54) 대비 우수성을 입증