

1. 데이터 개요 및 인사이트

본 프로젝트는 **KODEX 200 ETF**의 증가 또는 수익률 예측을 목표로 하며, 약 **10년간**의 일별 데이터를 기반으로 분석을 진행한다. 수집된 데이터는 크게 **ETF 가격** 관련 변수와 **거시경제** 변수로 구성된다. 가격 데이터에는 증가, 수익률, 거래량 등 시장의 직접적인 움직임을 반영하는 지표가 포함되어 있으며, 이는 단기적인 가격 패턴과 모멘텀을 학습하는 핵심 입력 변수로 활용된다. 거시경제 변수로는 달러 인덱스(**DXI**), 미국 **10년물** 국채 금리, **VIX** 지수, **M2** 통화량, **CPI** 인플레이션, 연방기금금리 등을 포함하였다. 이러한 변수들은 글로벌 자금 흐름, 금리 환경, 시장 변동성, 유동성 수준 및 통화 정책 방향을 반영하며, **ETF** 가격 변동에 구조적으로 영향을 줄 수 있는 외생 변수로 작용한다. **10년치** 데이터를 확보함으로써 상승장과 하락장, 변동성 확대 구간 등 다양한 시장 국면이 포함되어 있으며, 이는 모델의 일반화 성능을 확보하는 데 중요한 기반이 된다. 특히 가격 변수와 거시경제 변수를 함께 활용함으로써 단기 기술적 패턴과 중장기 거시 흐름을 동시에 반영할 수 있다는 점이 본 데이터의 주요 특징이다.

2. 활용 모델 및 고도화 계획

본 연구에서는 전통적인 머신러닝 모델과 딥러닝 기반 시계열 모델을 함께 활용하여 성능을 비교하고자 한다. 먼저 **XGBoost**는 트리 기반 앙상블 모델로, 변수 간 비선형 관계와 상호작용을 효과적으로 학습할 수 있어 금융 데이터와 같이 복잡한 패턴을 가진 문제에서 높은 예측력을 기대할 수 있다. 또한 **feature importance** 분석을 통해 예측에 중요한 변수들을 파악할 수 있어 모델 해석 및 피처 분석 측면에서도 활용도가 높다. **GRU** 또는 **LSTM**은 시계열 데이터의 순서 정보를 반영하는 순환 신경망 기반 모델로, 과거 일정 기간의 가격 및 거시 변수 흐름을 입력으로 사용하여 미래 수익률을 예측한다. 이를 통해 정적 피처 기반 모델과 시계열 구조 기반 모델 간의 성능 차이를 비교할 수 있다. 추가적으로 **Transformer** 기반 시계열 모델인 **PatchTST**를 적용하여 장기 시계열 패턴 학습 능력을 검증할 계획이다. **PatchTST**는 입력 시계열을 패치 단위로 분할하여 **self-attention**을 적용함으로써 긴 시퀀스에서도 효율적으로 학습할 수 있도록 설계된 모델로, 장기 의존성을 효과적으로 반영할 수 있다는 특징이 있다. 이를 통해 **RNN** 계열(**GRU/LSTM**) 모델과 **Transformer** 기반 모델 간의 예측 성능 및 장기 패턴 학습 능력을 비교하고자 한다.

특히 본 연구에서는 단순 예측 성능 비교뿐 아니라 **SHAP** 기반 설명가능성(**Explainable AI**)에 초점을 맞추고자 한다. 각 모델에서 도출된 **SHAP** 값을 통해 거시경제 변수와 가격 피처가 예측 결과에 미치는 상대적 영향력을 분석하고, 시장 상황에 따라 중요 변수의 변화 양상을 비교함으로써 모델의 의사결정 구조를 해석할 예정이다. 이를 통해 블랙박스 모델의 한계를 보완하고, 실제 금융 의사결정에 활용 가능한 해석 기반 인사이트 도출을 목표로 한다. 또한 단순 정확도뿐 아니라 방향성 예측 정확도, **F1-score** 등 다양한 지표를 활용하여 모델의 실질적 예측력을 종합적으로 평가할 계획이다.

A Comparative Analysis of LSTM versus PatchTST in Predictive Modeling of Asset Prices, 2024

LTSF 방식: 여러 변수를 여러시간에 걸쳐 동시에 예측하는 방식

LTSF의 예측 전략 수식 (Direct Forecasting)

LTSF 모델이 미래의 여러 시점을 한꺼번에 출력하는 방식에 대한 수식입니다.

기존의 LSTM 같은 모델 -> $t+1$ 을 예측하고 그 결과를 다시 넣어 $t+2$ 를 예측하는 재귀적 방식
PatchTST 같은 최신 LTSF 모델 -> 직접(Direct) 방식 사용.

$$Y_{t+1:t+H} = f(X_{tL:t})$$

- L : 과거 데이터 길이 (Look-back window)
- H : 미래 예측 길이 (Horizon)

의미: 과거 데이터(X)를 넣으면 미래의 덩어리(Y)가 한 번에 튀어나옴

-> 오차 누적(Error Accumulation) 문제를 해결 -> 장기 예측에서 훨씬 유리

PatchTST 모델이란?

기존 Transformer가 시계열의 개별 데이터 포인트를 처리할 때 발생하는 국소적 문맥 상실 문제를 해결하기 위한 최신 기법이다.

기존 트랜스포머는 NLP를 위해 설계되어 시계열 데이터에 적용했을 때 데이터를 한 점(시점)씩 처리하기 때문에, 단일 수치 자체의 노이즈에 취약하며 데이터가 가진 '흐름(Trend)'을 파악하기 어려웠다. 또한 데이터의 길이가 길어질수록 어텐션 연산량이 기하급수적으로 늘어나 장기 예측이 힘들었다.

PatchTST 모델은 복잡한 패턴을 포착하는 데 능숙하며, 이는 자산 가격 예측에서 LSTM 모델보다 잠재적으로 우수함을 시사한다.

(1) 패칭

패치 개수 계산 수식

- 입력 시계열 L 을 패치 길이 P 와 스트라이드 S 를 기반으로 일정 단위로 묶어 처리한다. 패치의 개수 N 은 다음과 같이 결정된다.

$$N = \lfloor \frac{L - P}{S} \rfloor + 2$$

이 과정을 통해 모델은 개별 시점(L)이 아닌 패치 개수(N)에 비례하는 연산만 수행하게 되어 효율성이 극대화된다.

패치 생성 수식

원본 시계열 데이터를 x 라고 할 때, i 번째 패치인 $x_p(i)$ 는 다음과 같은 범위를 가짐.

$$x_p^i = x(i-1)S : (i-1)S + P$$

즉, $(i-1)S$ 시점부터 P 만큼의 길이를 잘라내어 하나의 토큰으로 만들

(2) 채널 독립성

Channel Independence: 다변량 데이터의 각 변수를 독립적인 채널로 처리하여 변수 간 노이즈 간섭을 최소화하고, 패치 간의 상관관계를 **Attention** 메커니즘을 통해 학습한다.

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

1. 유사도 계산 (QK^T): Query와 모든 Key 사이의 내적(Dot-product)을 통해 연관성을 계산한다. 내적 값이 클수록 두 데이터는 높은 상관관계를 가진다.
2. 스케일링 ($\sqrt{d_k}$): 데이터의 차원(d_k)이 커질수록 내적 값이 과하게 커지는 것을 방지하기 위해 상숫값으로 나누어준다.
3. 확률화 (Softmax): 계산된 유사도를 0과 1 사이의 확률값으로 변환한다. 모든 가중치의 합은 1이 된다.
4. 가중치 합산 (V 곱하기): 계산된 가중치를 실제 정보값(V)에 곱하여, 중요한 정보는 강조하고 불필요한 정보는 약화시킨 최종 벡터를 산출한다.

모든 채널이 동일한 **embedding**과 **transformer weight**를 공유하여 복잡도 감소, 공통된 패턴 학습 능력 향상

방법론

EDA

- > 가격뿐만 아니라 VIX와 금리 스프레드 같은 거시 경제 지표를 결합
- > 5년 단위의 흐름(Window)으로 데이터 재구성

1. 데이터 수 월별 조정 증가

- 변동성 지수 (1개): VIX 지수 (시장의 공집 및 범위 (Data Collection))
- 기간: 2000년 10월 ~ 2023년 11월 (총 278개월)
- 출처: Yahoo Finance, pandas_datereader 라이브러리
- 대상 자산: S&P 500, 미국 10년 국채, 금, 원유, 밀, 미국 달러 (총 6개 주요 금융 자산의 월별 선물 계약 가격)

2. Feature Engineering

모델이 시장의 복잡한 패턴을 더 잘 이해할 수 있도록 총 9개의 변수(Features) 구성

- 과거 가격 데이터 (6개): 각 자산의 과거포와 불확실성을 측정)
- 수익률 스프레드 (2개): 채권 수익률 간의 차이를 직접 계산하여 추가
 - 2년물 - 3개월물 국채 수익률 차이

- 10년물 - 2년물 국채 수익률 차이 (경기 침체 예측 지표로 자주 쓰임)

3. 데이터 구조화 (롤링 윈도우)

시계열 데이터의 특성을 살리기 위해 데이터를 쪼개는 방식 매우 중요

- 정렬: 날짜 기준 오름차순 정렬
- 윈도우 설정: 60개월(5년)의 데이터를 하나의 입력 단위, 토큰으로 묶어서 만들
- 타겟 설정: 60개월의 패턴을 보고 바로 다음 달인 61번째 달의 가격을 예측하도록 설계 (롤링윈도우 접근 방식)

시각화

- > 금 데이터는 까다로움
- > 가격변동 추이와 예측 가격 비교

모델 평가

R-제곱(R²)과 정규화된 평균 제곱 오차(NMSE)로 모델 성능 평가

- 정규화된 평균제곱오차(NMSE) : 데이터의 변동성에 대한 예측 정확도

예측 정확도 측정: NMSE는 예측된 값과 실제 값 사이의 평균 제곱 차이를 측정하며, 실제 값의 분산으로 정규화됨

낮은 NMSE = NMSE가 낮을수록 예측 정확도가 더 높다.

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad NMSE = \frac{MSE}{\text{Variance of Actual Data}} = \frac{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}{\text{Var}(y)}$$

Interpretable Stock Price Prediction via Keyword-Guided Integration of News and Technical Indicators

GRU

LSTM의 복잡한 구조를 단순화하여 연산 효율성을 높이면서도, 시계열 데이터의 장기 의존성(Long-term dependency) 문제를 효과적으로 해결하기 위해 고안된 순환 신경망(RNN)의 변형 모델이다. 논문에서도 뉴스 키워드 간의 순차적 관계를 학습하여 요약 벡터를 생성하는 핵심 모듈로 GRU를 채택하고 있다.

IKNet 기반의 뉴스-지표 통합 및 SHAP 해석 기법

뉴스 데이터와 기술적 지표를 결합하여 예측의 정밀도와 해석 가능성을 동시에 확보한다.

- **FinBERT** 기반 키워드 추출: 금융 문맥에 최적화된 FinBERT를 사용하여 뉴스 내 토큰의 중요도를 산출한다. 특정 단어의 민감도를 측정하는 Saliency Score 수식은 다음과 같다

$$s_i = \left\| \frac{\partial p}{\partial e_i} \right\|_2$$

FinBERT는 금융(Finance)과 구글의 인공지능 모델인 **BERT**의 합성어로, 금융 도메인에 특화된 자연어 처리(NLP) 모델을 의미한다. 일반적인 언어 모델이 일상적인 대화를 학습한다면, **FinBERT**는 금융 뉴스와 리포트 등을 집중적으로 학습하여 경제 전문 용어와 문맥을 정확하게 파악하는 것이 특징이다. **IKNet** 논문에서는 **FinBERT**를 단순한 감성 분석기를 넘어 다음과 같은 고도화된 방식으로 활용한다.

- ➔ 키워드 추출 및 임베딩: 뉴스 텍스트에서 주가 예측에 가장 중요한 영향을 미치는 상위 N개의 키워드를 식별하고 이를 벡터(Embedding) 형태로 변환한다.
- ➔ 중요도(Saliency) 계산: 특정 단어가 모델의 출력값에 얼마나 큰 변화를 주는지를 미분 수식을 통해 계산하며, 이때 **FinBERT**의 사전 학습된 지식을 기반으로 한다.

$$s_i = \left\| \frac{\partial p}{\partial e_i} \right\|_2$$

- ➔ 비정형 데이터의 구조화: 뉴스라는 비정형 데이터를 수치화된 특징(Feature)으로 변환하여 기술적 지표와 결합할 수 있게 한다.

“이 뉴스의 어떤 단어가 **KODEX** 수익률에 어느 정도 영향을 줄 것인가”를 판단.

- **SHAP (Shapley Additive Explanations)**: 게임 이론을 기반으로 각 입력 특성이 예측 결과에 미치는 정량적 기여도를 산출한다. 예측 함수 $f(z)$ 를 특성들의 기여도 합으로 분해하여 시각화함으로써 모델의 판단 근거를 제시한다.

$$f(z) = \phi_0 + \sum_{i=1}^M \phi_i z_i$$

IKNet은 이러한 독립적인 비선형 투영 층을 통해 키워드 단위의 기여도를 명확히 분리하여 해석성을 높인다.

XGBoost

XGBoost는 가산학습 알고리즘으로서, 각 단계에서 이전 모델의 오차를 보정하는 새로운 트리를 추가하여 예측 성능을 극대화한다. 기술적 지표와 같은 정형 데이터의 복잡한 비선형 패턴을 학습하기 위해 베이스라인 모델로 선정한다.

- **가산 학습(Additive Learning):** 여러 개의 약한 학습기(Decision Tree)를 순차적으로 추가하여 이전 모델의 오차를 보완하는 방식이다.
- **목적 함수의 최적화:** 손실 함수에 L2 정규화 항 Ω 를 추가하여 과적합을 방지하며, 2차 테일러 전개(2nd Order Taylor Expansion)를 통해 최적화의 정확도를 높인다.

$$Obj = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k)$$

- **분할 기준(Gain):** 분할 전후의 구조 점수 차이를 나타내는 이득(Gain)을 산출하여 최적의 나무 구조를 결정한다.

$$Gain = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

Attention 메커니즘

모델이 입력 데이터의 모든 부분을 동일한 비중으로 처리하는 것이 아니라, 예측에 중요한 특정 부분에 집중하도록 만드는 기술이다. 핀테크 프로젝트에서 주가나 뉴스 데이터를 다룰 때, 특정 시점의 가격 변동이나 핵심 키워드가 미래 수익률에 더 큰 영향을 미친다는 점을 고려하면 매우 필수적인 개념이다.

어텐션은 기본적으로 '검색(Search)' 시스템의 원리와 유사하다. 수많은 정보 중에서 현재 내가 찾고자 하는 정보와 가장 관련이 깊은 데이터를 골라내어 가중치를 부여하는 방식이다.

어텐션 매커니즘은 데이터를 세 가지 요소로 변환하여 처리한다.

- **Query (Q):** 현재 시점에서 정보를 찾고자 하는 주체이다 (예: "오늘의 주가 예측을 위해 참고할 과거 데이터는?").
- **Key (K):** 입력된 데이터들이 가지고 있는 고유한 식별값 또는 인덱스이다 (예: 각 과거 날짜별 데이터의 특징).
- **Value (V):** 실제 데이터가 담고 있는 정보의 값이다 (예: 해당 날짜의 실제 종가나 거래량).

3. 수행 내용 상세

본 프로젝트에서는 **KODEX 200 ETF** 가격 예측을 위한 데이터 구축 작업을 수행하였다. 네이버 금융을 통해 **KODEX 200**의 일별 주가 데이터를 수집하고, 날짜 형식 변환 및 결측치 제거 등 기본적인 전처리를 진행하였다. 또한 **FRED API**를 활용하여 달러 인덱스, 미국 10년물 금리, **VIX** 지수, **M2** 통화량, **CPI**, 연준 기준금리 등 주요 거시경제 지표를 수집하였다. 이후 주가 데이터와 거시경제 데이터를 날짜 기준으로 병합하여 통합 데이터셋을 구축하였으며, 데이터 주기 차이로 발생하는 결측치는 **forward fill** 방식으로 보완하였다. 이를 통해 향후 모델 학습에 활용 가능한 시계열 데이터 기반을 마련하였다.

4.차후 본 학기 계획

본 프로젝트는 방학 동안 구축한 **KODEX 200** 가격 및 거시경제 통합 데이터셋을 기반으로, 본 학기에는 모델 성능 개선과 분석 범위 확장을 목표로 한다. 기존 베이스라인 모델 **XGBoost**의 한계를 보완하기 위해 **GRU/LSTM**와 같은 시계열 특화 딥러닝 모델 및 **Transformer** 기반 구조의 적용 가능성을 검토하며, 입력 시퀀스 길이 조정, 하이퍼파라미터 튜닝, **feature engineering** 등을 통해 예측 성능을 고도화할 계획이다. 또한 거시경제 변수의 단순 수준 값뿐 아니라 **lag** 변수나 변화율, 금리 스프레드 등 파생 변수를 추가하여 시장 흐름 반영력을 높이려 한다.

모델 평가 단계에서는 시계열 분할 기반 검증과 간단한 백테스트를 수행하여 실제 활용 가능성을 검증하며, **SHAP** 기반 해석을 통해 주요 변수의 영향력과 시장 국면별 특징을 분석할 예정이다. 추가적으로 **KODEX 200** 관련 뉴스 데이터를 수집하여 텍스트 정보를 결합하는 멀티모달 접근을 서브 프로젝트 형태로 탐색하고, 가격 데이터와 뉴스 임베딩을 함께 활용하는 방향으로 분석 범위를 확장할 가능성도 열어둔다. 본 연구는 예측 성능 개선과 모델 해석력 강화, 그리고 멀티모달 확장 가능성까지 포함한 프로젝트로 발전시키는 것을 목표로 한다.