

KR-FinBERT × LSTM

다중 모달 융합 기반 KODEX 200 수익률 예측 및 변동성 분석

매크로 팀 | 구다연 · 이예현 · 이지수 · 이찬영

DAT 7th 캡스톤 프로젝트 · 2026.06.04

Hit Ratio (방향성 적중률)

73.56%

Pearson 상관계수

0.5238

RMSE

0.03695

최고 Hit Ratio (Ablation)

73.86%

연구 기간 : 2021.03 ~ 2026.03 (약 5년, ~1,150 거래일)

01

연구 배경 및 목적

정형 데이터의 한계 · 기존 연구 한계 · 연구 목표

02

데이터 구성 & KR-FinBERT

5년 데이터셋 · 뉴스 임베딩 파이프라인 · 17개 기술지표

03

모델 설계

XGBoost Baseline · 2-Layer LSTM · AT-LSTM 비교

04

실험 결과

성능 비교 테이블 · Hit Ratio · Pearson 상관계수 · DM 검정

05

Ablation Study

뉴스 정보 기여도 정량 검증 · 비선형 시너지 실증

06

피처 중요도 분석

AT-LSTM 어텐션 가중치 · Bond_Yield_Change 핵심 발견

07

결론

3대 핵심 발견

08

한계 및 향후 연구

한계점 및 개선 방향

[1] 기존 통계 모델의 한계

ARIMA, GARCH 등은 가격, 거래량 등의 정형 시계열만 활용
→ 금리 결정, 기업 실적, 지정학적 리스크 등
텍스트 이벤트 포착 불가

[2] 딥러닝 도입 이후에도 남은 과제

복잡한 Attention · Gate 메커니즘
→ 금융 데이터 특유의 고주파 노이즈, 무작위성으로
과적합 및 학습 불안정



[3] 본 연구의 질문

"구조적 복잡성을 배제한 단순 결합(Concatenation)만으로도
정형+비정형 융합이 금융 중기 추세를 안정적으로 포착할 수 있는가?"

02 데이터 구성 — 5년간 ~1,150 거래일 통합 데이터셋

구분	기간	샘플 수	특징 차원
기술지표	2021.04.22 ~ 2026.03.10	1,194	17개 (+target)
뉴스 임베딩	2021.03.10 ~ 2026.02.02	1,269	769 (768 + sentiment)
결합 데이터셋	교집합 기간	~1,150	786

17개 기술지표 그룹

수익률/모멘텀

Return_Lag1 · Momentum_10D ·
Log_Return

변동성

Vol_5 · Vol_21 · RV_Trend_5_21 ·
RV_Trend_21_63 · ATR_Pct

기술지표

MACD · RSI · SMA_21_Disparity ·
SMA_63_Disparity

거래량/범위

Volume_MA_Ratio · Intraday_Range_Pct

거시지표 ★

VIX_Change · DXY_Return ·
Bond_Yield_Change

★ 거시지표(VIX · DXY · Bond Yield)는 AT-LSTM 어텐션 분석에서 핵심 피처로 자동 선별됨

02 KR-FinBERT — 한국어 금융 언어 모델 활용 파이프라인



① 뉴스 임베딩 벡터 (emb_0 ~ emb_767)

64차원으로 압축된 의미론적 맥락 벡터
→ 시장 배경 정보, 이벤트 텍스트 패턴 압축 표현

② 감성 점수 sentiment_score

범위: -1.0 (매우 부정) ~ +1.0 (매우 긍정)
수집 통계: 평균 0.112 · 표준편차 0.200 · 중앙값 0.082
→ 양성 편향(Positive Bias) 특성 확인

뉴스 없는 거래일(휴장 등): 임베딩 0-패딩 + news_missing 플래그 별도 피처로 추가 → 모델이 뉴스 부재를 명시적으로 인식

03 모델 설계 — 3단계 점진적 실험 설계

Baseline

XGBoost Regressor

단일 시점 입력 · 기준선 확립

- 입력: 전일 기술지표 + 뉴스 감성 점수 (단일 시점)
- 그래디언트 부스팅 앙상블 알고리즘
- 하이퍼파라미터: $n_{est}=150$, $depth=3$, $lr=0.02$
- 시계열 구조 미활용
→ 방향성 포착 한계 확인

제안 모델

2-Layer Stacked LSTM

최종 제안 · 다중 모달 단순 결합

- 입력: 기술지표(13d) + 감성점수(1d) + 임베딩(64d) → Concat
- Lookback Window $T=20$, Hidden=192, Dropout=0.07
- 출력: 미래 5거래일 누적 로그수익률
- 손실: MSE, 최적화: Adam ($lr=0.0004$)

비교 모델

AT-LSTM


Feature Attention 메커니즘 · 해석 가능성

- 매 타임스텝 피처별 중요도 가중치 β_t 동적 산출
- Attention → LSTM 2단계 구조
- 하이퍼파라미터: hidden=128, attn=16, $lr=0.0002$
- 시장 국면별 피처 기여도 해석 목적


04 실험 결과 — 모델 성능 비교 (테스트 기간: 90 거래일)

모델	RMSE	MAE	Hit Ratio	Corr (상관계수)	비고
XGBoost Baseline	0.04797	0.04117	31.03%	0.0919	기준선
AT-LSTM	0.0890	N/A	56.67%	0.191	비교
2-Layer LSTM (Full)	0.03695	0.02894	73.86%	0.5299	✓ 최고

Hit Ratio 비교 (%)



Pearson 상관계수 비교



Diebold-Mariano 검정 | 2-Layer LSTM vs XGBoost: Squared Error $p = 0.0369$ (*) · Absolute Error $p = 0.00585$ (***)

→ 통계적으로 유의한 성능 우위

05 Ablation Study — (보고서 오류 수정)

Fig 2. Ablation Study — Incremental Effect of News Information





그림 4-5. 2-Layer LSTM Ablation Study: 입력 모달리티 단계별 추가에 따른 성능 변화

모델명	RMSE	MAE	Hit Ratio	Corr
Tech_only	0.0891	0.0800	29.55%	0.3723
Tech_Sentiment	0.0552	0.0459	32.95%	0.3006
Tech_Embedding	0.0612	0.0525	43.18%	0.2864
Tech_Sentiment_Embedding	0.0369	0.0290	73.86%	0.5299

05 Ablation Study — 뉴스 정보의 기여도 정량 검증

모델명	RMSE	MAE	Hit Ratio	Corr	Shape Score
Tech_only	0.0891	0.0800	29.55%	0.3723	0.0809
Tech + Sentiment	0.0552	0.0459	32.95%	0.3006	0.0646
Tech + Embedding	0.0612	0.0525	43.18%	0.2864	0.0643
Tech + Sentiment + Embedding	0.0369	0.0290	73.86%	0.5299	0.0306

입력 조합별 Hit Ratio (%)




Diebold-Mariano 검정

비교	유의성
Tech_only vs Tech+Sent	*** ($p < 0.001$)
Tech_only vs Tech+Emb	** ($p < 0.01$)
Tech_only vs Full	*** ($p < 0.001$)
Full vs Tech+Sent	** ($p < 0.01$)
Full vs Tech+Emb	*** ($p < 0.001$)

감성 점수(단기 방향 신호) + 뉴스 임베딩(풍부한 맥락)의 동시 결합 시 비선형 시너지
→ 각 단독 효과의 단순 합산을 크게 상회하는 Hit Ratio 73.86% 달성

06 피처 중요도 분석 — AT-LSTM 어텐션 가중치 (테스트 셋 기준)



Bond_Yield_Change 가중치(8.29%) = 2위 Vol_5(4.18%)의 약 2배

→ 2022~2024 글로벌 금리 인상 사이클 환경에서 채권 수익률 변화를 KODEX200 단기 예측의 핵심 트리거로 모델이 자동 인식

① 단계적 · 통계적으로 유의한 성능 향상

기술지표 단독(29.55%) → + 감성(32.95%) → + 임베딩(43.18%) → **전체(73.86%)**

모든 단계의 성능 개선이 Diebold-Mariano 검정으로 통계적 유의성 확인

② 뉴스 정보의 비선형 시너지 실증

단기 방향 신호(감성 점수) + 풍부한 배경 맥락(768d 임베딩) 동시 결합

→ 단독 활용 대비 비선형 시너지 → 단순 복잡성 증가 없이 압도적 성능 향상

③ Bond_Yield_Change = 핵심 예측 트리거

AT-LSTM 어텐션 가중치 8.29% (2위 대비 2배)

→ 금리 인상 사이클 시 채권 수익률 변화가 KODEX200 단기 예측에서 가장 중요한 거시 지표임을 모델이 자동 학습

한계점

- ① 테스트 셋 규모 제한 (90거래일)
- ② 수익률 절대 크기 예측 보수적 편향 (MSE 손실 구조)

향후 연구

- ① 비대칭 손실함수 도입
- ② 뉴스 발행 시의성 반영
- ③ 예측 기간 확장

감사합니다.

매크로 팀 | 구다연 · 이예현 · 이지수 · 이찬영

DAT 7th 캡스톤 프로젝트 · 2026.06.04